

PROFEPI

Introdução à Inteligência Artificial para Predições em Vigilância em Saúde e Ambiente

Pré-processamentos de dados

Predição com Machine Learning

- Desenvolver algoritmos que façam boas predições em saúde.
- Principais razões técnicas pelas quais algoritmos às vezes não apresentam boa performance preditiva:
  - Extrapolação inadequada dos resultados;
  - Pré-processamento inadequado dos dados;
  - Sobreajuste (mais importante);
  - Validação inadequada da qualidade dos algoritmos.
- Se fizer a parte técnica correta, o motivo para a baixa performance preditiva é que não foram usadas variáveis preditoras fortes.

Extrapolação inadequada

Desenvolver os algoritmos para uma população e esperar que funcionem corretamente para outra diferente.

- Importar algoritmos dos EUA/Europa: nossas características genéticas e socioeconômicas são muito diferentes.
- Extrapolação para períodos diferentes (cuidado com doenças sazonais).

Extrapolação inadequada

Editorial da Lancet, 12 agosto 2023.

- A maioria dos dados de saúde vem de países de alta renda, o que pode influenciar os modelos, exacerbando a injustiça histórica e a discriminação quando usados em outro lugar.
- Sem investimento em infraestrutura e pesquisa local, os países de baixa e média renda continuarão dependendo da IA desenvolvida nos EUA e na Europa, e os custos podem ser proibitivos.



Editorial

AI in medicine: creating a safe and equitable future

The meteoric progress of generative artificial intelligence (AI)—such as Open AI's ChatGPT, capable of holding realistic conversations, or others of creating realistic images and video from simple prompts—has renewed interest in the transformative potential of AI, including for health. It has also sparked sobering warnings. Addressing the UN Security Council in July, Secretary General António Guterres spoke of the "horrific levels of death and destruction" that malicious AI use could cause. How can the medical community navigate AI's substantial challenges to realise its health potential?

AI in medicine is nothing new. Non-generative machine learning can already perform impressively at discrete tasks, such as interpretating medical images. *The Lancet Oncology* recently published one of the first randomised controlled trials of AI-supported mammography, demonstrating a similar cancer detection rate and nearly halved screen-reading workload compared with unassisted reading. AI has driven progress in infectious diseases and molecular medicine and has enhanced field-deployable diagnostic tools. But the medical applications of generative AI remain largely speculative. Automation of evidence synthesis and identification of de novo drug candidates could expedite clinical research. AI-enabled generation of medical notes could ease the administrative burden for health-care workers, freeing up time to see patients. Initiatives such as the Bill & Melinda Gates Foundation's Global Grand Challenges seek innovative uses of large language models in low-income and middle-income countries (LMICs).

These advances come with serious risks. AI performs best at well defined tasks and when models can easily augment rather than replace human judgement. Applying generative AI to heterogeneous data is complicated. The black box nature of many models makes it challenging to appraise their suitability and generalisability. Large language models can make mistakes easily missed by humans or hallucinate non-existent sources. Transfer of personal data to technology firms without adequate regulation could compromise patient privacy. Health equity is a particularly serious concern. Algorithms trained on health-care datasets that reflect bias in health-care spending, for example, worsened racial disparities in access to care in the USA. Most health data come from high-income countries, which could bias models exacerbating historical injustice and discrimination when used elsewhere. These issues all risk eroding patient trust.

How then to ensure that AI is a force for good in medicine? The scientific community has a key role in rigorous testing, validation, and monitoring of AI. The UN is assembling a high-level advisory body to build global capacity for trustworthy, safe, and sustainable AI; it is crucial that health and medicine are well represented. An equitable approach will require a diversity of local knowledge. WHO has partnered with the International Digital Health and AI Research Collaborative to boost participation from LMICs in the governance of safe and ethical AI in health through cross-border collaboration and common guidance. But without investment in local infrastructure and research, LMICs will remain reliant on AI developed in the USA and Europe, and costs could be prohibitive without open access alternatives. At present, the pace of technological progress far outstrips the guidance, and the power imbalance between the medical community and technology firms is growing.

Allowing private entities undue influence is dangerous. The UN Secretary General has urged the Security Council to help ensure transparency, accountability, and oversight on AI. Regulators must act to ensure safety, privacy, and ethical practice. The EU's AI Act, for example, will require high risk AI systems to be assessed before approval and subjected to monitoring. Regulation should be a key concern of the first major global summit on AI safety, being held in the UK later this year. Although technology companies should be part of the regulatory conversation, there are already signs of resistance. Amazon, Google, and Epic have objected to proposed US rules to regulate AI in health technologies. The tension between commercial interests and transparency risks compromising patient wellbeing, and marginalised groups will suffer first.

There is still time for us to create the future we want. AI could continue to bring benefits if integrated cautiously. It could change practice for the better as an aid—not a replacement—for doctors. But doctors cannot ignore AI. Medical educators must prepare health-care workers for a digitally augmented future. Policy makers must work with technology firms, health experts, and governments to ensure that equity remains a priority. Above all, the medical community must amplify the urgent call for

See World Report page 517

For the **AI-assisted mammography trial** see **Articles** *Lancet Oncology* 2023; **24:** 936–44

For more on **AI in infectious diseases** see *Science* 2023; **381:** 164–70

For more on **AI in molecular medicine** see *N Engl J Med* 2023; **388:** 2456–65

For more on **generative AI in medicine** see **Comment** *Lancet Digit Health* 2023; **5:** e107–8

For more on the **Global Grand Challenges** see https://gcgh.grandchallenges.org/challenge/catalyzing-equitable-artificial-intelligence-ai-use

For more on the **dangers of biased health data** see *Science* 2019; **366:** 447–53

For more on **WHO's efforts to improve access to AI** see https://www.who.int/news/item/06-07-2022-who-and-i-dair-to-partner-for-inclusive-impactful-and-responsible-international-research-in-artificial-intelligence-and-digital-health

For more on the **UN Secretary General's remarks** see https://press.un.org/en/2023/sgsm21880.doc.htm

For more on the **AI Act** see https://artificialintelligenceact.eu

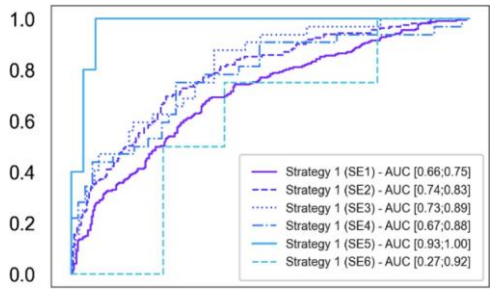
For more on the **global summit on AI** see https://www.gov.uk/government/news/uk-to-host-first-global-summit-on-artificial-

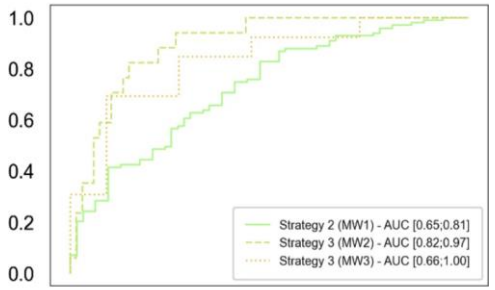
Improving the performance of machine learning algorithms for health outcomes predictions in multicentric cohorts

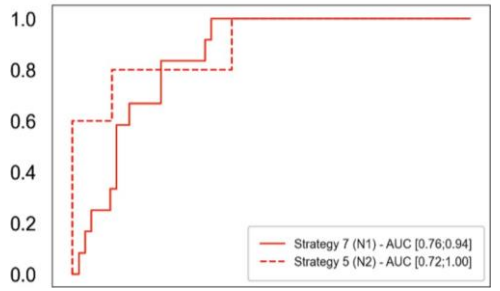
Roberta Moreira Wichmann, Fernando Timoteo Fernandes, Alexandre Dias Porto Chiavegatto Filho

Scientific Reports 2023; 13, 1022.

- Coorte multicêntrica de pacientes com RT-PCR positivo para covid-19 (n = 8.477) em 18 hospitais das cinco regiões brasileiras.
- Oito estratégias diferentes foram usadas para treinar e avaliar o desempenho de algoritmos de machine learning para predizer óbito.
- Os melhores desempenhos preditivos foram obtidos ao usar dados de treinamento do mesmo hospital, que foi a estratégia vencedora para 11 (61%) dos 18 hospitais participantes.
- O uso de mais dados de pacientes de outras regiões diminuiu o desempenho preditivo.





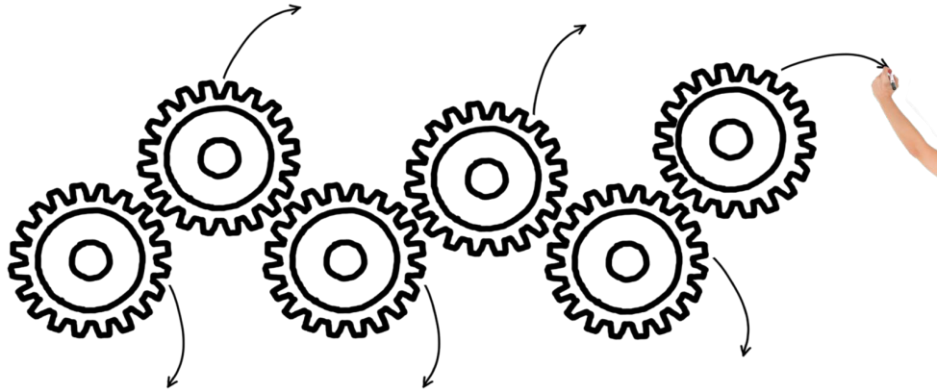


Pré-processamento dos dados

- Pré-processamento de dados é um conjunto de atividades que envolvem **preparação**, **organização** e **estruturação** dos dados.
- Qualquer processamento aplicado a dados brutos para prepará-los para outras análises ou tarefas de processamento.
- Etapa **fundamental** que precede a realização de análises e predições.

Pré-processamento dos dados

- Método de análise, filtragem, transformação e codificação para que o algoritmo possa compreender os dados.
- Parte considerável de um projeto: **cerca de 80% do tempo**



Pré-processamento dos dados

Imagine um laboratório que irá realizar exames de sangue para diagnóstico. 🩺🩸

Se as amostras forem coletadas sem os cuidados adequados, os resultados dos exames serão inválidos, não importando a qualidade dos equipamentos ou dos profissionais.

Da mesma forma, **se os dados estiverem incompletos, despadronizados ou com erros, os modelos de IA "diagnosticarão" incorretamente**.

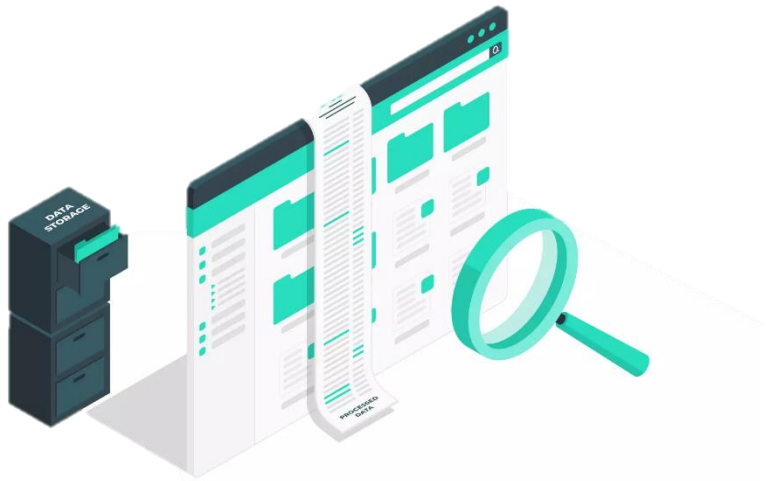
Por que o pré-processamento é necessário?

- Algoritmos são equações que aprendem com os dados
- "Se entra lixo, sai lixo"
- Necessidade de dados de alta qualidade
- Dados de mundo real sempre possuem ruídos e valores ausentes
- Solução: Pré-processamento (tratamento dos dados)



Técnicas de pré-processamento de dados

- Seleção das variáveis.
- Limpeza de dados
- Vazamento de dados.
- Valores missing.
- One-hot encoding
- Colinearidade.
- Padronização.
- Redução de dimensão.



Seleção de variáveis

Preditores Plausíveis:

Pré-selecionar variáveis que sejam preditoras plausíveis **(Bom senso do pesquisador)**

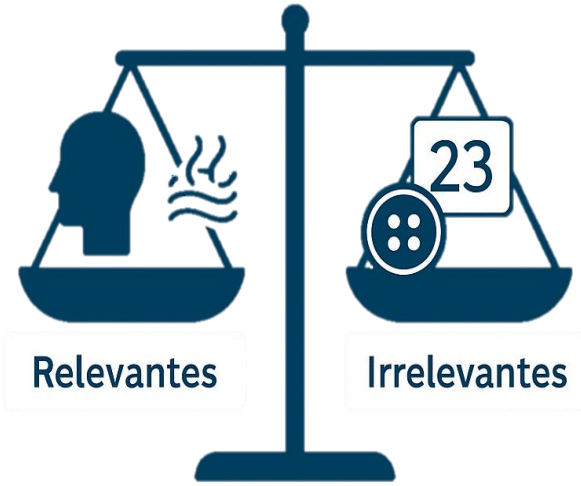
Exemplo: Para prever surtos de dengue, faz sentido usar temperatura, chuvas e dados de notificação.

⊘ Mas não faz sentido usar o número de cinemas no bairro, mesmo que esteja correlacionado!

Seleção de variáveis

⚠ Cuidado com associações espúrias

Coincidências acontecem em análises de big data e pode ser que o algoritmo aprenda padrões sem sentido se não filtrado bem.



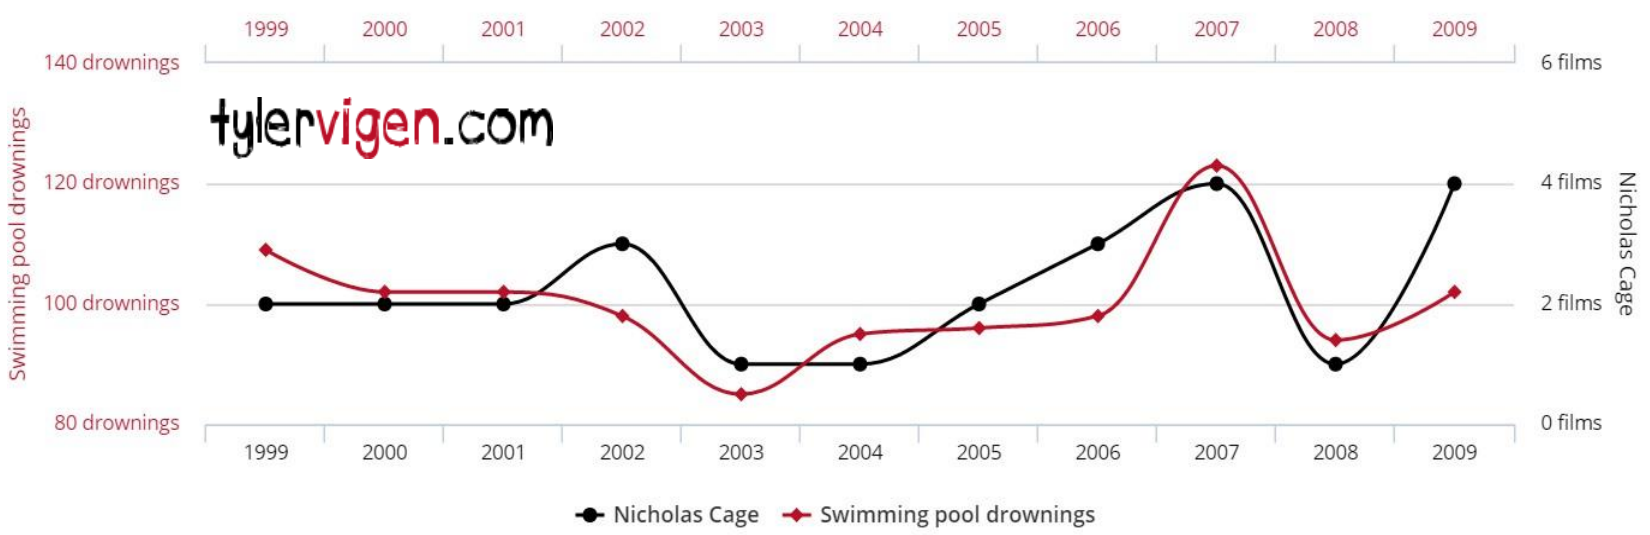
Seleção de variáveis

Número de pessoas que se afogaram ao cair em uma piscina

se correlaciona com

o número de filmes em que Nicolas Cage apareceu

Correlação: 66,6% (r=0,666004)



Limpeza de dados

- **Tratamento de valores ausentes** (imputação ou exclusão)
- **Remoção de duplicatas** (manter registros únicos)
- **Detecção de outliers** (Z-score, IQR, detecção de anomalias)
- **Correção de inconsistências** (formatos, unidades, valores padronizados)
- **Validação de integridade** (regras de negócio, limites coerentes)

Limpeza de dados

Etapa prática inicial do pré-processamento

Responsável por remover, corrigir ou imputar valores incorretos, inconsistentes, duplicados ou ausentes, garantindo que o algoritmo de predição receba dados confiáveis.

Por que é importante?

- Melhora a precisão dos modelos
- Evita vieses e conclusões equivocadas
- Crucial em saúde e meio ambiente, onde erros podem prejudicar decisões públicas

Remoção das duplicatas

Processo de identificar e excluir registros repetidos que representam a mesma observação em um banco de dados.



Por que é importante?

- Evita superestimação de casos
  (Ex.: contar o mesmo paciente duas vezes)
- Reduz viés em modelos de IA e estatísticas
- Melhora a integridade e consistência dos dados

Remoção das duplicatas



	ID	Nome
0	1	Maria Silva
1	2	Maria Silva
2	3	Maria Silva

Remoção das duplicatas

	ID	Nome	Data de Nascimento	Nome da Mãe	Data da Notificação
0	1	Maria Silva	1990-05-14	Ana Lúcia	2023-03-01
1	2	Maria Silva	1990-05-14	Ana Lúcia	2023-03-01

Remoção das duplicatas

	ID	Nome	Data de Nascimento	Nome da Mãe	Data da Notificação
0	1	Maria Silva	1990-05-14	Ana Lúcia	2023-03-01
1	2	Maria Silva	1990-05-14	Ana Lúcia	2023-03-01
2	3	Maria Silva	1989-11-23	Mariana Silva	2022-04-15

Transformação e Integração

Transformação de Dados

Conversão de formatos

- Ex: transformar datas de “14/05/1990” para formato padrão ISO (“1990-05-14”)
- Ex: padronizar strings (como nomes em maiúsculas, remoção de acentos)

Agrupamentos ou categorização

- Ex: agrupar idades em faixas etárias (“0-5”, “6-12”, “13-17” etc.)
- Ex: transformar renda em categorias (“baixa”, “média”, “alta”)

Transformação e Integração

Integração de Dados

Objetivo: enriquecer as análises combinando fontes diversas

Exemplo:

- Unir base de mortalidade (SIM) com base de notificação de violência (SINAN)
- Chave de ligação: nome, data de nascimento, nome da mãe
- Pode usar técnicas como *record linkage* ou *linkage* probabilístico

Vazamento de dados

Cuidado com vazamento de informação (“data leakage”).

Acontece quando os dados de treino apresentam informação escondida que faz com que o modelo aprenda padrões que não são do seu interesse

Uma variável preditora tem escondida o resultado certo:

Não é a variável que está predizendo o desfecho, mas o desfecho que está predizendo ela.

JOURNAL OF MEDICAL INTERNET RESEARCH Chiavegatto Filho et al

Letter to the Editor

Data Leakage in Health Outcomes Prediction With Machine Learning. Comment on “Prediction of Incident Hypertension Within the Next Year: Prospective Study Using Statewide Electronic Health Records and Machine Learning”

Alexandre Chiavegatto Filho, PhD; André Filipe De Moraes Batista, MSc, PhD; Hellen Geremias dos Santos, MPH, PhD

Department of Epidemiology, School of Public Health, University of São Paulo, São Paulo, Brazil

Vazamento de dados

Exemplo

Incluir o número identificador do paciente como variável preditora

Problema

- Se pacientes de hospital especializado em câncer tiverem números semelhantes.
- Se o objetivo for predizer câncer, algoritmo irá dar maior probabilidade a esses pacientes.
- Esse algoritmo aprendeu algo interessante para o sistema de saúde?

Motivo

- Motivo pelo qual os dados e os algoritmos de machine learning precisam ser abertos.
- Sempre analisar importância preditora das variáveis (Shapley).

Variáveis Missing

É importante entender por que valores de uma variável estão faltantes.

Motivo sistemático → **informação preditiva**.

- Grande diferença em relação a estudos de inferência, em que valores missing devem ser evitados.

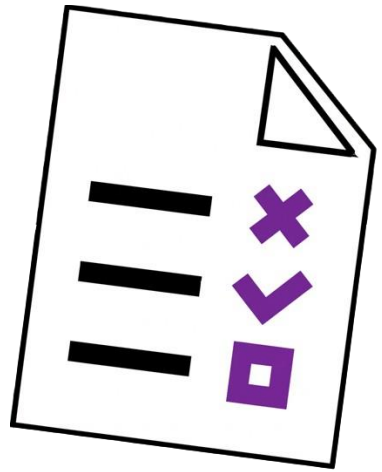
Não conseguir responder a uma pergunta sobre o seu passado → **informação preditiva.**

- Pode ajudar na predição de problemas cognitivos graves no futuro
- Em variáveis categóricas adicionar uma categoria para missing.
- Imputação com machine learning para valores contínuos (adicionar nova variável indicativa de missing).

Manipulação de valores ausentes

1. **Excluir observações**
   Apenas útil quando conta-se com uma grande base de dados.

2. **Substituir pela média, mediana ou moda**
   São aproximações mais coerentes, quando comparadas a substituição por zero.



Manipulação de valores ausentes

3 **Interpolar**
Gera valores dentro de uma faixa de valores da distribuição dessa variável

4 **Extrapolar**
Gera valores além de uma faixa
Precisa do auxílio de outra variável como referência guiada (em geral o desfecho)

5 **Predizer os valores ausentes**
Algoritmo estuda as demais variáveis (exceto a com valores faltantes) e prediz seus valores.
Variável com dados ausentes usada como desfecho.

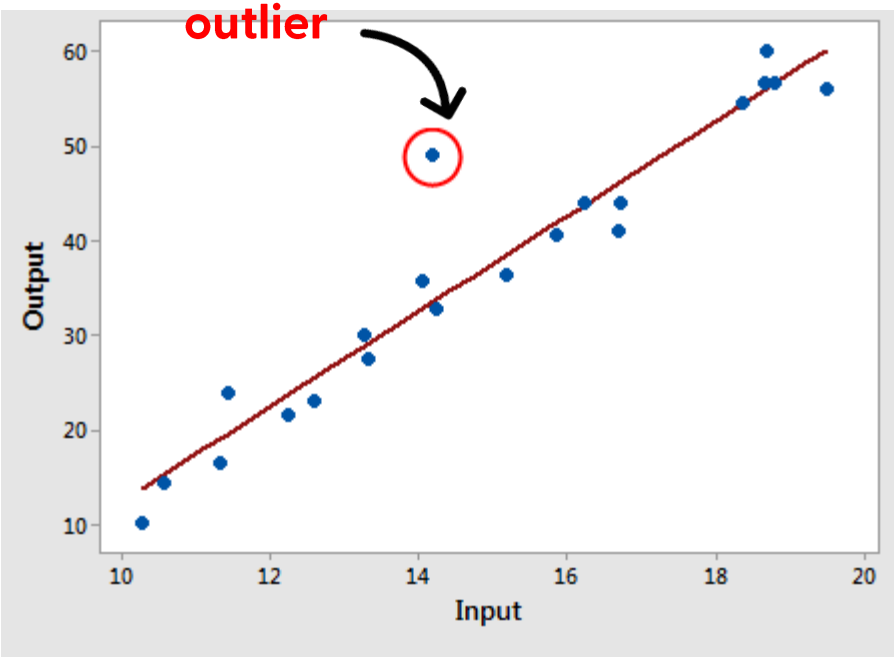
Outliers

O que são outliers?

Pontos fora do padrão

Por que são importantes?

- Podem indicar erros de digitação ou medição.
- Podem distorcer médias, regressões e outros modelos.
- Às vezes representam casos reais importantes (ex.: paciente com idade de 105 anos).



Outliers

Como identificar?

Métodos estatísticos

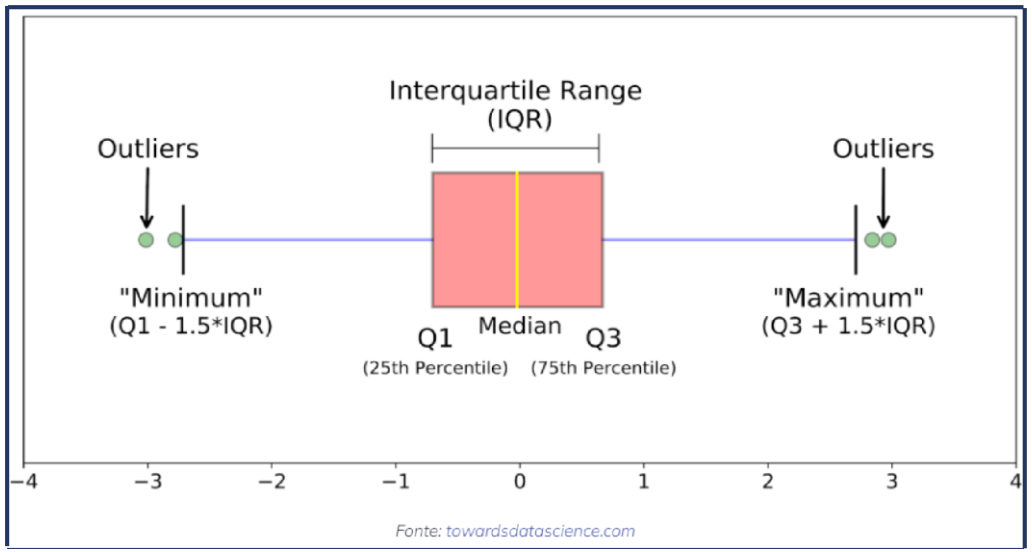
- Z-Score
- Intervalo Interquartil (IQR)

Técnicas visuais

- Gráfico box – plot

```
# Note: this is dummy code.
# It won't work unless a data with a column named "column" is imported

from scipy import stats
z_scores = stats.zscore(data['column']) outliers = abs(z_scores) > 3 # Identifyin
```



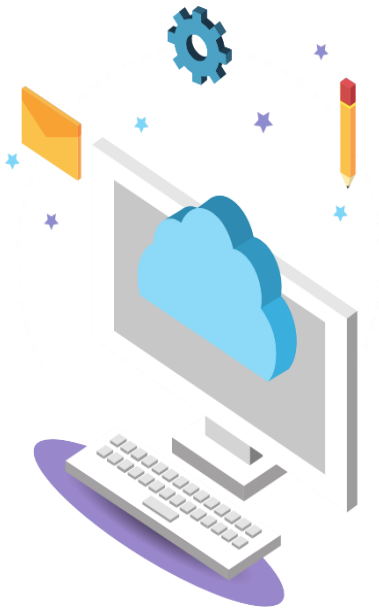
Como tratar?

Remoção, se for erro

Categorização

Codificação de Variáveis Categóricas

Transforma variáveis de texto em números para que possam ser processadas por algoritmos.



Label Encoding

- Atribui um número inteiro para cada categoria.
- Ex: Sexo → {'Feminino': 0, 'Masculino': 1}
- Risco: induzir uma ordem inexistente entre categorias.

One hot encoding

- Gera uma coluna binária para cada categoria da variável (um x todos)

One-Hot Encoding

Alguns algoritmos têm dificuldade em entender variáveis que têm mais do que uma categoria.

- Acham que é uma variável contínua (0, 1, 2, 3...) → porém esses números não representam uma escala contínua verdadeira.

A solução é transformar cada categoria em uma nova coluna com valores 0 ou 1 (one-hot encoding).

- Variável com n categorias → criadas n variáveis.

One-Hot Encoding

ID	Região
1	Norte
2	Sul
3	Sudeste
4	Centro-Oeste
5	Nordeste

One-Hot Encoding

Após One-Hot Encoding:

ID	Região_Norte	Região_Sul	Região_Sudeste	Região_Centro-Oeste	Região_Nordeste
1	1	0	0	0	0
2	0	1	0	0	0
3	0	0	1	0	0
4	0	0	0	1	0
5	0	0	0	0	1

One-Hot Encoding

Pode trazer problemas em alguns modelos, como na regressão linear.

Solução: criar dummies.

- n-1 variáveis (deixar a mais frequente como categoria de referência).

One-Hot Encoding

Cada vez mais popular: **target encoding**

Transforma variáveis categóricas em contínuas

- O valor da categoria vira o seu valor médio do desfecho entre os indivíduos dessa categoria

Padronização

Técnica de transformação de variáveis numéricas para que tenham **média 0 e desvio padrão 1**.

Especialmente importante quando os dados têm **escalas diferentes**
(ex: peso em kg, altura em cm, idade em anos).

Por que é importante?

- A escala das variáveis pode afetar muito a qualidade das predições.
- Alguns algoritmos darão preferência para utilizar variáveis com valores muito alto.

Padronização

Para cada valor x, a padronização é calculada por:

$$z = \frac{x - \mu}{\sigma}$$

Ou seja, é feita a subtração da média e a divisão pelo desvio padrão dos valores da variável.

Padronização

Paciente	Idade (anos)	Pressão Sistólica (mmHg)
João	25	120
Maria	80	180
Pedro	50	140

Padronização

Paciente	Idade (anos)	Pressão Sistólica (mmHg)
João	25	120
Maria	80	180
Pedro	50	140

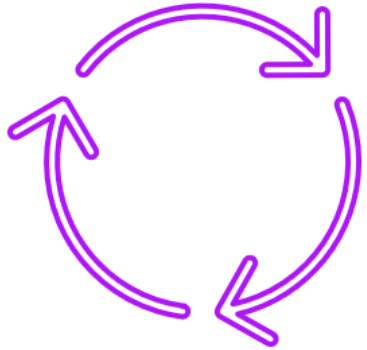


Paciente	Idade (padronizada)	Pressão (padronizada)
João	-1.14	-1.00
Maria	1.33	1.33
Pedro	-0.19	-0.33

Variáveis Colineares

Aquelas que estão fortemente correlacionadas entre si, ou seja, quando uma variável pode ser, em grande parte, explicada por outra.

- Essa colinearidade pode ser um problema, porque dificulta a identificação do impacto individual de cada variável no desfecho.



Variáveis Colineares

Para lidar com esse problema, pode-se optar por remover uma das variáveis correlacionadas, ou aplicar técnicas como a redução de dimensionalidade, utilizando, por exemplo, a análise de componentes principais (ACP).

Uma das razões pela qual a ACP é tão utilizada, é o fato de que **cria componentes principais não correlacionados**.

Na prática, alguns algoritmos conseguem melhor performance preditiva com variáveis com baixa correlação.

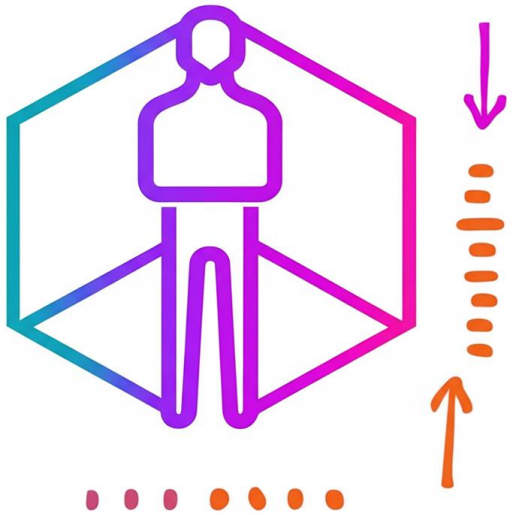
Variáveis Colineares

Uma outra forma de diminuir a presença de variáveis com alta correlação é excluí-las.

- Variáveis colineares trazem informação redundante (tempo perdido).
- Além disso, aumentam a instabilidade dos modelos.
- Estabelecer um limite de correlação com alguma outra variável (0,75 a 0,90).

Redução da dimensionalidade

Quanto maior a dimensão dos dados (número de variáveis) maior o risco de o algoritmo encontrar e utilizar associações espúrias.



Redução da dimensionalidade

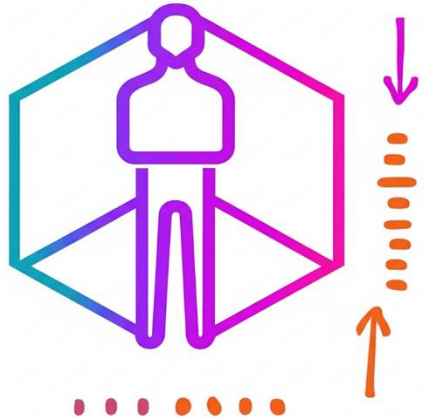
É o processo de diminuir o número de **variáveis (features)** em um conjunto de dados, preservando ao máximo a informação relevante.

Por que usar/ Vantagens?

- Reduz ruído e redundância nos dados
- Melhora o desempenho de algoritmos (menos tempo e memória)
- Evita o overfitting (Menos variáveis irrelevantes = Menos propagação de ruído nas decisões do modelo)
- Facilita a visualização de dados complexos

Redução da dimensionalidade

Análise de Componentes Principais



O objetivo é encontrar combinações lineares das variáveis preditoras que incluam a maior quantidade possível da variância original.

O primeiro componente principal irá preservar a maior combinação linear possível dos dados, o segundo a maior combinação linear possível não correlacionada com o primeiro componente, etc.

Ferramentas e bibliotecas

Python

Scikit Learn Preprocessing Impute

Automunge (ferramenta em python)

Dados tabulares para ML

R

Framework muito utilizado por pesquisadores.

Diversos pacotes para pré-processamento

Weka

Software com suporte para mineração e pré-processamento embutidas no modelo de ML

Rapidminer

Similar ao Weka. Com várias ferramentas para pré-processamento.

Resumo

1

Obtenha uma visão geral

- Entender o formato dos dados
- Entender a estrutura em que eles estão armazenados
- Média
- Mediana
- Quantis
- Desvio-padrão

Resumo

2

Identifique dados ausentes

- Problema comum
- Pode interromper padrões
- Pode levar a perda de outros dados (linhas e colunas)
- Alguns algoritmos não aceitam dados ausentes

Resumo

3

Identifique outliers e anomalias

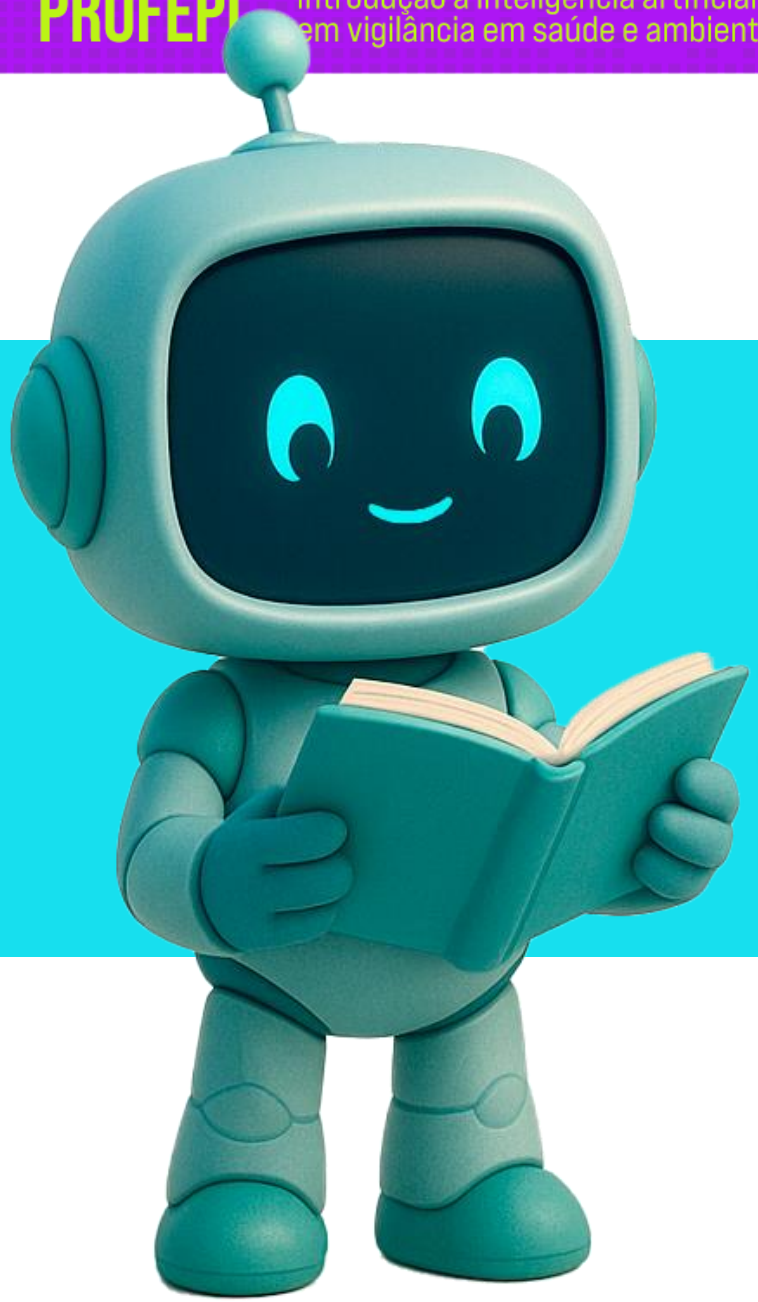
- São pontos fora do padrão
- Podem precisar ser descartados
- Só devem ser mantidos para detecção da anomalia

Resumo

4

Remova inconsistências

- Problema comum
- Ex.: colunas e linhas preenchidas incorretamente
- Ex.: dados duplicados
- Podem ser tratadas por meio de automação
- Geralmente precisam de um check-up manual



Qualidade dos dados é o alicerce de qualquer modelo de ML: Dados incompletos, inconsistentes, desatualizados ou mal codificados comprometem diretamente a capacidade dos algoritmos de aprender padrões reais e fazer boas previsões

Obrigada!

Keisyanne de Araujo Moura



@labdaps

keisyannemoura@usp.br