

PROFEPI

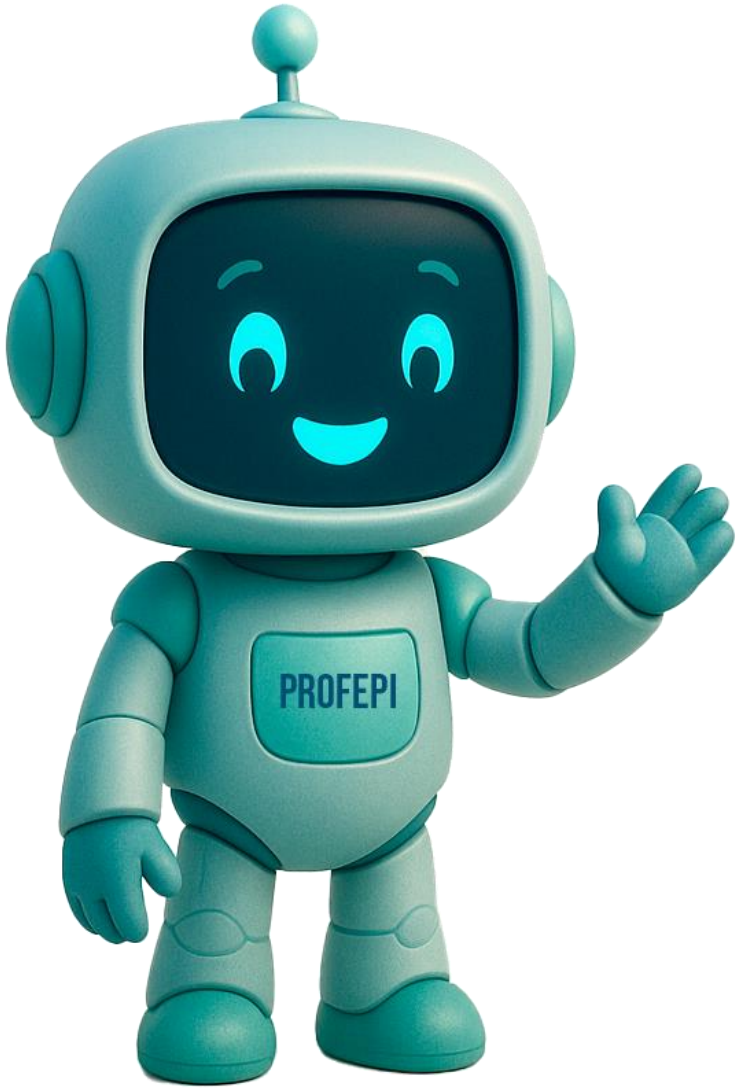
Introdução à Inteligência Artificial para Predições em Vigilância em Saúde e Ambiente

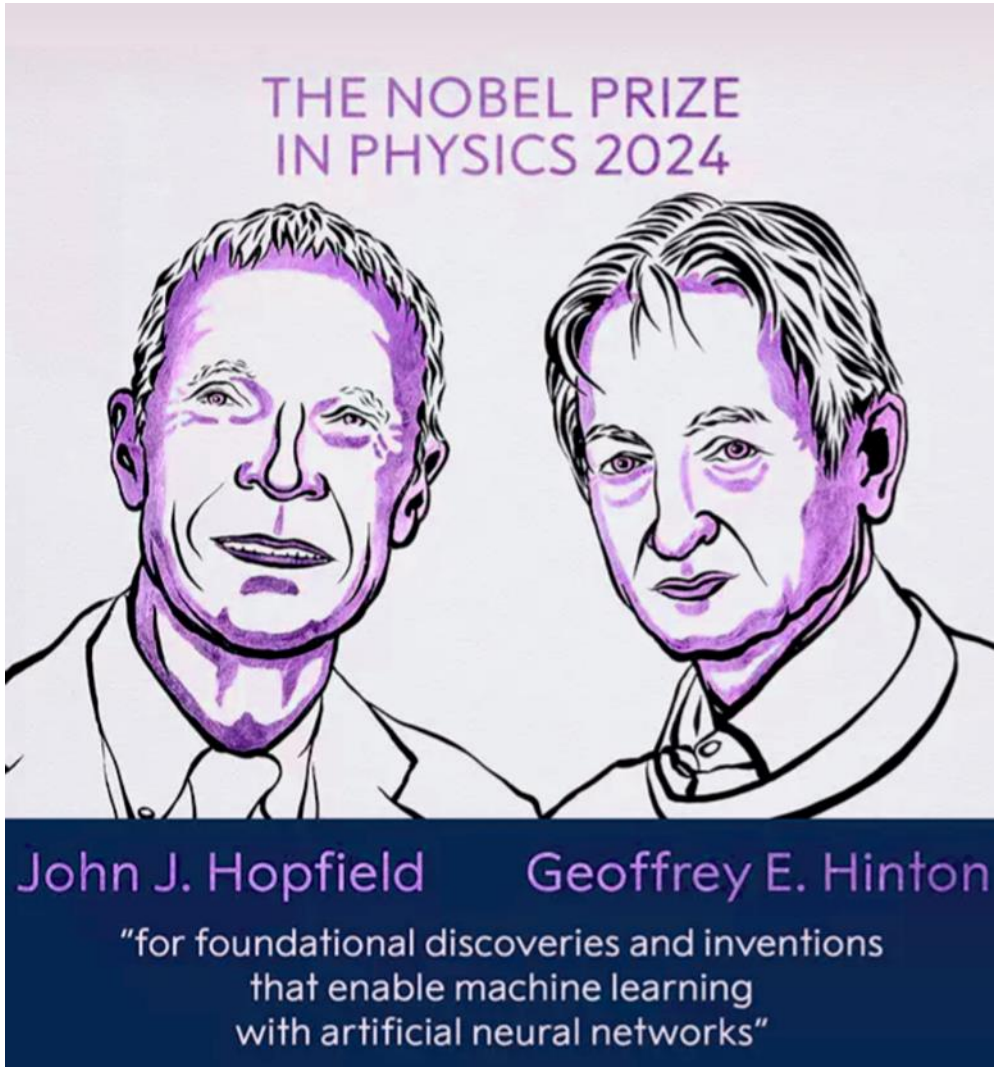
Alexandre Chiavegatto Filho

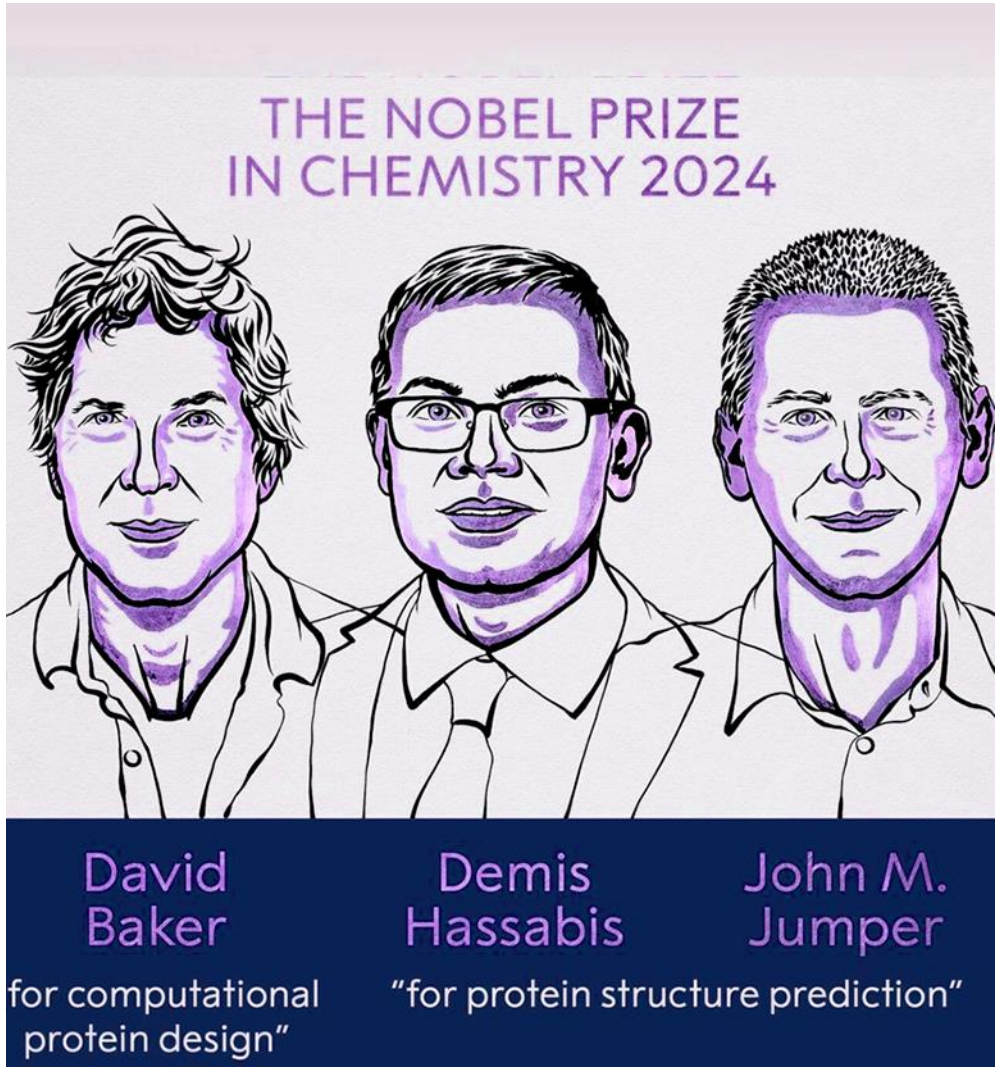
- Professor da Faculdade de Saúde Pública da USP na área de machine learning em saúde.
- Editor-Chefe da Revista de Saúde Pública.
- Diretor do Laboratório de Big Data e Análise Preditiva em Saúde (LABDAPS-USP).



LABDAPS
Laboratório de Big Data e Análise Preditiva em Saúde




THE NOBEL PRIZE
IN PHYSICS 2024
John J. Hopfield
Geoffrey E. Hinton
"for foundational discoveries and inventions
that enable machine learning
with artificial neural networks"


THE NOBEL PRIZE
IN CHEMISTRY 2024
David
Baker
for computational
protein design"
Demis
Hassabis
John M.
Jumper
"for protein structure prediction"

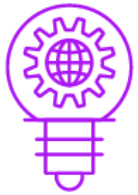
Por que têm ocorrido avanços exponenciais em IA nos últimos anos?



Aumento da **quantidade de dados** coletados em saúde (big data)



Avanços em **capacidade computacional** (empresas desenvolvendo chips específicos para IA).



Novos algoritmos para problemas mais complexos (*transformers, TabPFN*).

Machine Learning

Inteligência artificial clássica

Regras para a tomada de decisão pré-estabelecidas por humanos

- Traduzir uma frase utilizando dicionário e regras de gramática.
- Identificar spam de e-mails por meio de palavras-chaves.
- Identificar caras humanas por meio da forma de nariz, olho, boca etc.

Machine Learning

Inteligência artificial com machine learning

Máquinas aprendendo as regras para a tomada de decisão!

Aprendizado via identificação de padrões complexos nos dados.



É como uma criança aprende!

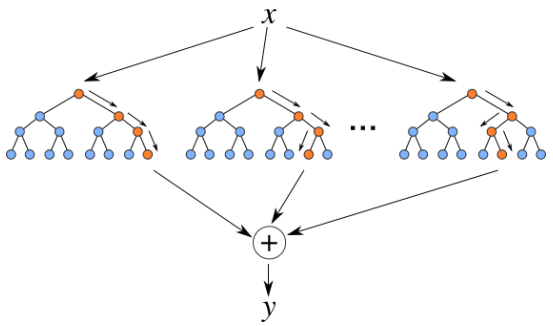


Machine Learning

Problemas **práticos** de predição (para a tomada de decisão)

Pouco interesse em *interpretar* os modelos.
Liberdade para modelar a complexidade do mundo real

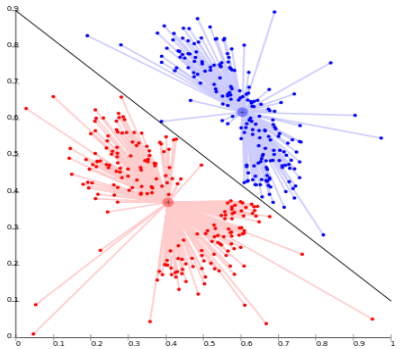
Redes neurais

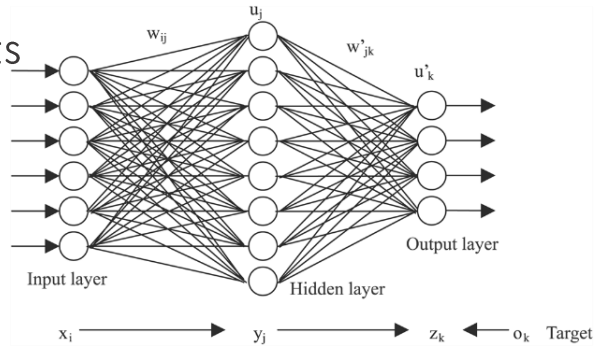


TabPFN

Xgboost

Random forests





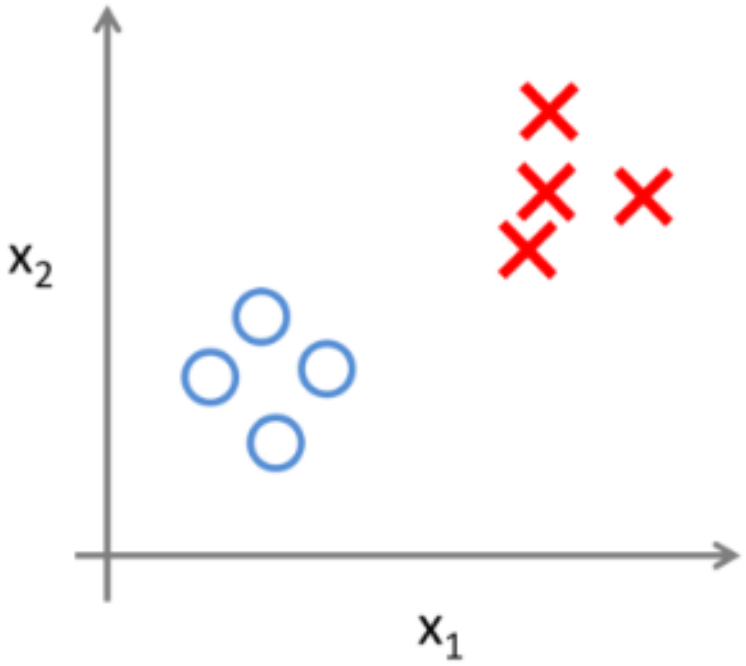
Regressões penalizadas

QUATRO CATEGORIAS DE MACHINE LEARNING

1. Aprendizado Supervisionado

Objetivo: Acertar um resultado que existe

- Treinar um modelo para obter a melhor performance preditiva possível para um problema;
- Quando os dados incluídos para treinar o algoritmo incluem a solução desejada, ou **rótulo** (“label”);



QUATRO CATEGORIAS DE MACHINE LEARNING

1. Aprendizado Supervisionado

Divididos em dois grandes grupos

1. Classificação

Quando a variável a ser predita é categórica.

Exemplo: Óbito em 5 anos, incidência de doença em 10 anos, etc.

2. Regressão

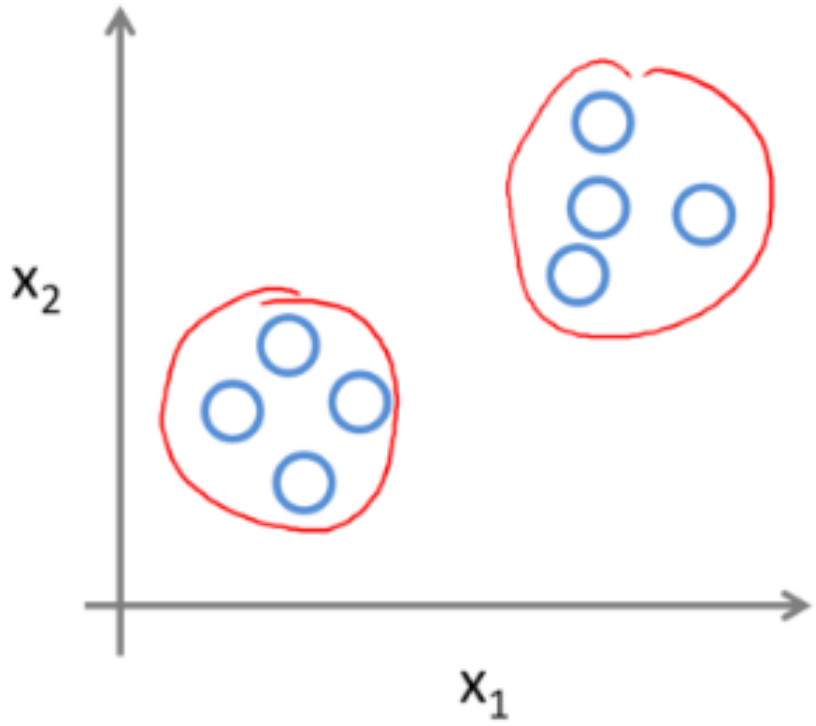
Quando a variável a ser predita é quantitativa

Exemplo: Quantos meses de vida a pessoa tem pela frente, qual será o seu IMC no próximo ano, etc.

QUATRO CATEGORIAS DE MACHINE LEARNING

2. Aprendizado não-supervisionado

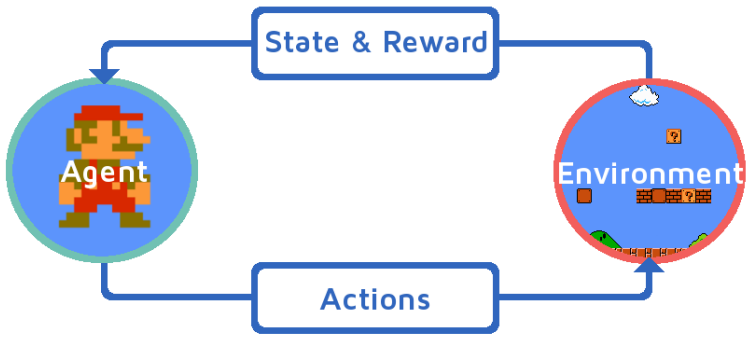
- Não existe rótulo (“label”);
- Algoritmo aprende sem uma resposta certa;
- O objetivo é encontrar padrões nos dados;
- Mais comuns: clustering (agrupamentos) e redução de dimensão (ACP).



QUATRO CATEGORIAS DE MACHINE LEARNING

3. Aprendizado por reforço

- Agente interage com um ambiente dinâmico;
- Feedbacks constantes em termos de **premiações** e **punições**;
- Jogos.



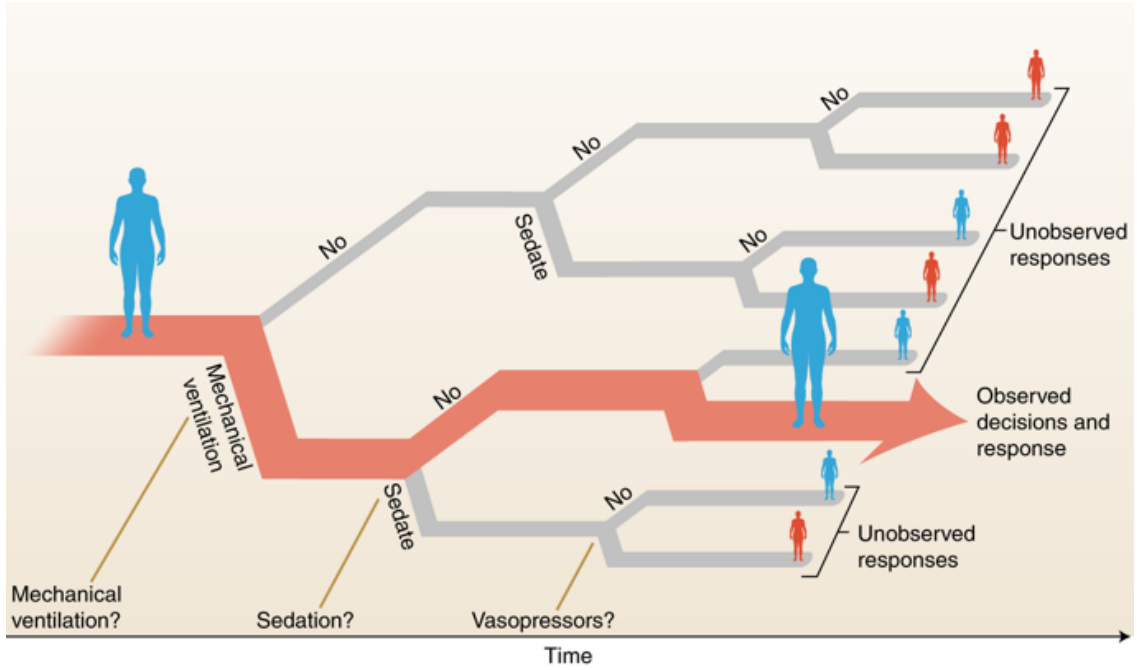


QUATRO CATEGORIAS DE MACHINE LEARNING

3. Aprendizado por reforço

Área promissora:

- Diferentes etapas do tratamento médico para identificar sequência ótima (ex: sepse).



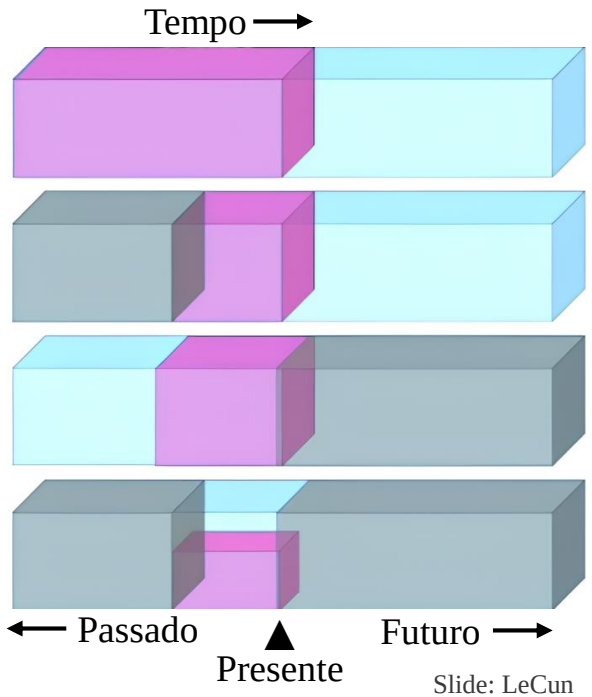
Gottesman O, Johansson F, Komorowski M, Faisal A, Sontag D, Doshi-Velez F, Celi LA. Guidelines for reinforcement learning in healthcare. Nat Med 2019. 25(1)16-18.

QUATRO CATEGORIAS DE MACHINE LEARNING

4. Autossupervisionado

- Um problema não supervisionado é transformado em um problema supervisionado pela geração automática dos rótulos;
- O processo de aprendizado autossupervisionado consiste em identificar partes ocultas dos dados.

- **Prever qualquer parte da entrada a partir de qualquer outra parte.**
- **Prever o futuro a partir do passado.**
- **Prever o futuro a partir do passado recente.**
- **Prever o passado a partir do presente.**
- **Prever o topo a partir da parte inferior.**
- **Prever o que está oculto a partir do que está visível.**
- **Fingir que há uma parte da entrada que você não conhece e prever essa parte.**



Slide: LeCun

Pré-treinamento
(Pre-training)

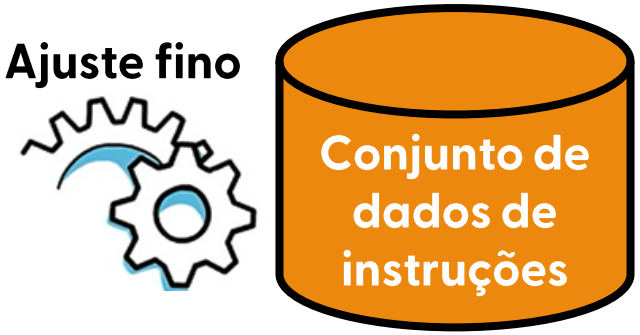
☺ Predição da próxima palavra

☹ Não é especialista em seguir instruções



Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna .....

Ajuste fino supervisionado
(Supervised fine-tuning)



`(instrução, resposta)`

☺ Segue instruções

Aprendizado por Reforço
(Reinforcement Learning)

Aprendizado por Reforço com Feedback Humano
(Reinforcement Learning from Human Feedback - RLHF)

Aprendizado por Reforço com Feedback de IA
(RLAIF - Reinforcement Learning from AI Feedback)

Predição com Machine Learning

- Em predição estamos interessados em performance preditiva.
- Em inferência o interesse é entender a relação entre variáveis, normalmente como Y muda com uma alterações entre seus determinantes.
- Problema: modelos facilmente interpretáveis (regressões linear e logística, árvores de decisão) normalmente têm pior performance preditiva.
- Trade-off entre predição e interpretação.
- Pensar bem sobre o objetivo da análise: é inferência ou predição?

Predição com Machine Learning

Dados

Preferencialmente muitos e com boa qualidade (preenchidos corretamente e preditores fortes). Realizar o pré-processamento das variáveis.

Algoritmos

Inserir os dados no algoritmo de machine learning para aprender as regras de decisão que melhor conectam os preditores ao desfecho.

Testar no futuro

Inserir no algoritmo os novos dados para testar a qualidade desse algoritmo para predizer dados futuros.

Artigo:

How to avoid machine learning pitfalls: a guide for academic researchers

Autor: Michael A. Lones* *School of Mathematical and Computer Sciences, Heriot-Watt University, Edinburgh, Scotland, UK

Objetivo



- Elencar erros comuns ao aplicar técnicas de machine learning;
- Como evitar esses erros;
- Destina-se como um guia para estudantes;
- Foco em questões de pesquisa acadêmica;



Discussão

1. O que fazer antes de construir um modelo
2. Como construir modelos
3. Como avaliar modelos
4. Como comparar modelos
5. Como relatar resultados

1 Antes de começar a construir modelos



Entenda os dados

É importante saber:

- Forma de coleta
- Se há artigos que descreveram o banco de dados
- Se os dados fazem sentido para predição
- Comece sempre por uma análise exploratória

1 Antes de começar a construir modelos



Não olhe para todos os seus dados

- Evite analisar os dados de teste durante a análise exploratória inicial (suposições consciência ou inconscientes)

- Cuidado com vazamentos (acesso aos dados de teste)

1 Antes de começar a construir modelos



Certifique-se de que há dados suficientes

- Sem dados suficientes é impossível treinar um modelo que generalize
- Descobrir isso pode não ser tão simples (sinal vs ruído)
- Sinal forte = pode usar menos dados
- Sinal fraco = precisa de mais dados

ou usar validação cruzada

- Data Augmentation = aumento no número de observações

Em classificação: importante em dados desbalanceados

Não usar acurácia como medida de desempenho



1 Antes de começar a construir modelos



Converse com especialistas no assunto

- Ajuda para entender o problema (ex.: variáveis uteis)

- Modelo útil na prática real

- Checar de importância de variáveis fazem sentido e identificar vazamentos

1 Antes de começar a construir modelos



Faça um levantamento de literatura

- Entender o que foi feito anteriormente

- Progresso acadêmico = Processo iterativo

- Aproveitar o conhecimento existente

1 Antes de começar a construir modelos



Pense em como o modelo será utilizado

- "Por que você quer construir esse modelo?"

- Implementação em ambiente real

- Vinculação do modelo a um Sistema (prontuário eletrônico, aplicativo)

2 Como construir modelos confiáveis



Impeça vazamento de dados pro teste

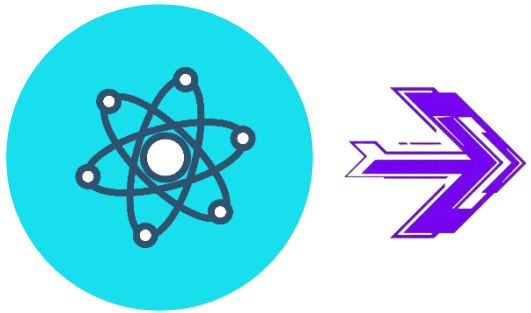
- Separe o conjunto de teste e não mexa nele!

- Vazamento torna modelos inúteis

- Falta de confiabilidade

- Exemplos:
  - Pré-processamento só no treino
  - Seleção de variáveis e otimização de hiperparâmetros só no treino

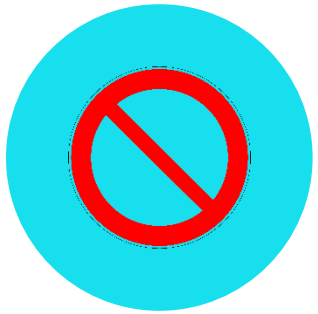
2 Como construir modelos confiáveis



Teste vários modelos

- Não existe um único algoritmo melhor
- Teorema do almoço grátis
- Encontrar algoritmo que gere a melhor predição
- Python: Scikit Learn

2 Como construir modelos confiáveis



Não use modelos inapropriados

- Modelos inadequados aos dados: variáveis categóricas quando o modelo só aceita numéricas

- Modelos desnecessariamente complexos (deep learning para dados estruturados)

- Modelos mais recentes nem sempre são melhores (cuidado com artigos de benchmark em que autores querem que seu algoritmo vença)

2 Como construir modelos confiáveis



Otimize os hiperparâmetros

- Hiperparâmetros: parâmetros externos ao treinamento que afetam a configuração do modelo

- Hiperparâmetros afetam o desempenho

- Estratégias de otimização (random search, grid search, hyperopt etc)

2 Como construir modelos confiáveis



Cuidado com a otimização de hiperparâmetros e seleção de variáveis

- Erro comum: seleção de variáveis antes da divisão dos dados

- Seleção estatística de variáveis e otimização de hiperparâmetros devem ser feitas com dados de treino

- Técnica: Validação cruzada aninhada (definição de hiperparâmetros e parâmetros dentro da mesma validação cruzada)

3 Como avaliar modelos



Use um conjunto de teste adequado

- Sempre use um conjunto de teste!

- Dados de teste apropriados (representativo)

3 Como avaliar modelos



Use um conjunto de validação

- Conjunto de validação: conjunto de dados intermediário ao treino e teste, para medir desempenho

- Pode ser usado para orientar o treinamento

3 Como avaliar modelos



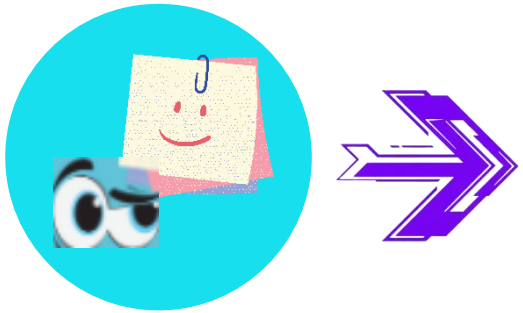
Não use a acurácia com dados desbalanceados

- Cuidado com as métricas de avaliação!

- Acurácia: Em classificação só funciona com amostras balanceadas (mesmo número de observações de ambas classes)

- Os dados de saúde costumam ser desbalanceados

4 Como comparar modelos



Não presuma que valores maiores signifiquem modelos melhores

- Cuidado ao comparar seus resultados com o de outras pesquisas (diferentes bancos de dados)

- Comparações devem ser justas

- Desempenho depende de como o modelo foi desenvolvido (tipo de dados de treino, formas de avaliação, otimização dos hiperparâmetros, etc)

4 Como comparar modelos

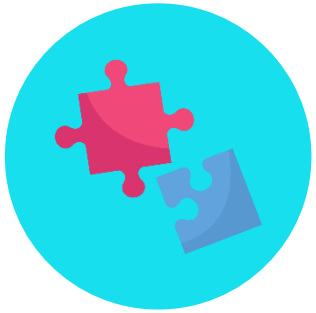


Nem sempre acredite nos resultados já encontrados em outros trabalhos

- Problema da utilização de dados de mesmos bancos

- Desconhecer se não olharam o teste antes
- Coletivamente o teste está sendo usado muitas vezes (overfitting nesse teste)

4 Como comparar modelos



Considere combinações de modelos

- Compensar pontos fracos com pontos fortes

- Exemplo:
  - Bagging e Boosting

- Como combinar diferentes modelos de base? (votação ou usar um algoritmo final para agregação de resultados)

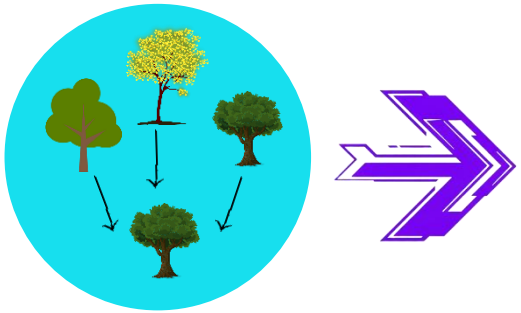
5 Como relatar resultados



Seja transparente

- Objetivo é contribuir com o conhecimento
- ML possui muitos trade-offs
- Compartilhe o modelo de forma acessível (ex.: github)
- Código limpo e organizado (documente as etapas)
- Facilitar a reprodutibilidade

5 Como relatar resultados



Não generalize para além do seu conjunto de dados

- Não faça afirmações exageradas

- Esteja ciente das limitações do estudo

- Variações com a qualidade dos dados e diferenças de distribuição

5 Como relatar resultados



Olhe seus modelos

- Mostre como o modelo aprendeu e tomou as decisões

- Objetivo: gerar conhecimento

- Forneça visualizações

- Use técnicas de explicabilidade (Shapley)



Em ML, assim como em qualquer tipo de pesquisa:

- mantenha a mente aberta;

- acompanhe o desenvolvimento da área;

- aceite que você não sabe tudo.

LONES, Michael A. How to avoid machine learning pitfalls: a guide for academic researchers. arXiv preprint arXiv:2108.02497, 2021.

Obrigado!

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho

@labdaps

alexdiasporto@usp.br