

PROFEPI Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde

Introdução à Inteligência Artificial para Predições em Vigilância em Saúde e Ambiente

Módulo 2

Generalização e avaliação de modelos

OPAS Organização Pan-Americana da Saúde / Organização Mundial da Saúde Américas

SUS

MINISTÉRIO DA SAÚDE

MINISTÉRIO DA SAÚDE
SECRETARIA DE VIGILÂNCIA EM SAÚDE E AMBIENTE (SVSA)

Coordenação-Geral

Mariângela Simão

Secretária de Vigilância em Saúde e Ambiente–SVSA/MS

Guilherme Loureiro Werneck

Diretor do Departamento de Ações Estratégicas de Epidemiologia e Vigilância em Saúde e Ambiente–Daevs/SVSA/MS

Vivian Siqueira Santos Gonçalves

Coordenadora-Geral de Desenvolvimento da Epidemiologia em Serviços–CGDEP/Daevs/SVSA/MS

Equipe Técnica

Amanda Maciel de Quadros–CGDEP/Daevs/SVSA/MS

Antonio Ygor Modesto de Oliveira–CGDEP/Daevs/SVSA/MS

Cíntia Pereira Donateli–CGDEP/Daevs/SVSA/MS

Criação Digital

Matheus Nunes Oliveira Alves–CGDEP/Daevs/SVSA/MS

Otávio Francisco Batista Martins–CGDEP/Daevs/SVSA/MS

Professores Conteudistas

Alexandre Dias Porto Chiavegatto Filho–Universidade de São Paulo (USP)

Keisyanne de Araujo Moura–Universidade de São Paulo (USP)

Tutores

André Henrique Alves Carneiro–Universidade de São Paulo (USP)

Marcela Quaresma Soares–Universidade de São Paulo (USP)

Vinícius de Camargo–Universidade de São Paulo (USP)

ORGANIZAÇÃO PAN-AMERICANA DE SAÚDE ORGANIZAÇÃO MUNDIAL DA SAÚDE (OPAS/OMS)

Coordenação-Geral

Cristian Morales Fuhrimann–Representante da OPAS/OMS no Brasil

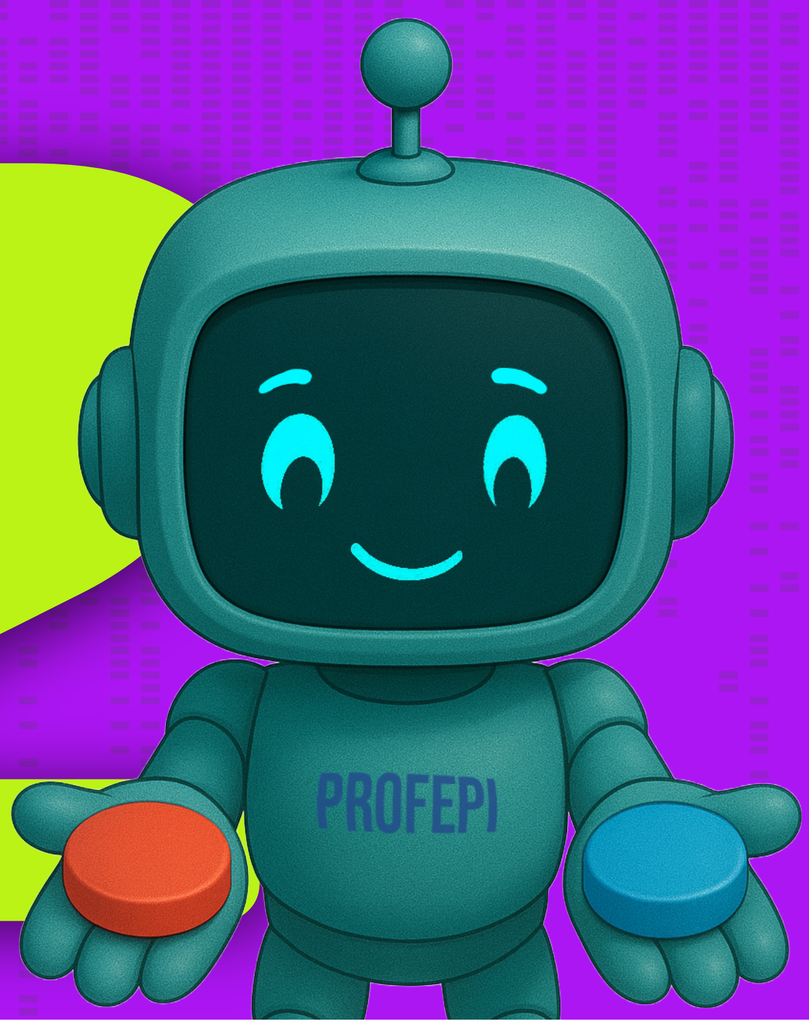
Alexander Rosewell–Coordenador de Emergências, Evidência e Inteligência em Saúde no Brasil

Equipe Técnica

Josy Maria de Pinho da Silva–OPAS/OMS

capítulo 5

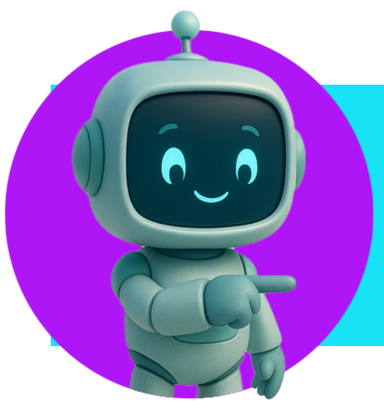
MÓDULO 2



Avaliação e Seleção de Modelos de *Machine Learning*

Introdução

O uso de algoritmos de *machine learning* (ML) em saúde tem avançado em velocidade impressionante, com aplicações que vão da predição de mortalidade neonatal ao diagnóstico assistido por imagem. Entretanto, a força de qualquer modelo está menos na sofisticação de seu algoritmo e mais na qualidade da sua avaliação. Modelos que parecem perfeitos em ambientes controlados podem falhar gravemente quando expostos à realidade clínica, gerando vieses, erros diagnósticos ou decisões administrativas incorretas.



É nesse ponto que entram os métodos de **avaliação e seleção de modelos**. Sem eles, estaríamos aplicando ferramentas de alto impacto em saúde sem qualquer garantia de validade.

Um princípio norteador é o **teorema do "não há almoço grátis" (no free lunch theorem)**: em um número infinito de problemas diferentes, nenhum algoritmo é universalmente superior. Assim, o único caminho é testar, comparar e validar. Embora, na prática, alguns algoritmos tenham desempenho superior em muitas situações reais – como gradient boosting, random forests ou TabPFN – a escolha final só pode ser feita com base em evidências empíricas.

Função alvo (target function): representa a verdadeira relação entre as variáveis preditoras (x) e o desfecho de interesse (y), isto é, a função y = f(x) que origina o fenômeno real. Em problemas de saúde, por exemplo, pode ser a relação entre características clínicas de um paciente e a probabilidade de desenvolver determinada doença. Essa função, no entanto, é quase sempre desconhecida e difícil de ser observada em sua totalidade.

Modelo: trata-se de uma aproximação da função alvo, construída a partir dos dados disponíveis. Formalmente, o modelo gera uma predição $\hat{y} = f(x)$. Diferentes modelos, como árvores de decisão ou redes neurais, oferecem maneiras distintas de representar essa aproximação. Nenhum modelo é uma cópia perfeita da realidade, mas sim uma tentativa de capturar padrões relevantes o suficiente para que as previsões sejam úteis.

Algoritmo de aprendizado: é o conjunto de instruções que utilizamos para ajustar o modelo a partir dos dados. Ele define como os parâmetros internos do modelo são otimizados para que as predições se aproximem ao máximo dos valores observados. No fundo, o algoritmo é a "receita" que ensina o modelo a aprender com os exemplos apresentados, seja minimizando erros em uma função de perda ou maximizando alguma métrica de desempenho.

O grande desafio, entretanto, não é apenas construir um modelo que se ajuste bem aos dados já observados, mas avaliar sua **capacidade de generalização**. Isso significa estimar o quão bem o modelo se comportará diante de dados novos, nunca vistos anteriormente. Um modelo que memoriza demais os exemplos de treino pode ter baixo erro naquele conjunto, mas falhar completamente em situações reais – fenômeno conhecido como sobreajuste. Por outro lado, modelos muito simples podem não capturar padrões essenciais, resultando em sub-ajuste.

Estratégias de Avaliação

A avaliação de modelos em *machine learning* é fundamental para garantir que os resultados sejam confiáveis e possam ser aplicados de forma prática. Diferentes estratégias são desenvolvidas para medir a capacidade de generalização dos modelos, equilibrando simplicidade, eficiência e rigor estatístico.

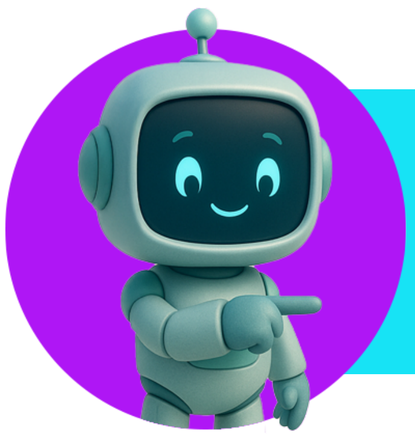
Método Holdout

O método holdout consiste em dividir o conjunto de dados em duas partes: uma para treinar o modelo e outra para testá-lo. Proporções como 70/30 ou 80/20 são comuns, mas a escolha depende do tamanho do banco de dados e da variabilidade do problema.

Apesar de simples, esse método apresenta duas limitações importantes:

Viés pessimista: quando a parte usada para treino é pequena, o modelo pode não captar todos os padrões relevantes, levando a uma avaliação mais negativa do que seria se houvesse mais dados disponíveis.

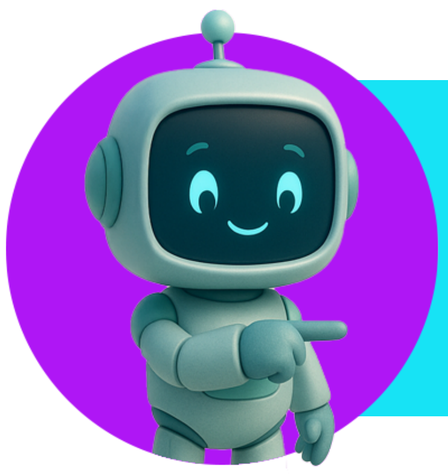
Alta variabilidade: diferentes formas de dividir treino e teste podem gerar resultados bastante distintos. Por exemplo, se por acaso todos os casos raros ficarem concentrados em apenas um dos conjuntos, a avaliação será distorcida.



Por isso, o holdout é útil em análises iniciais, quando se deseja uma visão rápida do desempenho, mas não deve ser usado como avaliação final. Para estimativas mais estáveis, a técnica mais utilizada é a **validação cruzada**, que reduz tanto o viés quanto a variabilidade.

Estratificação

Em saúde, é comum lidar com classes muito desbalanceadas. Imagine um estudo em que apenas 1% dos pacientes tem um determinado tipo de câncer. Se a divisão dos dados for feita de forma totalmente aleatória, pode acontecer de o conjunto de treino ou o de teste quase não conter pacientes com câncer, prejudicando o aprendizado do modelo e também a avaliação.



A solução é usar a **amostragem estratificada**, que garante que a proporção entre classes seja mantida tanto no treino quanto no teste. Assim, mesmo em situações de desbalanceamento extremo, como doenças raras ou complicações pouco frequentes, asseguramos que o modelo terá contato com exemplos relevantes e que a avaliação refletirá melhor o problema real.

FIQUE ATENTO!

Esse cuidado é ainda mais importante na área da saúde. Sem estratificação, um modelo pode parecer muito bom simplesmente porque aprendeu a predizer a classe majoritária (por exemplo, "não tem a doença"). Isso gera uma falsa sensação de desempenho, mas na prática pode significar diagnósticos errados, atrasos em tratamentos e risco para os pacientes.

Viés e Variância

Um dos conceitos mais fundamentais em *machine learning* é o equilíbrio entre viés e variância, conhecido como *trade-off* viés-variância. Esse dilema reflete a tensão entre modelos excessivamente simples e modelos excessivamente complexos. Nenhum modelo é perfeito, e todo processo de predição envolve algum nível de erro. Compreender de onde vem esse erro é necessário para desenvolver soluções mais robustas.

Viés: O viés representa erros sistemáticos introduzidos quando o modelo é incapaz de capturar a verdadeira relação entre as variáveis. Isso ocorre tipicamente em modelos muito simples, que reduzem demais a complexidade do problema. Esse cenário, chamado de **sub-ajuste**, resulta em previsões ruins tanto nos dados de treino quanto nos de teste.

Exemplo: utilizar apenas a média de idade dos pacientes para predizer risco cardiovascular. Esse modelo ignora variáveis como pressão arterial, colesterol, histórico familiar ou hábitos de vida, levando a erros previsíveis e recorrentes.

Variância: A variância está associada à instabilidade de modelos muito complexos, que aprendem não apenas os padrões reais dos dados, mas também o "ruído" – variações aleatórias e irrelevantes. Nesse caso, temos o **sobreajuste:** o modelo apresenta desempenho excelente nos dados de treino, mas falha ao generalizar para novos conjuntos.

Exemplo: uma árvore de decisão que cresce demais, ajustando-se perfeitamente a cada paciente do conjunto de treino, mas incapaz de predizer corretamente o risco de novos pacientes.

O ponto de equilíbrio

O desafio central em machine learning é encontrar um modelo que seja suficientemente complexo para captar padrões relevantes, mas não tão complexo a ponto de se tornar instável e pouco generalizável. Esse ponto de equilíbrio é identificado por meio de técnicas de validação e reamostragem, como validação cruzada, bootstrap e regularização. Essas estratégias permitem testar diferentes modelos e ajustar hiperparâmetros de forma controlada, aproximando o modelo do ponto ótimo entre viés e variância.

Implicações práticas em saúde

Na prática, esse equilíbrio é muito importante: um modelo com alto viés pode falhar em detectar pacientes em risco (falso-negativo), enquanto um modelo com alta variância pode gerar muitos alarmes falsos (falso-positivo). Em sistemas de saúde, ambos os cenários trazem consequências sérias, desde diagnósticos perdidos até sobrecarga de exames desnecessários. Por isso, compreender e gerenciar o trade-off viés-variância não é apenas uma questão técnica, mas também ética e de impacto direto na atenção à saúde.

Validação Cruzada e Hiperparâmetros

Para avaliar de forma robusta o desempenho de modelos em machine learning, uma das estratégias mais utilizadas é a validação cruzada, que permite reduzir a influência do acaso na separação treino/teste e, ao mesmo tempo, fornece uma estimativa mais confiável da sua capacidade de generalização.

k-Fold Cross-Validation

Na validação cruzada do tipo k-fold, o conjunto de dados é dividido em k partes (ou folds) de tamanho aproximadamente igual. O modelo é então treinado k vezes, e a cada rodada um dos folds é reservado para validação, enquanto os demais servem para o treino. O desempenho final do modelo é calculado como a média dos erros obtidos em cada uma das k iterações. O desempenho final é a média dos k testes:

$$Erro\ Médio = \frac{1}{k}\sum_{i=1}^{k} \text{Erro}_i$$

Esse processo garante que cada observação seja usada tanto para treino quanto para validação, mas nunca nas duas funções ao mesmo tempo. Diversos estudos mostraram que escolher k = 10 representa um bom compromisso entre viés e variância: valores menores (como k = 5) podem produzir estimativas mais rápidas, porém menos estáveis, enquanto valores maiores (como leave-one-out) tendem a ter variância elevada e custo computacional muito maior.

Seleção de Hiperparâmetros

Outro passo importante é a escolha dos hiperparâmetros, que são configurações externas ao modelo e definem sua complexidade e comportamento. Diferentemente dos parâmetros internos (como os coeficientes em uma regressão ou os pesos em uma rede neural), os hiperparâmetros não são aprendidos diretamente a partir dos dados e precisam ser ajustados por meio de experimentação.

Entre os principais métodos de busca de hiperparâmetros, destacam-se:

1. **Grid Search:** avalia de forma exaustiva todas as combinações possíveis de valores dentro de um conjunto previamente definido. É simples e garante a exploração completa do espaço especificado, mas pode ser extremamente custoso em termos computacionais.

2

Random Search: em vez de testar todas as combinações, seleciona pontos aleatórios do espaço de hiperparâmetros. Essa abordagem costuma ter boa eficiência, pois evita gastar tempo em regiões pouco promissoras.

3

Otimização Bayesiana: utiliza modelos probabilísticos para guiar a busca. A ideia é estimar quais regiões do espaço de hiperparâmetros têm maior probabilidade de conter boas soluções e direcionar os experimentos nessa direção. Essa técnica é mais sofisticada e, em geral, mais eficiente quando o espaço de busca é amplo ou quando cada treino de modelo é muito custoso.

Métricas em Regressão

Nos problemas de regressão, em que o objetivo é predizer valores contínuos (como a pressão arterial de um paciente, o número de internações esperadas em uma região ou o tempo de sobrevida após um diagnóstico), é necessário avaliar não apenas se o modelo acerta aproximadamente, mas também como e em que magnitude erra. Para isso, utilizamos métricas que quantificam a diferença entre os valores observados e os valores preditos.

- **Erro Quadrático Médio (MSE):**

$$Erro\ Quadrático\ Médio = \frac{1}{n}\sum_{i=1}^{n}(y - \hat{y}_i)^2$$

O MSE mede o erro médio ao quadrado, dando maior peso a discrepâncias grandes. Por isso, ele é bastante útil quando queremos penalizar fortemente previsões muito distantes da realidade. Em saúde, isso pode ser vantajoso em contextos como predição de glicemia ou dosagem de medicamentos, onde grandes erros podem ser clinicamente críticos. Porém, por elevar ao quadrado, o MSE é altamente influenciado por outliers.

- **Raiz do Erro Quadrático Médio (RMSE):**

$$Erro\ Quadrático\ Médio = \sqrt{\text{MSE}}$$

O RMSE é simplesmente a raiz quadrada do MSE. Sua vantagem é trazer o erro de volta para a mesma escala da variável de interesse, o que facilita a interpretação. Por exemplo, se estamos prevendo tempo de internação em dias e o RMSE for 2, significa que, em média, os erros do modelo estão na ordem de 2 dias. Assim como o MSE, também é bastante sensível a valores extremos.

- **Erro Absoluto Médio (MAE):**

$$Erro\ Absoluto\ Médio = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

O MAE calcula a média das diferenças absolutas, sem elevar ao quadrado. Dessa forma, cada erro contribui proporcionalmente ao resultado final, tornando o MAE mais robusto a outliers. Ele é especialmente útil em contextos em que os valores extremos podem estar ligados a ruídos de medição ou situações excepcionais, como erros laboratoriais em exames clínicos.

Métricas em Classificação

Nos problemas de classificação, em que o objetivo é prever categorias (por exemplo, presença ou ausência de uma doença), a avaliação do modelo vai além de simplesmente contar quantas vezes ele acerta.

> É preciso analisar os diferentes tipos de erro que podem ocorrer, especialmente porque, em saúde, **um falso negativo pode ter consequências muito diferentes de um falso positivo**.

Matriz de Confusão

A matriz de confusão é a base para praticamente todas as métricas de classificação. Ela organiza os resultados possíveis em quatro grupos:

Verdadeiros Positivos (TP):
casos em que o modelo previu corretamente a presença da condição.

Falsos Negativos (FN):
casos em que o modelo não identificou a condição, embora ela estivesse presente.

Falsos Positivos (FP):
casos em que o modelo indicou a presença da condição, mas na realidade ela não existia.

Verdadeiros Negativos (TN):
casos em que o modelo previu corretamente a ausência da condição.

Principais métricas:

A matriz de confusão é a base para praticamente todas as métricas de classificação. Ela organiza os resultados possíveis em quatro grupos:

- **Acurácia:**

$$Acurácia = (\mathrm{TP} + \mathrm{TN}) / (\mathrm{TP} + \mathrm{TN} + \mathrm{FP} + \mathrm{FN})$$

Representa a proporção total de acertos do modelo. Embora seja intuitiva, pode ser **enganosa em cenários de classes desbalanceadas**. Por exemplo, se apenas 1% dos pacientes têm câncer e o modelo sempre prevê “não tem câncer”, ele terá 99% de acurácia, mas será inútil na prática.

- **Sensibilidade (Recall):**

$$Sensibilidade = \mathrm{TP} / (\mathrm{TP} + \mathrm{FN})$$

Mede a capacidade do modelo de identificar corretamente os casos positivos. É frequentemente usado na saúde, já que indica a fração de pacientes doentes que realmente foram detectados. Alta sensibilidade reduz falsos negativos, algo crítico em diagnósticos precoces de doenças graves.

- **Especificidade:**

$$Especificidade = \mathrm{TN} / (\mathrm{TN} + \mathrm{FP})$$

Avalia a capacidade do modelo de reconhecer os casos negativos. Alta especificidade significa poucos falsos positivos, importante em exames que envolvem procedimentos caros ou invasivos, como biópsias.

- **Precisão (Precision):**

$$Prec = TP / (TP + FP)$$

Mostra a proporção de previsões positivas que estavam corretas. Ou seja, dado que o modelo indicou "doente", qual a chance de isso ser verdade? É especialmente relevante quando o custo de um falso positivo é elevado (ex.: indicar uma cirurgia desnecessária)

- **F1-Score:**

$$F1 = 2 * (\mathrm{Precisão} * \mathrm{Sensibilidade}) / (\mathrm{Precisão} + \mathrm{Sensibilidade})$$

É a média harmônica entre precisão e sensibilidade. Funciona como um equilíbrio quando precisamos considerar tanto os falsos positivos quanto os falsos negativos. Em contextos de saúde, é bastante usado quando queremos modelos que sejam ao mesmo tempo sensíveis e precisos.

Interpretação prática em saúde

- Em **rastreamento populacional** (ex.: triagem de câncer de colo do útero), normalmente prioriza-se **alta sensibilidade**, para reduzir falsos negativos e não deixar casos reais sem diagnóstico.
- Em **testes confirmatórios** (ex.: exame de alta precisão antes de indicar cirurgia), prioriza-se **alta especificidade e precisão**, para minimizar falsos positivos.
- Quando existe a necessidade de equilíbrio entre os dois extremos, o **F1-score** pode ser uma boa métrica de referência.

Assim, a escolha da métrica depende menos de uma "receita universal" e mais do **contexto clínico ou epidemiológico**, equilibrando o impacto de cada tipo de erro na prática real.

Métricas de Ranking

Nos problemas de classificação em saúde, os modelos não retornam apenas uma previsão binária ("doente" ou "não doente"), mas sim uma **probabilidade** associada a cada indivíduo. Isso permite ordenar (ou ranquear) os casos de acordo com o risco predito, sendo muito útil em contextos como triagem de pacientes, alocação de recursos hospitalares ou priorização de exames. Para avaliar esse tipo de saída probabilística, usamos métricas baseadas em **curvas de desempenho**.

Curva ROC e AUC

A **curva ROC** (Receiver Operating Characteristic) mostra a relação entre a **taxa de verdadeiros positivos (TPR)** e a **taxa de falsos positivos (FPR)** para diferentes limiares de decisão:

$$TPR = TP / (TP + FN)$$

$$FPR = FP / (FP + TN)$$

Cada ponto da curva representa um possível limiar de corte (por exemplo, considerar "doente" se a probabilidade for maior que 0,3; 0,5; 0,7 etc.). A área sob a curva ROC, chamada AUC-ROC, mede a capacidade de o modelo distinguir entre as classes. Um AUC de 0,5 equivale a um chute aleatório, enquanto um AUC de 1,0 indica discriminação perfeita.

Na prática em saúde:

- Um **AUC próximo de 0,9** sugere excelente discriminação, como em modelos para diagnóstico de doenças já bem estudadas.
- Um **AUC em torno de 0,7** pode ser aceitável em contextos mais desafiadores, como predição de doenças raras ou desfechos multifatoriais.
- O grande valor do AUC-ROC é que ele é independente do ponto de corte escolhido, avaliando o desempenho global do modelo em diferentes cenários.

Métricas de Probabilidade e Calibração

Em muitas aplicações de machine learning em saúde, não basta classificar corretamente os pacientes em grupos de risco, é fundamental que as probabilidades preditas sejam confiáveis. Afinal, decisões médicas e de políticas públicas frequentemente dependem de valores absolutos de risco. Por exemplo, indicar ou não um tratamento invasivo, decidir a prioridade em listas de espera, ou calcular o número esperado de leitos em uma epidemia.

Calibração de Modelos

Um modelo é considerado **bem calibrado** quando suas probabilidades preditas refletem a frequência real dos eventos. Por exemplo, se em um grupo de pacientes o modelo estima risco de 70% para óbito em 30 dias, espera-se que aproximadamente 70% de fato venham a óbito nesse período. Da mesma forma, para um risco predito de 20%, o evento deveria ocorrer em torno de 20% dos pacientes.

Esse alinhamento é diferente da **discriminação** (avaliada por métricas como AUC-ROC), que mede apenas a capacidade do modelo de distinguir entre quem terá e quem não terá o desfecho. É possível ter um modelo com excelente discriminação, mas má calibração – e vice-versa. Em saúde, ambos são igualmente importantes: discriminação indica quem está em maior risco, calibração indica quanto é esse risco.

Métrica de Calibração

- **Brier Score:** mede o erro quadrático médio entre as probabilidades previstas e os desfechos reais. Quanto menor o valor, melhor a calibração.

$$Brier\ Score = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)$$

Importância em Saúde

A calibração é importante porque decisões de saúde são muitas vezes sensíveis à magnitude exata do risco:

- Exames preventivos: um risco de 10% pode justificar exames adicionais, mas 2% talvez não.
- Terapias intensivas: em modelos de mortalidade hospitalar, uma predição mal calibrada pode superlotar UTIs ou, ao contrário, negar suporte a quem realmente precisa.
- Política pública: previsões de risco mal calibradas podem levar a erros de planejamento, como subestimar o número de vacinas necessárias em uma região.

Rebalanceamento de Classes

Em problemas de machine learning aplicados à saúde, é muito comum lidar com dados desbalanceados, em que a maioria dos pacientes não apresenta o desfecho de interesse (classe majoritária), enquanto apenas uma pequena fração realmente o apresenta (classe minoritária). Exemplos típicos incluem predição de doenças raras, identificação de complicações pós-cirúrgicas ou detecção de óbitos em bases hospitalares. Quando esse desbalanceamento é ignorado, os algoritmos tendem a favorecer a classe majoritária, resultando em modelos que apresentam alta acurácia aparente, mas são incapazes de identificar adequadamente os casos mais importantes.

Técnicas de Rebalanceamento

- **Down-sampling (subamostragem da classe majoritária):** reduz artificialmente o número de exemplos da classe mais frequente, tornando a base mais equilibrada. Isso diminui o viés em favor da classe majoritária, mas pode descartar informações úteis, especialmente quando o conjunto de dados é pequeno.
  Exemplo: em um banco com 10.000 pacientes sem câncer e apenas 200 com câncer, poderíamos selecionar aleatoriamente 200 ou 400 negativos para manter uma proporção mais equilibrada.
- **Up-sampling (superamostragem da classe minoritária):** replica exemplos da classe menos representada até atingir uma proporção mais próxima da classe majoritária. Isso aumenta a chance do modelo aprender padrões da minoria, mas pode levar ao overfitting, já que os mesmos exemplos são repetidos muitas vezes.
- **SMOTE (Synthetic Minority Oversampling Technique):** em vez de replicar os exemplos minoritários, o SMOTE gera **novos exemplos sintéticos** com base na interpolação de vizinhos próximos. Essa técnica enriquece o espaço de treinamento, oferecendo mais diversidade à classe minoritária e reduzindo o risco de sobreajuste. Existem variações como Borderline-SMOTE e ADASYN, que focam em gerar exemplos mais informativos, próximos às fronteiras de decisão.

Evidências e Impacto nos Algoritmos

Estudos recentes mostram que o rebalanceamento traz mais benefícios em algoritmos considerados “fracos”, como máquinas de vetores de suporte (SVM) e árvores de decisão simples, pois esses métodos tendem a ser muito sensíveis ao desbalanceamento. Já modelos mais sofisticados e “fortes”, como XGBoost, LightGBM e CatBoost, muitas vezes já incorporam estratégias internas de ponderação de classes e, portanto, podem não apresentar ganhos significativos – ou até sofrer degradação de desempenho se o rebalanceamento for mal aplicado.

Conclusão

Ao longo deste capítulo percorremos os principais conceitos, estratégias e métricas que sustentam a aplicação de *machine learning* em saúde, sempre com foco na avaliação crítica de modelos. Vimos que não basta treinar algoritmos, é importante compreender fundamentos como o trade-off entre viés e variância, escolher métodos de validação robustos, ajustar hiperparâmetros de forma criteriosa e selecionar métricas adequadas ao problema em questão. Exploramos ainda a importância de avaliar modelos sob diferentes perspectivas, seja pelo erro em regressão, pela matriz de confusão em classificações binárias, pelas curvas de ranking em problemas probabilísticos, ou pela calibração em cenários onde decisões clínicas dependem de estimativas de risco confiáveis.

Discutimos também os desafios do desbalanceamento de classes, uma realidade comum em dados de saúde, e as diversas técnicas para corrigi-lo ou atenuar seus efeitos. Ficou claro que a avaliação não é apenas um passo técnico, mas uma etapa central que define a utilidade real de um modelo. Em saúde, um algoritmo mal avaliado pode gerar consequências éticas e práticas graves: atrasos em diagnósticos, tratamentos desnecessários ou falhas no planejamento de recursos.

Mais do que buscar modelos sofisticados ou métricas isoladas, precisamos adotar uma postura crítica e contextualizada, reconhecendo limitações, entendendo implicações clínicas e sociais, e priorizando sempre a **generalização e a confiabilidade** das previsões. *Machine learning* só se transforma em ferramenta de impacto positivo na saúde quando aliado a rigor metodológico, avaliação cuidadosa e compromisso com a prática real.

Esse equilíbrio entre teoria, técnica e aplicação é o que sustenta o avanço da inteligência artificial na saúde, permitindo que modelos não apenas façam previsões, mas contribuam para decisões mais seguras, efetivas e justas.



OPAS
Organização Pan-Americana da Saúde
Organização Mundial da Saúde
ESCRITÓRIO REGIONAL PARA AS Américas

SUS

MINISTÉRIO DA SAÚDE

PROFEPI

Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde