

PROFEPI

Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

Artigo:

Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning

Autor: Sebastian Raschka*
*Department of Statistics, University of Wisconsin-Madison

Objetivo



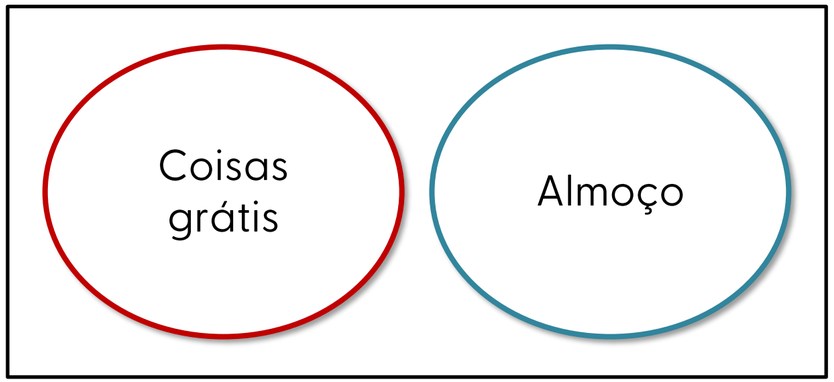
- Revisar diferentes técnicas para cada uma dessas sub tarefas;
- Vantagens e desvantagens de cada técnica;
- Recomendações para melhores práticas em ML.

Discussão

1. Introdução: Termos e técnicas essenciais de avaliação do modelo
2. Bootstrapping e Incerteza
3. Validação cruzada e otimização de hiperparâmetros

Teorema do "não há almoço grátis"

- Em infinitos conjuntos diferentes de dados, nenhum algoritmo é garantido a priori de ter melhor performance.
- A única forma de saber qual vai ter melhor performance é testar todos.



Segredo:
com dados reais, alguns costumam ganhar mais vezes (gradient boosting, random forests, TabPFN).

1 Introdução: Termos e técnicas essenciais de avaliação do modelo



Estimação de performance dos algoritmos

- Estimar o desempenho não é trivial;
- Configurações diferentes do mesmo algoritmo resultam em performances diferentes;
- Necessidade de comparação do desempenho antes do teste;
- Motivos para avaliar o desempenho de algoritmos:
  - Estimar a capacidade de generalização (futuro);
  - Selecionar o modelo com melhor desempenho;
  - Comparar e selecionar o melhor algoritmo de ML.

How Machine Learning Algorithms Work

Supervised learning is the computerized task of inferring a function from labeled training data.

$$Y = f(x),$$

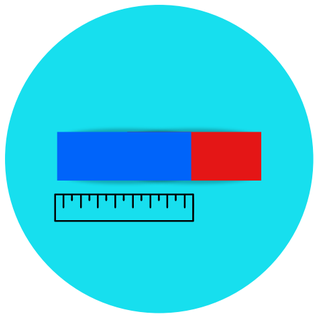
1 Introdução: Termos e técnicas essenciais de avaliação do modelo



Hipótese e Terminologia

- Função alvo (target): verdadeira função y=f(x), a qual queremos aprender ou aproximar;
- Modelo: função que acreditamos (esperamos) que seja semelhante a verdadeira;
- Algoritmo de aprendizado: conjunto de instruções para modelar uma função alvo usando dados de treinamento.

1 Introdução: Termos e técnicas essenciais de avaliação do modelo



Validação de re-substituição e Método Holdout

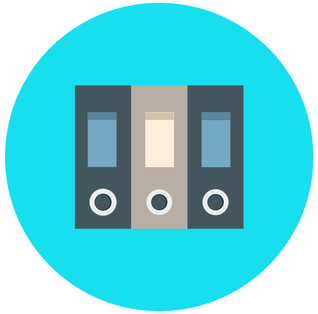
- Divisão entre treino e teste: técnica de avaliação mais comum

1° divide-se o conjunto de dados rotulados em duas partes: treino e teste (subamostragem aleatória) para evitar sobreajuste

2° ajusta-se o modelo aos dados de treinamento para efetuar a predição no teste

O teste deve ocorrer em um conjunto de novos dados (não "vistos" pelo modelo)

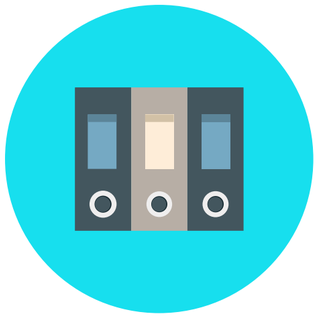
1 Introdução: Termos e técnicas essenciais de avaliação do modelo



Estratificação

- Banco de dados → amostra aleatória (distr. probabilidade)
- Assume-se que é representativa da população real a ser predita
- Subamostragem sem reposição modifica estatísticas da amostra
- Corrigido com o uso da divisão aleatória estratificada

1 Introdução: Termos e técnicas essenciais de avaliação do modelo

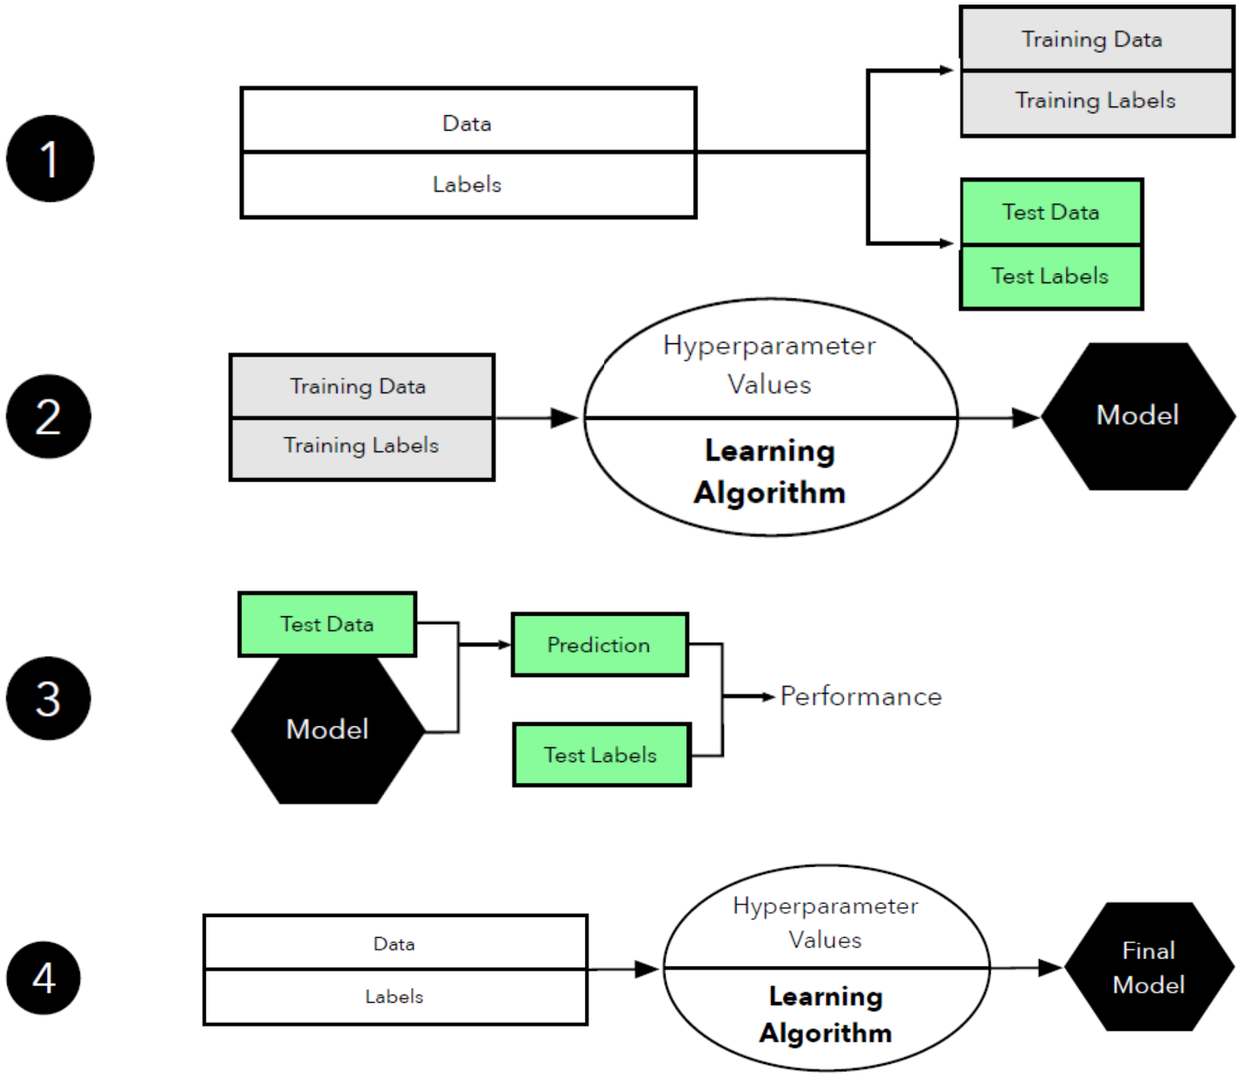


Estratificação

- Nesse caso as classes estarão proporcionalmente representadas nos subconjuntos (treino e teste)
- Serve para manter a proporção nos subconjuntos
- Importante que sempre seja realizada, principalmente quando as classes originais já possuem um alto desequilíbrio

1 Introdução: Termos e técnicas essenciais de avaliação do modelo

Validação Holdout



1º Divide-se os dados
Teste = novos dados (mundo real)
O teste deve ser usado apenas uma vez!

2º Escolhemos os algoritmos
Procedimento para otimizar os hiperparâmetros ou utilizar os padrões.

3º Quão bom é o modelo?
Desempenho é medido pela predição nos dados de teste e comparação com realidade.

4º Resultado da performance no dados não vistos anteriormente.
Assume-se mesma performance do que dados futuros.

1 Introdução: Termos e técnicas essenciais de avaliação do modelo



Viés pessimista

- Se o modelo não atingiu a sua plena capacidade então a estimativa do desempenho obtém um viés pessimista;
- O algoritmo poderia aprender um modelo melhor se tivesse mais dados;
- Solução: ajustar o modelo a todo o banco de dados após estimar o desempenho de generalização;
- Problema: não se pode estimar o desempenho de generalização do modelo reajustado.

2 Incerteza



Visão geral

- Por que queremos avaliar o modelo?

1º Queremos estimar o desempenho preditivo em dados futuros

2º Queremos aumentar o desempenho ajustando o algoritmo e selecionando o melhor modelo

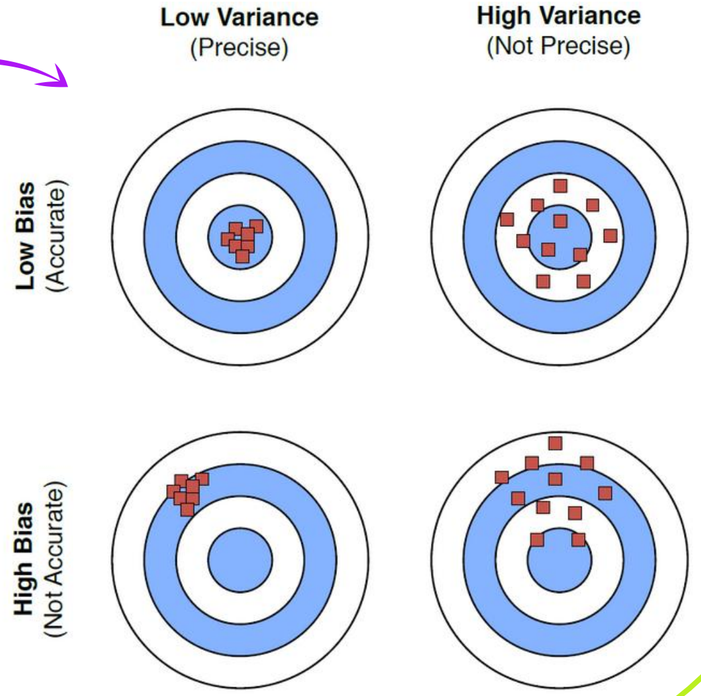
3º Queremos identificar o algoritmo mais adequado para o problema em questão, ou seja, queremos comparar diferentes modelos e algoritmos

2 Incerteza



Reamostragem

- **Relação viés x variância**
- Variância é a mudança do modelo devido a pequenas mudanças nos dados.
- Viés é o erro consistente do modelo.

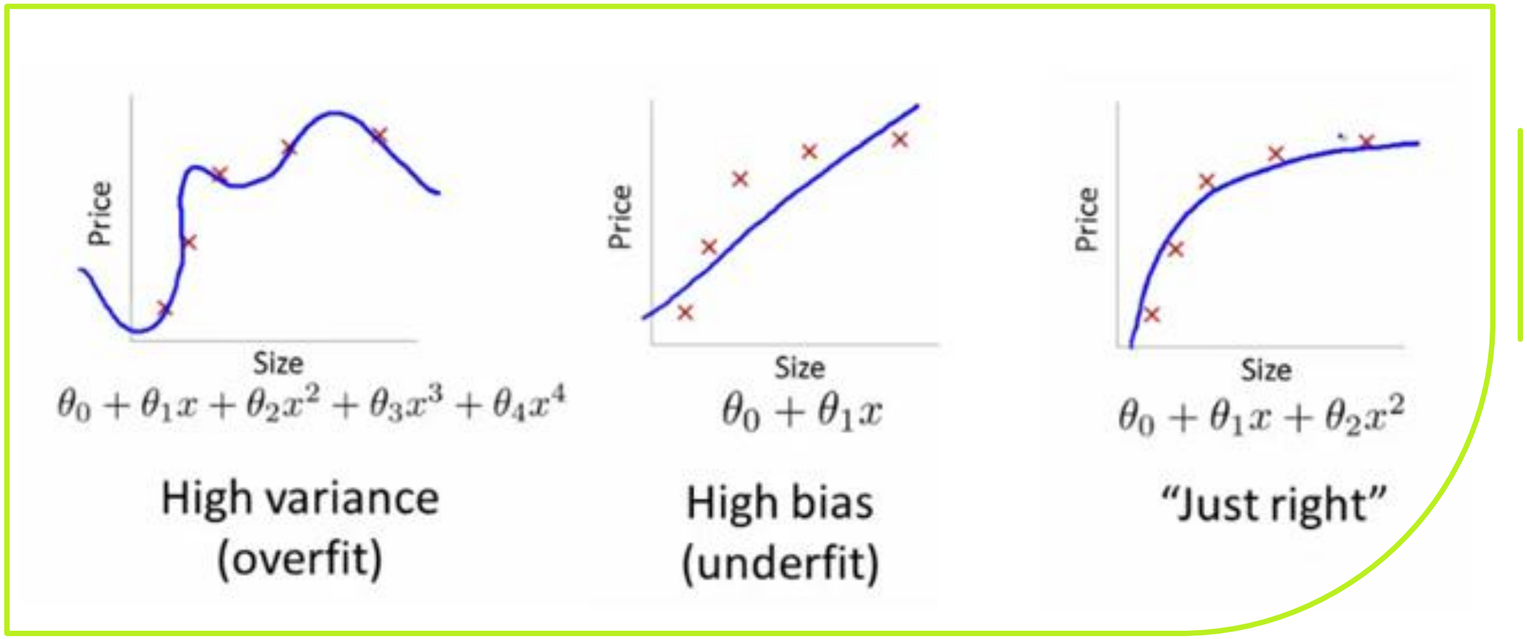


2 Incerteza

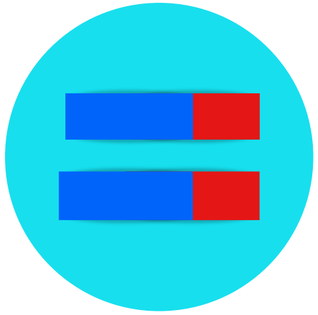


Reamostragem





2 Incerteza



Validação
Holdout repetida

- Estimativa de desempenho mais robusta repetindo o método holdout k vezes com diferentes sementes aleatórias;
- Resultado será o desempenho médio dado por: $\mathrm{ACC}_{avg} = \frac{1}{k}\sum_{j=1}^{k} ACC_j$
- Mostra quão bem o modelo funciona e informa sobre a estabilidade do modelo com diferentes divisões de treino e teste
- Amostragem sem reposição

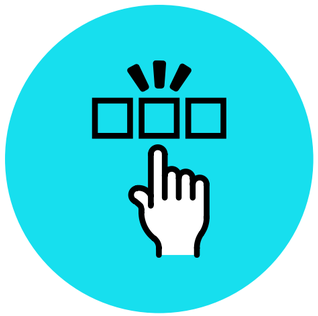
3 Validação cruzada e otimização de hiperparâmetros



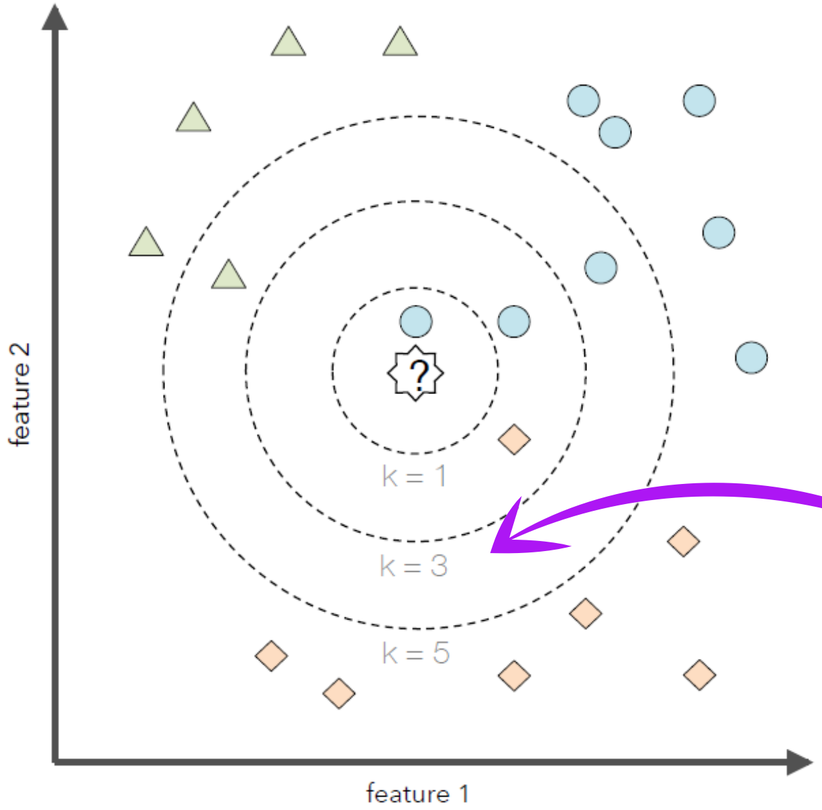
Visão geral

- Quase todos os algoritmos tem configurações a serem especificadas;
- Os "botões de ajuste" são os hiperparâmetros (em geral regularizadores – tentativas de segurar a complexidade);
- Eles ajudam a otimizar o desempenho encontrando o equilíbrio entre o viés e a variância;

3 Validação cruzada e otimização de hiperparâmetros

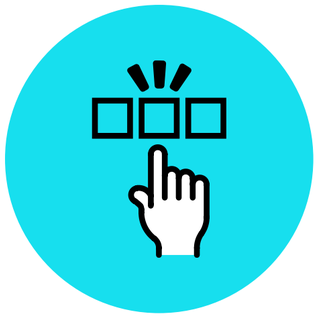


Hiperparâmetros e seleção de modelo



Hiperparâmetro do algoritmo K-nearest neighbors

3 Validação cruzada e otimização de hiperparâmetros



Hiperparâmetros e seleção de modelo

- Alterar valores de hiperparâmetros durante o treinamento resulta em diferentes modelos;
- Seleção do modelo: processo para encontrar o modelo com melhor desempenho, comparando o desempenho de modelos produzidos com diferentes hiperparâmetros;

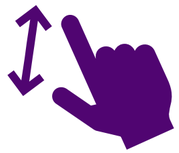
Otimização de Hiperparâmetros

Por que alteramos os hiperparâmetros?

Alteramos as configurações dos hiperparâmetros para obtermos melhores desempenhos na etapa de validação, e **preferencialmente** no teste.

Buscamos uma combinação ótima que maximize a performance do modelo.

Otimização pode ser feita



Manualmente, testando diferentes combinações e avaliando o resultado de cada uma delas



De maneira automatizada, por meio de métodos como random search, grid search e otimização bayesiana

Otimização de Hiperparâmetros

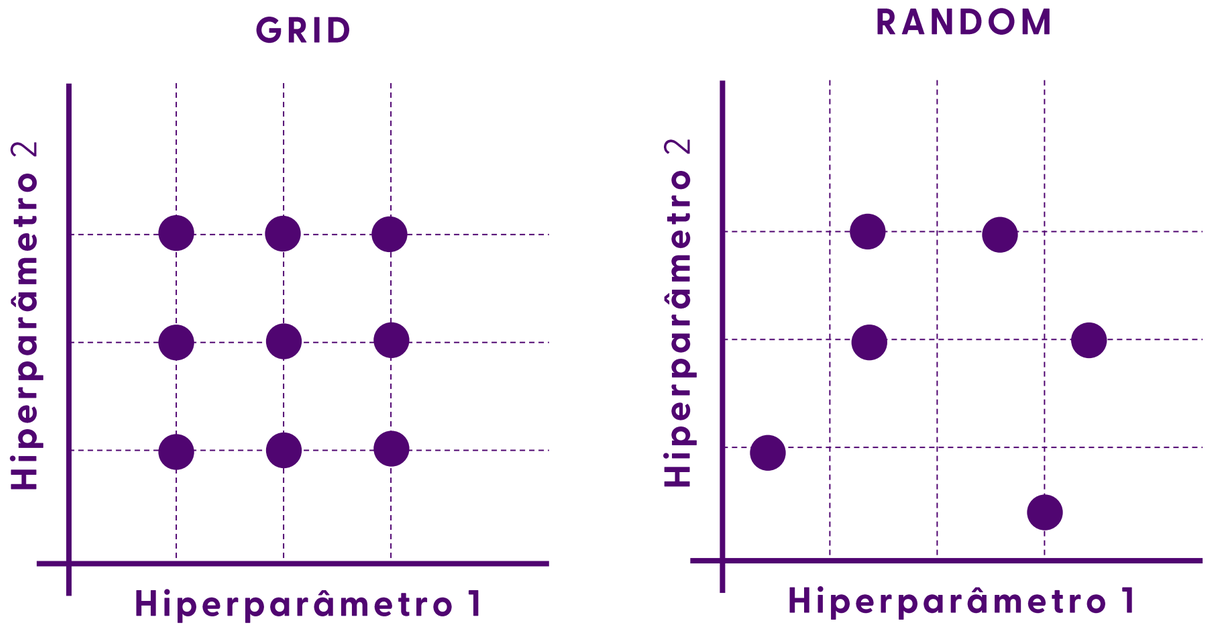
Grid Search

Grid Search: método iterativo e automatizado de otimização que testa que testa todas as combinações dos hiperparâmetros a partir de uma grade de valores.

Passo 1: Definição dos valores dos hiperparâmetros a serem utilizados no processo de otimização.

Passo 2: Algoritmo (GridSearch) combina todos os valores de hiperparâmetros em uma grade de possibilidades e realiza os treinamentos com base nestas combinações

Passo 3: Retorno da combinação de hiperparâmetros de melhor desempenho na etapa de treinamento



Otimização de Hiperparâmetros

Random Search

Random Search: método iterativo e automatizado de otimização que testa aleatoriamente as combinações entre os valores dos hiperparâmetros, de modo a se obter uma combinação ótima para determinado número de iterações.

Passo 1: Definição dos valores dos hiperparâmetros a serem utilizados no processo de otimização
Passo 2: Definição do número de iterações a serem feitas
Passo 3: Algoritmo (RandomSearch) realiza sorteios nos valores de cada hiperparâmetros e cria combinações para treinamento dos dados para cada iteração
Passo 4: Retorno da combinação de hiperparâmetros de melhor desempenho na etapa de treinamento

Otimização de Hiperparâmetros

Otimização Bayesiana

HYPEROPT

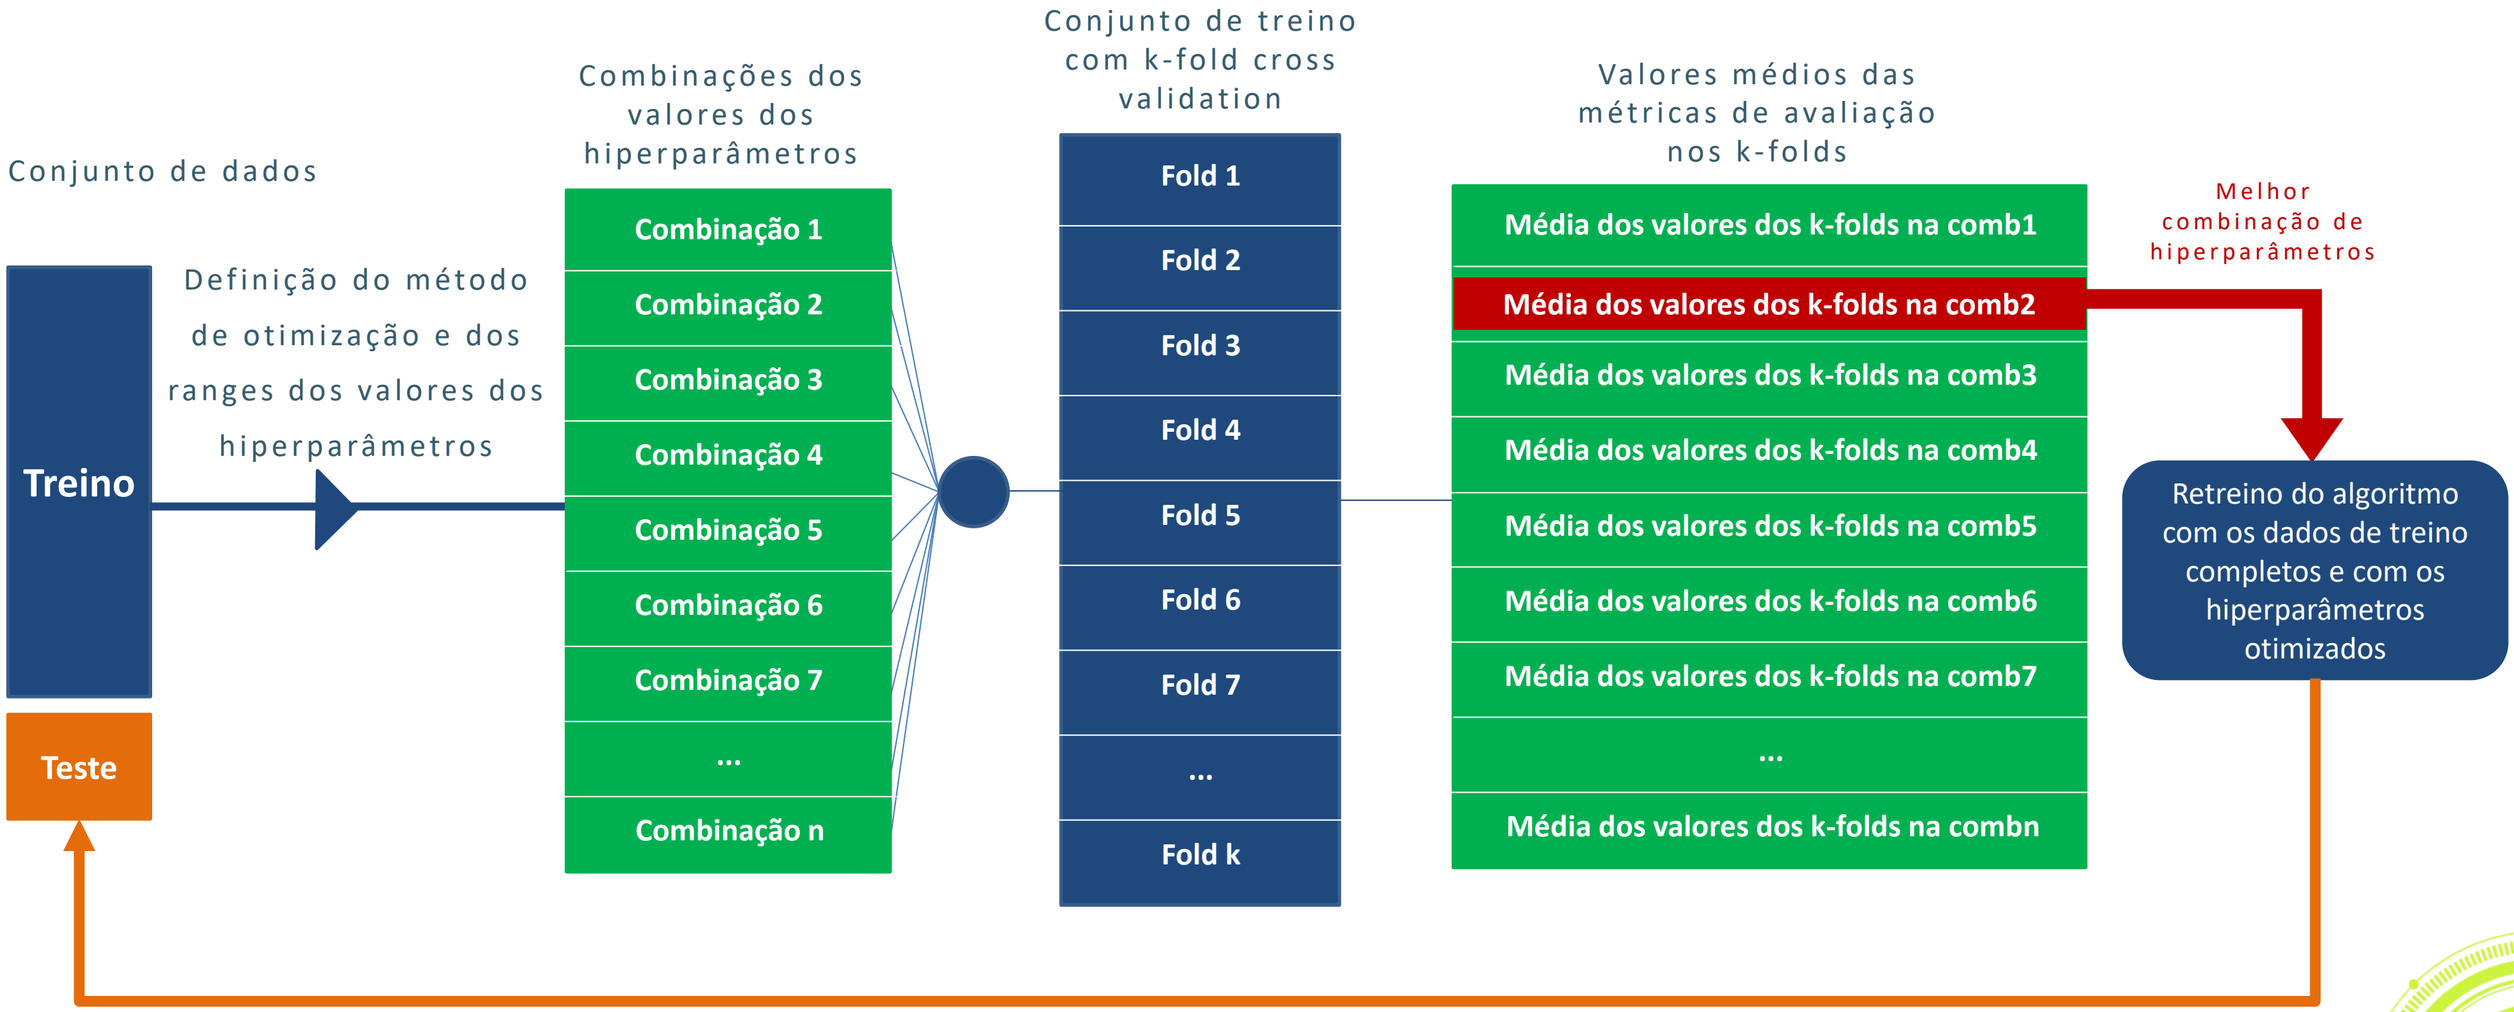
Otimização Bayesiana : considerando que a escolha pela melhor combinação de hiperparâmetros é um problema de otimização, a aplicação de métodos bayesianos busca encontrar a combinação de hiperparâmetros no ponto mínimo ou máximo da função objetivo.

Em geral, para aplicação da otimização de hiperparâmetros por métodos bayesianos, utilizamos o **Hyperopt**, uma biblioteca do Python que trabalha com algoritmos como Tree of Parzen Estimators (TPE), Adaptive Tree of Parzen Estimators (ATPE) e Gaussian Processes (GP).

O HyperOpt divide os resultados das combinações entre “boas” e “ “ruins” e ajusta um gráfico de densidade de probabilidade média. Com isso é identificada a possível melhor combinação de hiperparâmetros

Otimização de Hiperparâmetros

Funcionamento Geral



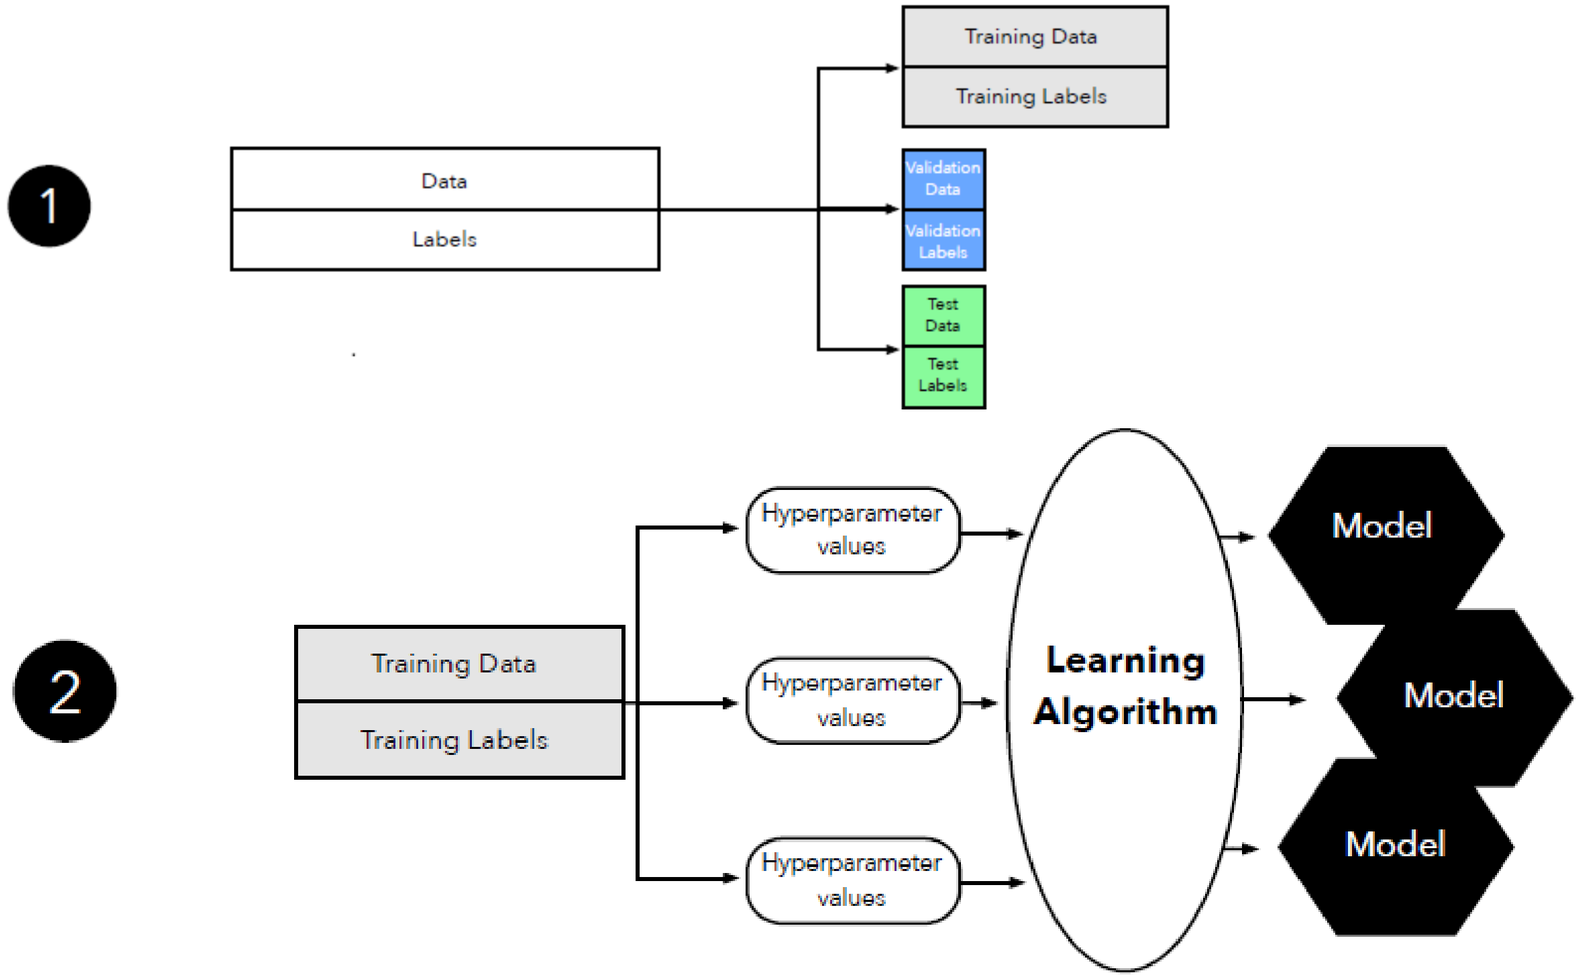
3 Validação cruzada e otimização de hiperparâmetros



As 3 vias do Método Holdout para ajuste de hiperparâmetros

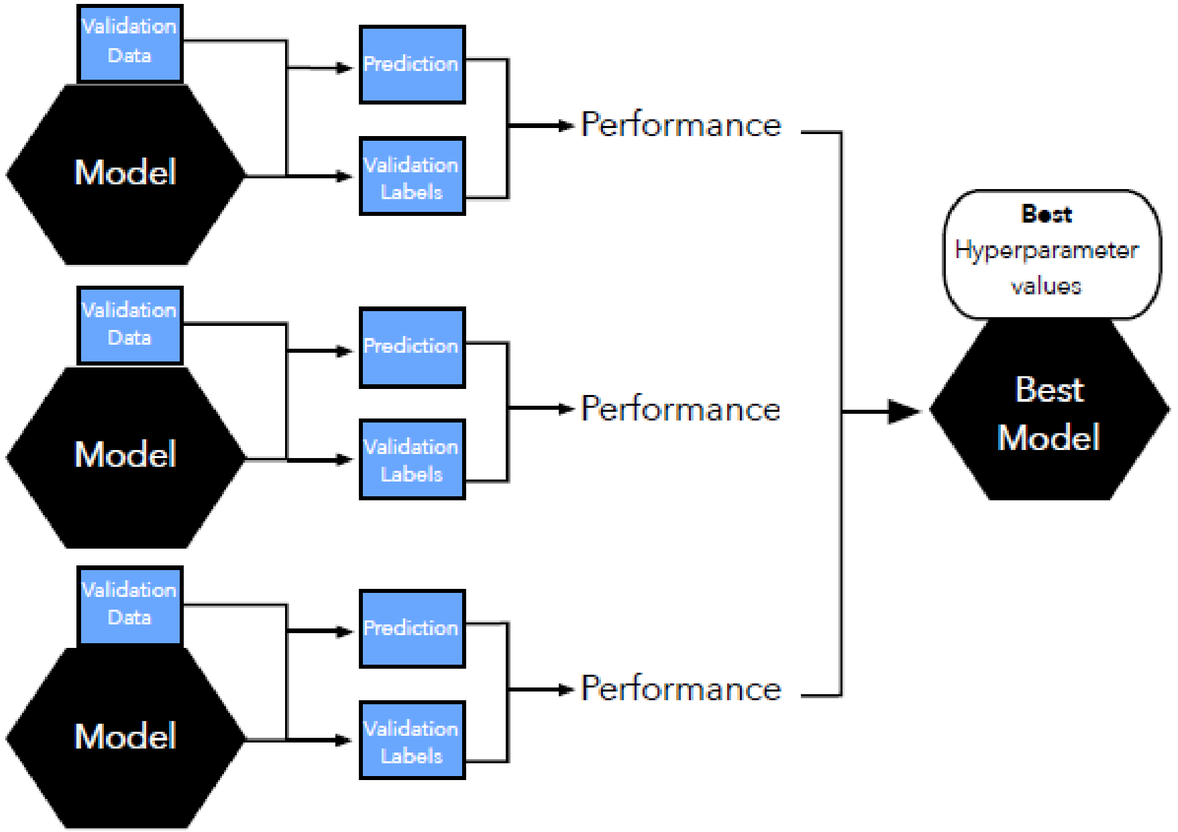
- Como selecionar hiperparâmetros se o teste só pode ser olhado uma única vez?
- Três vias: Treinamento/ Validação / Teste;
- Treinamento e validação para ajuste dos hiperparâmetros e seleção dos modelos;
- Entretanto, quanto menor o conjunto de dados, maior será o viés pessimista do desempenho e a variância.

3 Validação cruzada e otimização de hiperparâmetros



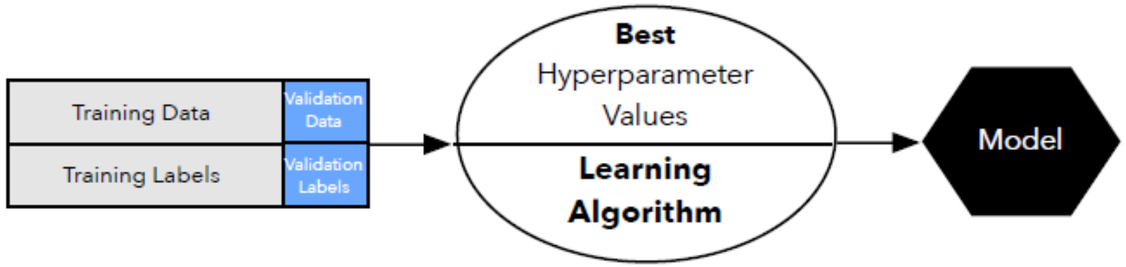
3 Validação cruzada e otimização de hiperparâmetros

3

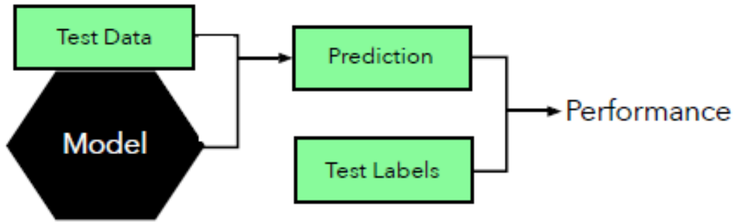


3 Validação cruzada e otimização de hiperparâmetros

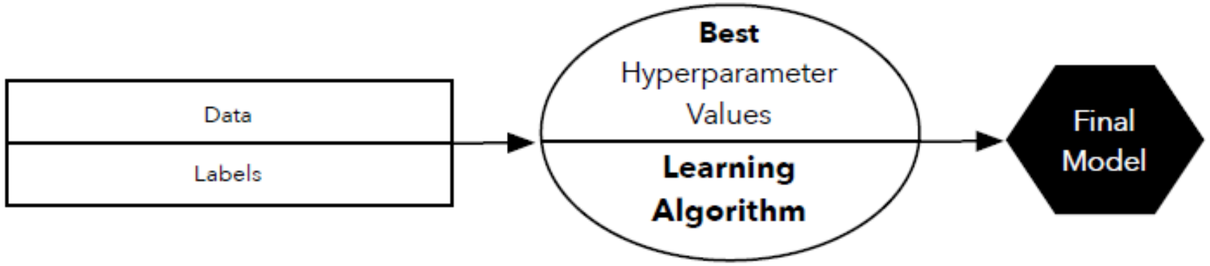
4



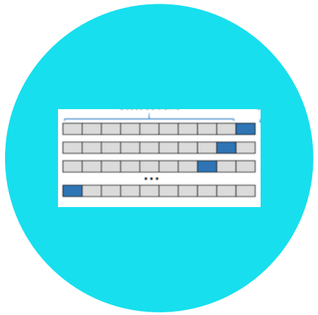
5



6



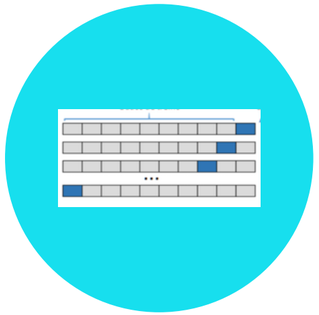
3 Validação cruzada e otimização de hiperparâmetros



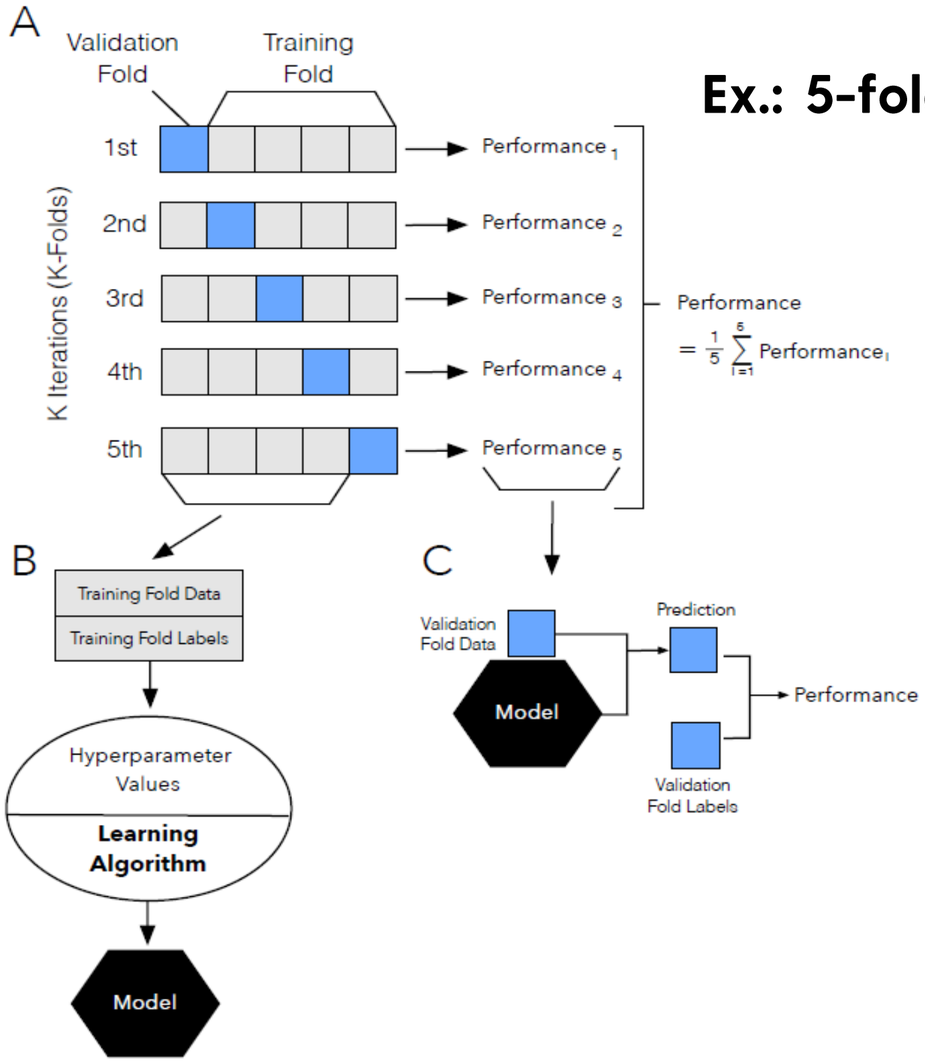
Introdução à validação cruzada k-fold

- Validação cruzada: cruzamento de estágios de treinamento e validação em rodadas sucessivas;
- Cada amostra do conjunto de dados tem a oportunidade de ser testada;
- K-fold: itera-se sobre o conjunto de dados k vezes e a cada rodada uma parte é usada na validação e o restante é mesclado para treinamento;
- Usa todos os dados para treinamento e uma vez para teste.

3 Validação cruzada e otimização de hiperparâmetros



Introdução à validação cruzada k-fold



Ex.: 5-fold

- 5 modelos diferentes;
- Ajustados para conjuntos de treinamento distintos e parcialmente sobrepostos;
- Avaliados em conjuntos de validação não sobrepostos;
- Desempenho: média aritmética dos k desempenhos na validação.

3 Validação cruzada e otimização de hiperparâmetros



Validação cruzada k-fold e o trade-off viés x variância

- Outros autores demonstram que 10-folds otimiza o trade-off entre viés e variância e repetir a validação cruzada melhora performance.
- Quando aumentamos o número de folds em geral:
  - O viés de desempenho diminui;
  - A variância aumenta;
  - O custo computacional aumenta;

3 Validação cruzada e otimização de hiperparâmetros



Seleção de modelo via validação cruzada k-fold

1º Divide-se o conjunto de dados em duas partes (treino e teste);

2º Experimenta-se várias configurações de hiperparâmetros (Bayesian optimization, randomized search, ou grid search). Para cada configuração de hiperparâmetro aplica-se o método de validação cruzada k-fold no treino;

3º Com as melhores configurações de hiperparâmetros resultantes da validação cruzada k-fold, utiliza-se então o conjunto de treinamento completo para o ajuste do modelo;

4º Utiliza-se então o conjunto de teste para avaliar o desempenho.

Obrigado!

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho

@labdaps

alexdiasporto@usp.br

Referência: RASCHKA, Sebastian. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. arXiv:1811.12808v3 [cs.LG] 11 Nov 2020.