

PROFEPI

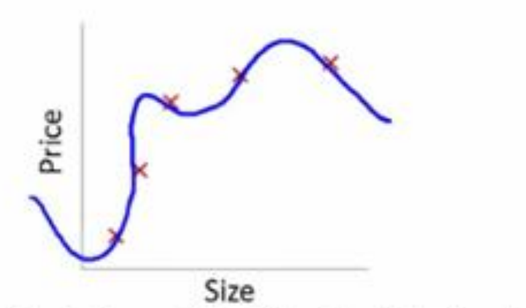
Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

2 Bootstrapping e Incerteza

$$Y = f(x)$$



Reamostragem



Tipos de modelos preditivos

Dois grandes grupos

1. Regressão

- Quando a variável a ser predita é quantitativa:
  - Ex: quantos meses de vida a pessoa tem pela frente, qual será o seu IMC no próximo ano, etc.

A maioria dos algoritmos pode ser utilizada para os dois problemas.

Tipos de modelos preditivos

Dois grandes grupos

2. Classificação

- Quando a variável a ser predita é categórica:
  - Ex: óbito em 5 anos, incidência de doença em 10 anos, diagnóstico de doenças etc

Medição de performance em problemas de regressão

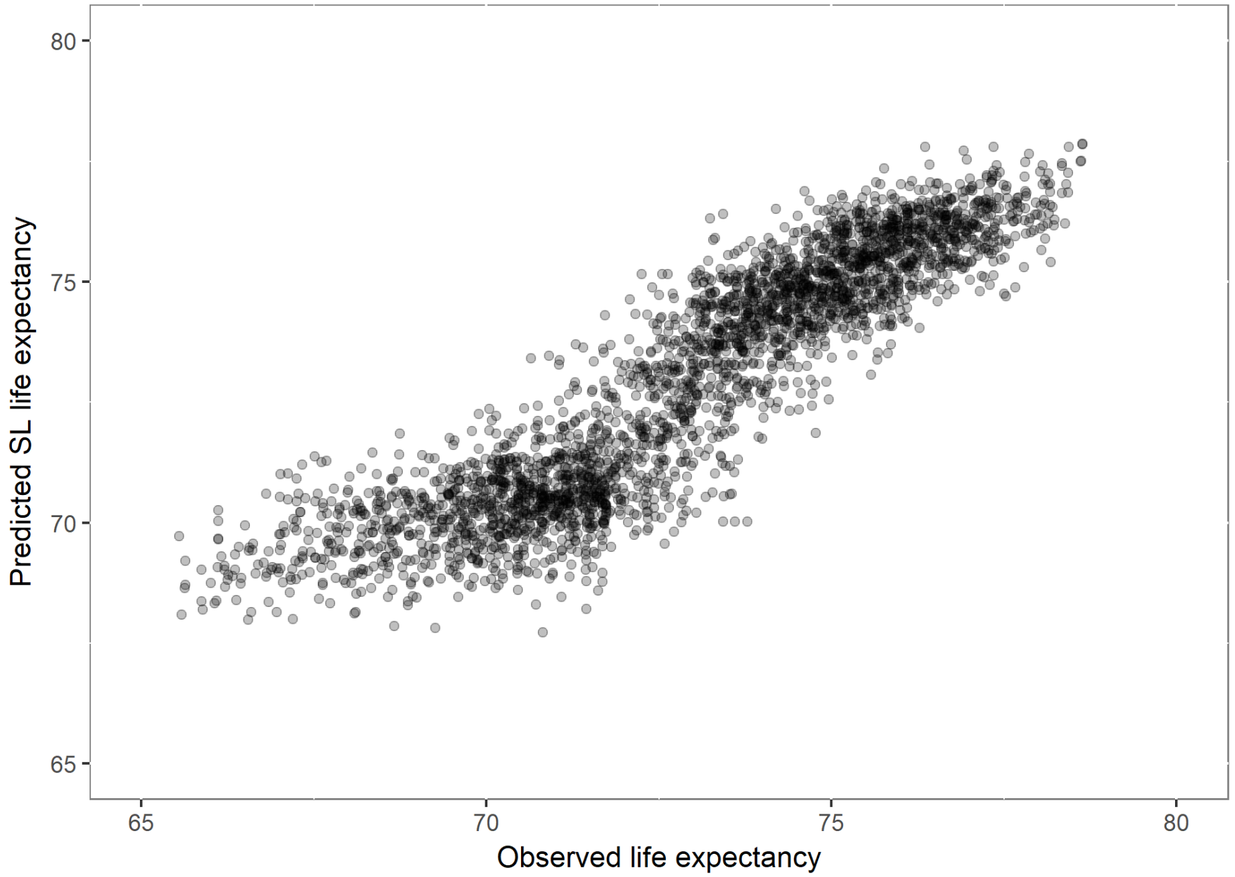
- O mais comum é o uso da **raiz quadrada do erro quadrático médio** (RMSE, em inglês)
  - Subtrair cada valor real do seu valor predito e elevá-lo ao quadrado. Somar todos e dividir pelo número de observações. Tirar a raiz quadrada para retomar o valor à sua escala original.

Medição de performance em problemas de regressão

- O mais comum é o uso da **raiz quadrada do erro quadrático médio** (RMSE, em inglês)
  - Subtrair cada valor real do seu valor predito e elevá-lo ao quadrado. Somar todos e dividir pelo número de observações. Tirar a raiz quadrada para retomar o valor à sua escala original.

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}$$

Forma mais intuitiva de apresentar resultados de regressão: gráfico de dispersão da predição vs. realidade



Medição de performance em problemas de classificação



KEEP
CALM

Medição de performance em problemas de classificação

Modelos de classificação produzem dois resultados: Probabilidade individual e Categoria predita.

Primeira possibilidade

Acurácia

proporção de acertos

Problema: algoritmos são malandros.

- Se uma categoria ocorrer em 99% dos casos, o algoritmo vai predizer que todos os casos estão nessa categoria. Acurácia: 99%.

Porém: isso não nos traz nenhuma informação.

Medição de performance em problemas de classificação

Modelos de classificação produzem dois resultados: Probabilidade individual e Categoria predita.

Primeira possibilidade

Acurácia

proporção de acertos

Ex: Identificar pacientes que possivelmente estão com câncer em amostra que só 1% tem câncer. Algoritmo: “ninguém tem câncer”!
Acurácia = 99%

- Esse algoritmo não nos diz nada.
- Preferimos um algoritmo com menor acurácia.
- Mas que acerte alguns/muitos casos de câncer.

Tour of evaluation metrics for imbalanced classification



Autor: Jason Brownlee
Machine Learning Mastery

Importante:

- Um classificador é tão bom quanto a métrica usada para avaliá-lo.
- Escolher a métrica adequada é um desafio para dados desbalanceados

por duas razões:



1. A maioria das métricas assume uma distribuição balanceada;
2. Geralmente, nem todas as classes (e nem todos os erros de predição) têm a mesma importância quando os dados são desbalanceados.

Desafios das Métricas de Avaliação



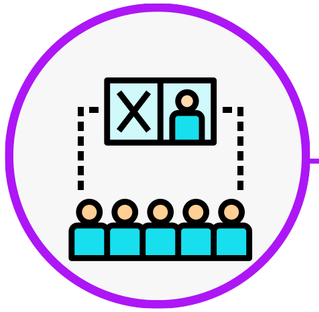
- Quantificam o desempenho de um modelo preditivo
- Orienta a modelagem
- Métricas iniciais: Acurácia e Erro
- Métricas fazem suposições sobre o desafio em questão
- Deve-se escolher a métrica que capture melhor o que é importante no problema de predição definido

CLASSIFICAÇÃO DESBALANCEADA

Classe majoritária
x
Classe minoritária

Métricas padrão podem não ser ideais (ex.: acurácia)

Erros da classe minoritária são mais importantes



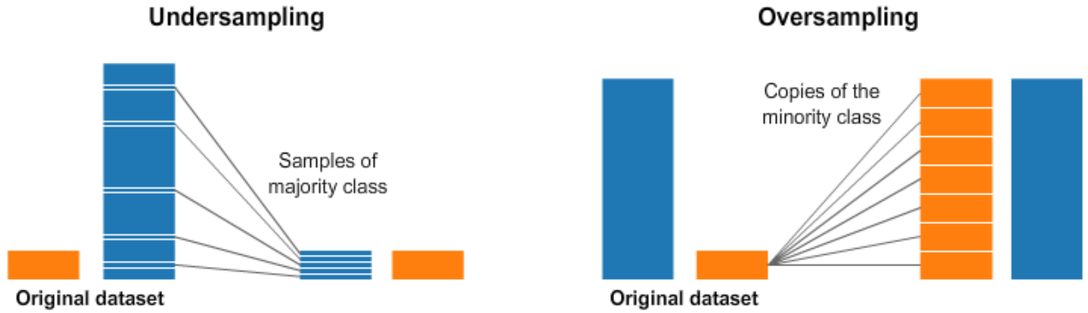
Conclusões enganosas

Classe Minoritária

Onde há menos dados

Técnicas de rebalanceamento

Alguns algoritmos na prática conseguem melhor performance com distribuição igual entre as categorias: desfecho binário com 50% cada.



Soluções:

- Down-sampling: selecionar amostra da classe mais frequente até se igualar à menos frequente.
- Up-sampling: amostragem com reposição da classe menos frequente até se igualar à mais frequente.
- Usar alguma combinação de de down e up-sampling.

Importante: balanceamento não é feito no teste (= mundo real).

To SMOTE, or not to SMOTE?

Yotam Elor
yotame@amazon.com
Amazon
New York, USA

Hadar Averbuch-Elor
hadarelor@cornell.edu
Cornell University
New York, USA

Elor Y e Averbuch-Elor H. To SMOTE, or not to SMOTE? ArXiv :2201.08528. (2022)

- "Algoritmos fracos": MLP, SVM, decision tree, Adaboost and LGBM.
- "Algoritmos fortes": XGBoost e Catboost.
- 73 bancos de dados

"Nossos resultados apoiam a conhecida utilidade do balanceamento para classificadores fracos. No entanto, descobrimos que o equilíbrio não melhora o desempenho da predição para os mais fortes."

Métricas Limiares

Acurácia: $\frac{\text{Predições corretas}}{\text{Total de predições}}$

- Quase sempre inadequada em saúde.
- Aponta a performance na classe majoritária.

Erro: $\frac{\text{Predições incorretas}}{\text{Total de predições}}$

- Erro da acurácia da classificação.

Medição de performance em problemas de classificação

Matriz de confusão

- Análise de concordância visual entre predição e realidade.

Realidade	Predição	
	Câncer	Sem câncer
Câncer	24	36
Sem câncer	10	130

Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:

		Valores Preditos	
		Classe positiva (1)	Classe negativa (0)
Valores reais	Classe positiva (1)	Verdadeiro positivo (TP)	Falso negativo (FN)
	Classe negativa (0)	Falso positivo (FP)	Verdadeiro negativo (TN)

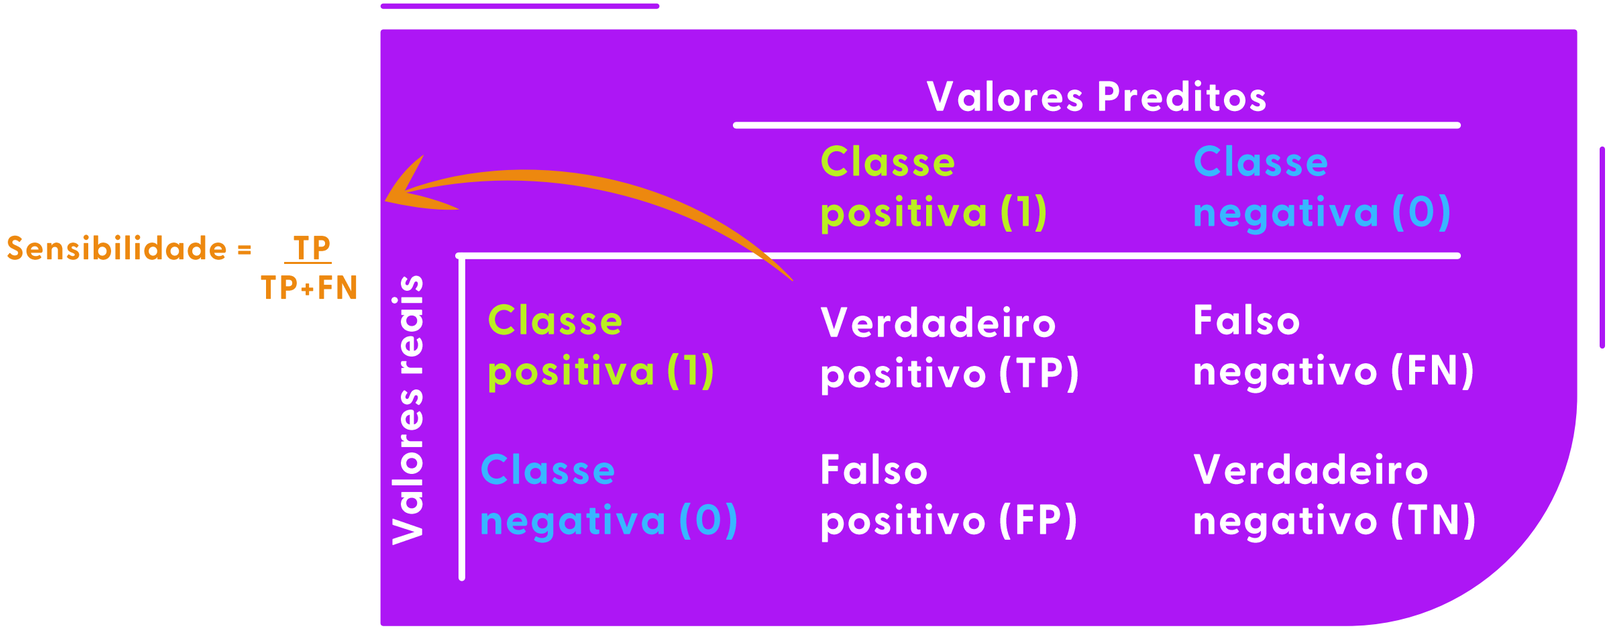
Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:



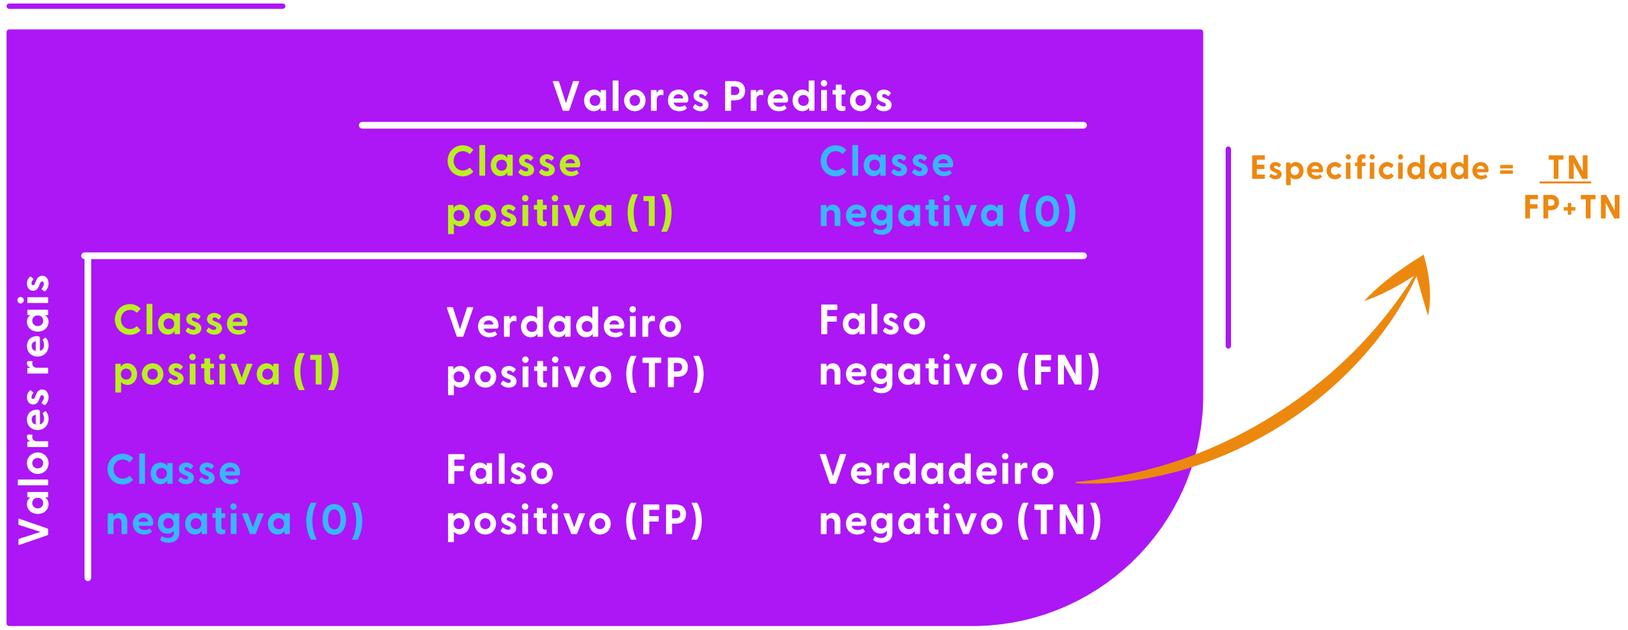
Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:



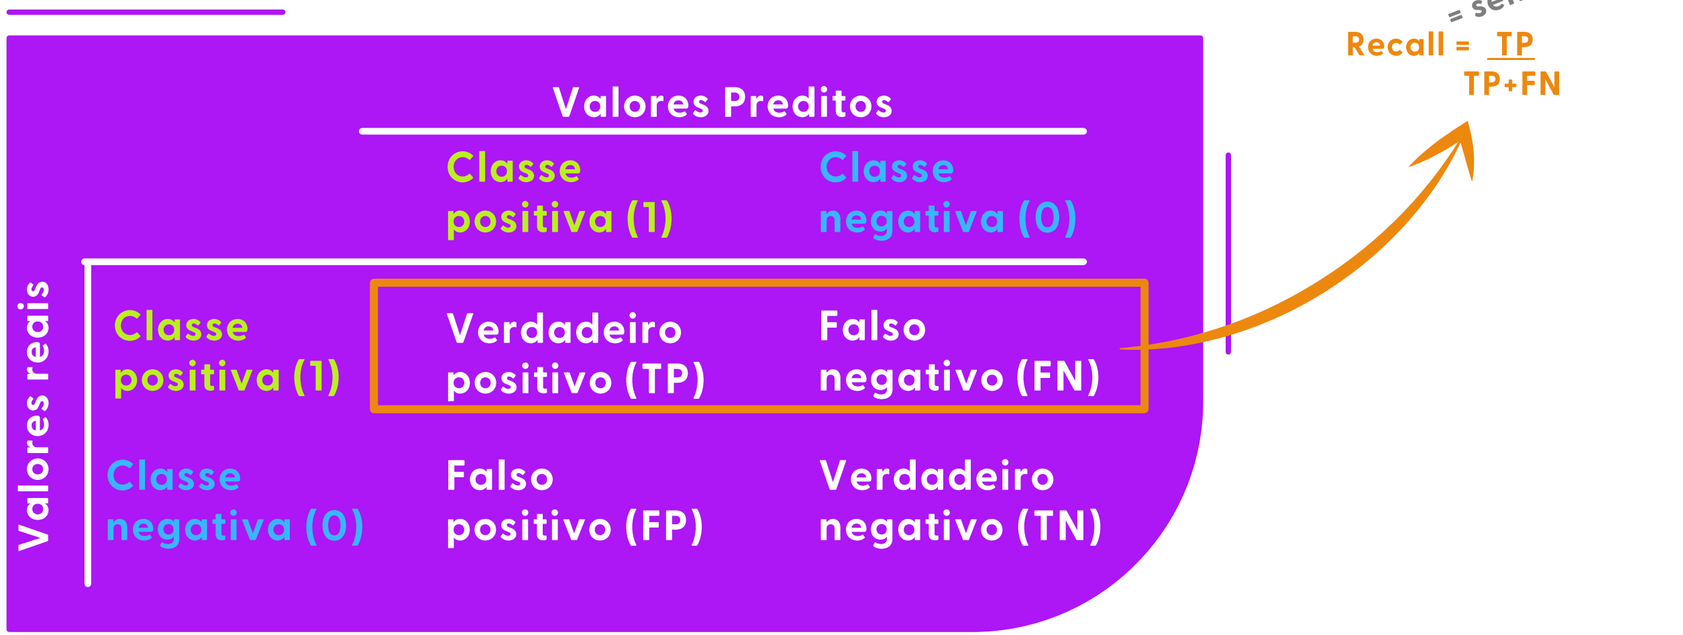
Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:



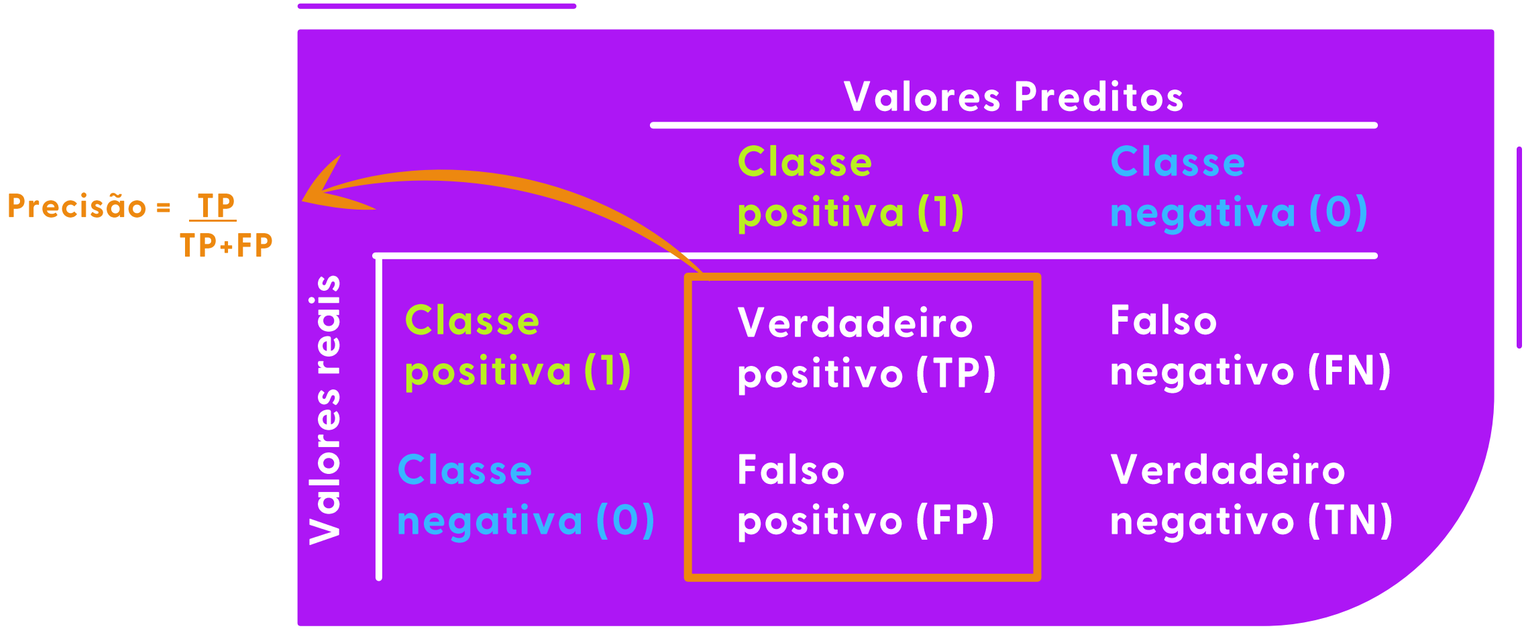
Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:



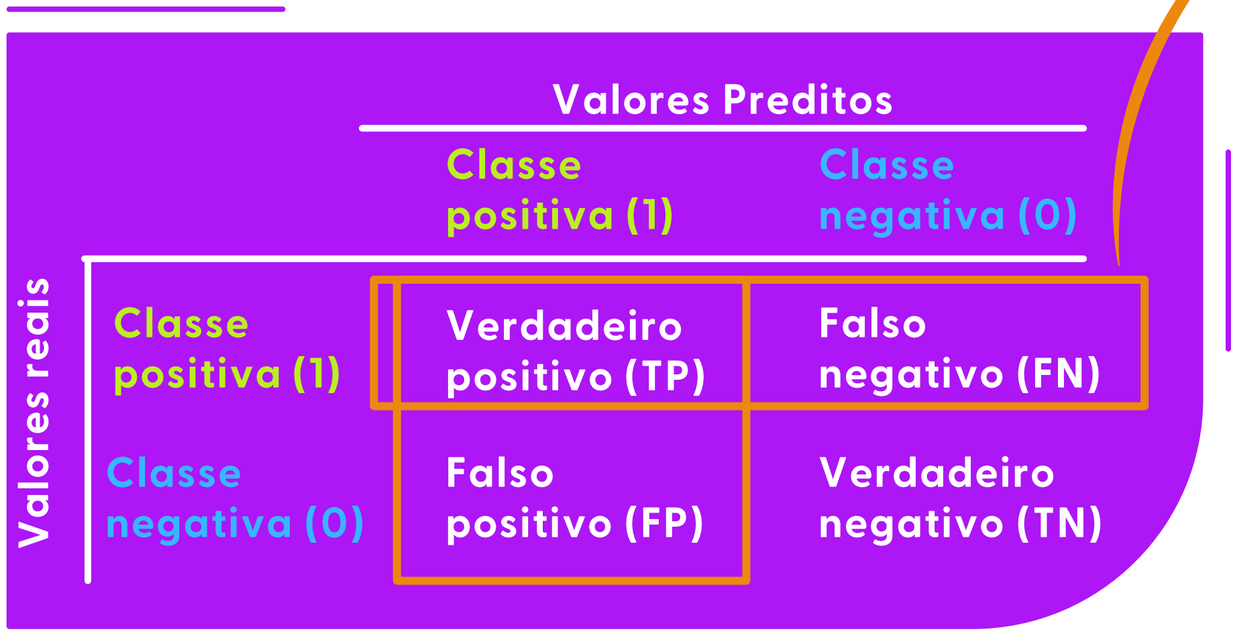
Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:



Precisão e Recall podem ser combinadas em um único escore

$$\text{F-score} = \frac{(2 * \text{Precisão} * \text{Recall})}{(\text{Precisão} + \text{Recall})}$$

Métricas Limiares

- Com dados desbalanceados tipicamente temos:

  Classe majoritária = Resultado negativo = Classe 0

  Classe minoritária = Resultado positivo = Classe 1

- Melhor compreensão por meio da matriz de confusão:

$$\text{Valor Predito Positivo} = \frac{TP}{TP+FP} = \text{Precisão}$$

$$\text{Valor Predito Negativo} = \frac{TN}{TN+FN}$$

		Valores Preditos: Classe positiva (1)	Valores Preditos: Classe negativa (0)
Valores reais	Classe positiva (1)	Verdadeiro positivo (TP)	Falso negativo (FN)
Valores reais	Classe negativa (0)	Falso positivo (FP)	Verdadeiro negativo (TN)

Medição de performance em problemas de classificação

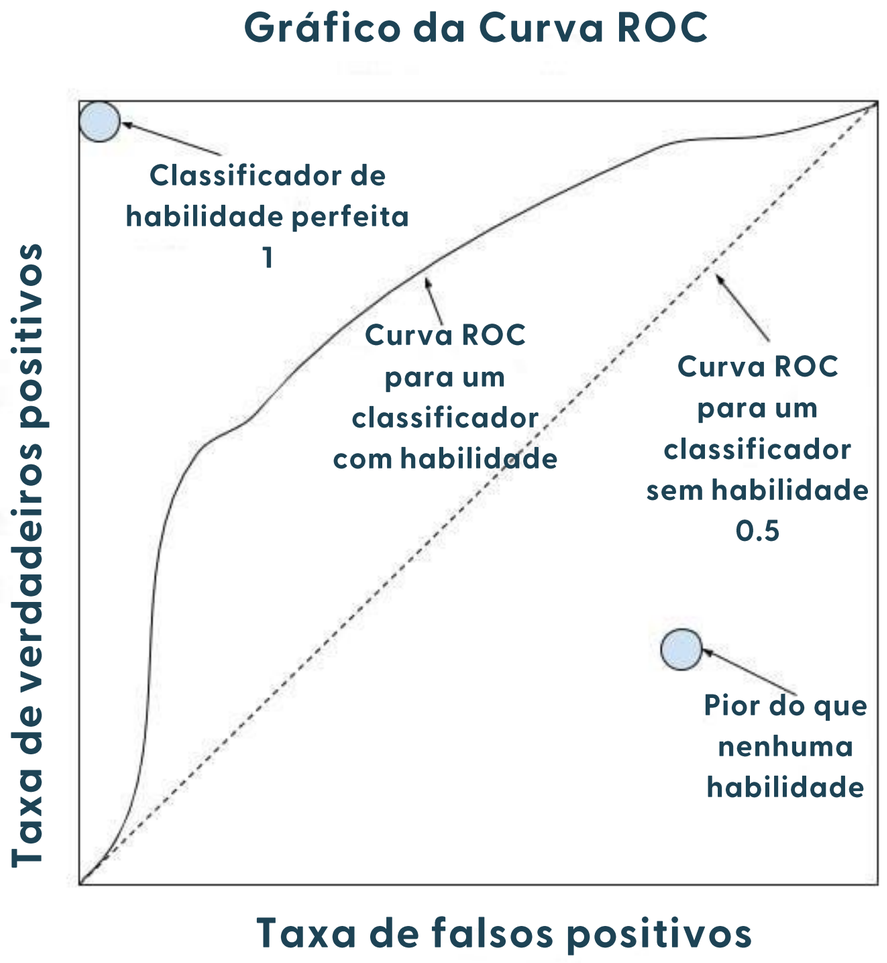
Para alguns desfechos de saúde é fundamental pensar nas diferentes métricas

Por exemplo:

- Teste de HIV/AIDS é importante diminuir falsos negativos (falsos positivos são um problema menor porque o teste será refeito). Sensibilidade.
- Indicação de cuidados paliativos: importante diminuir falsos positivos (não indicar seu início quando o tratamento aumentará a sobrevida). VPP.

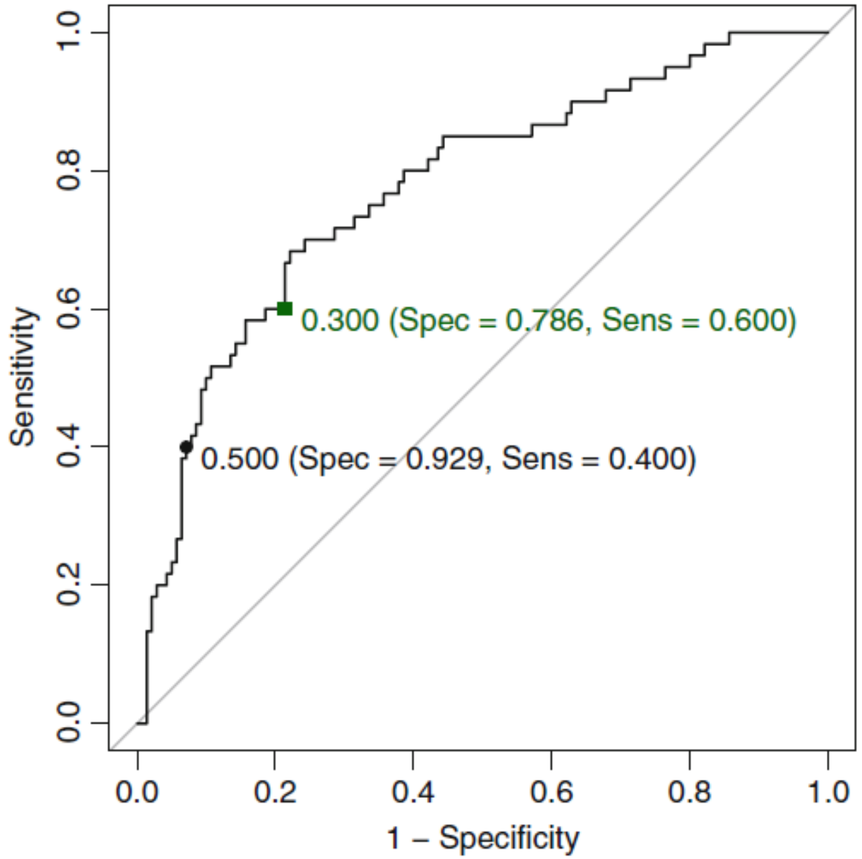
Métricas de Ranking

- Quão bem o modelo discrimina os exemplos
- Predição de uma pontuação ou probabilidade em relação à classe
- Métricas mais utilizadas: Curva ROC (Receptor Operating Characteristic) ou AUC (área sob a curva ROC)
- A curva ROC é um gráfico que resume o comportamento do modelo



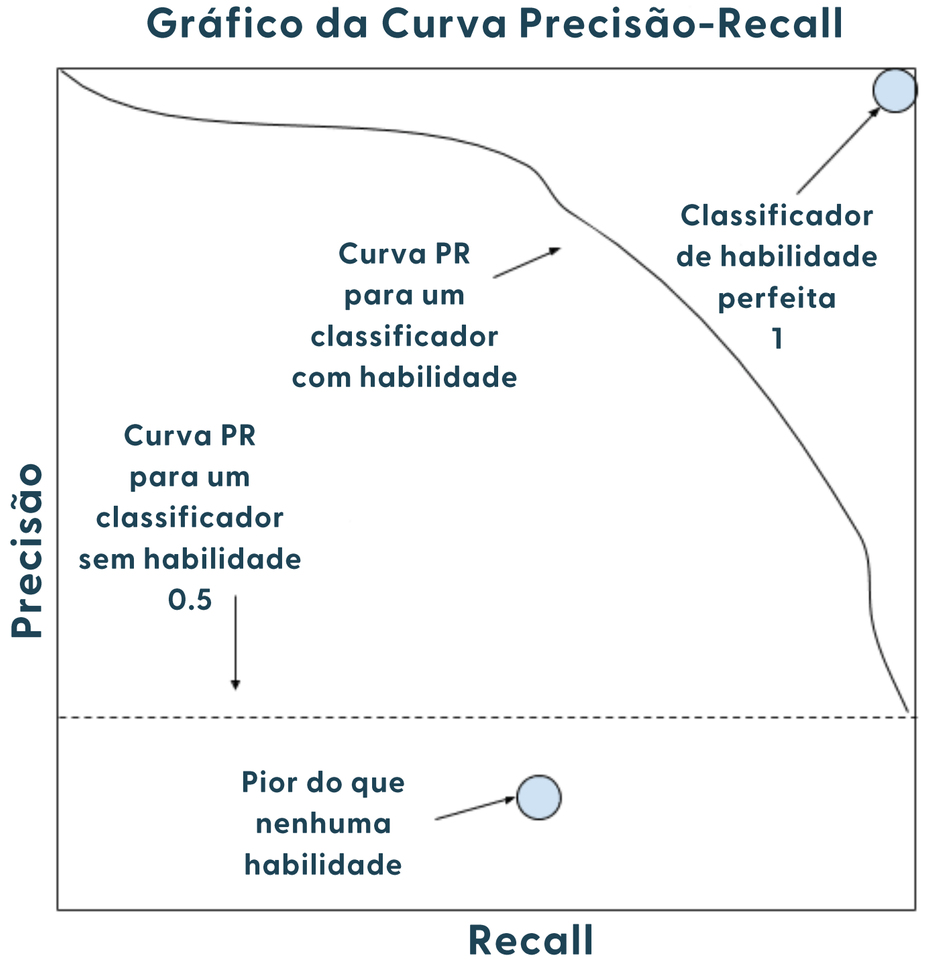
Área abaixo da curva ROC

- Matriz de confusão é baseada em o algoritmo dar > 50% de probabilidade.
- É possível melhorar a sensibilidade diminuindo o threshold?
  - Perfeito: 1,0
  - Ineficiente: 0,5
- Intuição: entre duas pessoas escolhidas aleatoriamente (em que uma tem o desfecho e a outra não), a AUC é a proporção de vezes que a predição será maior para a pessoa que de fato tem o desfecho



Métricas de Ranking

- ROC e AUC podem ser otimistas quando o número de exemplos da classe minoritária é pequeno
- Uma alternativa é o uso da Curva de Precisão-Recall (concentra o desempenho na classe minoritária)
- PR AUC = área sob a curva de precisão-recall



Métricas de Probabilidade

- Medem o desvio da probabilidade real
- São utilizadas quando o interesse está na incerteza que o modelo tem nas predições
- Avaliar um modelo com base nas probabilidades preditas requer que as probabilidades sejam calibradas
- Alguns classificadores são treinados usando uma estrutura probabilística, tendo a probabilidade já calibrada
- Exemplos de classificadores que precisam ser calibrados: SVM e KNN

Métricas de Probabilidade

$$BrierScore = \frac{1}{\mathrm{N}} * \sum_{i=1}^{N} (yhat_i - y_i)^2$$

- Erro quadrático médio entre as prob. reais e as prob. preditas para a classe positiva
- Está focado na classe positiva (minoritária), sendo preferível ao LogLoss que foca em toda a distribuição de probabilidade
- Classificador perfeito → Brier Score = 0.0
- As diferenças de Brier Score para diferentes classificadores podem ser pequenas

$$BrierSkillScore = 1 - \frac{BrierScore}{BrierScoreRef}$$

- Usa um score de referência
- Melhor classificador BSS = 1.0
- Pior classificador BSS = 0.0

Medição de performance em problemas de classificação

Solução para identificar onde a predição está errando.

Gráfico de calibração:

- Separar observações segundo grupos de probabilidade predita.
- Ex: [0 – 10%], ...]90 – 100%]
- Em cada grupo identificar quantos de fato apresentaram o evento.

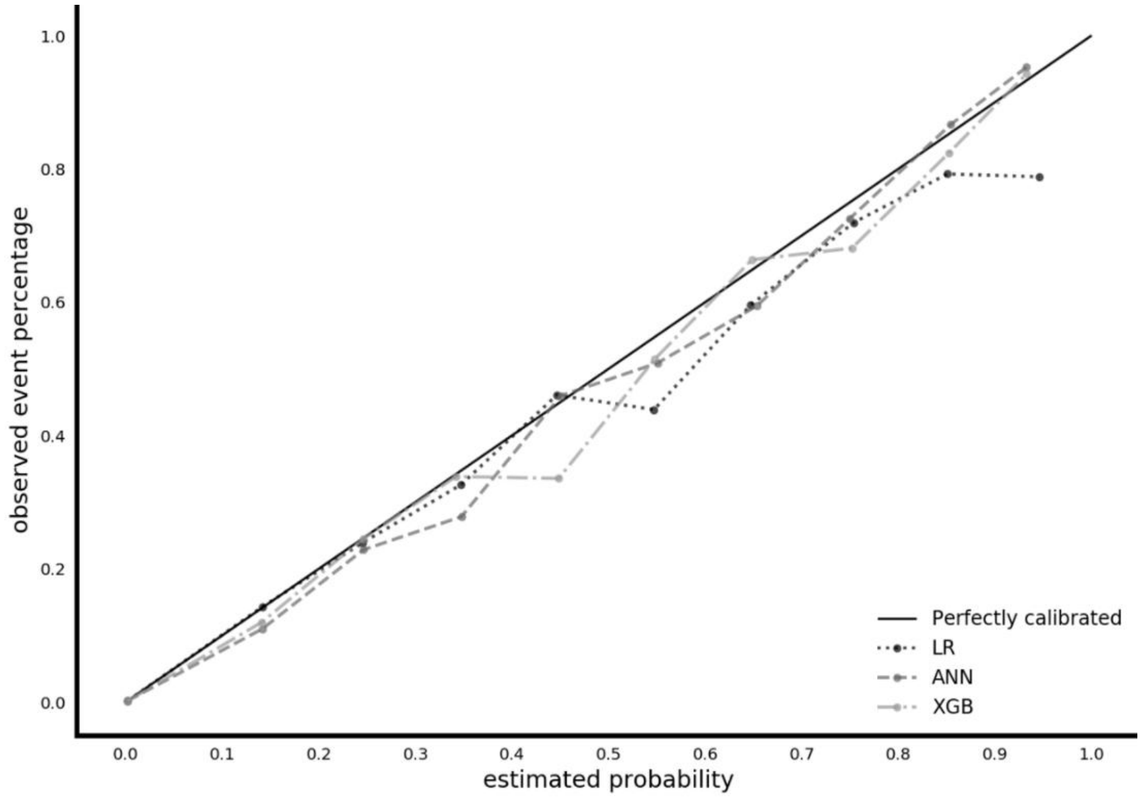
Neonatal mortality prediction with routinely collected data

Batista AFM, Diniz CSG, Bonilha EA, Kawachi I, Chiavegatto Filho ADP.
BMC Pediatrics 2021;21(32)

Bill & Melinda Gates foundation

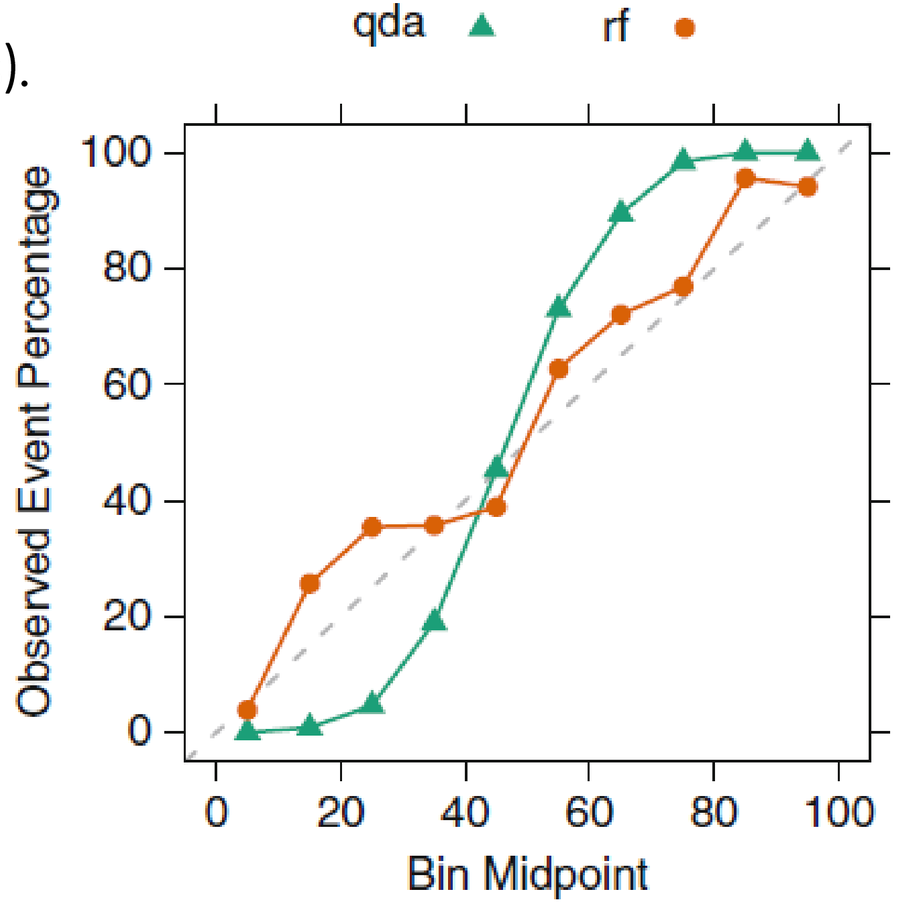
Predizer risco de mortalidade neonatal (até 28 dias) utilizando dados de nascimentos (SINASC) e óbitos (SIM) do município de São Paulo.

- 2012 a 2017 (1.202.843 nascimentos e 7.282 óbitos neonatais).
- Preditores: dados rotineiramente coletados pelo SINASC.
- AUC: 0,97 (mesmo com as 5 variáveis mínimas da OMS: 0,91).
- 5% maior risco: 90% de todos os casos.



Medição de performance em problemas de classificação

Gráfico de calibração (quadratic discriminant analysis e random forests).



Qual o melhor?

Obrigado!

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho

@labdaps

alexdiasporto@usp.br