

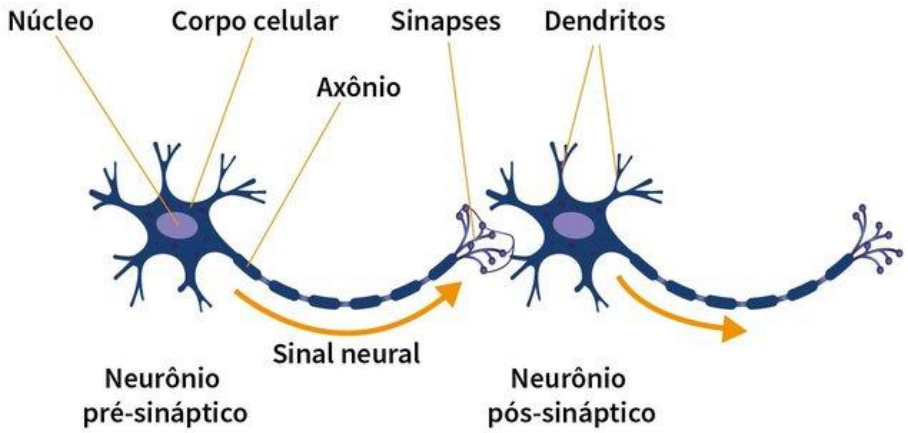
PROFEPI

Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

Algoritmos baseados em redes neurais

Definição

- Inspirados no funcionamento do cérebro humano
- Compostas por camadas de “neurônios” interconectados
- Aprendem padrões complexos a partir dos dados
- Muito utilizados em imagens, texto e dados de saúde

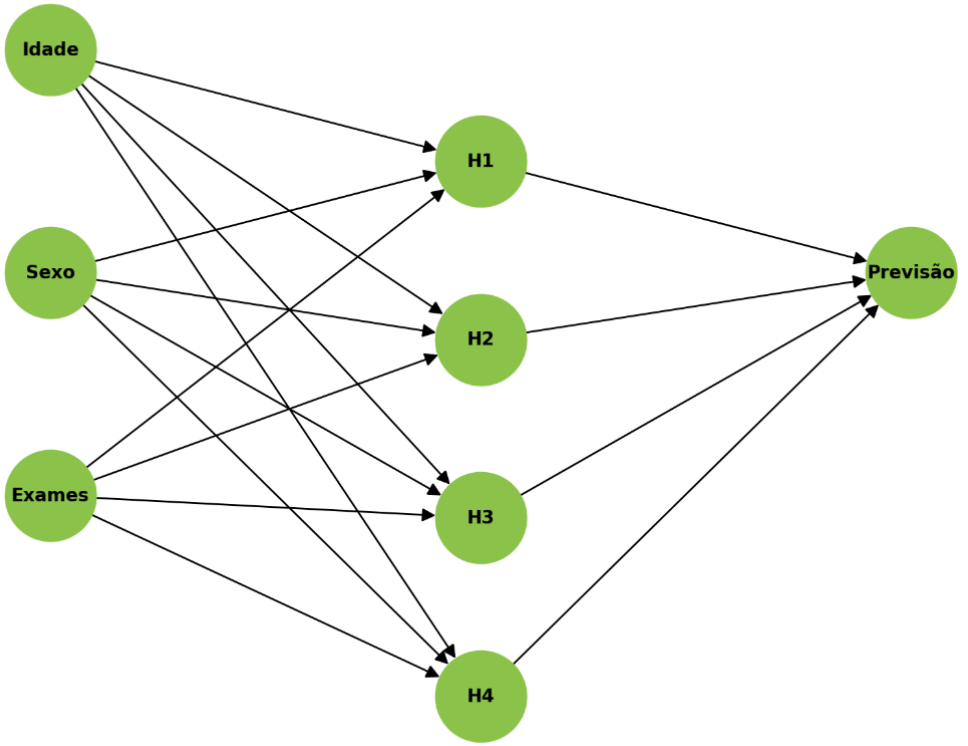


Tipos de algoritmos

	Família	Exemplos	Características
	~~Baseados em árvore~~	~~Árvores de decisão, Random Forest, XGBoost, CatBoost, LightGBM~~	~~Interpretáveis, robustos para dados tabulares, lidam bem com variáveis mistas, ótimos para classificação e regressão.~~
	Baseados em redes neurais	Redes neurais artificiais, Deep Learning, TabPFN	Poderosos para detectar padrões complexos, aplicáveis a diversos tipos de dados, mas menos interpretáveis.

Rede Neural Artificial

Estrutura Básica de uma Rede Neural Artificial



Camada de entrada: recebe os dados (ex.: idade, sexo, resultados de exames)

Camadas ocultas: processam e transformam as informações

Camada de saída: gera a previsão ou classificação

O aprendizado ocorre ajustando esses pesos para reduzir o erro

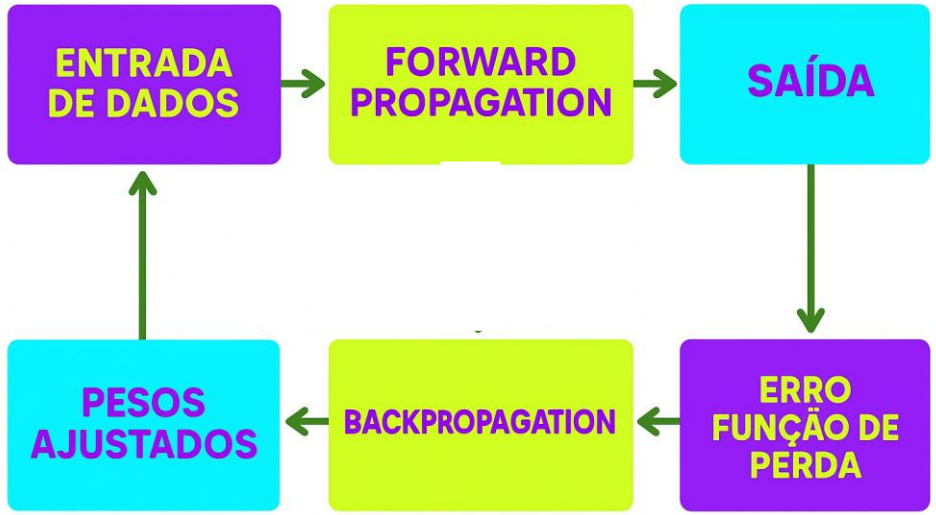
Cada conexão tem um peso que indica a importância da informação!

Rede Neural Artificial

Como uma Rede Neural Aprende?

Propagação para frente (*Forward Propagation*)

- Dados percorrem a rede camada por camada.
- Cada conexão tem um peso e cada neurônio aplica uma função de ativação.



Função de perda

- Mede o erro entre a previsão e o valor real.

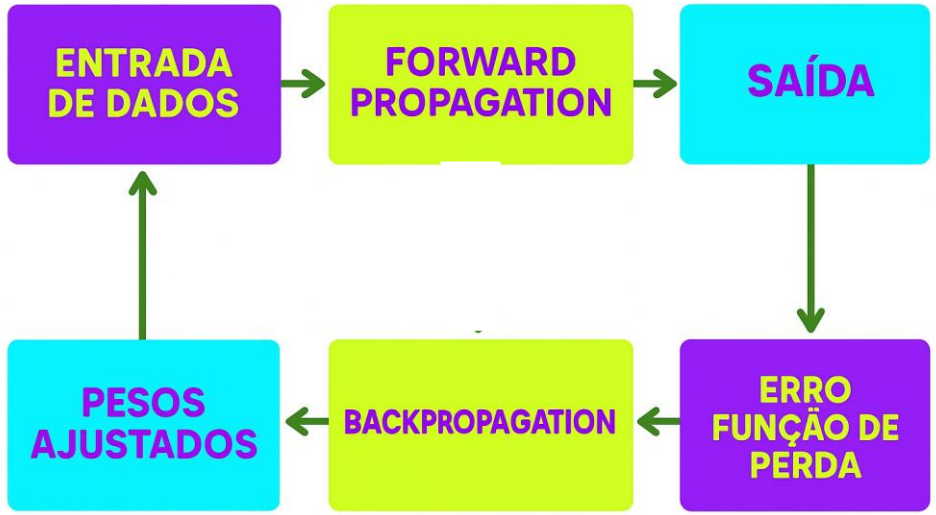
Rede Neural Artificial

Como uma Rede Neural Aprende?

Retropropagação (*Backpropagation*)

- Ajusta os pesos para reduzir o erro.
- Usa métodos como Gradient Descent.

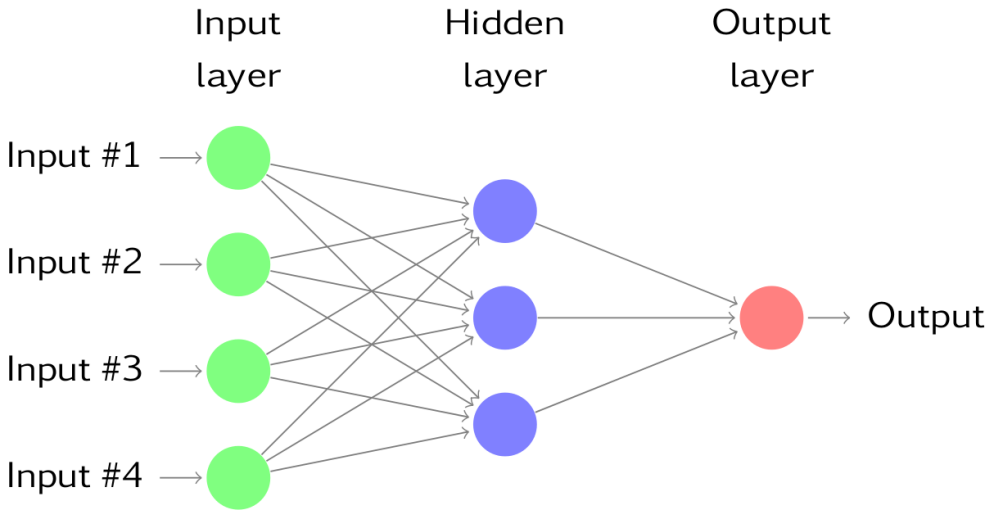
Objetivo: Melhorar a previsão para novos dados.



Rede Neural Artificial

Problemas de regressão: apenas um neurônio de desfecho (*output*), Y_1.

Problemas de classificação: número de neurônios presentes no output são iguais ao número total de categorias a serem preditas.



Rede Neural Artificial

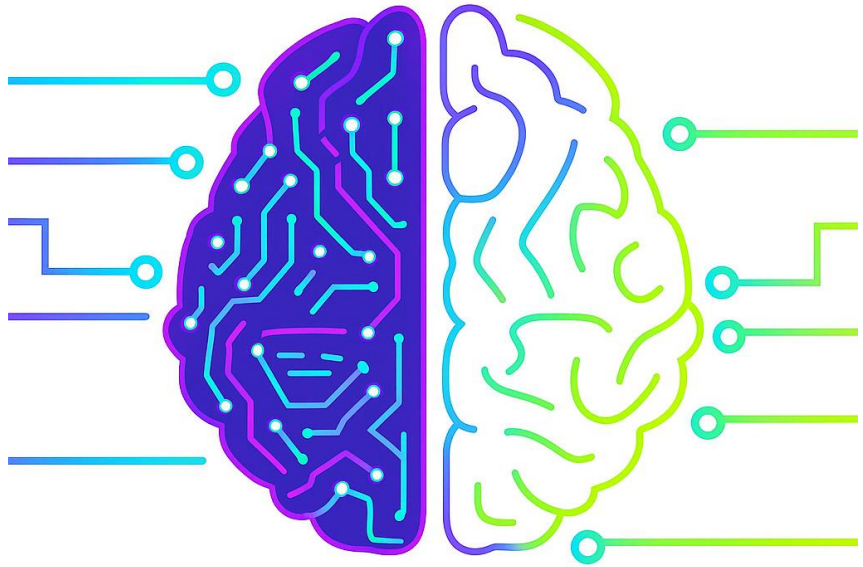
- O modelo com apenas uma camada de unidades latentes (“ocultas”) representa a estrutura mais simples de uma rede neural.

- Outros modelos, em que mais camadas são utilizadas como passo intermediário entre os preditores e a resposta: deep learning.

Rede Neural Artificial

Aplicações na saúde

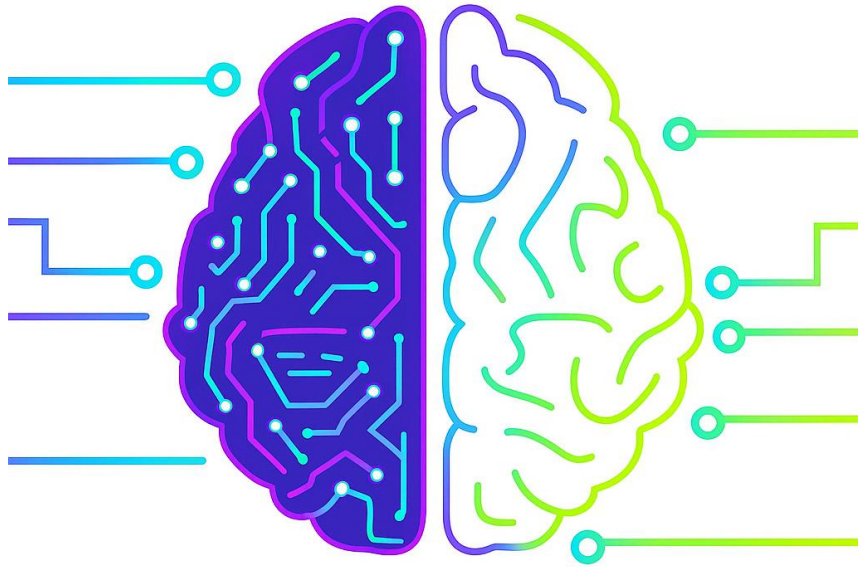
- Diagnóstico por imagem: detecção de tumores em exames de ressonância ou mamografias.
- Previsão de risco: estimar a probabilidade de eventos como infarto ou readmissão hospitalar.



Rede Neural Artificial

Aplicações na saúde

- Processamento de linguagem natural: análise automática de prontuários eletrônicos.
- Predição de epidemias: usando séries temporais para prever surtos de doenças.



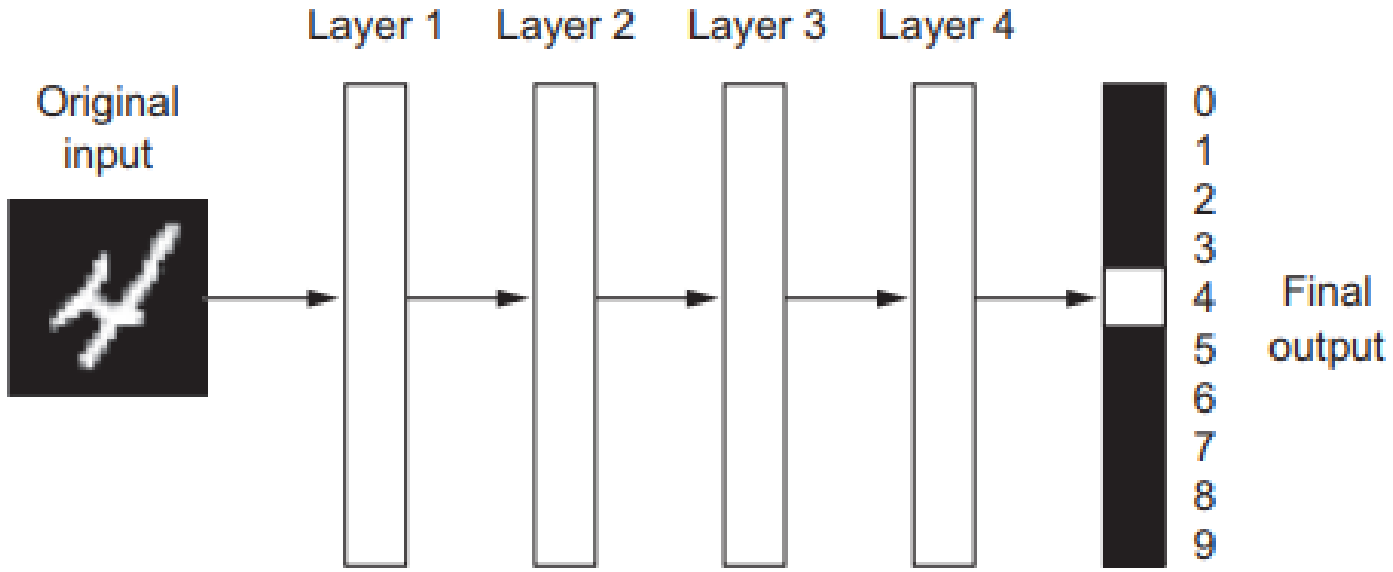
Essas aplicações demonstram como as redes neurais podem lidar tanto com dados tabulares quanto com dados não estruturados, como imagens e textos.

Deep Learning

- Subcampo do *Machine Learning* baseado em Redes Neurais Artificiais com múltiplas camadas ocultas.
- Capaz de aprender representações hierárquicas e extrair automaticamente características complexas dos dados.
- Amplamente utilizado em problemas que envolvem grandes volumes de dados e alta complexidade, como visão computacional, processamento de linguagem natural e análise de sinais.

Deep Learning

Redes neurais profundas (mais do que uma camada oculta), em que cada camada encontra novas representações para os dados.



Deep Learning

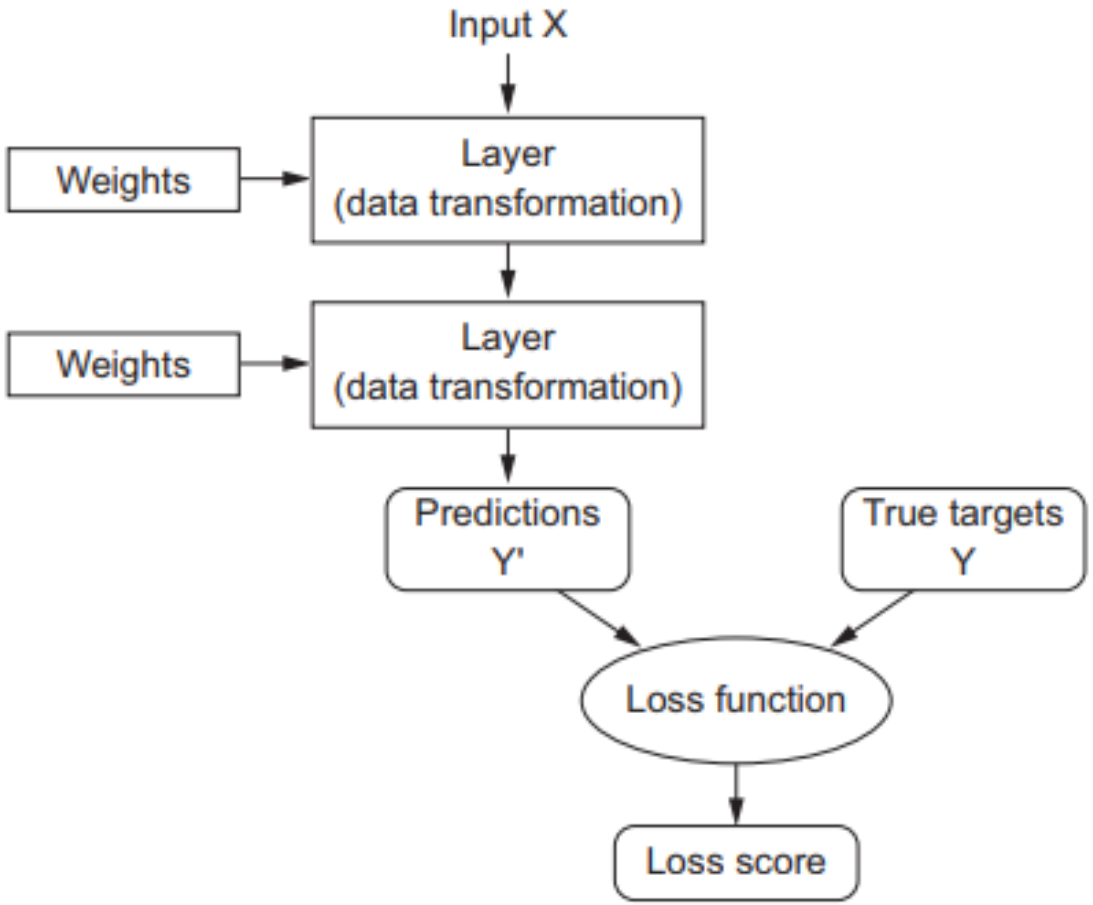
Como medir o erro da predição para calibrar os pesos e vieses?

Por meio da função de perda (ou função objetivo).

- Regressão: erro quadrático médio.
- Classificação: entropia cruzada.

Os pesos e vieses são ajustados de trás para frente por meio de backpropagation.

Deep Learning



Deep Learning

Os pesos e vieses são iniciados randomicamente com valores baixos.

- Nesses casos, o erro da função de perda será alto.
- Mas os erros são corrigidos pelo ajustes dos pesos de trás para frente.
- O processo é repetido diversas vezes com diferentes lotes (menos custoso computacionalmente que todos os dados) de observações sorteadas.

Deep Learning

Como corrigir os erros por meio do ajuste dos pesos?

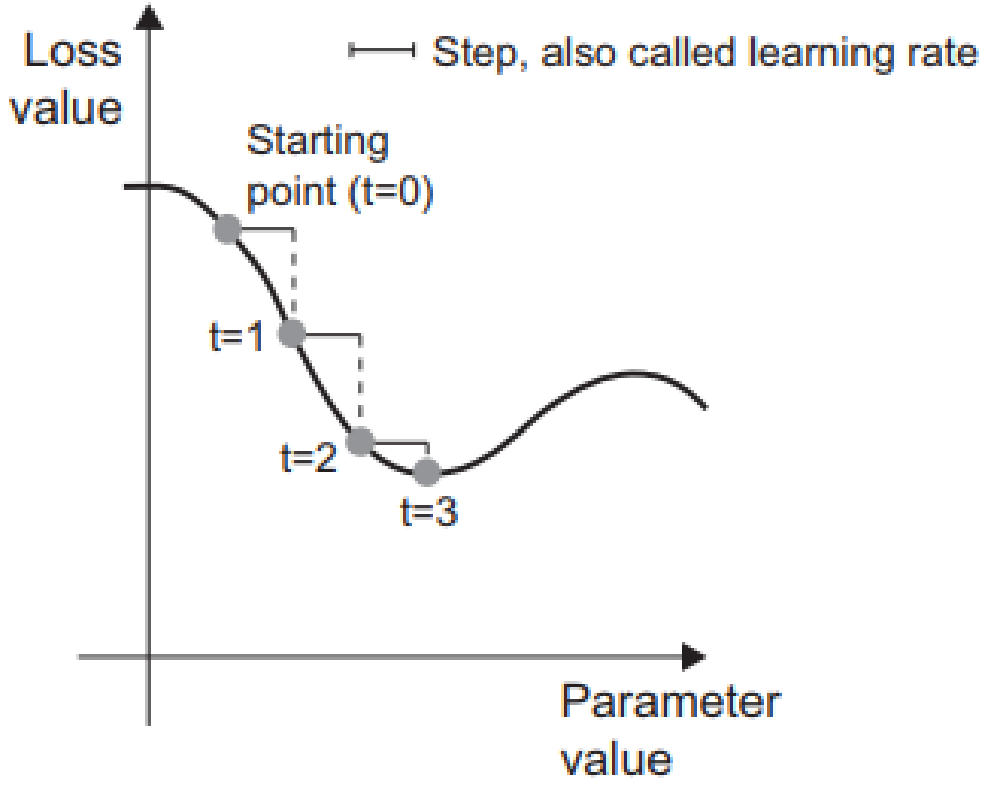
Solução simples: deixar todos os pesos fixos menos um.

Porém seria ineficiente, já que um lote de dados teria de passar pelo algoritmo para cada peso atualizado.

Solução: usar gradient descent.

- Calcular o gradiente da função de perda em relação aos pesos e mover o valor dos pesos na direção oposta do gradiente, diminuindo as perdas.

Mini-batch Stochastic Gradient Descent



Deep Learning

Mini-batch stochastic gradient descent.

Sorteio de lotes que vão sendo utilizados para calibrar os pesos.

Figura anterior foi para um só peso.

É possível realizar o mesmo em várias dimensões, uma para cada peso a ser estimado.

Função de ativação

- Sem uma função de ativação, os neurônios são apenas a soma dos pesos multiplicados pelos valores dos neurônios anteriores.

- Isso limita a rede a aprender transformações lineares.

- É preciso uma função de ativação não-linear: mais comum é relu (elimina dados negativos e permite ganhos de velocidade de computação).

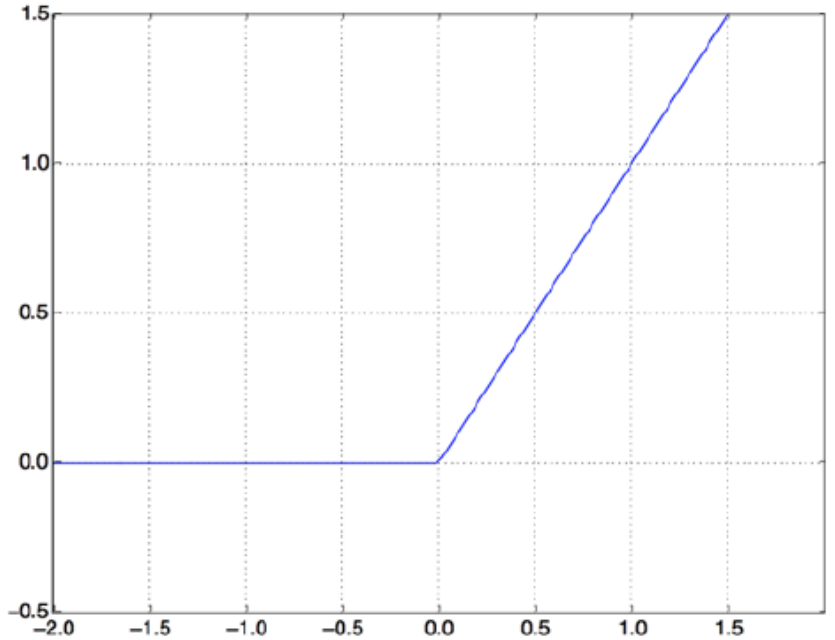
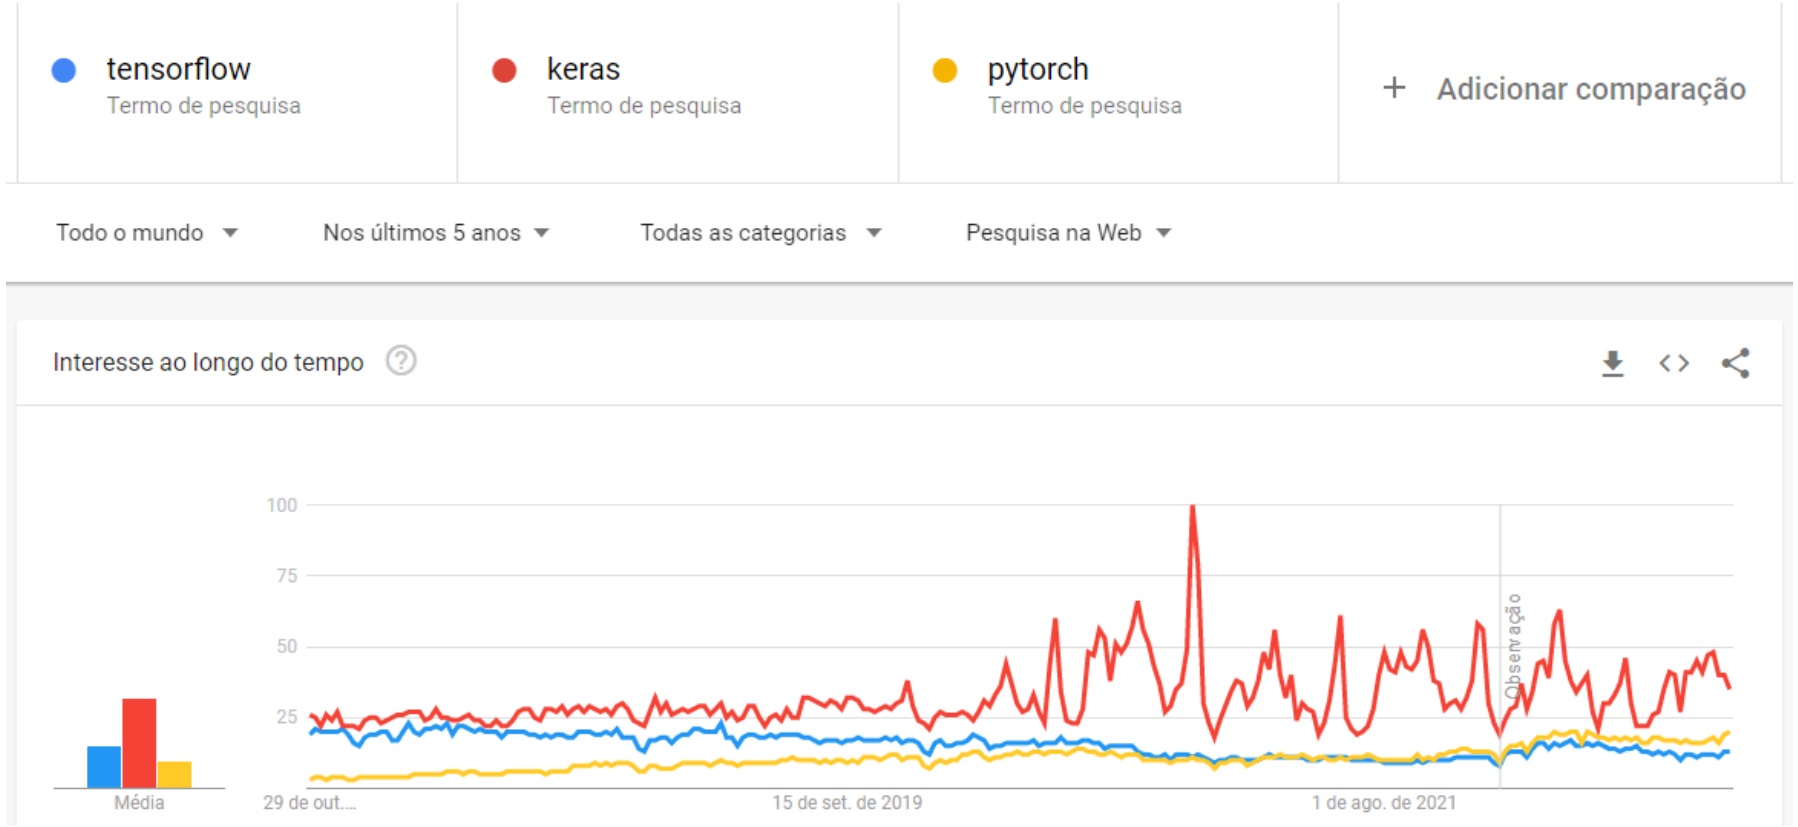
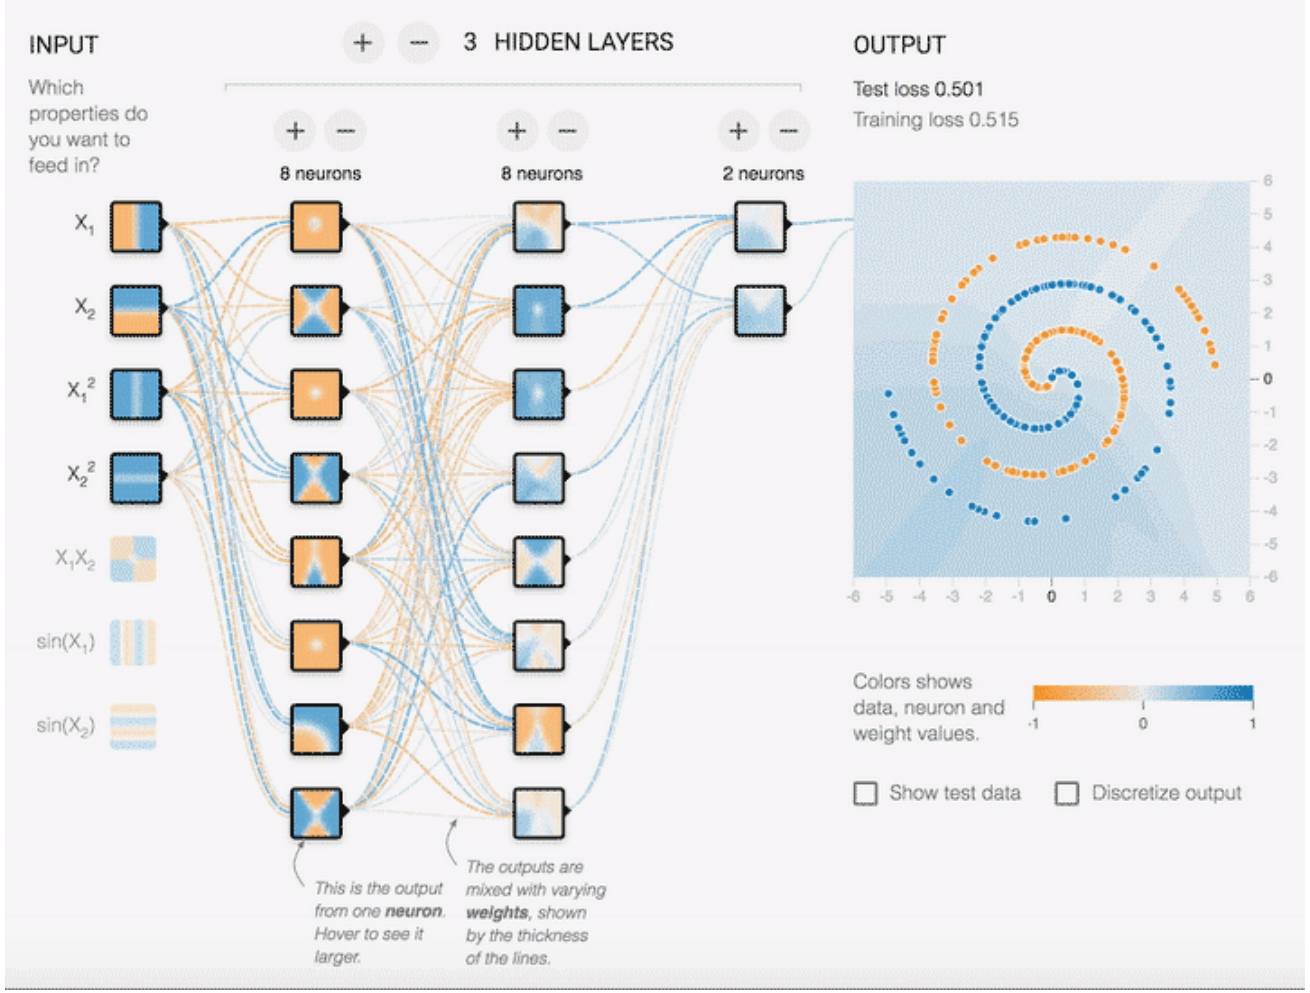


Figure 3.4 The rectified linear unit function

- **Keras** é uma biblioteca relativamente simples e com linguagem amigável para rodar modelos de deep learning.
- Bastante prática, só não é recomendada se você quiser desenvolver novos modelos ainda não existentes.
- Utiliza tensorflow.





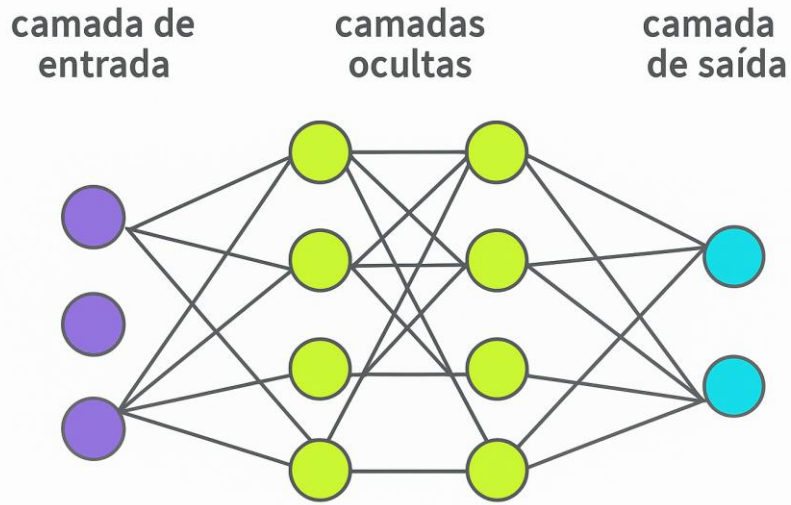
Dica: Playground Tensorflow
https://playground.tensorflow.org

Deep Learning

- **Overfitting**: quando o modelo aprende muito bem o conjunto de treino, mas não generaliza para novos dados.

- Impacto na saúde: previsões imprecisas em dados de pacientes não vistos.

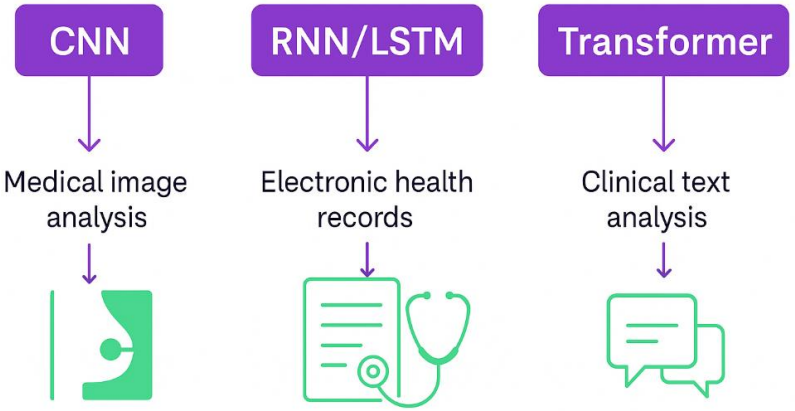
- Soluções comuns:
  - *Dropout* (desligar aleatoriamente neurônios durante o treino)
  - Regularização L2 (*weight decay*)
  - Aumento de dados (*data augmentation*)



Deep Learning

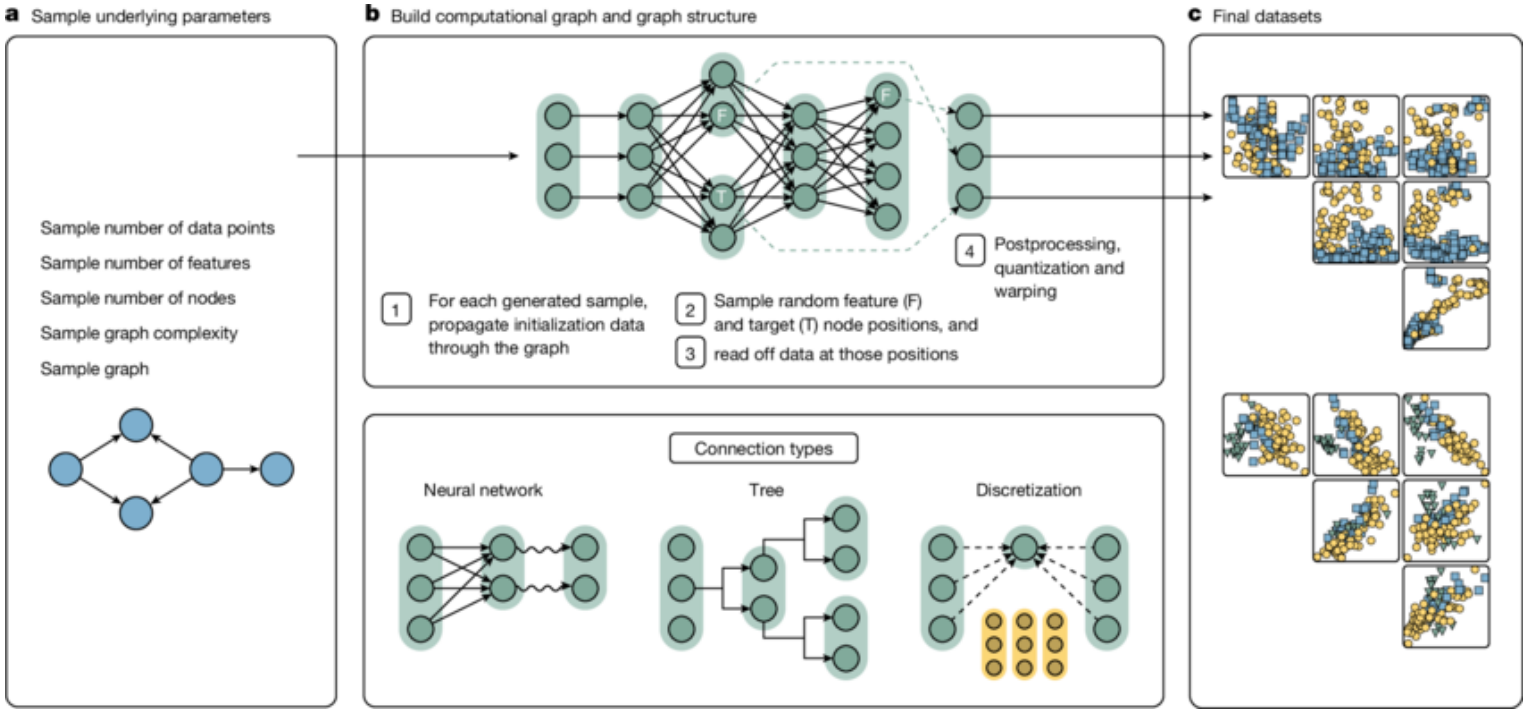
Arquiteturas Populares e Aplicações em Saúde

- **CNNs (Redes Neurais Convolucionais.)** → imagens médicas, detecção de lesões, classificação de exames.
- **RNNs / LSTMs (Rede Neural Recorrente)** → análise de séries temporais de sinais vitais, evolução clínica de pacientes.
- **Transformers** → processamento de linguagem natural para análise de prontuários e anotações médicas



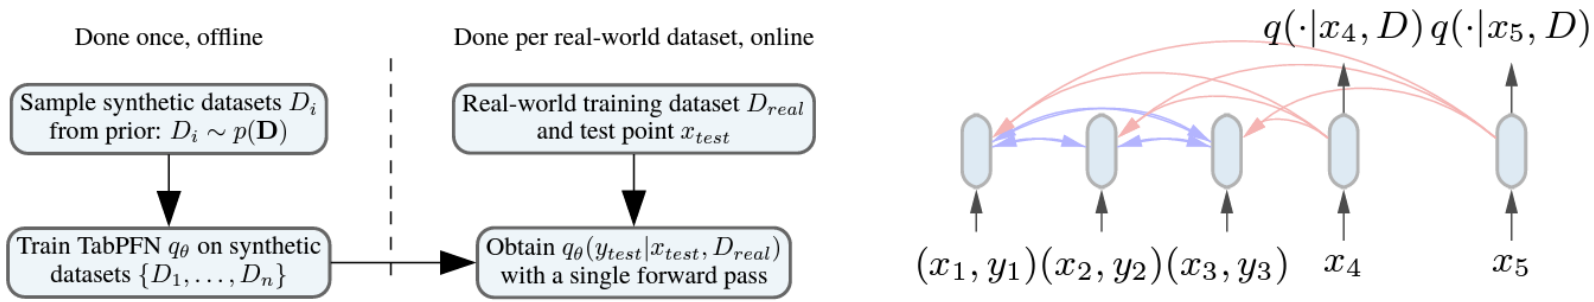
TabPFN

- Rede neural do tipo Trasnformer, pré-treinada em dados tabulares
- Aprende a resolver novas tarefas usando apenas os exemplos fornecidos no próprio dataset (*in-context learning*)
- Realiza previsões sem necessidade de treinamento adicional ou ajuste de hiperparâmetros



TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second

Noah Hollmann, Samuel Müller, Katharina Eggensperger, Frank Hutter. arXiv 2022.



(a) Prior-fitting and inference

(b) Architecture and attention mechanism

- Arquitetura baseada em Transformers, adaptada para o uso em bancos de dados estruturados.
- Velocidade: processamento assíncrono (não precisa de todos os dados) e aprendizado acontece paralelizado.

When Do Neural Nets Outperform Boosted Trees on Tabular Data?

Duncan McElfresh, Sujay Khandagale, Jonathan Valverde, Vishak Prasad C, Benjamin Feuer, Chinmay Hegde, Ganesh Ramakrishnan, Micah Goldblum, Colin White. arXiv 2023.

Table 9: Performance of algorithms according to ROC-AUC, over 98 datasets. Columns show the rank over all datasets, the average normalized ROC-AUC score (Mean AUC), the standard deviation of normalized ROC-AUC score across folds (Std. AUC), and the train time per 1000 instances. Min/max/mean/median are taken over all datasets.

		Rank				Mean AUC		Std. AUC		Time /1000 inst.	
Algorithm	Class	min	max	mean	med.	mean	med.	mean	med.	mean	med.
TabPFN*	PFN	1	17	5.30	3	0.91	0.97	0.17	0.07	0.25	0.01
CatBoost	GBDT	1	20	6.43	5	0.91	0.96	0.18	0.08	20.51	1.94
XGBoost	GBDT	1	19	7.17	6	0.90	0.96	0.19	0.09	0.84	0.38
ResNet	NN	1	21	8.23	7	0.84	0.93	0.19	0.12	15.83	8.78
SAINT	NN	1	21	8.35	7.50	0.84	0.93	0.19	0.12	170.31	145.99
RandomForest	base	1	20	8.64	8	0.87	0.94	0.19	0.10	0.41	0.28
DANet	NN	1	19	9.36	9	0.83	0.91	0.19	0.08	64.15	57.12
LightGBM	GBDT	1	21	10	9	0.83	0.91	0.22	0.10	0.89	0.29
NODE	NN	1	21	10.55	11	0.81	0.90	0.20	0.14	160.58	131.56
FTTransformer	NN	1	21	10.74	11.50	0.79	0.88	0.20	0.13	27.73	18.00
SVM	base	1	21	11.26	12.50	0.75	0.87	0.22	0.10	61.16	2.01
MLP-rtdl	NN	1	21	11.31	11	0.73	0.83	0.21	0.12	15.05	7.01
STG	NN	1	21	12.85	14	0.66	0.79	0.24	0.15	18.58	15.98
LinearModel	base	1	21	13.62	15	0.62	0.75	0.23	0.17	0.04	0.03
MLP	NN	1	21	14.13	15	0.65	0.71	0.23	0.14	18.17	11.16
TabNet	NN	1	21	14.46	16	0.63	0.75	0.32	0.19	35.06	29.32
DecisionTree	base	1	21	15.66	17	0.53	0.59	0.30	0.23	0.02	0.01
KNN	base	1	21	16.40	18	0.52	0.56	0.25	0.19	0.01	0.00
VIME	NN	1	21	16.74	18	0.49	0.50	0.30	0.20	17.84	15.55

Análise da performance preditiva de alguns dos algoritmos mais populares para dados estruturados em 98 bancos de dados

TabPFN

Aplicações na Saúde

- Diagnóstico rápido com dados clínicos estruturados.
- Classificação de risco em triagens.
- Predição de desfechos usando pequenas bases hospitalares.
- Aplicável em cenários com tempo de resposta crítico.

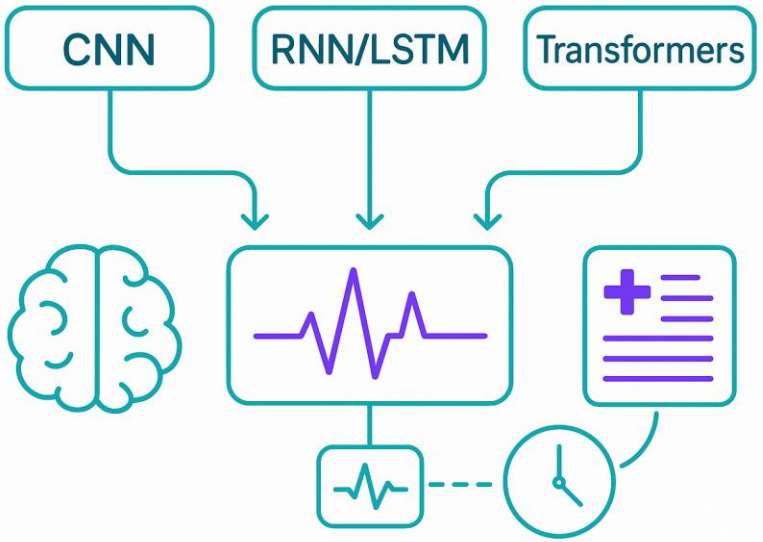


Revisando...

- Flexibilidade e poder preditivo

  Redes neurais são capazes de aprender padrões complexos, adaptando-se a diferentes tipos de dados (imagens, séries temporais, texto e dados tabulares).

- Arquiteturas especializadas:
  - **RNN/LSTM** → Ideais para dados sequenciais, como históricos clínicos.
  - **Transformers** → Alto desempenho em diferentes domínios, agora adaptados também a dados tabulares.
  - **CNN** → Excelentes para imagens médicas e sinais visuais.



Revisando...

Avanços recentes:

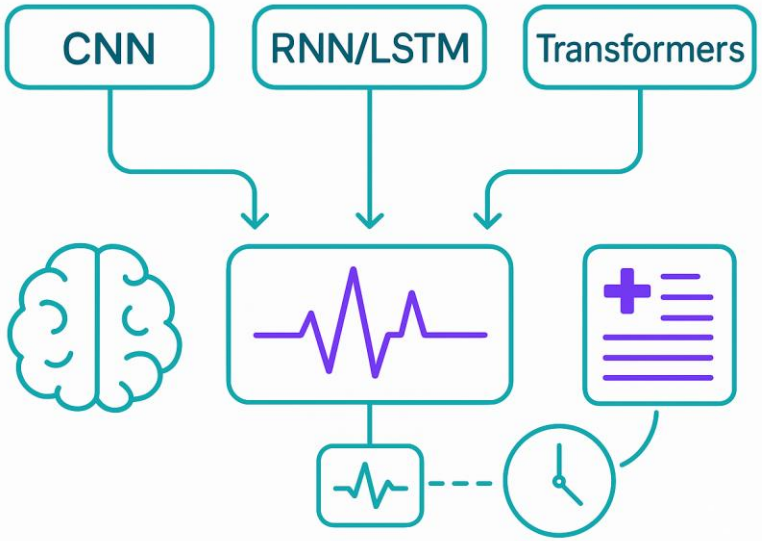
- TabPFN → Novo paradigma para dados tabulares: treinamento prévio massivo e inferência quase instantânea.

Perspectiva para saúde:

- Potencial para suporte à decisão clínica, triagem automatizada e identificação precoce de riscos.

Desafios e cuidados:

- Interpretabilidade, necessidade de grandes volumes de dados e recursos computacionais



Obrigada!

Keisyanne de Araujo Moura

@labdaps

keisyannemoura@usp.br

