

PROFEPI Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde

Introdução à

Inteligência Artificial para Predições

em Vigilância em Saúde e Ambiente

Módulo 3

Algoritmos e construção de modelos

OPAS Organização Pan-Americana da Saúde / Organização Mundial da Saúde Américas

SUS

MINISTÉRIO DA SAÚDE

MINISTÉRIO DA SAÚDE
SECRETARIA DE VIGILÂNCIA EM SAÚDE E AMBIENTE (SVSA)

Coordenação-Geral

Mariângela Simão

Secretária de Vigilância em Saúde e Ambiente/SVSA/MS

Guilherme Loureiro Werneck

Diretor do Departamento de Ações Estratégicas de Epidemiologia e Vigilância em Saúde e Ambiente/Daevs/SVSA/MS

Vivian Siqueira Santos Gonçalves

Coordenadora-Geral de Desenvolvimento da Epidemiologia em Serviços – CGDEP/Daevs/SVSA/MS

Equipe Técnica

Amanda Maciel de Quadros - CGDEP/Daevs/SVSA/MS

Antonio Ygor Modesto de Oliveira - CGDEP/Daevs/SVSA/MS

Cíntia Pereira Donateli - CGDEP/Daevs/SVSA/MS

Criação Digital

Matheus Nunes Oliveira Alves - CGDEP/Daevs/SVSA/MS

Otávio Francisco Batista Martins - CGDEP/Daevs/SVSA/MS

Professores

Alexandre Dias Porto Chiavegatto Filho - Universidade de São Paulo (USP)

Keisyanne de Araujo Moura - Universidade de São Paulo (USP)

André Henrique Alves Carneiro - Universidade de São Paulo (USP)

Marcela Quaresma Soares - Universidade de São Paulo (USP)

Vinícius de Camargo - Universidade de São Paulo (USP)

ORGANIZAÇÃO PAN-AMERICANA DE SAÚDE ORGANIZAÇÃO MUNDIAL DA SAÚDE (OPAS/OMS)

Coordenação-Geral

Cristian Morales Fuhrimann - Representante da OPAS/OMS no Brasil

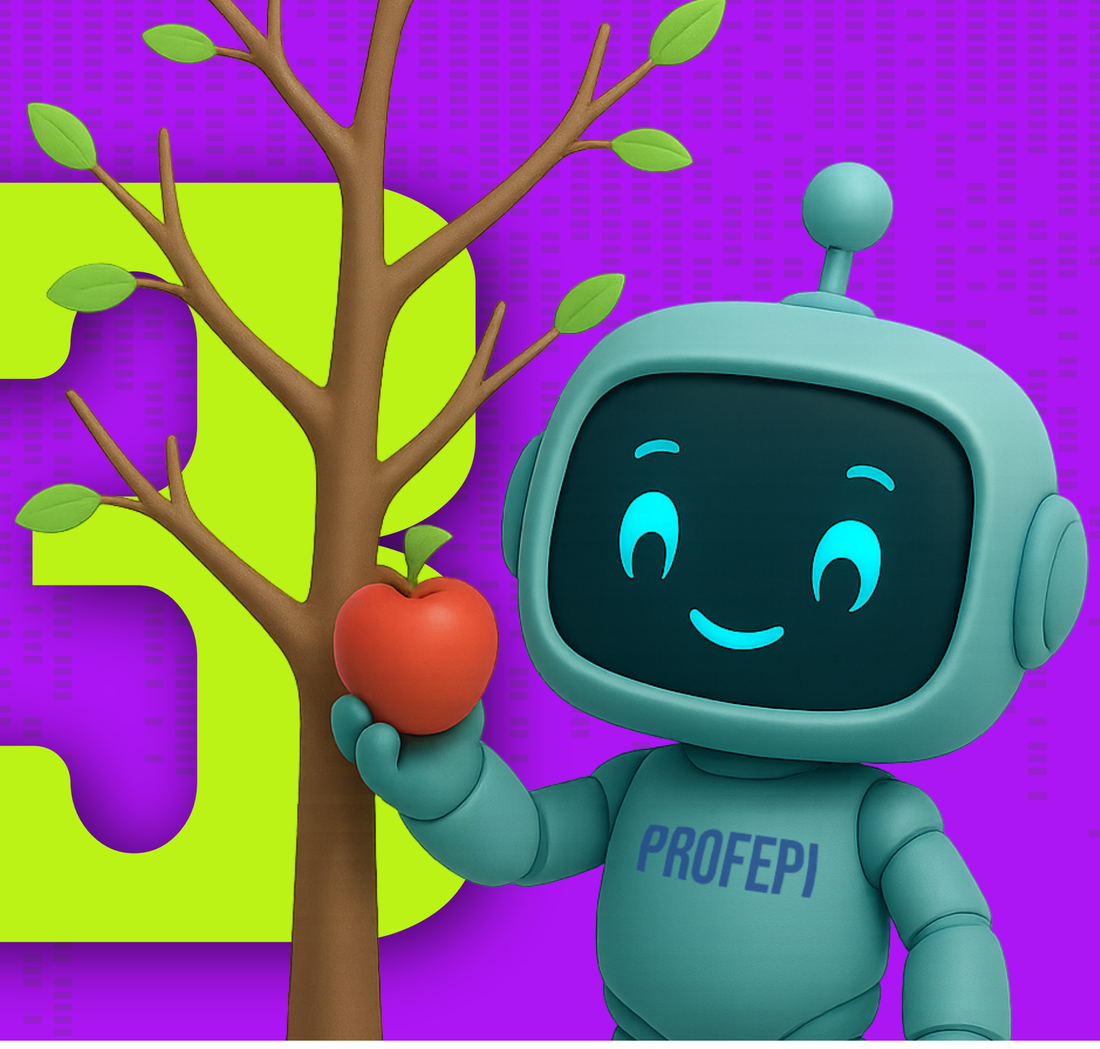
Alexander Rosewell - Coordenador de Emergências, Evidência e Inteligência em Saúde no Brasil

Equipe Técnica

Josy Maria de Pinho da Silva - OPAS/OMS

capítulo 6

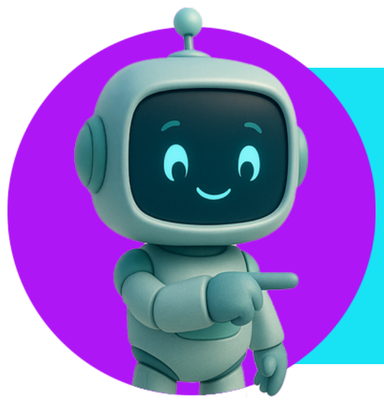
MÓDULO 3



Algoritmos Baseados em Árvores

Introdução aos Algoritmos

A palavra *algoritmo* refere-se a uma sequência finita e bem definida de instruções que, ao serem executadas, permitem resolver um problema ou realizar uma tarefa específica (Cormen et al., 2009).



No contexto da ciência de dados e da inteligência artificial (IA), os algoritmos constituem o núcleo do processo de aprendizado, sendo responsáveis por ajustar modelos a partir de dados e gerar previsões, classificações ou recomendações.

No campo da vigilância em saúde e ambiente, os algoritmos têm desempenhado um papel cada vez mais relevante, dada a crescente disponibilidade de grandes volumes de dados oriundos de sistemas de informação, como o Sistema de Informação sobre Mortalidade (SIM), o Sistema de Informação de Agravos de Notificação (SINAN) e plataformas de monitoramento climático. Por meio de técnicas de aprendizado de máquina (machine learning), esses algoritmos podem identificar padrões complexos, detectar anomalias e prever eventos futuros que auxiliem na tomada de decisão em saúde pública.

Entre as aplicações práticas destacam-se:

Previsão de surtos e epidemias: algoritmos preditivos podem antecipar o aumento de casos de doenças transmissíveis, como dengue e influenza, integrando dados de notificação, clima e mobilidade populacional (Nsoesie et al., 2014).

Antecipação de riscos ambientais: modelos treinados com dados de poluição do ar, temperatura e umidade relativa podem estimar a probabilidade de elevação de internações por doenças respiratórias (Guo et al., 2018).

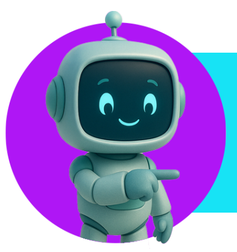
Detecção de padrões em grandes bases de dados: algoritmos de mineração de dados permitem identificar áreas geográficas ou populações de maior vulnerabilidade a doenças crônicas não transmissíveis, como hipertensão e diabetes (Chiavegatto Filho et al., 2020).

A relevância dos algoritmos para a saúde pública decorre de sua capacidade de generalizar – ou seja, aprender padrões a partir de dados históricos e aplicá-los para prever situações futuras, inclusive em contextos não observados anteriormente. Essa característica é fundamental para que políticas e ações sejam implementadas de forma proativa, reduzindo a morbimortalidade e otimizando recursos.

No entanto, a aplicação de algoritmos em saúde exige atenção a aspectos como a qualidade dos dados, a interpretabilidade dos modelos e a viabilidade computacional. Em ambientes onde as decisões afetam diretamente a vida das pessoas, a precisão preditiva deve ser equilibrada com a transparência e a robustez das soluções desenvolvidas (WHO, 2021).

Por que existem diferentes algoritmos?

A diversidade de algoritmos em machine learning decorre, principalmente, da variedade de tipos de dados, problemas e objetivos de aplicação.



Cada algoritmo apresenta pontos fortes e limitações que influenciam seu desempenho em diferentes contextos.

Não existe um modelo universalmente superior para todos os problemas – conceito formalizado pelo Teorema do "No Free Lunch" (Wolpert & Macready, 1997). Esse teorema estabelece que, considerando todos os possíveis conjuntos de dados, nenhum algoritmo é garantidamente melhor que outro sem conhecer previamente a estrutura e as propriedades dos dados.

Diferenças na natureza dos dados

Dados tabulares:

Comuns em bancos administrativos e de vigilância em saúde, como registros de hospitalizações e notificações de doenças. Modelos baseados em árvore (p. ex., Random Forest, XGBoost) e regressão logística são frequentemente eficazes.

Dados de imagem:

Relevantes em diagnósticos radiológicos e exames de patologia digital, geralmente processados por redes neurais convolucionais (Convolutional Neural Networks – CNNs).

Dados textuais:

Utilizados em prontuários eletrônicos ou redes sociais para vigilância sindrômica, processados com técnicas de processamento de linguagem natural (*Natural Language Processing* – NLP).

Séries temporais:

Úteis para previsão de tendências epidemiológicas, como curvas de incidência de doenças ou evolução de parâmetros ambientais.

Diferenças nos objetivos e métricas

- Os algoritmos também se distinguem em função dos objetivos de aplicação:
- Alta precisão: modelos mais complexos, como *gradient boosting*, tendem a apresentar maior acurácia em dados tabulares, porém podem sacrificar interpretabilidade.
- Interpretação clínica: modelos lineares ou árvores de decisão simples facilitam a explicação de resultados para gestores e profissionais de saúde.
- Velocidade e escalabilidade: algoritmos como LightGBM ou regressões regulares são mais rápidos e eficientes para grandes bases.

Exemplo aplicado à saúde

- Em um projeto de vigilância epidemiológica para prever internações por doenças respiratórias a partir de dados de poluição atmosférica, temperatura e umidade, diferentes algoritmos podem ser comparados:
- Regressão linear múltipla: oferece boa interpretabilidade, mas pode ter desempenho inferior se as relações forem não lineares.
- Árvore de decisão: capta interações não lineares, porém pode sobreajustar os dados.
- Random Forest: aumenta a robustez ao combinar múltiplas árvores, mas perde parte da interpretabilidade.
- XGBoost ou LightGBM: podem atingir maior acurácia, especialmente após ajuste fino de hiperparâmetros, mas exigem maior poder computacional.

Implicações para a vigilância em saúde

A escolha do algoritmo depende de um equilíbrio entre:

- Precisão do modelo
- Facilidade de explicação para tomada de decisão
- Viabilidade computacional
- Qualidade e quantidade de dados disponíveis

FIQUE ATENTO!

Em saúde pública, a decisão final sobre qual modelo adotar deve considerar não apenas métricas estatísticas, mas também aspectos éticos, transparência e a possibilidade de implementação prática (WHO, 2021).

Como os algoritmos "aprendem"

O processo de aprendizado em machine learning consiste no ajuste de parâmetros internos de um modelo a partir de dados, com o objetivo de minimizar o erro entre as previsões e os valores reais. Esse processo, denominado treinamento, permite que o algoritmo identifique padrões nos dados de forma a realizar generalizações – ou seja, fornecer previsões precisas mesmo para dados que nunca foram observados anteriormente (Mitchell, 1997).

Função de perda

O ponto central do aprendizado é a função de perda (loss function), que quantifica o erro cometido pelo modelo. O objetivo do algoritmo é encontrar os parâmetros que minimizam essa função. Exemplos comuns incluem:

- **Erro Quadrático Médio (MSE):** usado em regressões para medir a média dos quadrados das diferenças entre valores previstos e observados.
- **Entropia cruzada (cross-entropy):** amplamente utilizada em problemas de classificação, penalizando fortemente previsões incorretas com alta confiança.
- **Log loss:** semelhante à entropia cruzada, também empregada em classificação binária.

Exemplo na saúde

Ao prever risco de mortalidade hospitalar, a função de perda pode ser configurada para penalizar mais fortemente os falsos negativos (pacientes de alto risco classificados como baixo risco), de modo a priorizar a segurança do paciente.

Métodos de otimização

Para minimizar a função de perda, os algoritmos utilizam métodos de otimização, sendo o gradiente descendente (gradient descent) o mais comum. Ele ajusta iterativamente os parâmetros na direção de maior redução do erro. Variantes incluem:

Gradiente descendente estocástico (SGD): utiliza subconjuntos aleatórios de dados a cada iteração, acelerando o treinamento.

Adam: combina momento e adaptação da taxa de aprendizado, sendo eficaz em problemas complexos.

Overfitting e underfitting

- **Overfitting:** ocorre quando o modelo aprende detalhes e ruídos específicos do conjunto de treino, perdendo capacidade de generalizar. É comum em modelos muito complexos ou com excesso de treinamento.
- **Underfitting:** acontece quando o modelo é muito simples para capturar a complexidade dos dados, resultando em baixo desempenho tanto no treino quanto no teste.

Exemplo na saúde

Um modelo que prevê internações por doenças respiratórias com base em dados climáticos pode apresentar overfitting se incluir ruídos sazonais irrelevantes, enquanto um modelo linear simples pode apresentar underfitting ao não capturar interações não lineares entre poluição, temperatura e umidade.

Validação cruzada

A validação cruzada (cross-validation) é uma técnica essencial para avaliar o desempenho real de um modelo. A forma mais utilizada é a k-fold cross-validation, que divide o conjunto de dados em k partes (dobras), usando k-1 partes para treino e a restante para teste, repetindo o processo k vezes e calculando a média das métricas obtidas (Kohavi, 1995).

Anota essa informação!

Essa abordagem é particularmente importante em vigilância em saúde, pois reduz a probabilidade de que o desempenho observado seja fruto do acaso, aumentando a confiança nas previsões.

Generalização em contextos de saúde pública

A capacidade de um modelo generalizar é crucial para prever eventos futuros de forma confiável, como:

- Prever aumento de casos de dengue com base em dados climáticos e históricos de incidência.
- Antecipar picos de internação por doenças cardiovasculares considerando variáveis meteorológicas e poluentes atmosféricos.
- Estimar demanda por leitos hospitalares durante epidemias de influenza.

Em todos esses casos, é fundamental garantir que o modelo mantenha desempenho estável quando aplicado a dados de períodos e contextos distintos daqueles utilizados no treinamento.

Algoritmos Baseados em Árvore

Os algoritmos baseados em árvore constituem uma das abordagens mais utilizadas em machine learning, especialmente quando se busca equilíbrio entre desempenho preditivo e interpretabilidade. Eles funcionam estruturando o processo de decisão em uma série de divisões binárias ou múltiplas, formando um modelo visualmente representado como uma árvore invertida, onde cada nó interno representa uma decisão, os ramos representam caminhos possíveis e as folhas contêm a previsão final (classe ou valor).

A popularidade desses modelos na vigilância em saúde e ambiente decorre da sua capacidade de lidar com dados tabulares heterogêneos, combinando variáveis numéricas, categóricas e até mesmo variáveis derivadas de fontes distintas, como dados de clima, poluição e notificações de doenças. Diferentemente de modelos lineares, as árvores de decisão captam interações complexas e não lineares entre variáveis sem a necessidade de transformação prévia dos dados (Breiman et al., 1984; Quinlan, 1993).

Funcionamento e construção

O treinamento de uma árvore de decisão segue um processo recursivo. Inicialmente, todos os dados estão em um nó raiz. O algoritmo então avalia todas as variáveis preditoras e seus possíveis pontos de corte, selecionando a divisão que maximize a separação das classes (em classificação) ou minimize a variação residual (em regressão). Esse critério de separação pode ser medido por métricas como Índice de Gini, entropia ou erro quadrático médio.

Após a primeira divisão, o processo é repetido em cada subconjunto resultante, criando novos nós e ramos até que sejam atendidas condições de parada, como:

- Profundidade máxima da árvore.
- Número mínimo de observações por nó.
- Ganho mínimo de pureza para novas divisões.

Exemplo na saúde

Na predição de risco de internação por doenças respiratórias, o nó raiz poderia ser uma variável como "Idade ≥ 60 anos". Para indivíduos acima dessa idade, o modelo poderia avaliar o histórico de doença cardiovascular; já para indivíduos mais jovens, poderia priorizar variáveis ambientais como nível médio de poluição atmosférica nos últimos sete dias.

Os algoritmos baseados em árvore constituem uma das abordagens mais utilizadas em machine learning, especialmente quando se busca equilíbrio entre desempenho preditivo e interpretabilidade. Eles funcionam estruturando o processo de decisão em uma série de divisões binárias ou múltiplas, formando um modelo visualmente representado como uma árvore invertida, onde cada nó interno representa uma decisão, os ramos representam caminhos possíveis e as folhas contêm a previsão final (classe ou valor).

A popularidade desses modelos na vigilância em saúde e ambiente decorre da sua capacidade de lidar com dados tabulares heterogêneos, combinando variáveis numéricas, categóricas e até mesmo variáveis derivadas de fontes distintas, como dados de clima, poluição e notificações de doenças. Diferentemente de modelos lineares, as árvores de decisão captam interações complexas e não lineares entre variáveis sem a necessidade de transformação prévia dos dados (Breiman et al., 1984; Quinlan, 1993).

Interpretação e aplicabilidade

Um dos principais diferenciais das árvores de decisão é a interpretabilidade. A estrutura resultante pode ser traduzida em um conjunto de regras lógicas do tipo se-então, facilmente compreendidas por profissionais de saúde e gestores. Essa característica é especialmente valiosa quando decisões rápidas e transparentes precisam ser tomadas, como na priorização de recursos hospitalares ou na definição de áreas para intervenção epidemiológica.

Além disso, árvores de decisão não exigem normalização ou padronização de variáveis e são naturalmente robustas a outliers, já que decisões são tomadas com base em divisões e não em médias ou variâncias sensíveis a valores extremos.

Limitações

Apesar das vantagens, árvores de decisão apresentam instabilidade: pequenas alterações no conjunto de treinamento podem resultar em árvores completamente diferentes. Outro problema frequente é o sobreajuste (overfitting), quando a árvore cresce excessivamente e passa a capturar ruídos específicos dos dados de treino, prejudicando o desempenho em novos dados.

Além disso, embora sejam interpretáveis, árvores profundas podem gerar regras excessivamente complexas, dificultando sua comunicação.

Estratégias para melhorar desempenho

Para contornar essas limitações, desenvolveu-se o conceito de ensemble learning – métodos que combinam múltiplas árvores para melhorar robustez e acurácia.

As duas principais abordagens são:

Bagging (Bootstrap Aggregating): construção de diversas árvores independentes a partir de amostras aleatórias dos dados, como no Random Forest.

Boosting: construção sequencial de árvores, onde cada nova árvore corrige erros das anteriores, como nos modelos Gradient Boosting Decision Trees (GBDT), implementados no XGBoost, LightGBM e CatBoost.

Essas técnicas não apenas melhoram o desempenho preditivo, mas também aumentam a capacidade de generalização, especialmente quando aplicadas em bases de dados complexas e heterogêneas, comuns na saúde pública.

Exemplos na vigilância em saúde

O uso de algoritmos baseados em árvore é amplo e documentado na literatura:

- Monitoramento de epidemias: árvores de decisão foram usadas para prever surtos de dengue, integrando variáveis meteorológicas, dados de infestação de mosquitos e notificações oficiais (Zhu et al., 2019).
- Predição de mortalidade hospitalar: Random Forest e GBDT já foram aplicados para prever risco de morte por COVID-19 com base em dados clínicos e demográficos, auxiliando no manejo de pacientes em pronto-socorro (Vaid et al., 2020).
- Gestão de recursos hospitalares: modelos de árvore têm sido usados para prever demanda por leitos e ventiladores em períodos de pico de doenças respiratórias sazonais.

Métodos de Ensemble Baseados em Árvores

Apesar de serem intuitivas e interpretáveis, as árvores de decisão simples possuem limitações significativas, como instabilidade e propensão ao overfitting. Para superar esses problemas e melhorar a capacidade de generalização, surgiram os métodos de ensemble, que combinam múltiplas árvores para gerar modelos mais robustos e precisos (Dietterich, 2000).

Entre as abordagens mais populares estão o bagging (bootstrap aggregating) e o boosting, cada uma com variações e implementações específicas amplamente utilizadas na vigilância em saúde.

Bagging e Random Forest

O bagging consiste em treinar múltiplas árvores de decisão de forma independente, cada uma utilizando uma amostra aleatória (com reposição) do conjunto de dados original. Essa técnica reduz a variância do modelo e melhora sua estabilidade, já que erros cometidos por árvores individuais tendem a se compensar na agregação final (Breiman, 1996).

A implementação mais conhecida dessa abordagem é o Random Forest (Breiman, 2001), que introduz uma segunda camada de aleatoriedade: em cada nó, apenas um subconjunto aleatório de variáveis é considerado para determinar a divisão. Isso aumenta a diversidade entre as árvores e melhora a performance.

Vantagens:

- Alta robustez contra *overfitting*.
- Funciona bem com variáveis categóricas e numéricas.
- Fornece medidas de importância das variáveis.

Exemplo na saúde

Modelos de Random Forest foram utilizados para prever risco de mortalidade hospitalar em pacientes com COVID-19, combinando dados demográficos, comorbidades e resultados laboratoriais. O modelo auxiliou na priorização de pacientes para tratamento intensivo (Vaid et al., 2020).

Boosting e Gradient Boosting Decision Trees (GBDT)

O boosting adota uma abordagem sequencial: cada nova árvore é treinada para corrigir os erros da anterior, ajustando-se aos exemplos mais difíceis de prever. Esse processo é guiado pela minimização de uma função de perda por meio de gradiente descendente, resultando nos Gradient Boosting Decision Trees (GBDT) (Friedman, 2001).

As três implementações mais conhecidas e eficientes do GBDT são XGBoost, LightGBM e CatBoost, cada uma com características particulares.

XGBoost (Extreme Gradient Boosting)

O XGBoost (Chen & Guestrin, 2016) é otimizado para velocidade e desempenho, incorporando:

- Processamento paralelo.
- Regularização L1 e L2 para controle de overfitting.
- Suporte a valores ausentes e dados esparsos.
- Flexibilidade para usar diferentes funções de perda.

Vantagens:

- Alta acurácia, especialmente em dados tabulares.
- Estável em bases complexas.
- Ampla documentação e comunidade ativa.

Limitações:

- Mais lento que LightGBM em bases muito grandes.
- Exige ajuste fino de hiperparâmetros.

Exemplo na saúde

Usado na previsão de surtos de dengue com base em variáveis meteorológicas, índices de infestação vetorial e notificações de casos, atingindo alta sensibilidade na detecção precoce (Zhu et al., 2019).

LightGBM

Desenvolvido pela Microsoft (Ke et al., 2017), o LightGBM é projetado para alta performance em grandes volumes de dados. Ele utiliza uma estratégia de crescimento de árvore leaf-wise, priorizando a expansão dos ramos que mais reduzem o erro, o que o torna mais rápido e eficiente.

Vantagens:

- Treinamento extremamente rápido.
- Boa eficiência de memória.
- Suporte nativo a variáveis categóricas.

Limitações:

- Mais suscetível a overfitting se não houver regularização adequada.
- Menor interpretabilidade comparado a modelos mais simples.

Exemplo na saúde

Aplicado para modelar risco de desenvolvimento de hipertensão em coortes populacionais, usando variáveis clínicas e comportamentais, permitindo intervenções preventivas direcionadas (Ye et al., 2020).

CatBoost

O CatBoost (Dorogush et al., 2018), desenvolvido pela Yandex, foi projetado para lidar de forma nativa com variáveis categóricas, eliminando a necessidade de codificações complexas (*one-hot encoding*). Utiliza técnicas como ordered boosting para evitar vazamento de informação (*target leakage*).

Vantagens:

- Excelente desempenho com dados categóricos.
- Menor necessidade de pré-processamento.
- Boa performance em bases pequenas e médias.

Limitações:

- Menor comunidade e material de suporte que XGBoost e LightGBM.
- Pode ser mais lento que LightGBM em grandes volumes de dados numéricos.

Exemplo na saúde

Empregado para prever risco de internação por doenças crônicas em bases administrativas que combinam variáveis demográficas, socioeconômicas e clínicas.

Comparação entre os métodos

Algoritmo	Velocidade	Memória	Ideal para	Limitações principais
Random Forest	Média	Média	Modelos interpretáveis, análise de importância de variáveis	Pode ser menos preciso que GBDT
XGBoost	Alta	Alta	Dados tabulares complexos	Mais lento em bases muito grandes
LightGBM	Muito alta	Alta	Grandes bases de dados	Mais suscetível a overfitting
CatBoost	Alta	Alta	Bases com muitas variáveis categóricas	Comunidade menor

Considerações práticas na saúde

A escolha do algoritmo ideal deve equilibrar:

- Desempenho preditivo: acurácia, sensibilidade, especificidade.
- Interpretabilidade: essencial em decisões clínicas e epidemiológicas.
- Viabilidade computacional: tempo e custo de processamento.
- Disponibilidade de expertise: facilidade de ajuste e manutenção.



Referências

Bishop, C. M. (1995). **Neural Networks for Pattern Recognition**. Oxford University Press.

Breiman, L. (1996). **Bagging predictors. Machine Learning**, 24(2), 123–140. https://doi.org/10.1007/BF00058655

Breiman, L. (2001). **Random forests. Machine Learning**, 45, 5–32. https://doi.org/10.1023/A:1010933404324

Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). **Classification and Regression Trees**. Wadsworth International Group.

Chen, T., & Guestrin, C. (2016). **XGBoost: A scalable tree boosting system**. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

Dietterich, T. G. (2000). **Ensemble methods in machine learning**. International Workshop on Multiple Classifier Systems, 1–15. https://doi.org/10.1007/3-540-45014-9_1

Domingos, P. (2012). **A few useful things to know about machine learning**. Communications of the ACM, 55(10), 78–87. https://doi.org/10.1145/2347736.2347755

Dorogush, A. V., Ershov, V., & Gulin, A. (2018). **CatBoost: gradient boosting with categorical features support**. arXiv preprint, arXiv:1810.11363.

Friedman, J. H. (2001). **Greedy function approximation: A gradient boosting machine**. Annals of Statistics, 29(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). **LightGBM: A highly efficient gradient boosting decision tree**. Advances in Neural Information Processing Systems, 30.

Kohavi, R. (1995). **A study of cross-validation and bootstrap for accuracy estimation and model selection**. Proceedings of the 14th International Joint Conference on Artificial Intelligence, 2(12), 1137–1145.

Olson, R. S., La Cava, W., Mustahsan, Z., Varik, A., & Moore, J. H. (2018). **Data-driven advice for applying machine learning to bioinformatics**. Bioinformatics, 34(4), 623–632. https://doi.org/10.1093/bioinformatics/btx344

Quinlan, J. R. (1993). C4.5: **Programs for Machine Learning**. Morgan Kaufmann.

Vaid, A., Somani, S., Russak, A. J., De Freitas, J. K., Chaudhry, F., Paranjpe, I., ... & Narula, J. (2020). **Machine learning to predict mortality and critical events in COVID-19 positive New York City patients: A cohort study**. NPJ Digital Medicine, 3(1), 1–8. https://doi.org/10.1038/s41746-020-00383-x

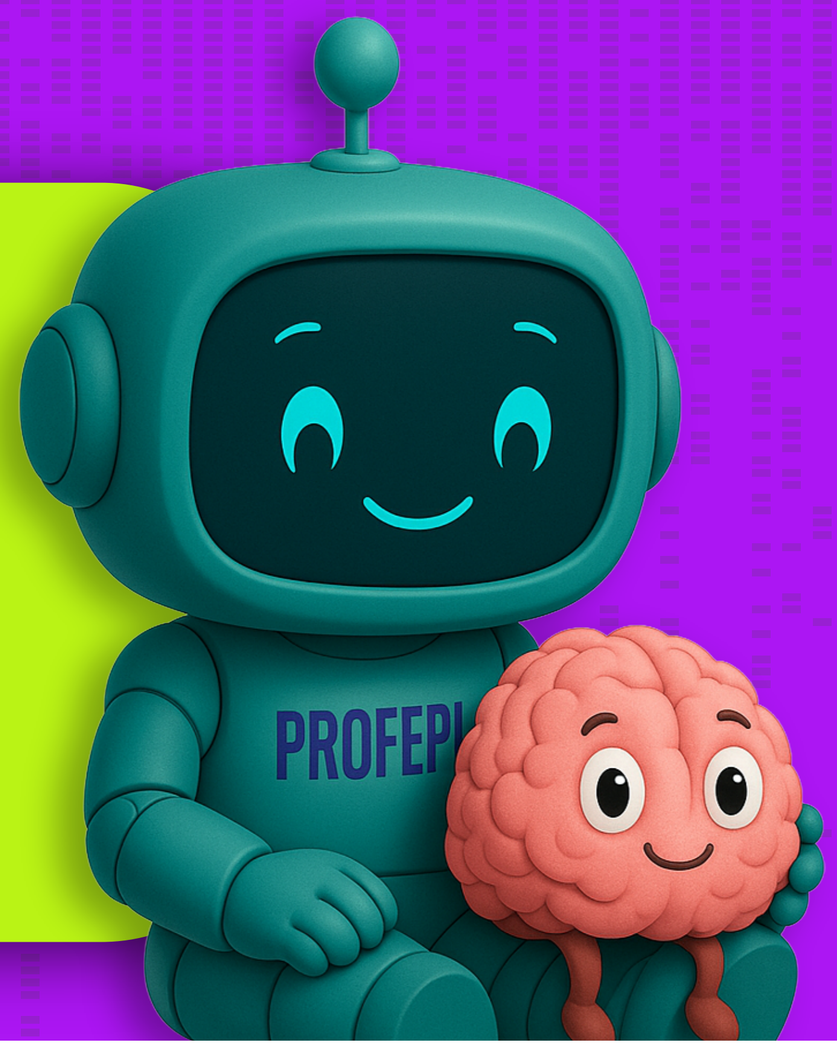
Wolpert, D. H., & Macready, W. G. (1997). **No free lunch theorems for optimization**. IEEE Transactions on Evolutionary Computation, 1(1), 67–82. https://doi.org/10.1109/4235.585893

World Health Organization (WHO). (2021). **Ethics and governance of artificial intelligence for health: WHO guidance**. WHO Press.

Zhu, G., Liu, J., Tan, Q., Shi, B., & Zhang, J. (2019). **Development and evaluation of a machine learning-based dengue risk prediction model using meteorological and entomological data**. PLoS Neglected Tropical Diseases, 13(10), e0007712. https://doi.org/10.1371/journal.pntd.0007712

capítulo 7

MÓDULO 3



Algoritmos Baseados em Redes Neurais

Introdução aos Algoritmos Baseados em Redes Neurais na Saúde

As redes neurais artificiais (RNA) são modelos computacionais inspirados no funcionamento do sistema nervoso biológico, compostos por unidades interconectadas denominadas *neurônios artificiais*, capazes de processar informações e aprender padrões complexos a partir de dados (McCulloch & Pitts, 1943; Rumelhart et al., 1986).

Embora o conceito tenha surgido na década de 1940, o uso prático das redes neurais passou por períodos de entusiasmo e estagnação (*AI winters*), ressurgindo com força no século XXI devido a três fatores centrais:

1. Aumento exponencial da capacidade computacional (uso de GPUs e TPUs).
2. Disponibilidade de grandes volumes de dados (big data).
3. Avanços em algoritmos de otimização e arquiteturas mais sofisticadas (LeCun, Bengio & Hinton, 2015).

No contexto da vigilância em saúde e da epidemiologia, as redes neurais ganharam relevância por sua habilidade em:

- Modelar relações não lineares e interações complexas entre variáveis.
- Integrar dados heterogêneos (tabulares, textuais, de imagens, séries temporais).
- Aprender padrões sutis que podem indicar riscos, surtos ou diagnósticos precoces.

Estrutura básica de uma rede neural

Uma RNA típica é organizada em três tipos de camadas:

- Camada de entrada: recebe as variáveis preditoras (ex.: idade, sexo, histórico de doenças, dados ambientais).
- Camadas ocultas: processam as informações por meio de combinações lineares de pesos e funções de ativação não lineares, permitindo que a rede capture padrões complexos.
- Camada de saída: gera a previsão final, que pode ser uma probabilidade, um valor contínuo ou uma classe.

Cada conexão entre neurônios possui um peso, ajustado durante o treinamento para minimizar uma função de perda (*loss function*), como erro quadrático médio ou entropia cruzada, dependendo do tipo de problema.

Processo de aprendizado

O treinamento de uma rede neural ocorre em três etapas principais:

1. Propagação direta (*forward pass*): os dados percorrem a rede até gerar a saída prevista.
2. Cálculo do erro: a previsão é comparada ao valor real usando a função de perda.
3. Retropropagação (*backpropagation*): o erro é propagado de volta, ajustando os pesos por meio de algoritmos de otimização, como o stochastic gradient descent (SGD) ou variações como Adam e RMSprop.

Esse processo é iterado em múltiplas épocas até que o modelo alcance um desempenho satisfatório ou atenda a um critério de parada.

Por que usar redes neurais na saúde?

As RNA apresentam vantagens decisivas para problemas de saúde pública:

- Capacidade de lidar com alta dimensionalidade: úteis em cenários onde o número de variáveis é grande e as relações são complexas.
- Integração de múltiplas fontes de dados: por exemplo, combinar dados do SINAN (notificações de agravos) e SIM (mortalidade) com variáveis ambientais e socioeconômicas.
- Detecção de padrões não triviais: essencial para identificar sinais precoces de surtos ou grupos de risco.

Exemplo real

Um estudo de Esteva et al. (2017) mostrou que redes neurais convolucionais treinadas com mais de 129 mil imagens foram capazes de diagnosticar câncer de pele com desempenho semelhante a dermatologistas. Embora esse seja um exemplo clínico, a lógica de detecção automática de padrões também pode ser aplicada em epidemiologia, por exemplo, para detectar clusters anômalos de notificações.

Desafios e limitações

Apesar do potencial, a adoção de redes neurais na saúde enfrenta desafios importantes:

- Necessidade de grandes volumes de dados: modelos profundos exigem muitos exemplos para evitar *overfitting*.
- Baixa interpretabilidade: redes neurais são frequentemente consideradas caixas-pretas, dificultando a explicação de decisões.
- Viabilidade computacional: treinamento pode ser inviável sem hardware especializado.
- Risco de vieses: se os dados de treinamento refletirem desigualdades sociais, o modelo pode reproduzi-las.

FIQUE ATENTO!

Por isso, a aplicação de redes neurais em saúde deve ser acompanhada de:

- Validação rigorosa em múltiplos cenários.
- Ferramentas de explicabilidade como SHAP e LIME.
- Supervisão ética e regulatória, garantindo que as decisões auxiliem e não prejudiquem a equidade no cuidado.

Aplicações na vigilância e gestão em saúde

As redes neurais já foram aplicadas em diversas frentes da saúde pública e epidemiologia, como:

- Predição de surtos: integração de dados climáticos, mobilidade populacional e notificações de doenças para prever epidemias de dengue ou influenza.
- Estimativa de demanda hospitalar: previsão de ocupação de leitos e necessidade de ventiladores em períodos de pico de doenças respiratórias.
- Classificação de risco individual: estratificação de pacientes com base em risco de hospitalização ou óbito.
- Detecção automática de eventos adversos: análise de textos de prontuários e sistemas de farmacovigilância para identificar reações medicamentosas.

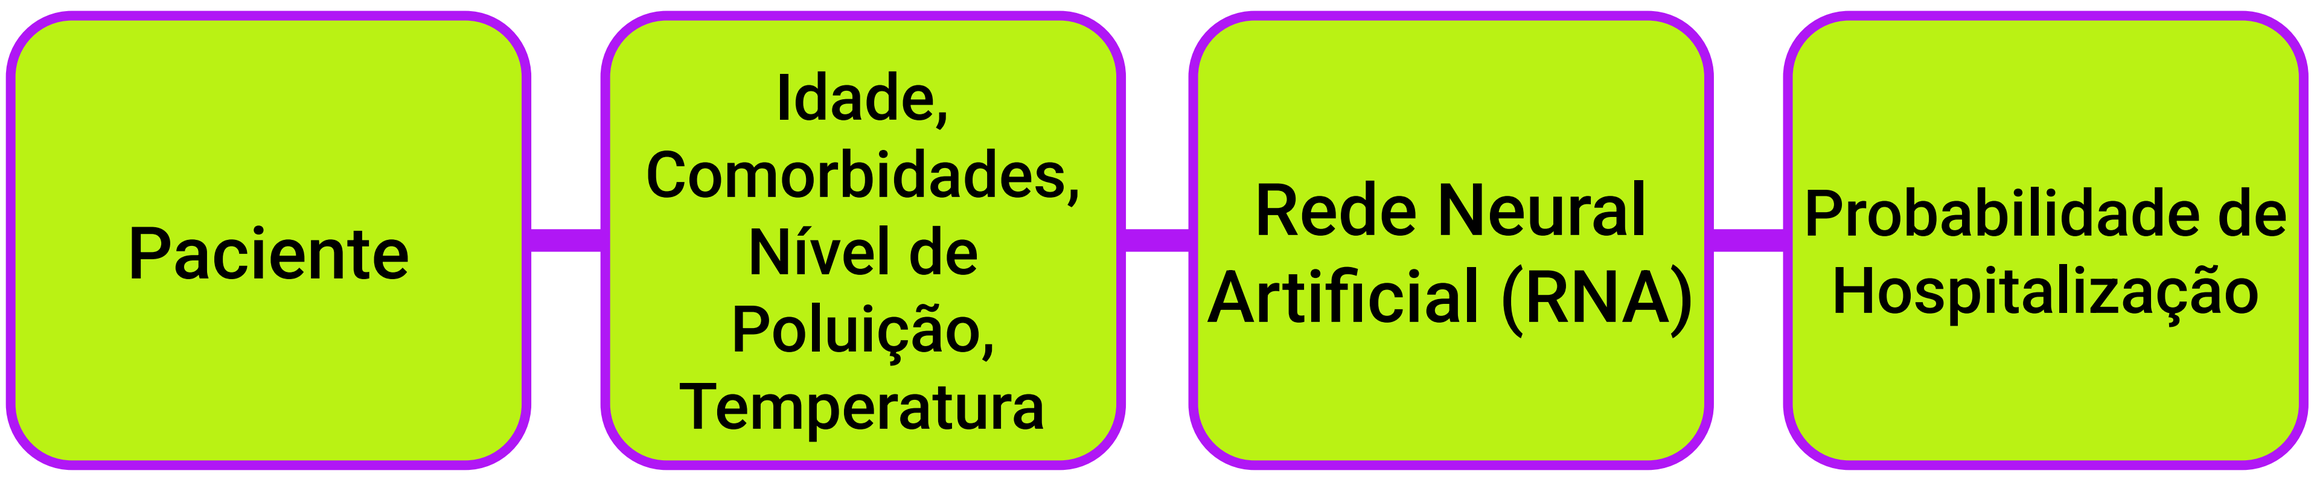
Introdução aos Algoritmos Baseados em Redes Neurais na Saúde

As Redes Neurais Artificiais (RNA), também conhecidas como *Multilayer Perceptrons* (MLP), são a forma mais clássica de rede neural. Apesar de sua simplicidade comparada a arquiteturas mais modernas, continuam sendo amplamente utilizadas em problemas de classificação, regressão e previsão em saúde pública devido à sua flexibilidade e capacidade de modelar relações não lineares.

Estrutura e componentes

Uma RNA típica é composta por:

- Camada de entrada: onde cada neurônio representa uma variável preditora (ex.: idade, índice de massa corporal, temperatura média semanal, níveis de poluição).
- Camadas ocultas: responsáveis por processar e transformar as informações. Cada neurônio de uma camada conecta-se a todos os neurônios da camada seguinte (*fully connected*).
- Camada de saída: onde é gerado o resultado final, podendo ser:
  - Uma classe (classificação binária ou multiclasse).
  - Um valor contínuo (regressão).
  - Uma probabilidade associada a cada classe.



Funcionamento interno

O processamento em uma RNA ocorre por meio de:

1. Combinação linear: cada neurônio recebe valores ponderados das entradas, somados a um viés (bias).

$$z = \sum_{i=1}^{n} w_i x_i + b$$

2. Função de ativação: transforma a combinação linear em uma saída não linear, permitindo que a rede capture relações complexas. As mais comuns incluem:
   - Sigmoide: útil para probabilidades, mas sofre com gradientes pequenos.
   - ReLU (*Rectified Linear Unit*): eficiente em redes mais profundas.
   - Tangente hiperbólica (tanh): centrada em zero, útil para dados normalizados.
3. Propagação direta (*forward pass*): os dados percorrem as camadas até gerar a saída.

4 Cálculo do erro: compara-se a previsão ao valor real usando funções de perda como *cross-entropy* (classificação) ou erro quadrático médio (regressão).

5 Retropropagação (*backpropagation*): calcula-se o gradiente do erro em relação aos pesos e ajusta-se cada conexão usando métodos como *stochastic gradient descent* ou Adam.

Hiperparâmetros críticos

O desempenho das RNA é fortemente influenciado por:

- Número de camadas ocultas e neurônios por camada: mais camadas permitem modelar relações mais complexas, mas aumentam risco de *overfitting*.
- Taxa de aprendizado (*learning rate*): controla a magnitude dos ajustes de pesos. Muito alta pode impedir a convergência; muito baixa torna o treino lento.
- Tamanho do lote (*batch size*): número de exemplos usados para calcular o gradiente a cada atualização.
- Função de ativação: impacta a capacidade de aprendizado e estabilidade.
- Regularização: técnicas como *dropout* (desativa aleatoriamente neurônios durante o treino) e penalizações L1/L2 evitam *overfitting*.

Vantagens das RNA

- Flexibilidade: aplicáveis a diferentes formatos de dados.
- Capacidade de capturar não linearidades: útil em cenários epidemiológicos complexos.
- Integração de múltiplas variáveis: combinam dados clínicos, demográficos e ambientais em um único modelo.

Limitações

- Necessidade de ajuste fino de hiperparâmetros: sem otimização, desempenho pode ser inferior a métodos mais simples.
- Menor interpretabilidade: embora mais explicáveis que redes profundas, ainda podem ser vistas como *caixa-preta*.
- Sensibilidade a dados desbalanceados: comum em saúde, onde eventos de interesse (ex.: óbito) podem ser raros.

Aplicações na saúde pública e vigilância epidemiológica

As RNA têm sido aplicadas com sucesso em diferentes contextos:

- Predição de internações hospitalares:
  Utilizando dados do SUS, RNA foram treinadas para prever internações por doenças cardiovasculares, integrando informações de prontuários, poluição atmosférica e dados meteorológicos.
  Impacto: melhor alocação de leitos e equipes médicas em períodos críticos.
- Estratificação de risco de doenças crônicas:
  Estudos com populações urbanas utilizaram RNA para identificar indivíduos com alto risco de desenvolver diabetes tipo 2, combinando fatores demográficos, hábitos de vida e indicadores laboratoriais.
- Previsão de surtos epidemiológicos:
  Redes neurais foram empregadas para prever surtos de dengue, Zika e chikungunya com base em variáveis climáticas (temperatura, chuva, umidade) e índices entomológicos.
- Apoio à triagem de pacientes em emergências:
  Modelos de RNA auxiliaram na predição de risco de óbito em prontos-socorros, otimizando protocolos de atendimento.

Exemplo prático: Prevendo surtos de dengue com RNA

Um projeto piloto no Nordeste do Brasil utilizou dados diários de:

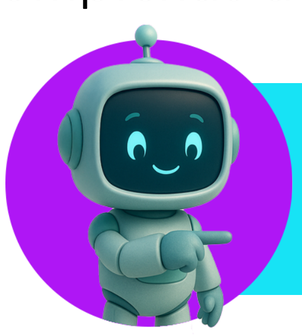
- Temperatura média e máxima.
- Precipitação acumulada.
- Índice de infestação do Aedes aegypti.
- Casos confirmados das últimas semanas.

O modelo RNA, com duas camadas ocultas (64 e 32 neurônios), função ReLU e *dropout* de 20%, alcançou AUC-ROC de 0,88 na previsão de surto para as semanas seguintes.

Benefício: permitiu que equipes de campo priorizassem regiões de maior risco, direcionando ações de controle vetorial.

Deep Learning

O *deep learning* é uma subárea das redes neurais artificiais caracterizada pelo uso de múltiplas camadas ocultas, permitindo ao modelo aprender representações hierárquicas e mais abstratas dos dados. Nas camadas iniciais, são captados padrões simples; nas camadas intermediárias, combinações desses padrões; e nas camadas finais, estruturas complexas de alto nível.



Esse avanço foi impulsionado por três fatores principais: maior capacidade computacional (GPU e TPU), disponibilidade de grandes volumes de dados e melhorias nos algoritmos de otimização.

Estrutura e funcionamento

- Camadas hierárquicas: a primeira camada recebe as variáveis de entrada, as camadas ocultas processam e transformam essas informações, e a camada de saída gera a previsão final.
- Extração automática de características: diferentemente de modelos tradicionais, o *deep* learning pode aprender automaticamente quais variáveis e combinações são mais relevantes, reduzindo a necessidade de engenharia manual de atributos (*feature engineering*).
- Funções de ativação não lineares: permitem que a rede capture padrões complexos; a ReLU é amplamente usada por evitar problemas de gradiente pequeno.
- Técnicas de regularização: *dropout*, *batch normalization* e *early stopping* ajudam a prevenir sobreajuste (*overfitting*).

Principais arquiteturas

- Redes neurais convolucionais (CNNs): ideais para análise de imagens médicas, como detecção de pneumonia em radiografias.
- Redes neurais recorrentes (RNNs) e LSTM: eficazes para séries temporais, como previsão de casos de doenças ao longo do tempo.
- Transformers adaptados para dados de saúde: aplicados ao processamento de linguagem natural (ex.: interpretação de prontuários eletrônicos).

Aplicações na saúde pública e vigilância epidemiológica

- Análise de imagens médicas: CNNs detectam padrões patológicos em exames de raio-X, tomografia e ressonância com precisão comparável à de especialistas humanos.
- Previsão de surtos: RNNs e LSTM combinam séries históricas de notificações, dados climáticos e mobilidade populacional para antecipar picos epidêmicos de doenças como dengue e influenza.
- Integração de múltiplas fontes de dados: redes profundas podem combinar dados administrativos (ex.: SINAN e SIM), laboratoriais e ambientais para modelar riscos de internação, óbito ou agravamento de doenças crônicas.
- Alertas precoces: modelos que cruzam dados de poluição atmosférica e clima com registros de pronto-socorro para emitir avisos de risco de internações por doenças respiratórias.

Desafios

- Necessidade de grandes volumes de dados: modelos profundos exigem muitos exemplos para evitar sobreajuste.
- Baixa interpretabilidade: a dificuldade em explicar decisões é crítica em saúde pública, exigindo ferramentas como SHAP ou LIME.

- Alta demanda computacional: treinamento e inferência podem requerer hardware especializado.
- Risco de vieses: dados de treinamento que refletem desigualdades sociais podem reproduzir ou amplificar essas disparidades.

FIQUE ATENTO!

Estratégias para aplicação responsável

- Uso de *transfer* learning para aproveitar modelos já treinados em domínios semelhantes.
- Implementação de técnicas de explicabilidade para aumentar a transparência das previsões.
- Validação rigorosa em diferentes cenários e populações para garantir robustez e generalização.

TabPFN (*Tabular Prior-Data Fitted Networks*)

O TabPFN (*Tabular Prior-Data Fitted Networks*) é um método extremamente recente e inovador que representa uma mudança de paradigma no uso de redes neurais para dados tabulares. Desenvolvido por Hollmann et al. (2022), ele combina conceitos de deep learning com técnicas de meta-learning e aprendizado probabilístico para criar um modelo que pode realizar previsões de alta qualidade em tabelas de dados de forma quase instantânea, mesmo com amostras muito pequenas.

Sua principal inovação é o uso de um modelo pré-treinado em milhões de tarefas sintéticas de classificação tabular, o que permite que, no momento da aplicação prática, ele já possua "experiência" prévia com uma enorme variedade de padrões possíveis. Isso contrasta com a lógica tradicional de redes neurais, que precisam ser treinadas do zero para cada novo problema, exigindo grandes volumes de dados e tempo computacional significativo.

Por que o TabPFN é considerado potente

- Velocidade de inferência: é capaz de fazer previsões em menos de um segundo para novos conjuntos de dados, mesmo sem re-treinamento.
- Desempenho competitivo: alcança resultados comparáveis ou superiores a modelos de ponta como XGBoost, LightGBM e CatBoost, especialmente em bases pequenas ou medianas.
- Capacidade de generalização: por ser treinado previamente em um vasto conjunto de problemas simulados, generaliza bem para diferentes contextos, mesmo quando os dados reais possuem padrões incomuns.
- Menor dependência de ajuste manual: dispensa, na maioria dos casos, longos processos de ajuste de hiperparâmetros.

Funcionamento

O TabPFN é baseado em arquiteturas de transformadores – a mesma base de modelos de linguagem como o GPT – adaptadas para lidar com dados tabulares. Durante seu pré-treinamento, ele aprende uma distribuição a priori sobre problemas de classificação e, posteriormente, quando recebe um novo conjunto de dados, utiliza essa distribuição para prever a probabilidade de cada classe para cada instância.

Esse mecanismo se aproxima de um raciocínio "metaestatístico": o modelo não aprende apenas a partir dos dados que lhe são fornecidos na aplicação, mas também aproveita todo o "conhecimento acumulado" do pré-treinamento.

Aplicações na saúde pública e vigilância epidemiológica

O TabPFN tem potencial disruptivo em áreas da saúde onde a escassez de dados é uma barreira para o uso de métodos tradicionais. Alguns exemplos de cenários promissores incluem:

- Doenças raras: previsão de risco ou classificação de casos quando há poucas amostras disponíveis, algo crítico para vigilância epidemiológica.
- Detecção precoce de surtos locais: classificação de municípios ou bairros como "em risco" ou "fora de risco" com base em poucas notificações iniciais e variáveis ambientais ou socioeconômicas.
- Predição de reincidência de violência ou agravos: análise de registros do SINAN e SIM para identificar padrões que indiquem maior probabilidade de repetição de eventos violentos, mesmo quando há poucos registros para treinamento.
- Triagem rápida em emergências: classificação imediata de pacientes com base em dados clínicos iniciais, útil para otimização de recursos em unidades de pronto atendimento.

Pontos fortes em relação a outros métodos

- Em bases pequenas, pode superar algoritmos clássicos como árvores de decisão, Random Forest ou GBDT, que geralmente precisam de muitos dados para alcançar alto desempenho.
- Rapidez de implementação, especialmente em contextos onde não há tempo para processos extensos de treinamento e validação.
- Maior adequação a problemas emergentes na saúde pública, onde novos agravos ou epidemias exigem respostas imediatas e não há um histórico robusto de dados.

Desafios e considerações

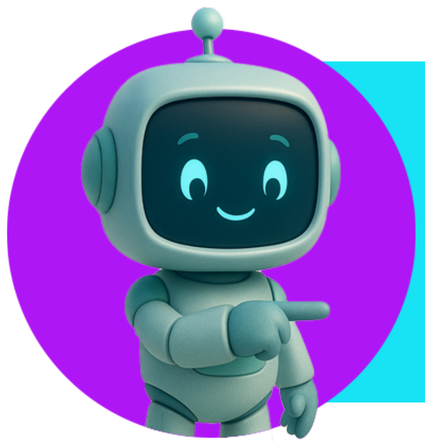
Apesar do seu potencial, o TabPFN ainda apresenta limitações para aplicação em larga escala na saúde:

- Tecnologia recente: a literatura científica e as validações no mundo real ainda são limitadas.
- Escopo restrito: atualmente, está mais voltado para tarefas de classificação supervisionada e pode exigir adaptações para outros tipos de problema (ex.: regressão, séries temporais).
- Infraestrutura e integração: embora rápido na inferência, exige recursos para integração com sistemas de saúde e pré-processamento adequado dos dados.

Perspectivas futuras

A tendência é que o TabPFN e métodos similares se tornem parte do arsenal de ferramentas para análise rápida e precisa em saúde, especialmente em situações onde:

- Há poucos dados disponíveis.
- O tempo para tomada de decisão é crítico.
- É necessário equilibrar desempenho com simplicidade de implementação.



A combinação de meta-aprendizado, deep learning e otimização para dados tabulares posiciona o TabPFN como uma tecnologia que pode redefinir a forma como utilizamos redes neurais na vigilância epidemiológica, tornando-as mais acessíveis e eficientes para problemas de baixa disponibilidade de dados.

Referências

Bishop, C. M. (1995). **Neural Networks for Pattern Recognition**. Oxford University Press.

Braga, A. P., Carvalho, A. C. P. L. F., & Ludermir, T. B. (2007). **Redes neurais artificiais: teoria e aplicações**. LTC.

Esteva, A., et al. (2017). **Dermatologist-level classification of skin cancer with deep neural networks**. Nature, 542, 115–118.

Hollmann, N., Müller, S., Müller, A. C., & Hutter, F. (2022). **TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second**. arXiv preprint, arXiv:2207.01848.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). **Deep learning**. Nature, 521, 436–444.

Hochreiter, S., & Schmidhuber, J. (1997). **Long short-term memory**. Neural Computation, 9(8), 1735–1780.

Shickel, B., Tighe, P. J., Bihorac, A., & Rashidi, P. (2018). **Deep EHR: A survey of recent advances in deep learning techniques for electronic health record (EHR) analysis**. IEEE Journal of Biomedical and Health Informatics, 22(5), 1589–1604.

Esteva, A., et al. (2017). **Dermatologist-level classification of skin cancer with deep neural networks**. Nature, 542, 115–118.

McCulloch, W. S., & Pitts, W. (1943). **A logical calculus of the ideas immanent in nervous activity**. The Bulletin of Mathematical Biophysics, 5, 115–133.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). **Learning representations by back-propagating errors**. Nature, 323, 533–536.

World Health Organization (WHO). (2021). **Ethics and governance of artificial intelligence for health**. WHO Press.

OPAS
Organização Pan-Americana da Saúde
Organização Mundial da Saúde
ESCRITÓRIO REGIONAL PARA AS Américas

SUS

MINISTÉRIO DA SAÚDE

PROFEPI

Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde