

PROFEPI

Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

Predição com machine learning

- Desenvolver algoritmos que façam boas predições em saúde.
- Principais razões técnicas pelas quais algoritmos às vezes não apresentam boa performance preditiva:

  - Extrapolação inadequada dos resultados.
  - Pré-processamento inadequado dos dados.
  - Sobreajuste (mais importante).
  - Validação inadequada da qualidade dos algoritmos.

- Se fizer a parte técnica correta, o motivo para a baixa performance preditiva é que não foram usadas variáveis preditoras fortes.

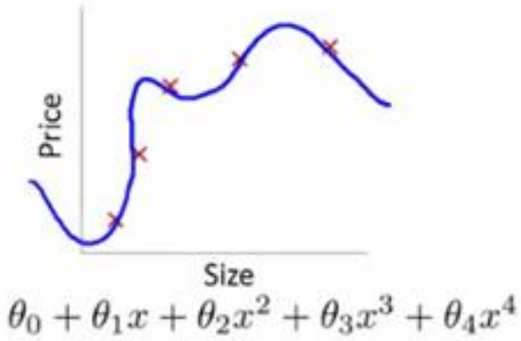
Extrapolação inadequada

- Desenvolver os algoritmos para uma população e esperar que funcionam corretamente para outra diferente.
  - Importar algoritmos dos EUA/Europa: nossas características genéticas e socioeconômicas são muito diferentes.
  - Extrapolação para períodos diferentes (cuidado com doenças sazonais).

Pré-processamento dos dados

- Técnicas de pré-processamento de dados
  - Seleção das variáveis.
  - Vazamento de dados.
  - Padronização.
  - Redução de dimensão.
  - Colinearidade.
  - Valores missing.
  - One-hot encoding.

Sobreajuste



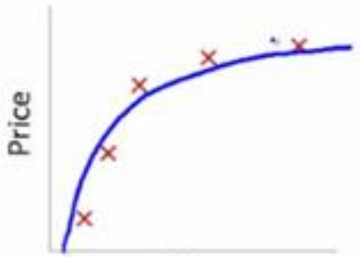
$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

High variance
(overfit)



$\theta_0 + \theta_1 x$

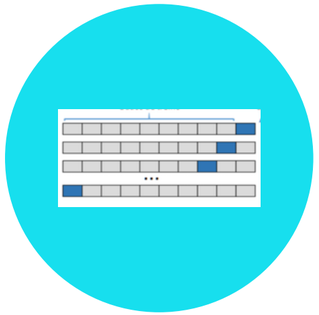
High bias
(underfit)



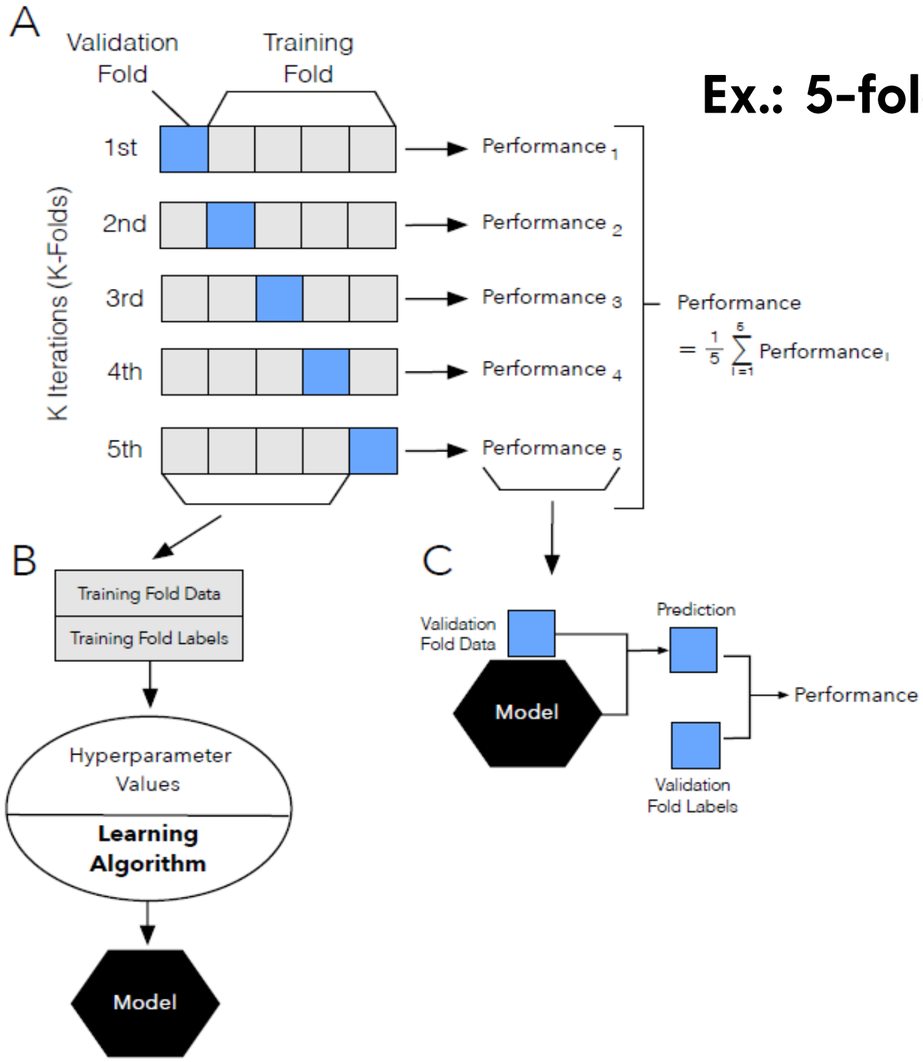
$\theta_0 + \theta_1 x + \theta_2 x^2$

"Just right"

Validação cruzada e otimização de hiperparâmetros



Introdução à validação cruzada k-fold



Ex.: 5-fold

- 5 modelos diferentes;
- Ajustados para conjuntos de treinamento distintos e parcialmente sobrepostos;
- Avaliados em conjuntos de validação não sobrepostos;
- Desempenho: média aritmética dos k desempenhos na validação.

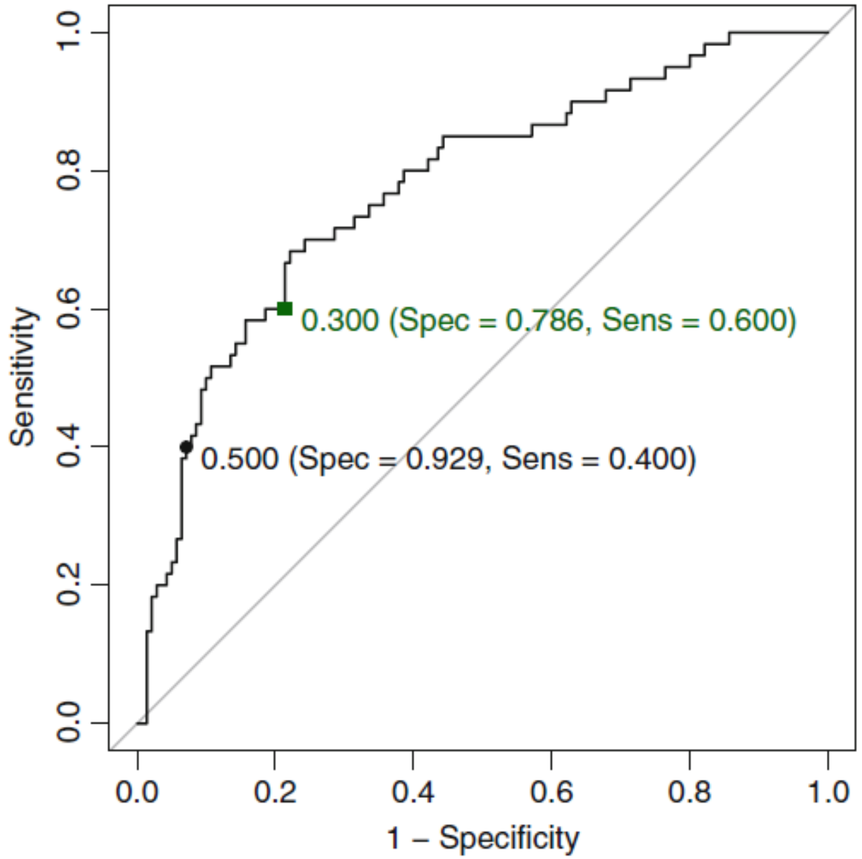
Medição de performance em problemas de regressão

- O mais comum é o uso da **raiz quadrada do erro quadrático médio** (RMSE, em inglês)
  - Subtrair cada valor real do seu valor predito e elevá-lo ao quadrado. Somar todos e dividir pelo número de observações. Tirar a raiz quadrada para retomar o valor à sua escala original.

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}$$

Área abaixo da curva ROC

- Matriz de confusão é baseada em o algoritmo dar > 50% de probabilidade.
- É possível melhorar a sensibilidade diminuindo o threshold?
  - Perfeito: 1,0
  - Ineficiente: 0,5
- Intuição: entre duas pessoas escolhidas aleatoriamente (em que uma tem o desfecho e a outra não), a AUC é a proporção de vezes que a predição será maior para a pessoa que de fato tem o desfecho



Data-driven advice for applying machine learning to bioinformatics

Randal S. Olson, William La Cava, Zairah Mustahsan, Akshay Varik, Jason H. Moore.
arXiv, 2018.

Análise da performance preditiva (acurácia de VC) de 13 algoritmos em 165 bancos de dados diferentes.

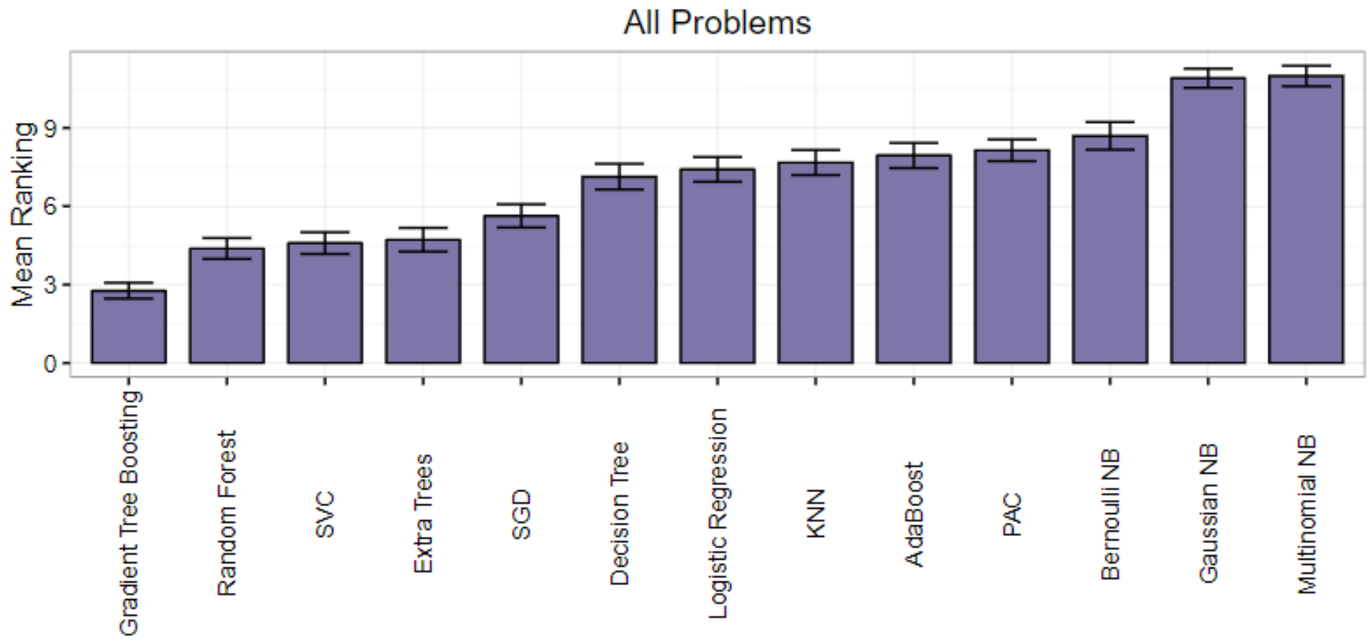


Fig. 1. Average ranking of the ML algorithms over all datasets. Error bars indicate the 95% confidence interval.

When Do Neural Nets Outperform Boosted Trees on Tabular Data?

Duncan McElfresh, Sujay Khandagale, Jonathan Valverde, Vishak Prasad C, Benjamin Feuer, Chinmay Hegde, Ganesh Ramakrishnan, Micah Goldblum, Colin White. arXiv 2023.

Table 9: Performance of algorithms according to ROC-AUC, over 98 datasets. Columns show the rank over all datasets, the average normalized ROC-AUC score (Mean AUC), the standard deviation of normalized ROC-AUC score across folds (Std. AUC), and the train time per 1000 instances. Min/max/mean/median are taken over all datasets.

		Rank				Mean AUC		Std. AUC		Time /1000 inst.	
Algorithm	Class	min	max	mean	med.	mean	med.	mean	med.	mean	med.
TabPFN*	PFN	1	17	5.30	3	0.91	0.97	0.17	0.07	0.25	0.01
CatBoost	GBDT	1	20	6.43	5	0.91	0.96	0.18	0.08	20.51	1.94
XGBoost	GBDT	1	19	7.17	6	0.90	0.96	0.19	0.09	0.84	0.38
ResNet	NN	1	21	8.23	7	0.84	0.93	0.19	0.12	15.83	8.78
SAINT	NN	1	21	8.35	7.50	0.84	0.93	0.19	0.12	170.31	145.99
RandomForest	base	1	20	8.64	8	0.87	0.94	0.19	0.10	0.41	0.28
DANet	NN	1	19	9.36	9	0.83	0.91	0.19	0.08	64.15	57.12
LightGBM	GBDT	1	21	10	9	0.83	0.91	0.22	0.10	0.89	0.29
NODE	NN	1	21	10.55	11	0.81	0.90	0.20	0.14	160.58	131.56
FTTransformer	NN	1	21	10.74	11.50	0.79	0.88	0.20	0.13	27.73	18.00
SVM	base	1	21	11.26	12.50	0.75	0.87	0.22	0.10	61.16	2.01
MLP-rtdl	NN	1	21	11.31	11	0.73	0.83	0.21	0.12	15.05	7.01
STG	NN	1	21	12.85	14	0.66	0.79	0.24	0.15	18.58	15.98
LinearModel	base	1	21	13.62	15	0.62	0.75	0.23	0.17	0.04	0.03
MLP	NN	1	21	14.13	15	0.65	0.71	0.23	0.14	18.17	11.16
TabNet	NN	1	21	14.46	16	0.63	0.75	0.32	0.19	35.06	29.32
DecisionTree	base	1	21	15.66	17	0.53	0.59	0.30	0.23	0.02	0.01
KNN	base	1	21	16.40	18	0.52	0.56	0.25	0.19	0.01	0.00
VIME	NN	1	21	16.74	18	0.49	0.50	0.30	0.20	17.84	15.55

Análise da performance preditiva de alguns dos algoritmos mais populares para dados estruturados em 98 bancos de dados

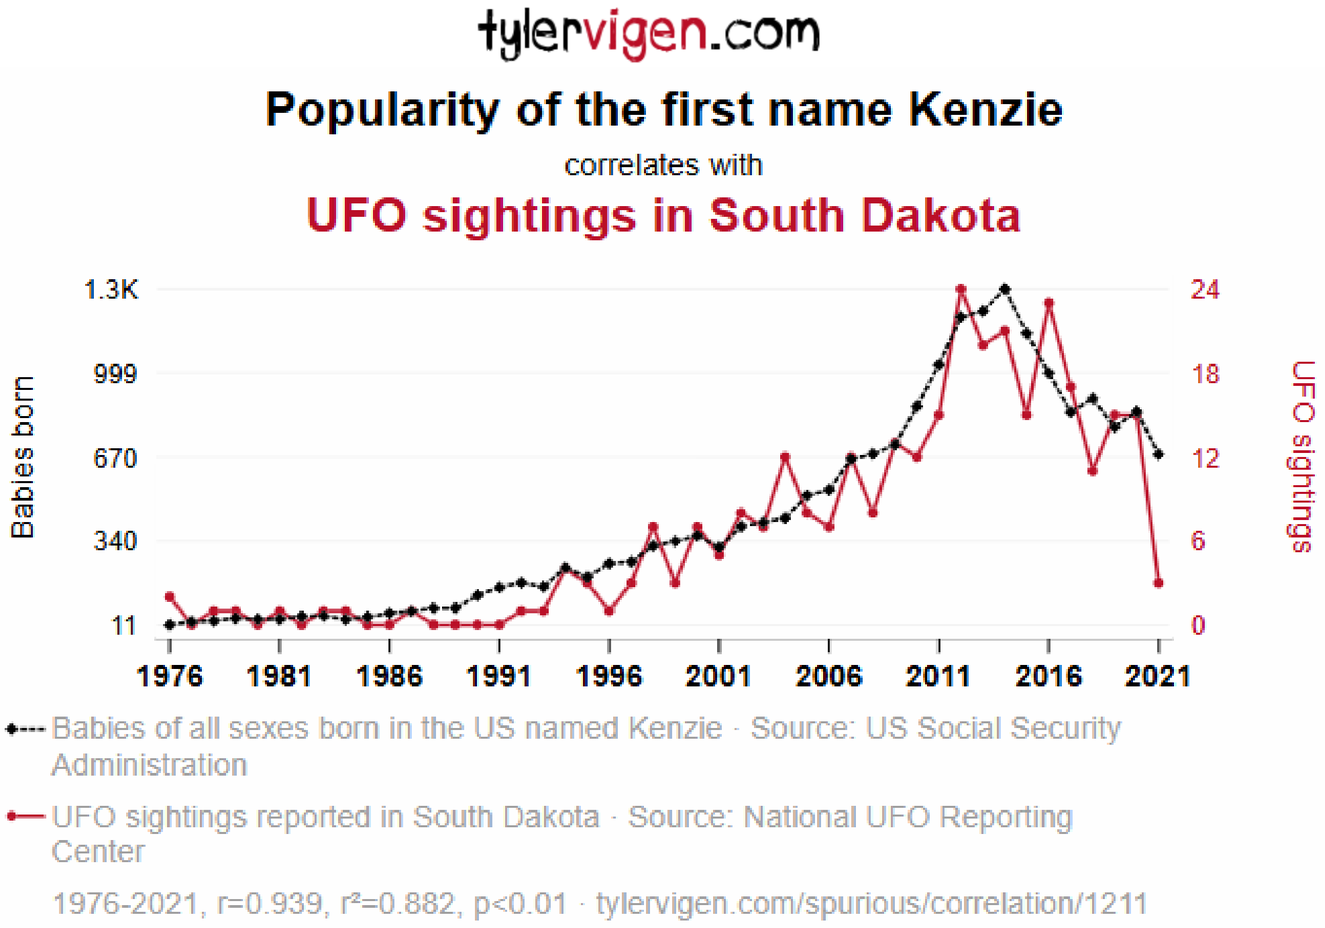
Pré-processamento de dados

1 - Preditores plausíveis:

- Pré-selecionar variáveis que sejam preditoras plausíveis (bom senso do pesquisador).

- Coincidências acontecem em análises de big data e pode ser que o algoritmo dê muita importância para associações espúrias

Pré-processamento de dados



Pré-processamento de dados

Entretanto não precisam ser causais.

- Exemplo: na predição de risco de uma pessoa ir a óbito talvez seja interessante incluir o fato de ela ter sido internada em UTI recentemente.
- O fato de ela ter ido para a UTI **não é a causa** de ela ir a óbito no futuro, é apenas um preditor (ninguém cogita proibir UTI para diminuir óbito).

Preditores não precisam causar o desfecho, apenas consistentemente predizê-lo (podem ter mediadores, serem uma proxy...).

Pré-processamento de dados

2 - Cuidado com vazamento de informação ("data leakage"):

- Acontece quando os dados apresentam informação escondida que faz com que o modelo aprenda padrões que não são do seu interesse
- Uma variável preditora tem escondida o resultado certo:
  - Não é a variável que está predizendo o desfecho, mas o desfecho que está predizendo ela.
  - A mesma pessoa aparece no treino e teste.

JOURNAL OF MEDICAL INTERNET RESEARCH Chiavegatto Filho et al

Letter to the Editor

Data Leakage in Health Outcomes Prediction With Machine Learning. Comment on "Prediction of Incident Hypertension Within the Next Year: Prospective Study Using Statewide Electronic Health Records and Machine Learning"

Alexandre Chiavegatto Filho, PhD; André Filipe De Moraes Batista, MSc, PhD; Hellen Geremias dos Santos, MPH, PhD

Department of Epidemiology, School of Public Health, University of São Paulo, São Paulo, Brazil

Pré-processamento de dados

Exemplo

Incluir o número identificador do paciente como variável preditora

Problema

- Se pacientes de hospital especializado em câncer tiverem números semelhantes.
- Se o objetivo for predizer câncer, algoritmo irá dar maior probabilidade a esses pacientes.
- Esse algoritmo aprendeu algo interessante para o sistema de saúde?

Motivo

- Motivo pelo qual os dados e os algoritmos de machine learning precisam ser abertos.
- Sempre analisar importância preditora das variáveis (Shapley).

Variáveis colineares

PRÉ-PROCESSAMENTO DOS DADOS
PADRONIZAÇÃO
REDUÇÃO DE DIMENSÃO
► VARIÁVEIS COLINEARES
VARIÁVEIS MISSING
ONE-HOT ENCODING

- Uma forma de diminuir a presença de variáveis com alta correlação é excluí-las.
  - Variáveis colineares trazem informação redundante (tempo perdido).
  - Além disso, aumentam a instabilidade dos modelos.
  - Estabelecer um limite de correlação com alguma outra variável (0,75 a 0,90).

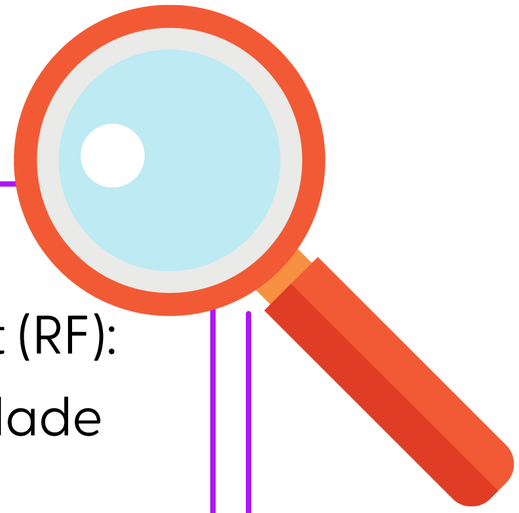
- Após seleção de preditores plausíveis e retirada de possíveis casos de vazamento de informação:
  - Muitas vezes é importante reduzir o número de variáveis para:
    - Facilitar a coleta dos dados (principalmente para a utilização dos algoritmos em regiões remotas, com menor estrutura).
    - Diminuir o tempo de treinamento dos algoritmos.
    - Fazer uma segunda triagem de preditores plausíveis (diminuir o ruído).

Artigo:

Evaluation of variable selection methods for random forests and omics data sets

Authors: Frauke Degenhardt, Stephan Seifert and Silke Szymczak.

Resumo



Comparação das abordagens de seleção de variáveis para alta dimensionalidade através de simulações utilizando o Random Forest (RF):

- **Boruta** : 1° Melhor/só ele pode ser usado com baixa dimensionalidade
- Importância variável relativa recorrente
- Permutação
- Eliminação recursiva de variáveis

ALGORITMOS DE
Machine Learning

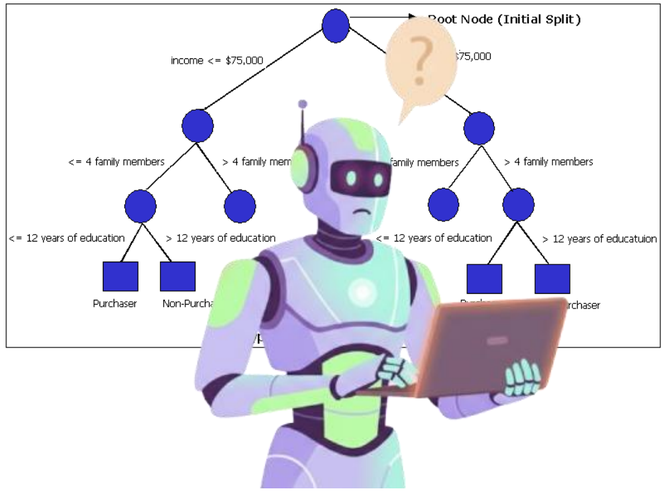
Regressões penalizadas

$$\mathrm{SSE}_{L_1} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{P} |\beta_j|.$$

- A penalização ridge encolhe os parâmetros, mas não reduz nenhum a 0, ou seja, não faz seleção de variáveis.
- Para isso, existe a penalização lasso (L1).
- Lasso faz regularização e seleção de variáveis preditoras, pela penalização dos valores absolutos dos parâmetros.

Como as árvores de decisão funcionam?

- Árvore de decisão é um método de ML que usa um gráfico semelhante a uma árvore
- O nó interno representa um teste em uma variável
- Cada ramo divide os dados em dois grupos
- As observações são atribuídas ao nó adequado
- O resultado da folha é a predição final



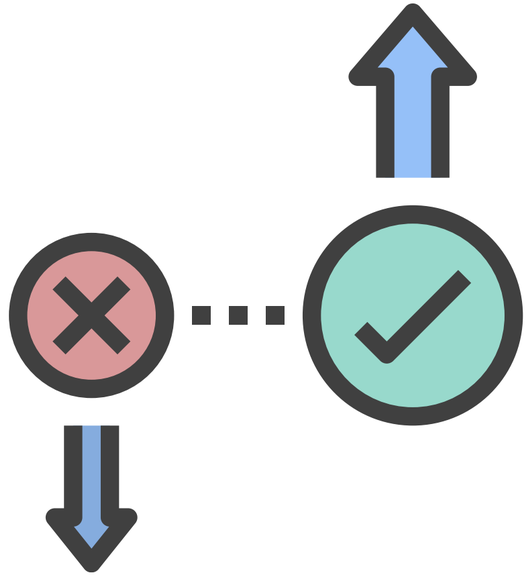
Exemplo: comprar um computador ou não

A predição do modelo mostra que um jovem estudante vai comprar

Feature importance nas árvores de decisão

- Métrica que quantifica a relevância de cada variável para as decisões de um modelo.
- Baseia-se na redução de impureza, que é a principal forma como as árvores de decisão são construídas.
- A importância de uma variável é a soma total da redução de impureza que ela gerou em todas as divisões da árvore.
- Essa pontuação é maior se a redução de impureza for alta e se o nó contiver muitas amostras.

Eliminação Recursiva de Variáveis



- Objetivo: encontrar um conjunto mínimo de variáveis
- A redução das variáveis é realizada de forma recursiva (retirada das variáveis menos importantes):
  - Até restar apenas uma variável (ranking recalculado a cada novo conjunto de variáveis)
- A performance preditiva é sempre mensurada nas observações que ficam de fora (out-of-bag)
- Melhor conjunto de variáveis será o que proporcionar um menor erro
- Método popular, muito utilizado com dados moleculares

Boruta



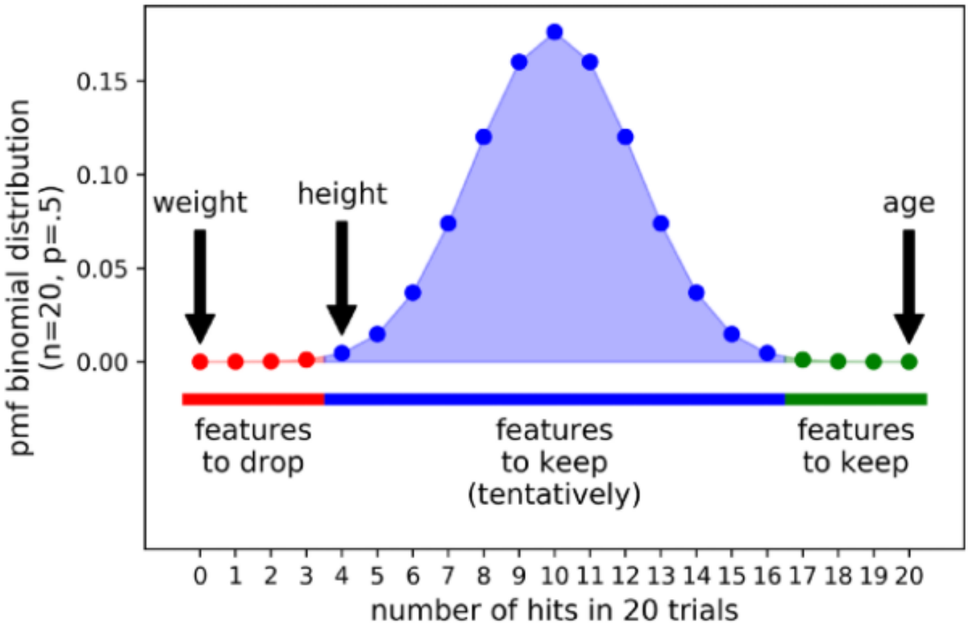
- Compara as importâncias das preditoras reais com “sombras”.
- A cada execução é gerada uma cópia de cada variável
- Valores das sombras são permutações das variáveis originais
- Random Forest é treinado com essa extensão dos dados
- Comparar a importância de variáveis reais com o valor máximo das sombras:
  - Variáveis só são relevantes se forem mais importantes do que todas as permutadas.

Boruta

Boruta explained the way I wish someone explained it to me

Looking under the hood of Boruta, one of the most effective feature selection algorithms

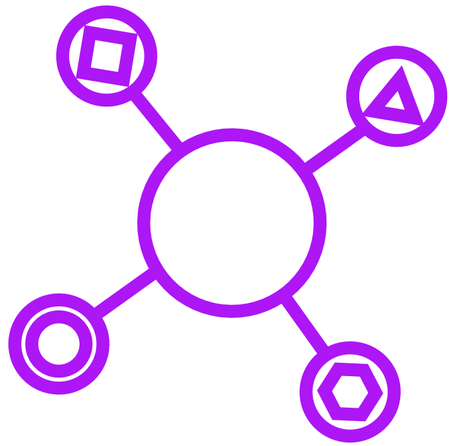
Medium / Samuele Mazzanti / 17 de mar. de 2020



Binomial distribution and positioning of the features

- Repetir o processo várias vezes e transformar em uma distribuição binomial
- Hit: quando a variável é mais importante que a sombra mais importante.
- Sombras e variáveis menos importantes são retiradas e o processo é repetido até haver uma classificação para cada variável.

Permutação



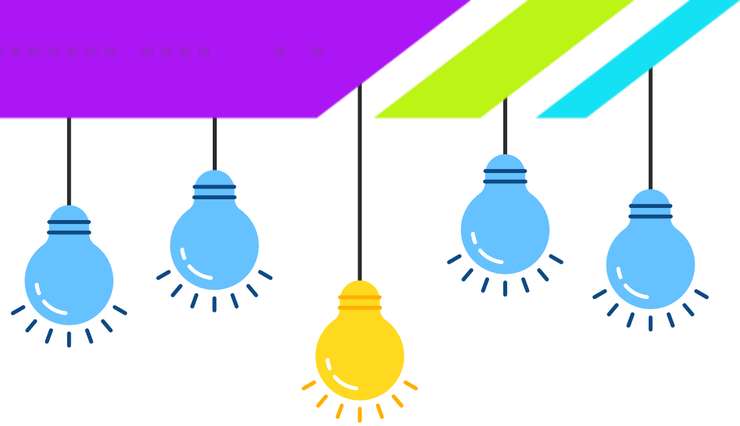
- Aplica-se um teste de permutação padrão
- Permuta valores do desfecho, ao contrário do Boruta
- Padrões de correlação ficam intocados
- Repetições das permutações
- Se a importância da variável no desfecho real for maior do que em todas as permutações, ela é selecionada como importante

Importância variável relativa recorrente

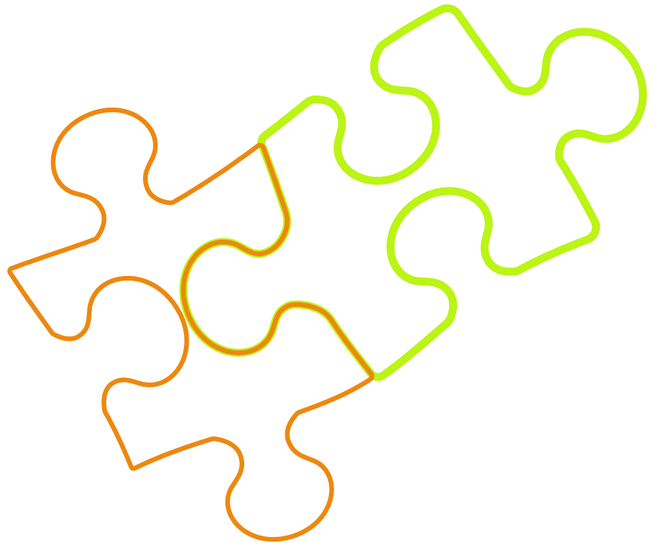


- Gera-se várias RF com o mesmo conjunto de dados e valores de parâmetros que diferem apenas na semente aleatória
- Cada RF é usada para calcular valores de importância preditora
- Esses são divididos pela importância mínima absoluta de cada execução
- São importantes aquelas com a importância maior ou igual a um valor especificado

Discussão e Conclusão



- Os estudos de simulação identificaram o algoritmo Boruta como melhor
- Boruta ideal também para trabalhar com baixa dimensionalidade
- Os resultados dos estudos de simulação são semelhantes tanto para as configurações de regressão quanto para classificação



Obrigado!

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho

@labdaps

alexdiasporto@usp.br

Referência: Degenhardt, F., Seifert, S., & Szymczak, S Evaluation of variable selection methods for random forests and omics data sets. Briefings in bioinformatics, 20(2), 492-503. (2019).