

PROFEPI

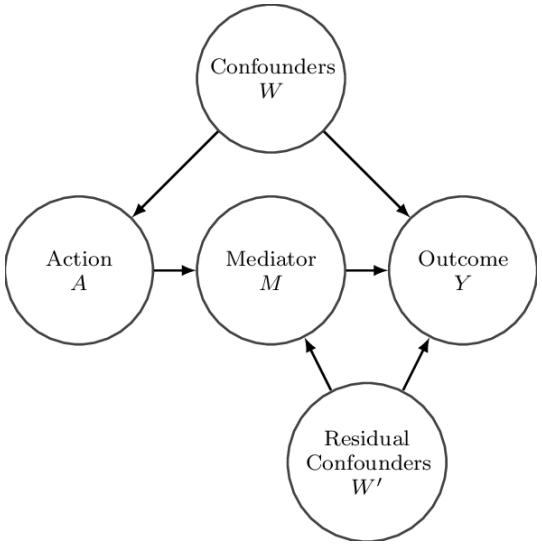
Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

A busca por algoritmos interpretáveis

Muito se fala sobre necessidade de “interpretação” dos algoritmos.

O objetivo de uma predição **não é compreender a causalidade de um fenômeno**, é predizê-lo!

Se o interesse for causalidade: usar métodos causais.



A busca por algoritmos interpretáveis

Am J Public Health. 2018 May; 108(5): 616–619.
Published online 2018 May. doi: 10.2105/AJPH.2018.304337
PMCID: PMC5888052
PMID: 29565659

The C-Word: Scientific Euphemisms Do Not Improve Causal Inference From Observational Data

Miguel A. Hernán, MD, DrPH

Abstract

Go to:

Causal inference is a core task of science. However, authors and editors often refrain from explicitly acknowledging the causal goal of research projects; they refer to causal effect estimates as associational estimates.

This commentary argues that using the term “causal” is necessary to improve the quality of observational research.

Specifically, being explicit about the causal objective of a study reduces ambiguity in the scientific question, errors in the data analysis, and excesses in the interpretation of the results.

A busca por algoritmos interpretáveis

Entretanto é sim possível interpretação da importância das variáveis em algoritmos preditivos.

- Importante: não confundir com causalidade.
- **Exemplo**: na predição de risco de uma pessoa ir a óbito talvez seja interessante incluir o fato de ela ter sido internada em UTI recentemente.
- O fato de ela ter ido para a UTI **não é a causa** de ela ir a óbito no futuro, é apenas um preditor (ninguém cogita impedir idas à UTI para diminuir óbito).

A busca por algoritmos interpretáveis

Conclusão: interpretação em machine learning não é causalidade, mas sim uma forma de entender como o algoritmo realizou a predição.

A busca por algoritmos interpretáveis

Por que interpretação:

- Identificar presença de preditores indesejáveis (vazamento de dados).
- Auxiliar na adesão pelos profissionais (médicos aceitarão melhor se entenderem como toma a decisão).

A busca por algoritmos interpretáveis

Por que interpretação:

- Garantir maior robustez (se o algoritmo de carro sem condutor está identificando motos pela roda, cuidado com motos com bolsas laterais).
- Identificar preconceitos (pode ser que o algoritmo esteja usando raça para rejeitar empréstimos bancários).

A busca por algoritmos interpretáveis

Por que **não** ter interpretação:

- **Manipular o sistema**: Imaginem se forem divulgados como um algoritmo estabelece prioridades para receber cirurgia, e uma das variáveis for morar no Butantã (bairro menos poluído de SP). As pessoas vão começar a dizer que moram no Butantã para manipular o algoritmo.

A busca por algoritmos interpretáveis

Por que **não** ter interpretação:

- **Manipular o sistema**: Imaginem se forem divulgados como um algoritmo estabelece prioridades para receber cirurgia, e uma das variáveis for morar no Butantã (bairro menos poluído de SP). As pessoas vão começar a dizer que moram no Butantã para manipular o algoritmo.


FOLHA DE S.PAULO

copa 2018

Brecha no ranking da Fifa prejudica seleções que jogam muitos amistosos

A busca por algoritmos interpretáveis

Possibilidades para interpretação:

- **Interpretação intrínseca**: utilizar algoritmos interpretáveis (regressão linear/logística ou árvores simples de decisão).
- **Interpretação extrínseca (explicabilidade)**: utilizar técnicas que permitem retirar interpretação de algoritmos complexos após o treinamento.

A busca por algoritmos interpretáveis

Solução mais comum:

Análise da mudança do erro de predição ao **permutar valores** da variável.

- Variável é importante para predição se erro aumenta.
- Se o modelo não utiliza essa variável o erro não muda.
- Outras soluções utilizando estratégias um pouco mais complexas (LIME, Shapley).

Estratégias para Identificação de Variáveis Preditivas em Saúde e Vigilância

Por que isso é importante?

- A vigilância em saúde lida com grandes volumes de dados (SINAN, SIM, SIH, e-SUS).
- Precisamos saber quais variáveis realmente ajudam a prever riscos (ex.: repetição de violência, óbitos por causas evitáveis, hipertensão em crianças).
- Isso permite priorizar intervenções e recursos no SUS.

O que é o SHAP?

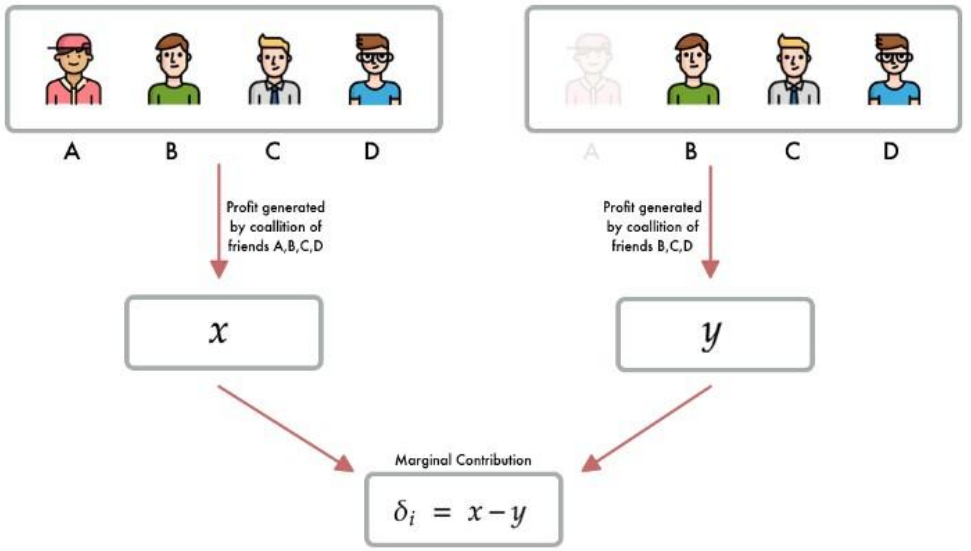
SHAP = SHapley Additive exPlanations

- Origem: teoria dos jogos de Shapley
- Ideia: medir a contribuição individual de cada variável na predição de um modelo
- Funciona em qualquer algoritmo (árvores, redes neurais, regressões, etc.)

O que é o SHAP?

Explicando predições individuais

- O objetivo é identificar a contribuição individual de cada jogador (variável).
- O valor de Shapley nos diz quanto cada variável muda a predição da predição média.
- O valor de Shapley é a contribuição média marginal de cada variável ao longo de todas as combinações possíveis de variáveis.



O que é o SHAP?

Explicando predições individuais

- Criar o conjunto de todas as combinações de valores existentes de variáveis F (chamadas coalizões).
- Calcular a predição de cada modelo.
- Para cada coalizão, calcular a diferença entre a predição do modelo com valor de F e a predição sem ela.

O que é o SHAP?

Explicando predições individuais

- Para cada coalizão, calcular a diferença entre a predição do modelo com esse mesmo valor de F e a predição sem ela.
- Para cada coalizão, calcular quanto F mudou a predição do modelo (ou seja, passo 4 – passo 3) – essa é a contribuição marginal de F.
- Valor de Shapley = a média de todos os valores calculados no passo 5 (ou seja, a média das contribuições marginais de F)

Propriedades dos valores de SHAP?

Aditividade

- Cada variável contribui de forma independente para a predição.
- **Exemplo**: ao prever risco de óbito hospitalar, podemos decompor quanto a idade, a presença de comorbidades e o histórico de internação contribuíram para a predição final.

Propriedades dos valores de SHAP?

Precisão local

- O SHAP mostra exatamente por que um paciente específico recebeu determinada predição.
- **Exemplo**: por que a Maria foi classificada como alto risco de repetição de violência? O modelo mostra que o fator mais pesado foi o histórico de notificações anteriores.

Propriedades dos valores de SHAP?

Falta (robustez a variáveis ausentes)

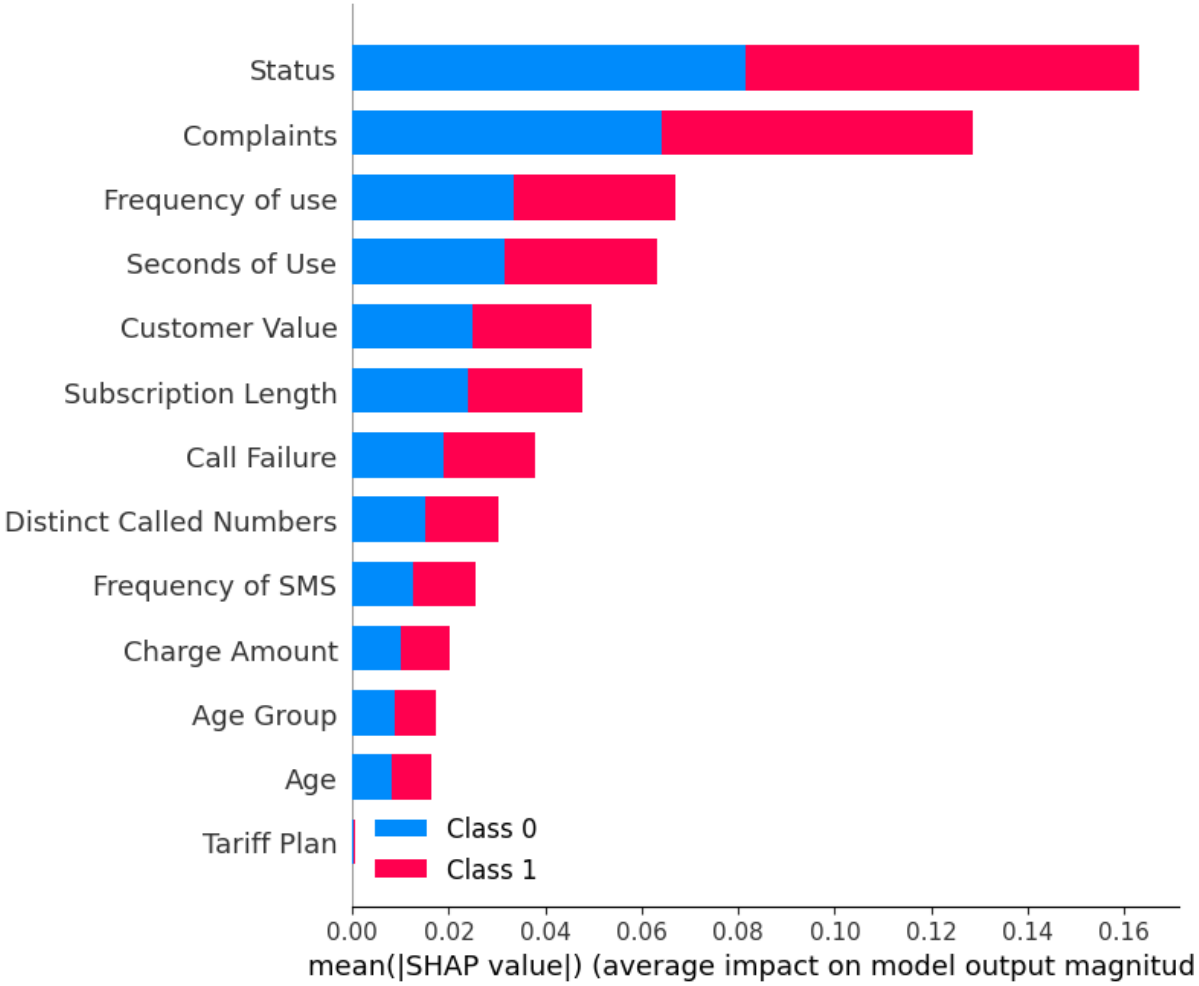
- Se uma variável está ausente ou não é relevante, sua contribuição no SHAP é zero.
- **Exemplo**: se a variável "ocupação" não tem impacto na predição de hipertensão em crianças, ela não distorce a interpretação.

Propriedades dos valores de SHAP?

Consistência

- Se a importância real de uma variável aumenta, o valor SHAP dela também aumenta.
- **Exemplo**: se em um novo modelo a variável "IMC" ganha mais relevância para prever hipertensão, isso será refletido nos valores SHAP

Resumo do enredo



- **O eixo Y** indica os nomes dos recursos em ordem de importância, de cima para baixo.
- **O eixo X** representa o valor SHAP, que indica o grau de alteração nas probabilidades de registro.
- A **cor** de cada ponto no gráfico representa o valor do recurso correspondente, com o vermelho indicando valores altos e o azul indicando valores baixos.
- Cada **ponto** representa uma linha de dados do conjunto de dados original.

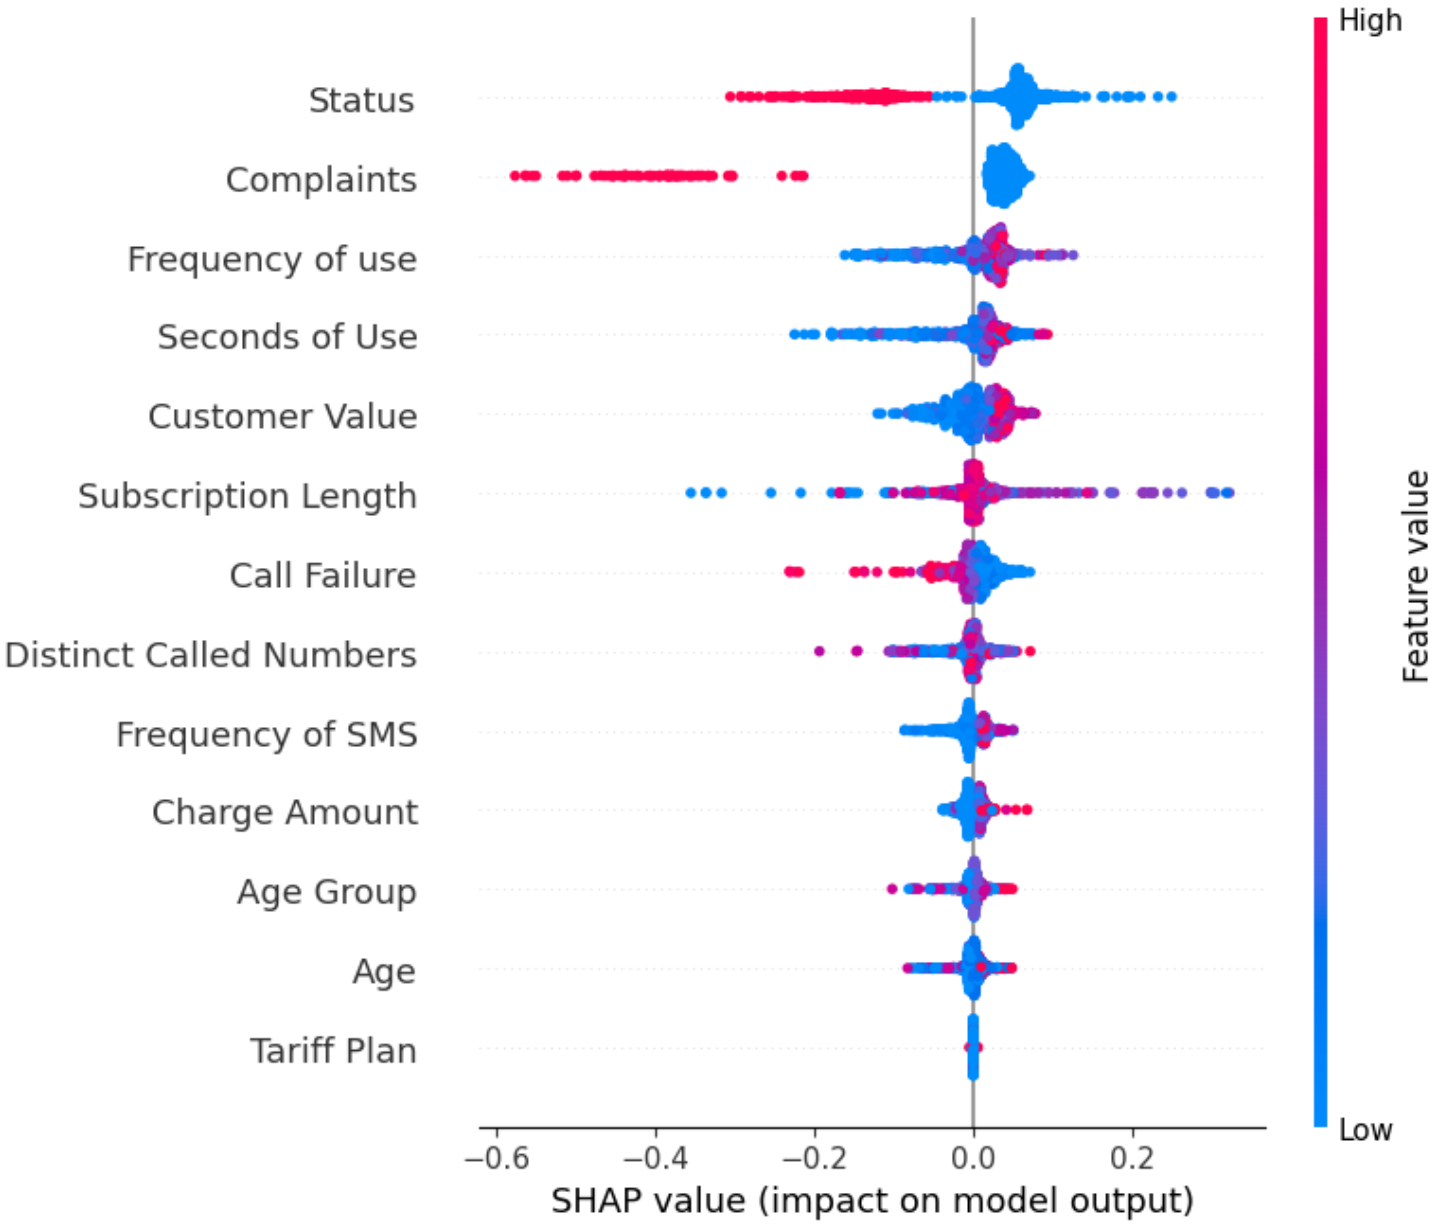
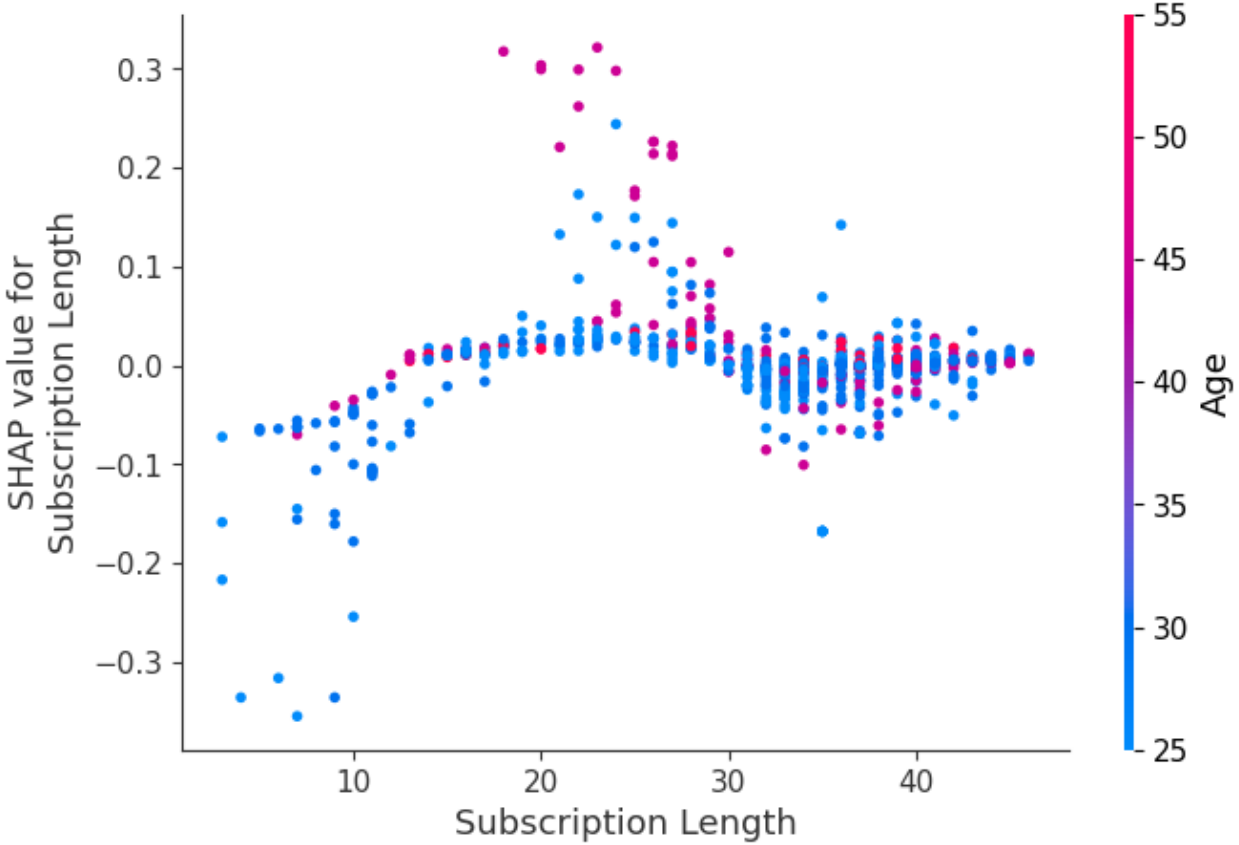

Status
Complaints
Frequency of use
Seconds of Use
Customer Value
Subscription Length
Call Failure
Distinct Called Numbers
Frequency of SMS
Charge Amount
Age Group
Age
Tariff Plan
−0.6
−0.4
−0.2
0.0
0.2
SHAP value (impact on model output)
High
Feature value
Low

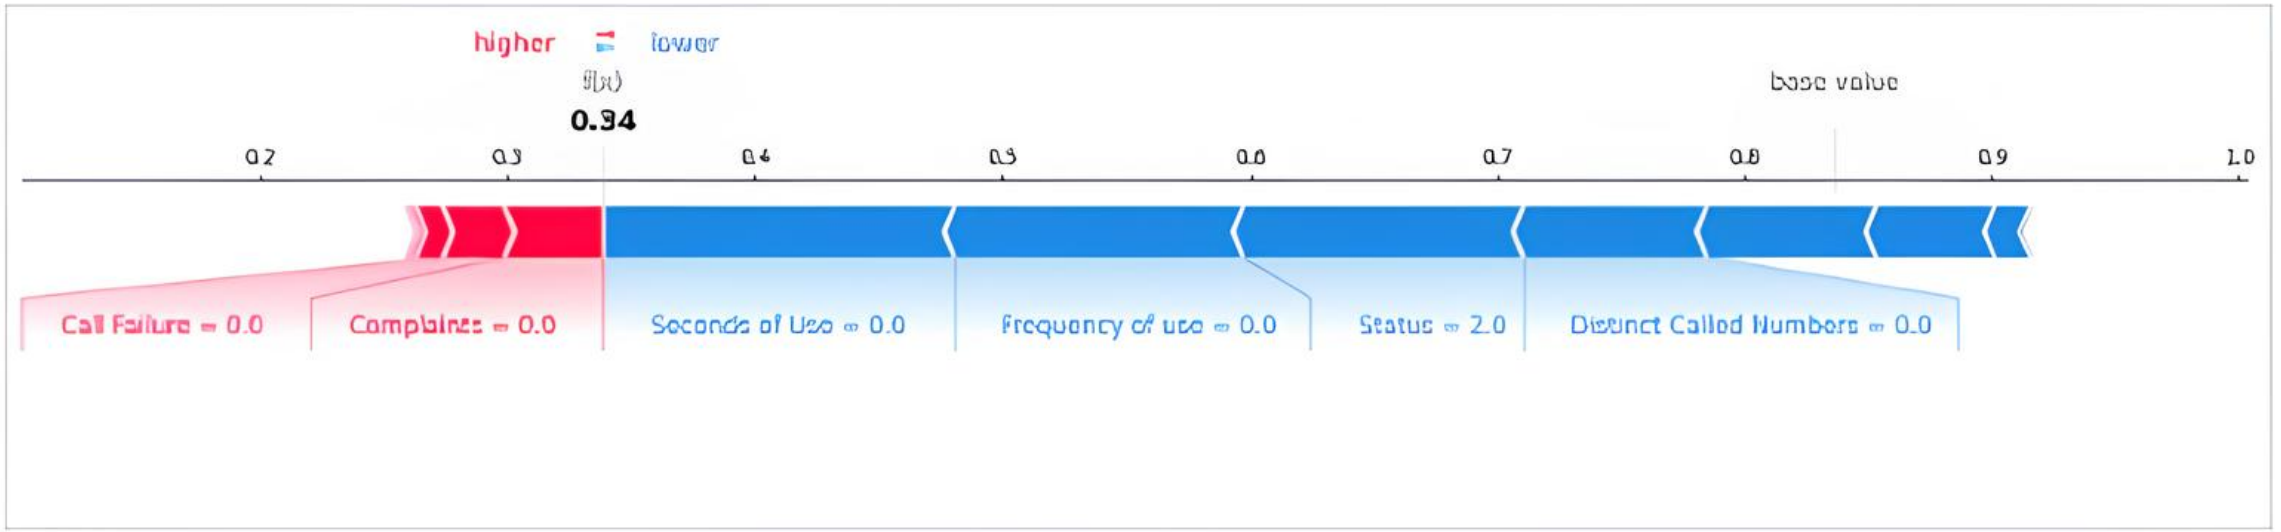
Gráfico de dependência



Tipo de gráfico de dispersão que mostra como as previsões de um modelo são afetadas por um recurso específico (comprimento da assinatura).

Em média, a duração das assinaturas tem um efeito positivo no modelo.

Gráfico de força



©2022 Christoph Molnar Anything missing? Please send feedback to christoph.molnar.ai@gmail.com version 1.0

SHAP Plots For Tabular Data – Interpretation Cheat Sheet

Quick Guide

- Explain single prediction ⇒ waterfall or force plot
- Overall effects + importance ⇒ beeswarm plot
- Feature effect in detail ⇒ scatter plot

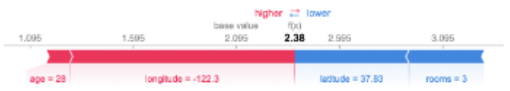
Example: Explain model that predicts house value (in $100k) from age, longitude, latitude an no. of rooms.

Waterfall Plot (Single)



- Visualizes Shapley values $\phi_{i,j}$ as arrows that either increase or decrease prediction $f(x_i)$ compared to expected prediction $E[f(x)]$.
- *Example*: The predicted value ($238k) of house #3 is larger than the average $209.5k. Longitude of -122.3 and, to lesser extent, age of 28 increase prediction; latitude of 37.83 and rooms=3 decrease predicted value, but don't cancel out the positive effects.

Force Plot (Single)

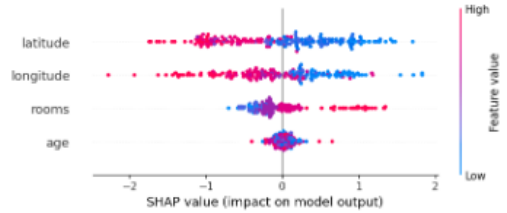


Rearrangement of arrows from waterfall plot.

Bar Plot (Single)

Also a rearrangement of arrows from waterfall plot. But no space left for the plot here. Sorry.

Summary / Beeswarm Plot (Multi)



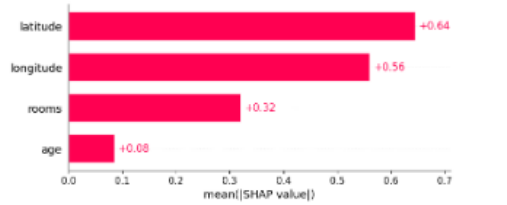
Each point is a Shapley value $\phi_{i,j}$. Color indicates the value of the feature. *Example*: latitude and longitude have the highest spread of Shapley values, which makes them the most important features; the lower the latitude/longitude, the higher the Shapley value and therefore the predicted house value.

Force Plot (Multi)



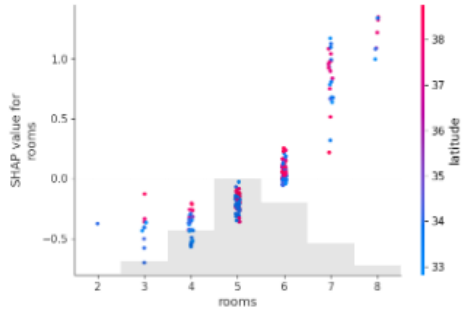
Individual force plots vertically put together. Difficult to interpret; better use summary plot.

Importance / Bar Plot (Multi)



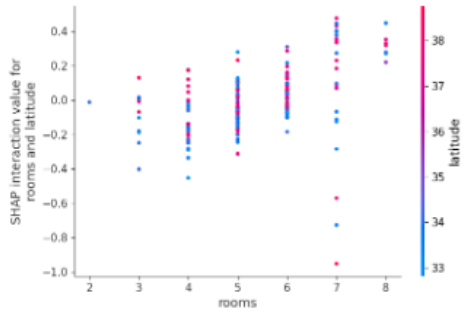
Summary plot reduced to importance: mean of $|\phi_j|$

Dependence / Scatter Plot (Multi)



Plot shows how Shapley values $\phi_{i,j}$ change with increasing value of feature j. 1 dot per data instance. Color based on the feature k that interacts most with j. *Example*: The higher the number of rooms the higher the associated Shapley value and therefore the predicted house value.

Interaction / Scatter Plot (Multi)



Plot shows how *interaction Shapley values* $\phi_{i,jk}$ change with increasing feature j (x-axis); color based on feature k. Interaction = combined effect on prediction after accounting for individual effects. *Example*: More rooms means higher house value due to interactions with latitude.

Aplicações de valores SHAP

🔍 Depuração de modelos

- Permite identificar distorções nos dados.
- **Exemplo**: se o modelo de risco de mortalidade hospitalar usa "tempo de internação" (variável pós-desfecho), o SHAP ajuda a detectar esse erro.

📊 Importância dos preditores

- Ajuda a selecionar variáveis mais relevantes e descartar as de baixo impacto.
- **Exemplo**: em um modelo de predição de hipertensão em crianças, o SHAP pode mostrar que "IMC" é muito mais relevante do que "número de consultas médicas no último mês".

Aplicações de valores SHAP

👤 Explicação individual (local)

- Mostra quais fatores foram determinantes para a predição de um caso específico.
- **Exemplo**: por que a vítima X foi classificada como alto risco de repetição de violência? O SHAP mostra que o fator principal foi “notificações anteriores”.

🌐 Resumo global do modelo

- Gráficos SHAP permitem visualizar os fatores mais importantes em toda a base de dados.
- **Exemplo**: em análises do SIM, pode revelar que “idade” e “nível de escolaridade” são os maiores preditores de mortalidade por DCNT.

Aplicações de valores SHAP

⚖️ Detecção de vieses

- Identifica se variáveis afetam desproporcionalmente determinados grupos.
- Exemplo: verificar se “raça/cor” está influenciando indevidamente a predição de risco de hospitalização.

🛡️ Auditoria e ética

- Facilita avaliação de imparcialidade e conformidade ética.
- Exemplo: verificar se um modelo de priorização de cirurgias não está discriminando grupos sociais.

📄 Aprovação regulatória

- SHAP ajuda a justificar decisões de modelos para órgãos reguladores.
- Exemplo: explicar de forma clara por que um algoritmo do SUS classificou um grupo como prioridade em determinada intervenção.

Vantagens

Interpretação local e global

- Permite entender tanto o que influencia um caso específico quanto os fatores mais importantes no conjunto todo.
- **Exemplo**: explicar por que um paciente foi classificado como alto risco de óbito e, ao mesmo tempo, mostrar que idade e comorbidades são os principais preditores na base inteira.

Vantagens

Compatível com qualquer algoritmo

- Funciona com modelos lineares, árvores de decisão, redes neurais, ensembles.
- **Exemplo**: pode ser aplicado tanto em uma regressão logística simples quanto em um XGBoost ou rede neural profunda.

Vantagens

Intuitivo e com boas visualizações

- Gráficos como beeswarm, waterfall e force plots facilitam a comunicação.
- **Exemplo**: gestores de saúde conseguem ver de forma clara quais variáveis pesaram mais na decisão do modelo.

Explicando o modelo de comportamento global

- Comportamento esperado médio em um banco de dados
- Importância da variável é o seu efeito total na predição
- Algumas medidas de importância utilizam a exclusão de variáveis do treino e subsequente retreino do modelo
- Efeito da variáveis é como uma mudança na variável afeta a predição do desfecho

Modelos substitutos

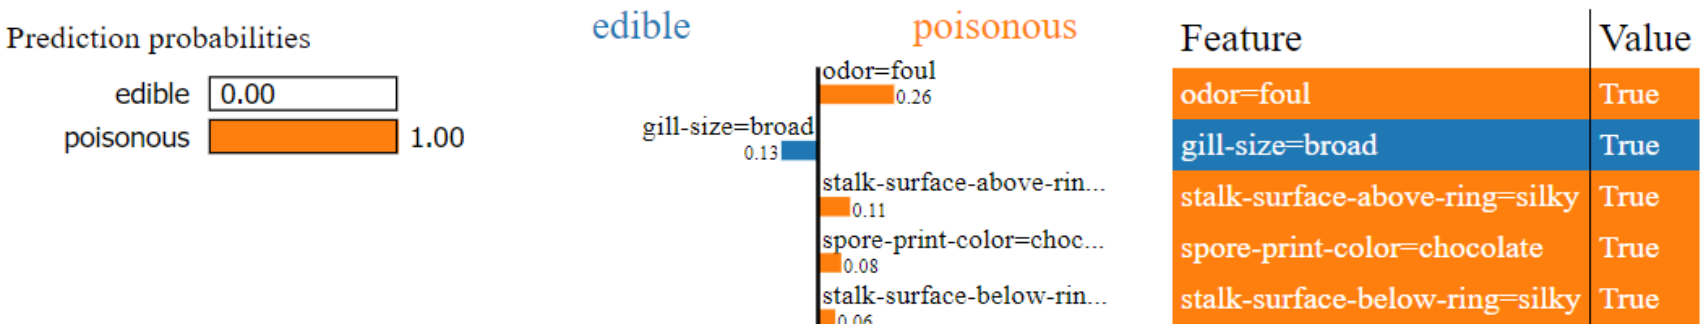
- Projetados para copiar o comportamento do modelo original de ML
- Interpretação baseada na análise dos componentes do modelo substituto (que é interpretável)
- Ex.: regressão linear com as mesmas variáveis.
- Frequentemente são usados métodos para extrair regras de decisão (ex.: pesos na NN)

Modelos substitutos



LIME é um método substituto local

- Gera um novo banco de dados com valores ligeiramente alterados das variáveis para ver predição.
- Modelo interpretável (e.g. regressão linear) a partir desses resultados.



Ribeiro, M. T., Singh, S., & Guestrin, C. (2016, August). " Why should i trust you?" Explaining the predictions of any classifier. In Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining (pp. 1135-1144).

Desafios

Incerteza estatística e inferência

- Muitos métodos fornecem explicações sem quantificar a incerteza
- Os modelos estão sujeitos à incerteza
- Precisamos fazer suposições estruturais ou distributivas
- Essas suposições precisam ser testadas

Desafios

Interpretação causal

- Um modelo deve refletir a estrutura causal para ter uma interpretação causal
- Desempenho preditivo x causalidade
- Exemplo: O tempo hoje causa o tempo de amanhã.

Mas...

Desafios

Tempo hoje



Tempo amanhã



Desafios

Tempo hoje



Variável disponível:
Solo úmido

Tempo amanhã



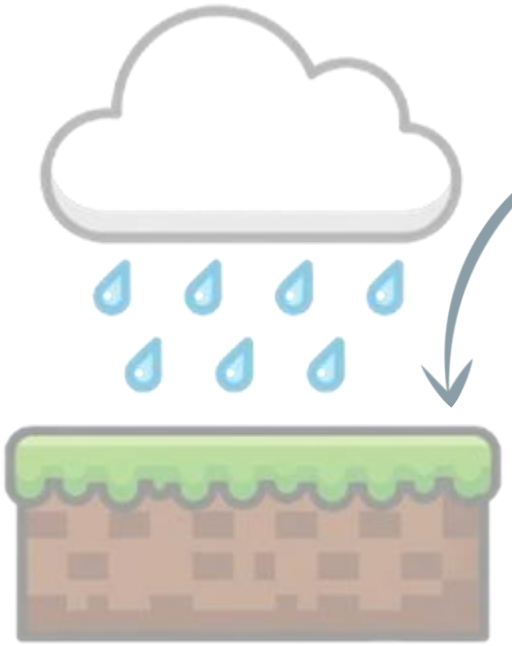
Desafios

Solo úmido
não causa um dia seguinte chuvoso...

Tempo hoje

Variável disponível:
Solo úmido

Tempo amanhã





Desafios

Dependência de variáveis

- Traz problemas em relação a atribuição e extrapolação
- Atribuição de importância - difícil quando as variáveis são correlacionadas
- Muitos métodos baseados em sensibilidade permutam variáveis
- No caso de alta correlação com outras variáveis esse efeito se perde
- Não existe efeito independente na prática
- Extrapolação pode gerar interpretações enganosas

Desafios

Definição de interpretabilidade

- Falta de definição é um problema
- Não existe uma forma direta de quantificar o quão interpretável é um modelo (ao contrário de performance preditiva) – não se sabe o "valor real"
- Duas principais formas de avaliar interpretabilidade:
- Métricas matematicamente quantificáveis, e
- Conversar com especialistas na área

Proximos desafios

Definição de interpretabilidade

- Necessidade de uma visão dinâmica da interpretação de ML
- Da coleta dos dados até o seu uso final
- Como explicar predições para indivíduos com backgrounds diferentes
- Necessidade do campo da interpretabilidade se estender para outros domínios, como psicologia e sociologia

Limitações

⚠ Alto custo computacional em modelos grandes

- Exige muitos cálculos para estimar a contribuição das variáveis.
- **Exemplo**: rodar SHAP em uma base nacional como o SIM pode demandar muito tempo e infraestrutura computacional.

⚠ Requer cuidado na interpretação

- O SHAP mostra impacto na predição, não causalidade.
- **Exemplo**: notificações prévias de violência podem ser um excelente preditor, mas não significam que sejam a causa da violência.

Obrigada!

Keisyanne de Araujo Moura

@labdaps

keisyannemoura@usp.br

