

PROFEPI

Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

Transfer Learning (TL)

- **TL** : transferência de conhecimento do domínio de origem para o domínio de destino.
- Objetiva melhorar o desempenho do modelo em um local com poucos dados.
- **TL vs ML tradicional**: TL envolve vários domínios e tarefas, ao contrário do ML tradicional que utiliza domínio único.

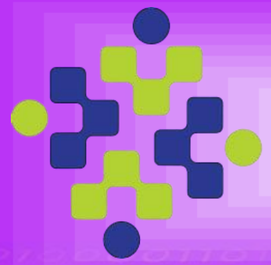
Agarwal, N., Sondhi, A., Chopra, K. and Singh, G., 2021. Transfer learning: Survey and classification. Smart Innovations in Communication and Computational Sciences: Proceedings of ICSICCS 2020, pp.145-155.

Transfer Learning (TL)

- **O que transferir?** Conhecimento adquirido (modelo pré-treinado / pesos)
- **Como transferir?** Historicamente mais comuns: redes neurais (Deep Learning)
- **Quando transferir?**
  - Disponibilidade de dados (abundante vs escasso)
  - Similaridade dos bancos (mesmos desfechos ou relacionados)
  - O modelo a ser transferido precisa melhorar a sua performance
  - Muito aplicado para imagens e NLP

Hosna, A., Merry, E., Gyalmo, J., Alom, Z., Aung, Z. and Azim, M.A., 2022. Transfer learning: a friendly introduction. Journal of Big Data, 9(1), p.102.

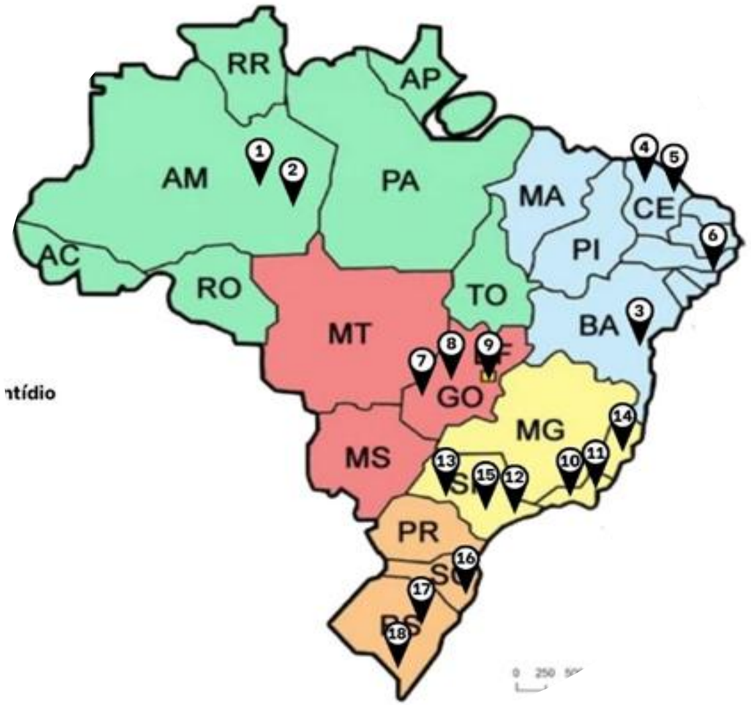
IACOV-BR



LABDAPS

Laboratório de Big Data e
Análise Preditiva em Saúde

IACOV-BR



- Estudo multicêntrico brasileiro para predição de desfechos relacionados a COVID-19: óbito, UTI, Ventilação Mecânica
- Março-Agosto de 2020
- 18 hospitais espalhados por todo o Brasil – grande diversidade demográfica, de recursos e práticas clínicas
- Tamanhos amostrais variando de 47 a 1776 pacientes

IACOV-BR

scientific reports

Check for updates

OPEN

Improving the performance of machine learning algorithms for health outcomes predictions in multicentric cohorts

Roberta Moreira Wichmann[1,2]✉, Fernando Timoteo Fernandes[1,3], Alexandre Dias Porto Chiavegatto Filho[1] & IACOV-BR Network[1*]

PLOS DIGITAL HEALTH

RESEARCH ARTICLE

Multicenter comparative analysis of local and aggregated data training strategies in COVID-19 outcome prediction with Machine learning

Carine Savalli[1,2*], Roberta Moreira Wichmann[3], Fabiano Barcellos Filho[2], Fernando Timoteo Fernandes[4], Alexandre Dias Porto Chiavegatto Filho[2], on behalf of IACOV-BR Network[¶]

Objetivo

Comparar estratégias de **agrupamentos** dos hospitais no treinamento dos algoritmos de ML para predição de **óbito** (Wichmann et al., 2023), **admissão em UTI** e **Ventilação Mecânica** (Savalli et al., 2024).

Objetivo: verificar se o aumento do volume de dados para treinamento poderia melhorar a capacidade preditiva de cada hospital.

Métodos

- Pacientes adultos (> 18 anos)
- 18 hospitais (Wichmann et al., 2023) e 14 hospitais (Savalli et al, 2024)
- 22 variáveis: demográficas, clinicas e laboratoriais
- Pré-processamento
- Divisão treino/teste (70%/30%)
- Algoritmos: lightGBM, catboost, e XGBoost (hiperparâmetros otimizados com validação cruzada de 10-fold)
- Métrica de desempenho AUC
- SHAP para avaliar importância das variáveis para predição

Estratégias de treinamento dos algoritmos

8 estratégias de treinamento:

- 70% do hospital referência (HR) - **treino local**



Estratégias de treinamento dos algoritmos

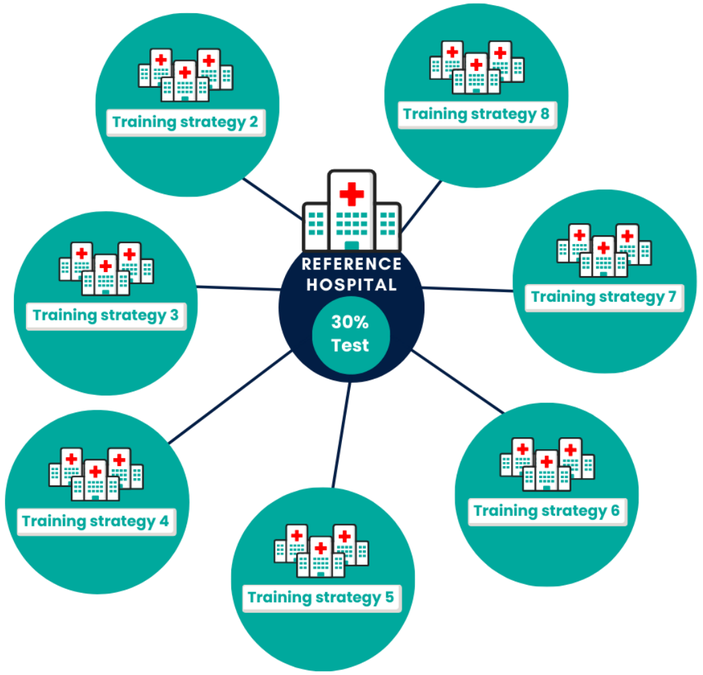
8 estratégias de treinamento:

- 70% do hospital referência (HR) – **treino local**

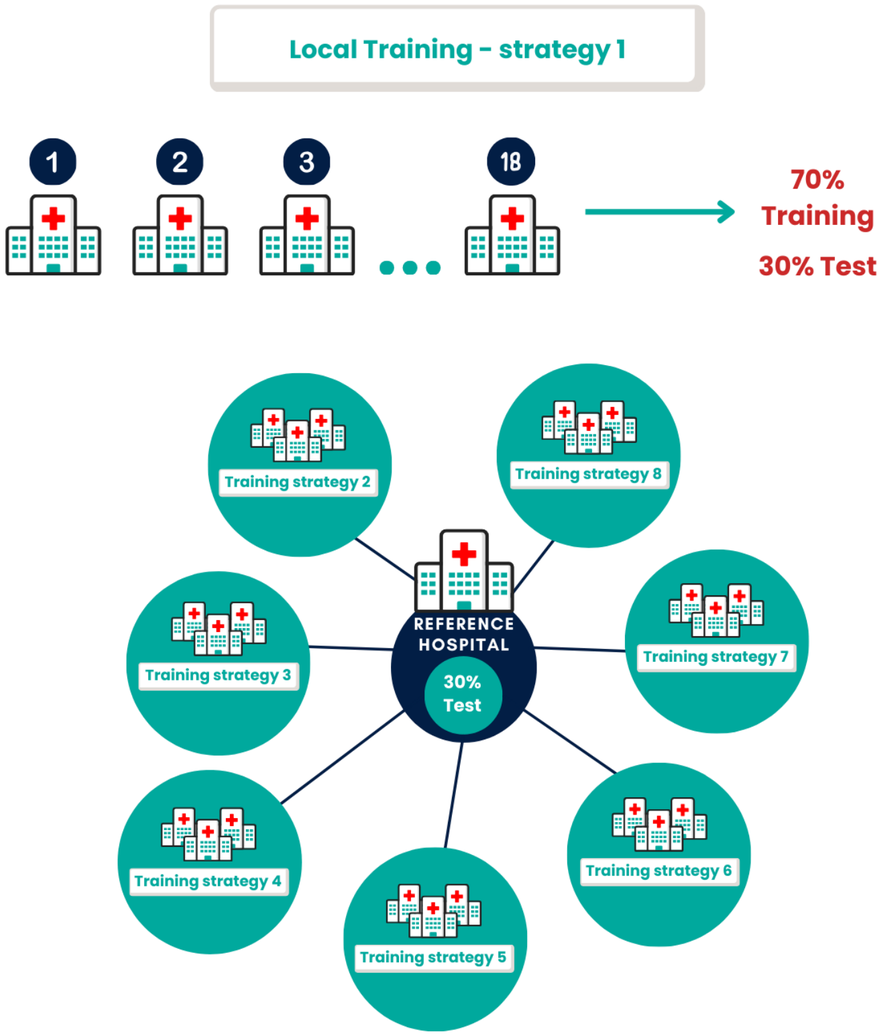
Agrupamentos de hospitais

- 70% de todos os hospitais exceto HR
- 70% dos hospitais da mesma região, exceto HR
- 70% dos hospitais das outras regiões
- 70% do HR + 70% de todos os outros hospitais
- 70% do HR + mesmo n de todos os outros hospitais
- 70% do HR + mesmo n dos hospitais da mesma região
- 70% do HR + mesmo n dos hospitais das outras regiões





Estratégias de treinamento dos algoritmos



Exemplo: Hospital de referência 1

Para **todas as estratégias de treinamento** o teste foi feito sempre nos 30% do hospital de referência

Teste

30% do hospital 1

Resultados

Table 3. AUROCs (AUCs) for the best aggregation strategies for training in each hospital for the three outcomes: the ICU admission, the use of mechanical ventilation (MV) and death (Wichmann et al. [6]).

		ICU		MV		Death (Wichmann et al. [6])	
Hospital*	n	Best AUC	Best strategy	Best AUC	Best strategy	Best AUC	Best strategy
Southeast—2	1500	0.799	Local Training	0.754	Local Training	0.79	Local Training
Southeast—3	449	0.764	Local Training	0.865	Local Training	0.81	Local Training
Southeast—5	124	0.667	Local Training	0.906	Local Training	0.98	Local Training
Southeast—6	56	0.814	Local Training	0.885	Local Training	0.60	Local Training
Northeast—1	1359	0.940	Local Training	0.947	Local Training	0.89	Local Training
Northeast—2	845	0.666	Local Training	0.781	Local Training	0.92	Local Training
Northeast—3	112	0.664	Local Training	0.779	Local Training	0.90	Local Training
Northeast—4	73	0.744	Strategy 2	0.908	Strategy 7	0.70	Strategy 4
MidWest -1	539	0.673	Local Training	0.624	Strategy 2	0.73	Strategy 2
South—1	456	0.748	Local Training	0.869	Local Training	0.90	Local Training
South—2	148	0.987	Local Training	0.976	Local Training	0.98	Local Training
South—3	91	0.770	Strategy 6	0.722	Strategy 2	0.85	Strategy 3
North—1	247	0.817	Local Training	0.885	Local Training	0.85	Strategy 7
North—2	47	0.909	Strategy 4	0.796	Strategy 2	0.90	Strategy 5

*Hospitals named Southeast-1, Southeast-4, MidWest-2 and MidWest-3 in Wichmann et al. [6] were excluded for the current study.

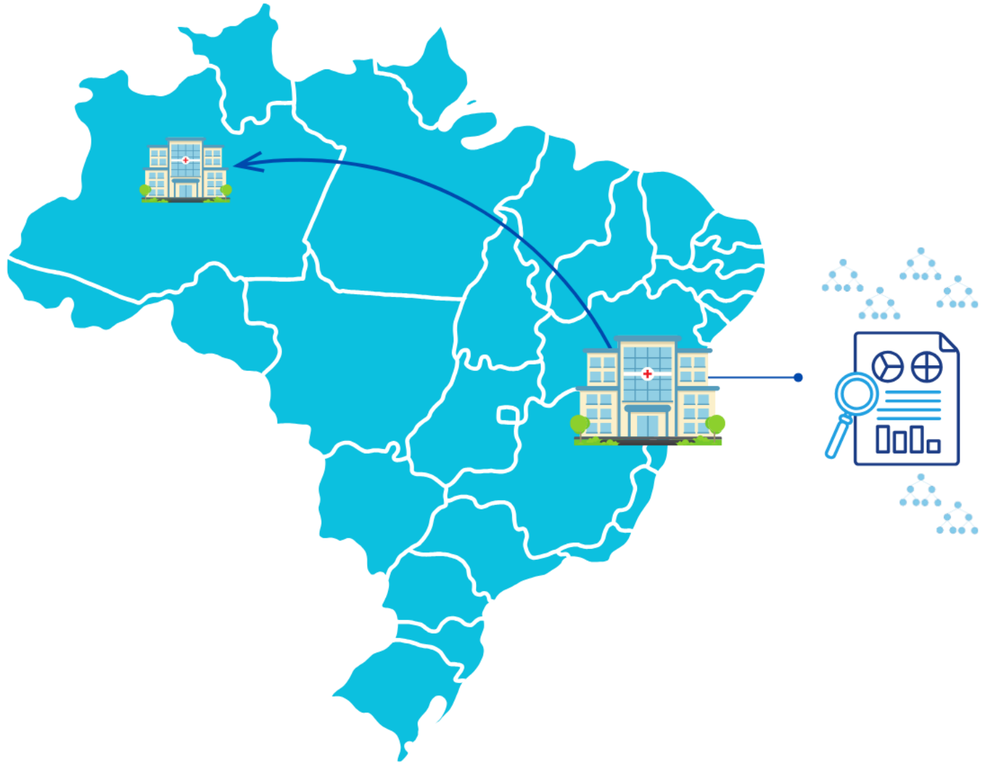
Melhores algoritmos: LightGBM (44,1% dos casos), XGBoost (35% dos casos) e CatBoost (20,9% dos casos)

IACOV-BR

Transfer learning for COVID-19 predictive modeling: A multicenter study of 12 hospitals (under review)

Carine Savalli, André Henrique Alves Carneiro, Fabiano Barcellos Filho, Murilo Afonso Robiati Bigoto, Roberta Moreira Wichmann, Alexandre Dias Porto Chiavegatto Filho, on behalf of IACOV-BR Network

Aprendizado por transferência em árvores



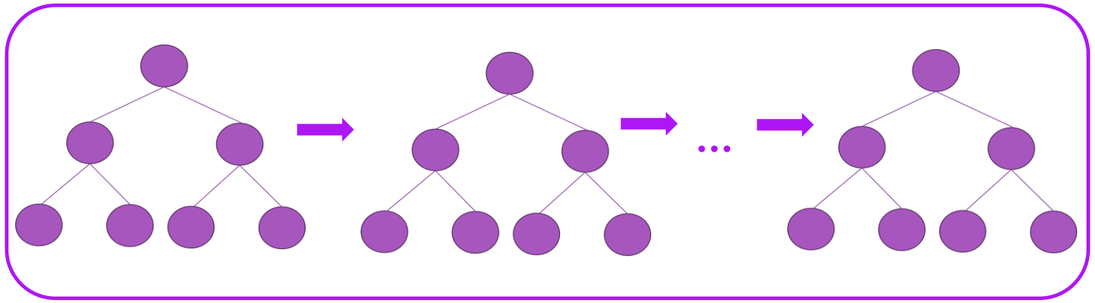
Aprendizado por transferência (Transfer learning) é uma técnica de ML em que um algoritmo é treinado para uma determinada tarefa em um local (contexto) com mais dados e recursos (**ORIGEM**), e este modelo é usado para inicializar o treinamento e acelerar o desenvolvimento do modelo em um outro local ou contexto (**ALVO**)

Fonte da ilustração: Savalli & Chiavegatto (em revisão). Generalização algorítmica na saúde digital: desafios para uma saúde integrada nas diversas regiões brasileira.

Aprendizado por transferência em árvores

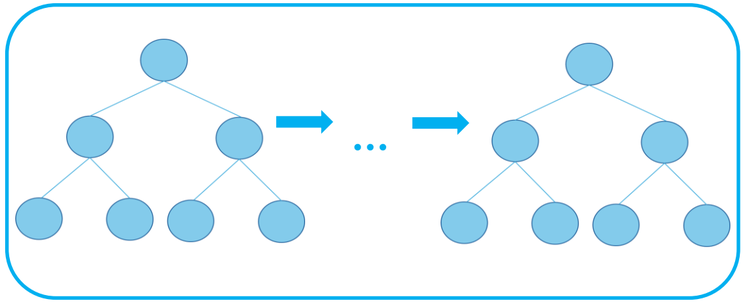
Dados do hospital **ALVO**

Modelo pré-treinado no hospital de ORIGEM - fixo



Resíduo da classificação dos dados do hospital **ALVO**

Ajuste fino: árvores adicionadas para capturar padrões específicos do ALVO



Predição para o hospital **ALVO**

Objetivo

- Avaliar a capacidade de generalização do modelo obtido hospital com melhor desempenho preditivo para os outros hospitais por meio de validação externa
- Utilizar o aprendizado por transferência e avaliar se apresenta melhores resultados do que a validação externa do melhor hospital

Métodos

- Desfecho: Admissão na UTI
- 22 possíveis preditores: sexo, idade, medidas clínicas e laboratoriais
- Pre-processamento
- treino/teste (70%/30%)
- XGBoost
- Métrica de desempenho: AUC
- SHAP (Shapley Additive exPlanations) para avaliar importância de variáveis
- Identificação do **melhor modelo** (hospital) e avaliação da **validação externa** desse modelo
- **Aprendizado por transferência no XGBoost**: árvores adicionadas ao modelo pré-treinado no hospital com melhor desempenho local
- **Análise de sensibilidade** para explorar o impacto da adição de cada árvore no desempenho do modelo no hospital alvo (total de 50 arvores adicionadas)

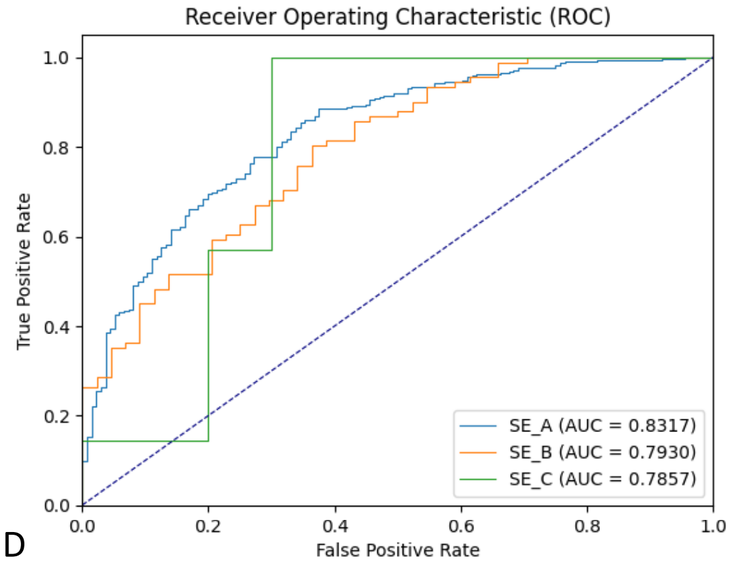
Resultados

O hospital que localmente apresentou melhor desempenho foi o NE_A

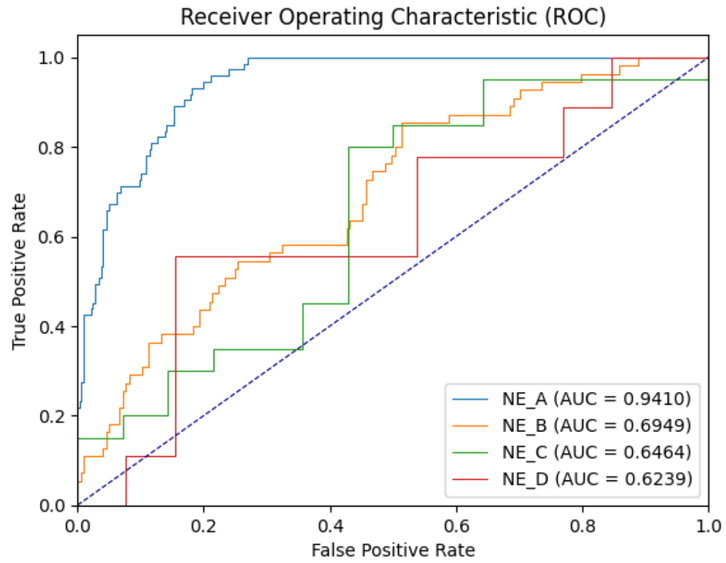
↓

ORIGEM

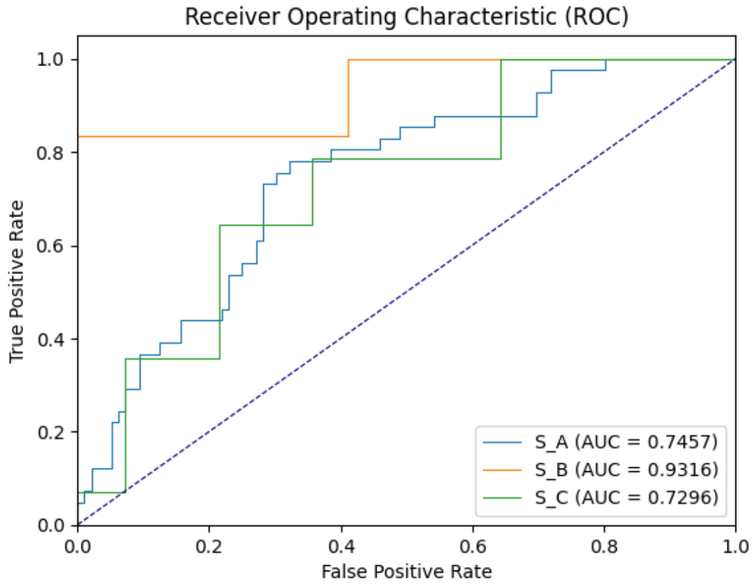
A



B



C



D

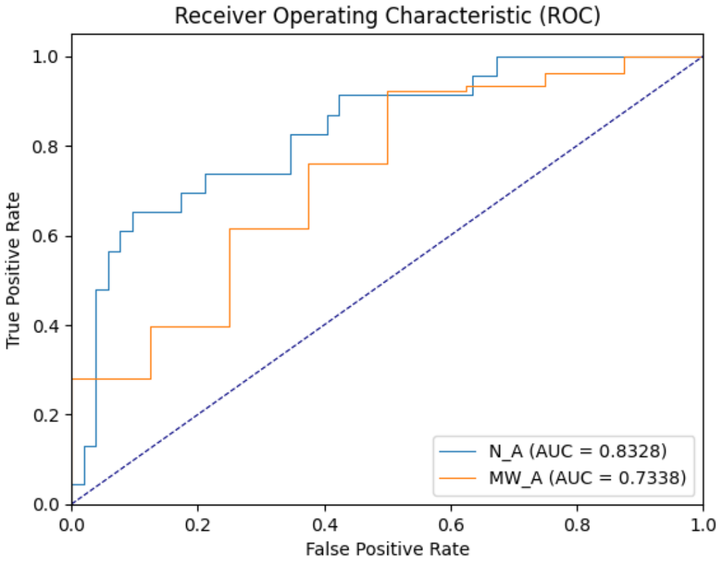


Figure 1. The Receiver Operating Characteristic curve and the area under the curve (AUC) of the XGBoost optimized for each hospital. A: SouthEast hospitals; B: NorthEast hospitals; C: South hospitals and D: North and MidWest hospitals.

Resultados

Table 2. The area under the receiver operating characteristic curve (AUC) for external validation of the best model (NE_A) and transfer learning (model from NE_A updated with 50 new trees in each target hospital), variation between the two AUC measures, proportion of outcomes and missing values for each target hospital.

Hospital	sample size	AUC external validation	AUC transfer learning	Variation	% outcomes	% missing
SE_A	1500	0.7745	0.8057	4.0%	69.9%	23.2%
SE_B	449	0.6811	0.8272	21.5%	67.5%	9.6%
SE_C	56	0.6571	0.8429	28.3%	42.9%	14.0%
NE_A	1330	source model	source model	source model	18.4%	30.1%
NE_B	840	0.6270	0.7024	12.0%	21.7%	15.2%
NE_C	112	0.6036	0.6393	5.9%	58.9%	22.2%
NE_D	72	0.8205	0.7436	-9.4%	41.7%	1.0%
S_A	456	0.7274	0.7574	4.1%	30.0%	37.7%
S_B	148	0.9359	0.9231	-1.4%	14.2%	1.6%
S_C	91	0.7602	0.7755	2.0%	50.5%	18.8%
MW_A	539	0.6420	0.6778	5.6%	95.4%	11.7%
N_A	247	0.6363	0.8060	26.7%	30.4%	24.1%

Verde: AUC acima de 0.7

Resultados

Table 2. The area under the receiver operating characteristic curve (AUC) for external validation of the best model (NE_A) and transfer learning (model from NE_A updated with 50 new trees in each target hospital), variation between the two AUC measures, proportion of outcomes and missing values for each target hospital.

Hospital	sample size	AUC external validation	AUC transfer learning	Variation	% outcomes	% missing
SE_A	1500	0.7745	0.8057	4.0%	69.9%	23.2%
SE_B	449	0.6811	0.8272	21.5%	67.5%	9.6%
SE_C	56	0.6571	0.8429	28.3%	42.9%	14.0%
NE_A	1330	source model	source model	source model	18.4%	30.1%
NE_B	840	0.6270	0.7024	12.0%	21.7%	15.2%
NE_C	112	0.6036	0.6393	5.9%	58.9%	22.2%
NE_D	72	0.8205	0.7436	-9.4%	41.7%	1.0%
S_A	456	0.7274	0.7574	4.1%	30.0%	37.7%
S_B	148	0.9359	0.9231	-1.4%	14.2%	1.6%
S_C	91	0.7602	0.7755	2.0%	50.5%	18.8%
MW_A	539	0.6420	0.6778	5.6%	95.4%	11.7%
N_A	247	0.6363	0.8060	26.7%	30.4%	24.1%

Verde: AUC acima de 0.7

Resultados

Table 2. The area under the receiver operating characteristic curve (AUC) for external validation of the best model (NE_A) and transfer learning (model from NE_A updated with 50 new trees in each target hospital), variation between the two AUC measures, proportion of outcomes and missing values for each target hospital.

Hospital	sample size	AUC external validation	AUC transfer learning	Variation	% outcomes	% missing
SE_A	1500	0.7745	0.8057	4.0%	69.9%	23.2%
SE_B	449	0.6811	0.8272	21.5%	67.5%	9.6%
SE_C	56	0.6571	0.8429	28.3%	42.9%	14.0%
NE_A	1330	source model	source model	source model	18.4%	30.1%
NE_B	840	0.6270	0.7024	12.0%	21.7%	15.2%
NE_C	112	0.6036	0.6393	5.9%	58.9%	22.2%
NE_D	72	0.8205	0.7436	-9.4%	41.7%	1.0%
S_A	456	0.7274	0.7574	4.1%	30.0%	37.7%
S_B	148	0.9359	0.9231	-1.4%	14.2%	1.6%
S_C	91	0.7602	0.7755	2.0%	50.5%	18.8%
MW_A	539	0.6420	0.6778	5.6%	95.4%	11.7%
N_A	247	0.6363	0.8060	26.7%	30.4%	24.1%

Variação na capacidade preditiva ao adicionar novas árvores treinadas com dados do ALVO não está relacionada a %desfecho ou %missing

Resultados

Análise de sensibilidade: maior variação na AUC para as primeiras árvores adicionadas, em seguida estabiliza

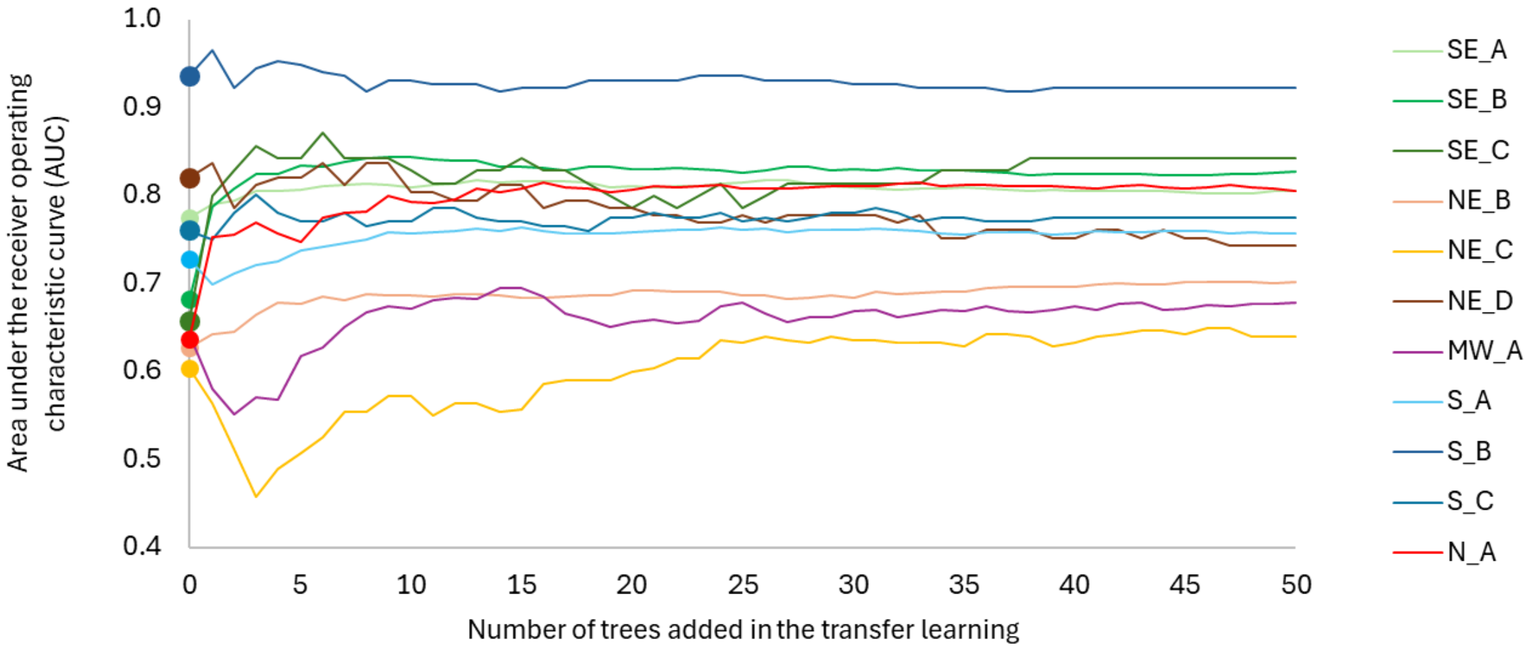


Figure 3. The area under the receiver operating characteristic curve (AUC) for each of the 50 trees added sequentially to the best-performing model (NE_A), trained with data from each target hospital. The AUC on point 0 represents the performance of the external validation of the best-performing model in each hospital.

Considerações finais

- Cenários com alta diversidade nos dados
- Resultados confirmam que não há um método que supera consistentemente os outros em todos os contextos
- É necessário testar múltiplas estratégias em dados do mundo real
- Pesquisas futuras devem explorar forma de hiperparametrizar as árvores adicionadas no *transfer*

Artigo:

Federated learning: challenges, methods, and future directions

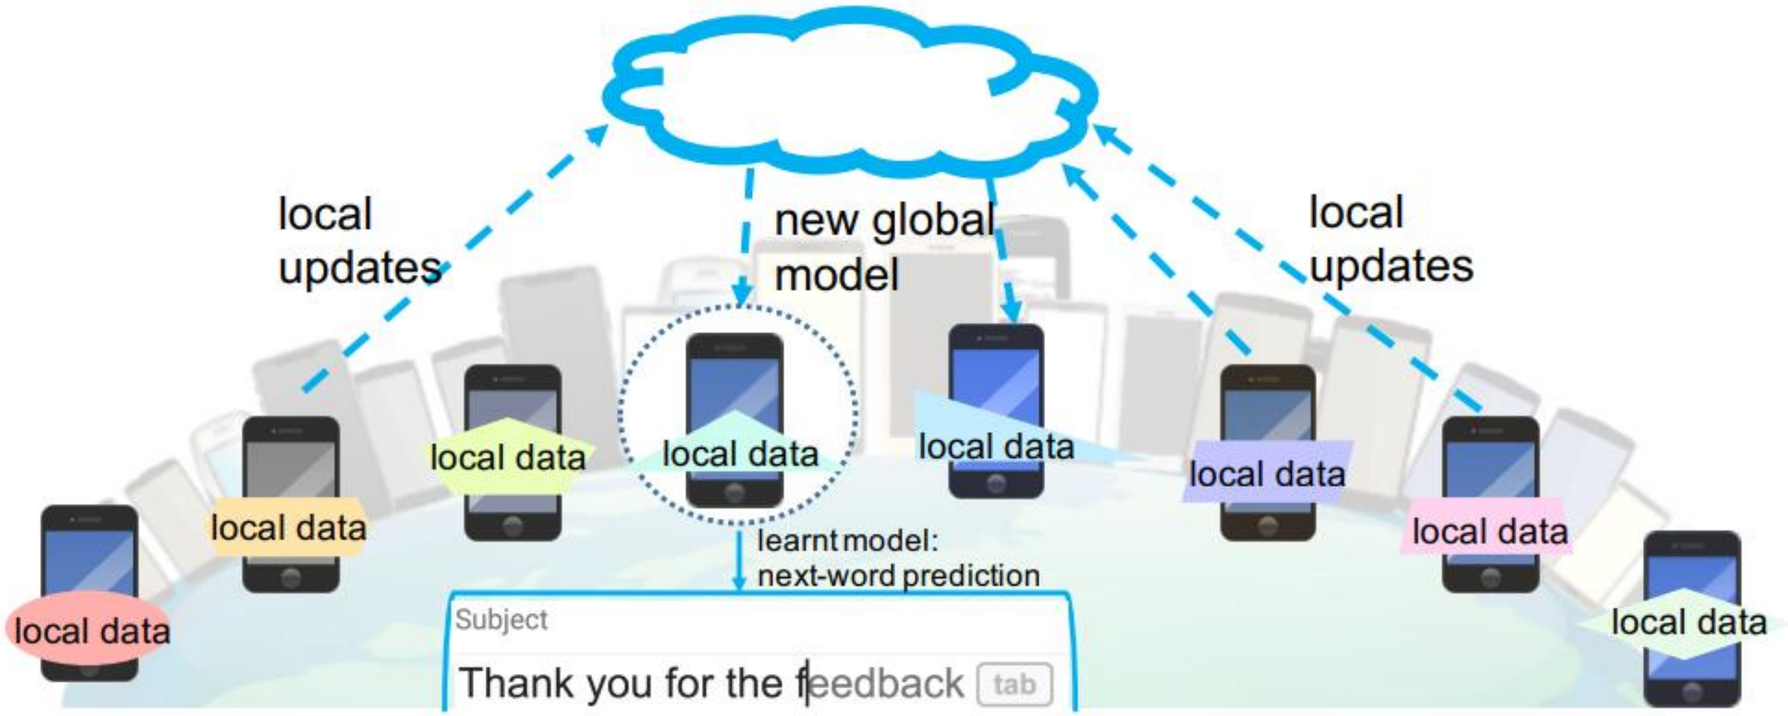
Authors: Tian Li, Anit Kumar Sahu, Ameet Talwalkar, Virginia Smith.

Resumo

- Treinamento em dispositivos remotos
- Desafios: heterogeneidade e grande quantidade de dados
- Dados locais
- Modelo global
- Principal objetivo: preservação da privacidade + aceitação de novas colaborações (sem perda de controle dos dados)

Contextualização

Exemplo: Aprendizado Federado para predição da palavra seguinte em dispositivos móveis.



Contextualização

- Outro exemplo importante são os Hospitais (dados dos pacientes)
- Hospitais operam com rigorosas práticas de privacidade (LGPD)
- Restrições legais e éticas
- Aprendizado federado aparece como uma solução promissora

Formulação do Problema

Objetivo é aprender o modelo sob restrição de que o armazenamento e o processamento são em geral locais, com algumas atualizações intermediárias periódicas

Direções Futuras

- Esquemas de comunicações extremos (mínimos)
- Redução da quantidade de informação comunicada (métodos de compressão e treinamento local)
- Novos modelos assíncronos: centrados nos dispositivos, que decidem quando interagir com o servidor central
- Diagnóstico de heterogeneidade: métodos estatísticos para identificar dissimilaridade
- Identificação da importância relativa de cada local

Referência

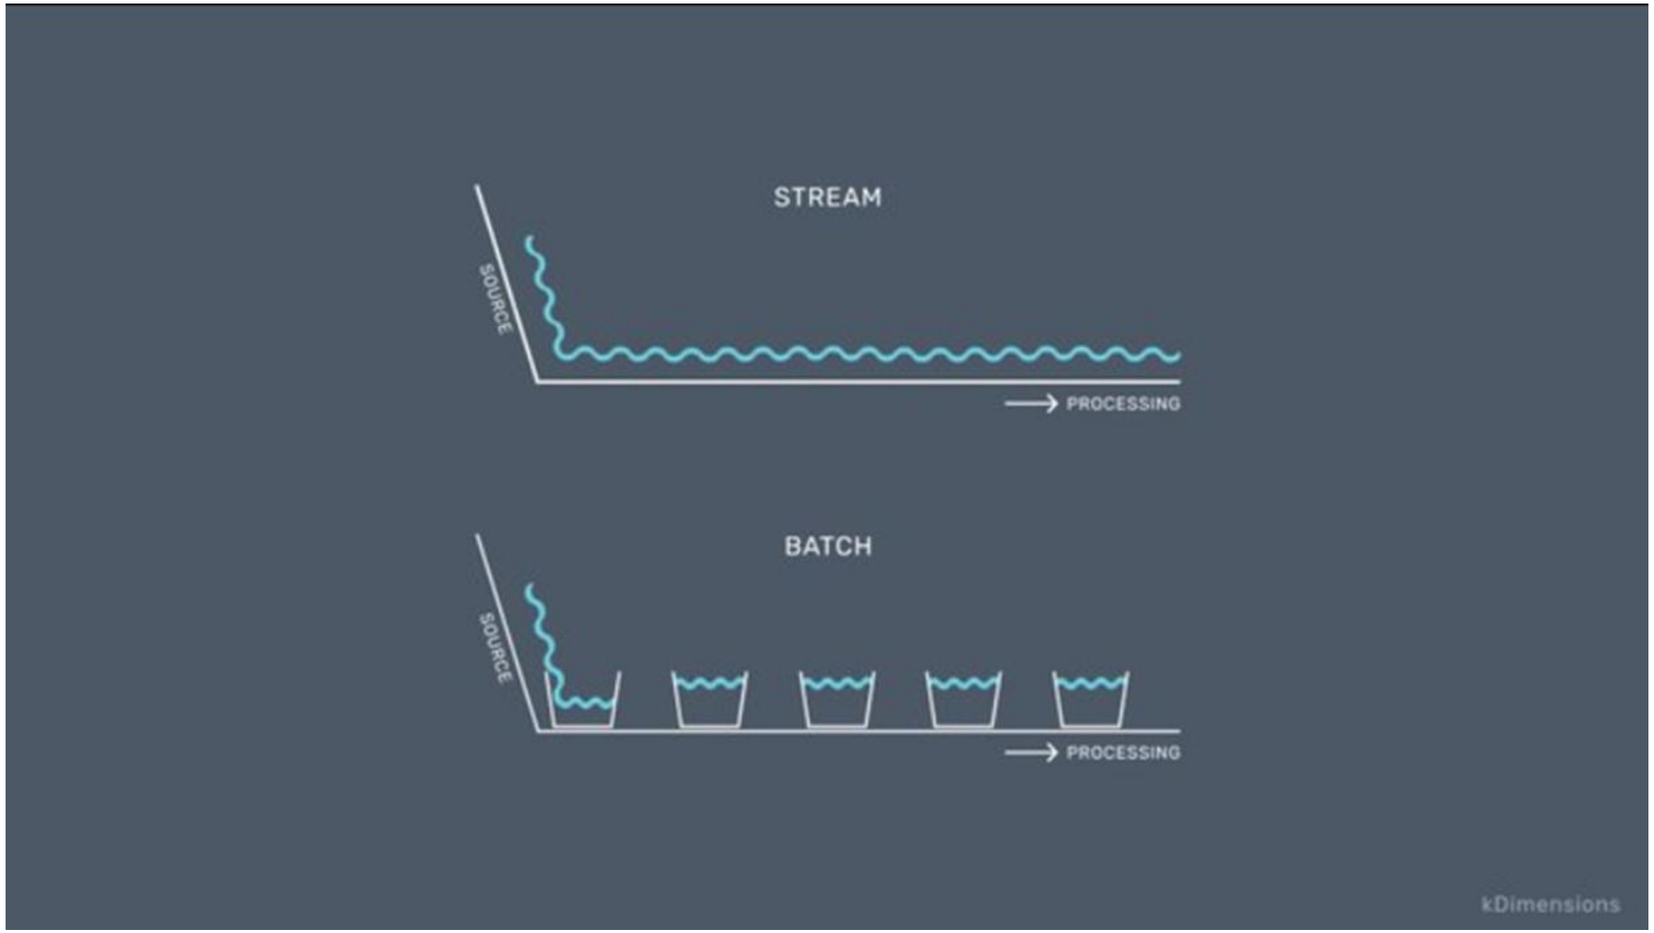


Li, T., Sahu, A. K., Talwalkar, A., & Smith, V. (2020). Federated learning: Challenges, methods, and future directions. IEEE Signal Processing Magazine, 37(3), 50-60.

O que é online learning?

- Aprendizado no qual os dados chegam sequencialmente, e o preditor é atualizado em cada etapa
- Atualização instantânea do modelo (menor custo)
- Bons para aplicações em grande escala (tamanho e velocidade)

Online learning X ML tradicional (offline)



Referência



Rajkomar, A., Hardt, M., Howell, M. D., Corrado, G., & Chin, M. H. (2018). Ensuring fairness in machine learning to advance health equity. Annals of internal medicine, 169(12), 866-872.

Obrigado!

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho

@labdaps

alexdiasporto@usp.br

Referência: Degenhardt, F., Seifert, S., & Szymczak, S Evaluation of variable selection methods for random forests and omics data sets. Briefings in bioinformatics, 20(2), 492-503. (2019).