

PROFEPI

Introdução à inteligência artificial para predições em vigilância em saúde e ambiente

Introdução

- Vamos examinar os princípios que podem ser utilizados para orientar o desenvolvimento e implementação de algoritmos de machine learning na saúde
- Vamos examinar exemplos de dilemas éticos que surgiram no uso de machine learning na área da saúde
- Vamos discutir as melhores práticas para abordar preocupações éticas no desenvolvimento e implementação de algoritmos de machine learning

Introdução

- O uso crescente de machine learning na área da saúde tem gerado preocupações éticas importantes
- Nesta aula, vamos explorar os principais desafios éticos que surgem quando se utiliza machine learning na área da saúde
- Vamos discutir as potenciais vantagens e desvantagens do uso de machine learning na área da saúde

Questões éticas em inteligência artificial em saúde

Premissa: IA vai trazer grandes benefícios na atenção à saúde.

Porém....

1 – Vieses nos dados:

1.1 - Preconceitos embutidos nos dados.





Questões éticas em inteligência artificial em saúde

Amostragem reduzida para subgrupos.

- Análises de prontuários eletrônicos – uso muito mais em pacientes ricos.
- Risco de algoritmo tomar melhores decisões em grupos com mais dados.

Humanos podem forçar algoritmos a serem preconceituosos.

- Alterar parâmetro e hiperparâmetro para isso.
- Escolher a estratégia de otimização que aumente preconceitos.

Importante: algoritmo não cria novos preconceitos, humanos criam.

Artigo:

Ensuring Fairness in Machine Learning to Advance Health Equity

Authors: : Rajkomar A et al.

Resumo

- Modelos de ML são cada vez mais utilizados nos cuidados clínicos
- Grupos protegidos: sofreram com consistentes vieses humanos e estruturais no passado
- Algoritmos podem exacerbar essas disparidades
- Devem ser proativos para promover equidade
- Incorporação de justiça distributiva aos projetos

Contextualização

Modelos de ML podem perpetuar desigualdades

Recomendação da Associação médica americana:

“Promover o desenvolvimento de IA em saúde cuidadosamente projetada, de alta qualidade e clinicamente validada que ... identifica e toma medidas para lidar com o viés e evita a introdução ou agravamento das disparidades de saúde, incluindo ao testar ou implantar novas ferramentas de IA para populações vulneráveis”.

Contextualização

- Os autores recomendam o uso proativo de sistemas de ML para promover equidade em saúde
- Sistemas de saúde são moldados de uma forma que sistematicamente prejudica a saúde de populações marginalizadas
- Não se pode maximizar a eficiência às custas dessas populações

Contextualização

- Equidade na saúde não será alcançada sem projetarmos propositalmente os sistemas sociais e de saúde para esse objetivo
- Fundamentos matemáticos complementados com critérios éticos
- Incorporação de justiça ao desenho, implantação e avaliação de modelos de ML

ESTUDO DE CASO 1

Unidade de monitoramento e cuidados intensivos

- Monitoramento de deterioração do estado de saúde dos pacientes
- Predição de transferência para UTI em até 6 horas
- Como seriam os possíveis danos disso?
- Considere afro-americanos como o grupo protegido
- Poucos afro-americanos entre as observações do treinamento
- Modelo será impreciso para esse grupo

ESTUDO DE CASO 2

Redução da duração da estadia

- Predição de pacientes que receberão alta mais cedo para deslocar recursos e evitar atrasos
- Se for o caso de ter predição de maior duração de internação para paciente de bairros com baixas condições socioeconômicas ou predominantemente de afro-americanos
- Alocação de recursos para bairros mais ricos e predominantemente brancos

O que pode fazer com que um sistema de ML seja injusto?

- Diagnósticos sistematicamente errados para grupos vulneráveis
- Distribuição distinta de exemplos de grupos (viés de minoria)
- Será que médicos confiam até quando o modelo está errado (viés de automação) ou ignoram quando não deveriam (viés de rejeição)?
- Prioridades para algoritmos sobre doenças que afetam mais os grupos privilegiados (viés de privilégio)

Como mitigar vieses e garantir justiça distributiva em ML



- Resultado igual
- Performance igual
- Alocação igual

Resultados iguais



- Grupos protegidos devem ter benefícios iguais em termos das aplicações práticas dos algoritmos de ML
- Forma ideal de fazer isso: garantir que ambos os grupos se beneficiam e não aumenta desigualdades

Performance igual

- Garantia de um modelo com boa performance para todos os grupos
- Três desafios:
  - Sensibilidade igual (mesma oportunidade)
  - Sensibilidade e Especificidade iguais (probabilidades equalizadas)
  - Valor Preditivo Positivo (paridade preditiva)

Performance igual

- Mesma performance pode não significar resultados iguais:
  - Tratamento pode ser menos eficaz para um grupo (e.g. por diferente resposta a tratamento)
  - Se o modelo for impreciso para um grupo, o médico pode compensar com vigilância adicional

Performance igual

- Mesma performance pode não significar resultados iguais:
  - Forçar que predições em um modelo tenham o mesmo desempenho para diferentes grupos pode ter consequências inesperadas
  - Exigir mesma sensibilidade por meio de diminuição de threshold aumenta falsos-positivos para esse grupo

Alocação igual de recursos (paridade demográfica)



- Predições muita vezes são feitas para alocar recursos
- Não é performance, porque alocação é definida pela proporção de predições positivas
- Importante garantir que recursos são alocados proporcionalmente entre grupos

Trade-offs

- Vários tipos de justiça às vezes são incompatíveis:
- O modelo pode ser justo quanto aos PPV e NPV iguais, mas injusto em relação a probabilidades
- É impossível qualquer modelo satisfazer todas as métricas
- Analisar qual métrica é mais importante em cada caso

Recomendações (para incorporar fairness em ML)

Desenho

- Determinar a meta de um modelo de ML e analisar em conjunto com as partes interessadas, incluindo grupos protegidos.
- Certificar de que o modelo está relacionado ao resultado desejado para o

paciente e pode ser integrado aos fluxos de trabalho clínicos.

Recomendações (para incorporar fairness em ML)

- Discutir as questões éticas de como o modelo poderia ser usado.
- Decidir quais grupos classificar como protegidos.
- Estudar se os dados históricos são afetados por disparidades de saúde que

podem levar a viés de rótulo. Em caso afirmativo, investigue rótulos alternativos.

Recomendações

Coleta de dados

- Colete e documente dados de treinamento para construir um modelo de ML.
- Certifique-se de que os pacientes no grupo protegido possam ser identificados (pesando a importância de identificação de preconceito vs. questões de privacidade).
- Avalie se o grupo protegido está representado adequadamente em termos de números e variáveis disponíveis.

Recomendações

Treinamento

- Treine um modelo levando em consideração os objetivos de *fairness*.

Avaliação

- Mensure importantes métricas e alocações entre os grupos.
- Analise os dados de teste com os dados de treinamento para garantir a comparabilidade.
- Avalie a utilidade das predições para os médicos.

Recomendações

Análise de lançamento

- Avalie se um modelo deve ser lançado em conjunto com todas as partes interessadas, incluindo representantes do grupo protegido.

Implantação monitorada

- Monitore sistematicamente os dados e métricas importantes durante a implantação.
- Lance gradualmente e avalie continuamente as métricas com alertas automatizados.
- Considere um projeto de ensaio clínico para avaliar os resultados do paciente.
- Colete feedback periodicamente de médicos e pacientes.

Conclusão

- Podemos reexaminar vieses históricos e garantir um futuro mais justo
- ML pode melhorar o atendimento aos pacientes caso seja cuidadosamente projetado e implantado
- Assim garantindo que todos se beneficiem da tecnologia

Referência



Rajkomar, A., Hardt, M., Howell, M. D., Corrado, G., & Chin, M. H. (2018). Ensuring fairness in machine learning to advance health equity. Annals of internal medicine, 169(12), 866-872.

Artigo:

Identifying Ethical Considerations for Machine Learning Healthcare Applications

Authors: Danton S. Char, Michael D. Abràmoff, Chris Feudtner

Resumo

- Benefícios de ML-HCAs vs. Preocupações éticas
- Avaliações éticas vão precisar definir o uso de ML
- O artigo fornece uma abordagem sistemática para identificar preocupações éticas
- Pipeline para avaliações éticas (concepção do modelo/ desenvolvimento/ implementação)
- Pipeline paralelo para avaliação e supervisão em cada etapa

Introdução

- ML-HCAs deixaram de ser futuro e se tornaram o presente
- Terão grande impacto nos processos de saúde, qualidade, custo e acesso
- Entre as preocupações éticas identificadas em literatura estão:
  - viés decorrente do tipo de dados de treino
  - privacidade
  - quem é o dono dos dados para treinamento
  - responsabilidade por falhas

Introdução

- Entre as preocupações éticas atualmente sem abordagem sistemática estão:
  - concepção
  - desenvolvimento
  - calibração
  - implementação
  - avaliação
  - supervisão

Introdução

- Para encontrar uma solução para um problema é necessário conhece-lo bem
- Mapeamento da área é necessário para:
  - reconhecer quais as preocupações éticas existentes
  - ajudar a localizar novas

Desafios para identificar considerações éticas

5 desafios importantes para identificar as considerações éticas da área:

- Impacto ainda incerto dessa tecnologias emergente
- Cuidado com focos em excepcionalismo de ML e IA
- Abrangência de aplicações (marco legal de IA)
- Excesso de foco restrito em uma área
- Diversos stakeholders (pacientes, médicos, TI...)

Pipeline para identificar considerações éticas

- **Concepção**: Auditabilidade, padrões de transparência, e conflitos de interesse
- **Desenvolvimento**: Perpetuação de preconceito nos dados de treinamento, risco de dano devido à associação a um grupo e obtenção de dados
- **Calibração**: Precisão, trade-off de características do teste e risco de dano calibrado
- **Implementação, avaliação e supervisão**: eventos adversos, avaliação contínua de precisão e uso

Concepção

- Quando as intenções de uso e objetivos são claros, as demais partes interessadas estão melhor preparadas para ter a autonomia avaliativa
- As partes interessadas nesse caso não precisam entender pormenores do funcionamento interno de uma ML-HCA para adquirir "capacidade de auditoria"
- Auditabilidade (arquitetura explicável de ponta a ponta)

Concepção

- Equilíbrio entre transparência e proteção da propriedade intelectual
- Transparência sobre ML-HCAs de aprendizagem offline ou contínuo
- Transparência sobre ML-HCAs assistencial ou autônomo
- Conflitos de interesse: financeiros e das instituições

Desenvolvimento

- Vieses nos dados de treinamento podem ser perpetuados ou mesmo amplificados
- **Exemplos**: auxílio de juízes nas sentenças; Framingham para risco cardiovascular, etc
- **Questões abertas**: quem possui esses dados, a rastreabilidade dos dados de cada indivíduo, e se os direitos à privacidade precisam ser estendidos ou reduzidos

Calibração

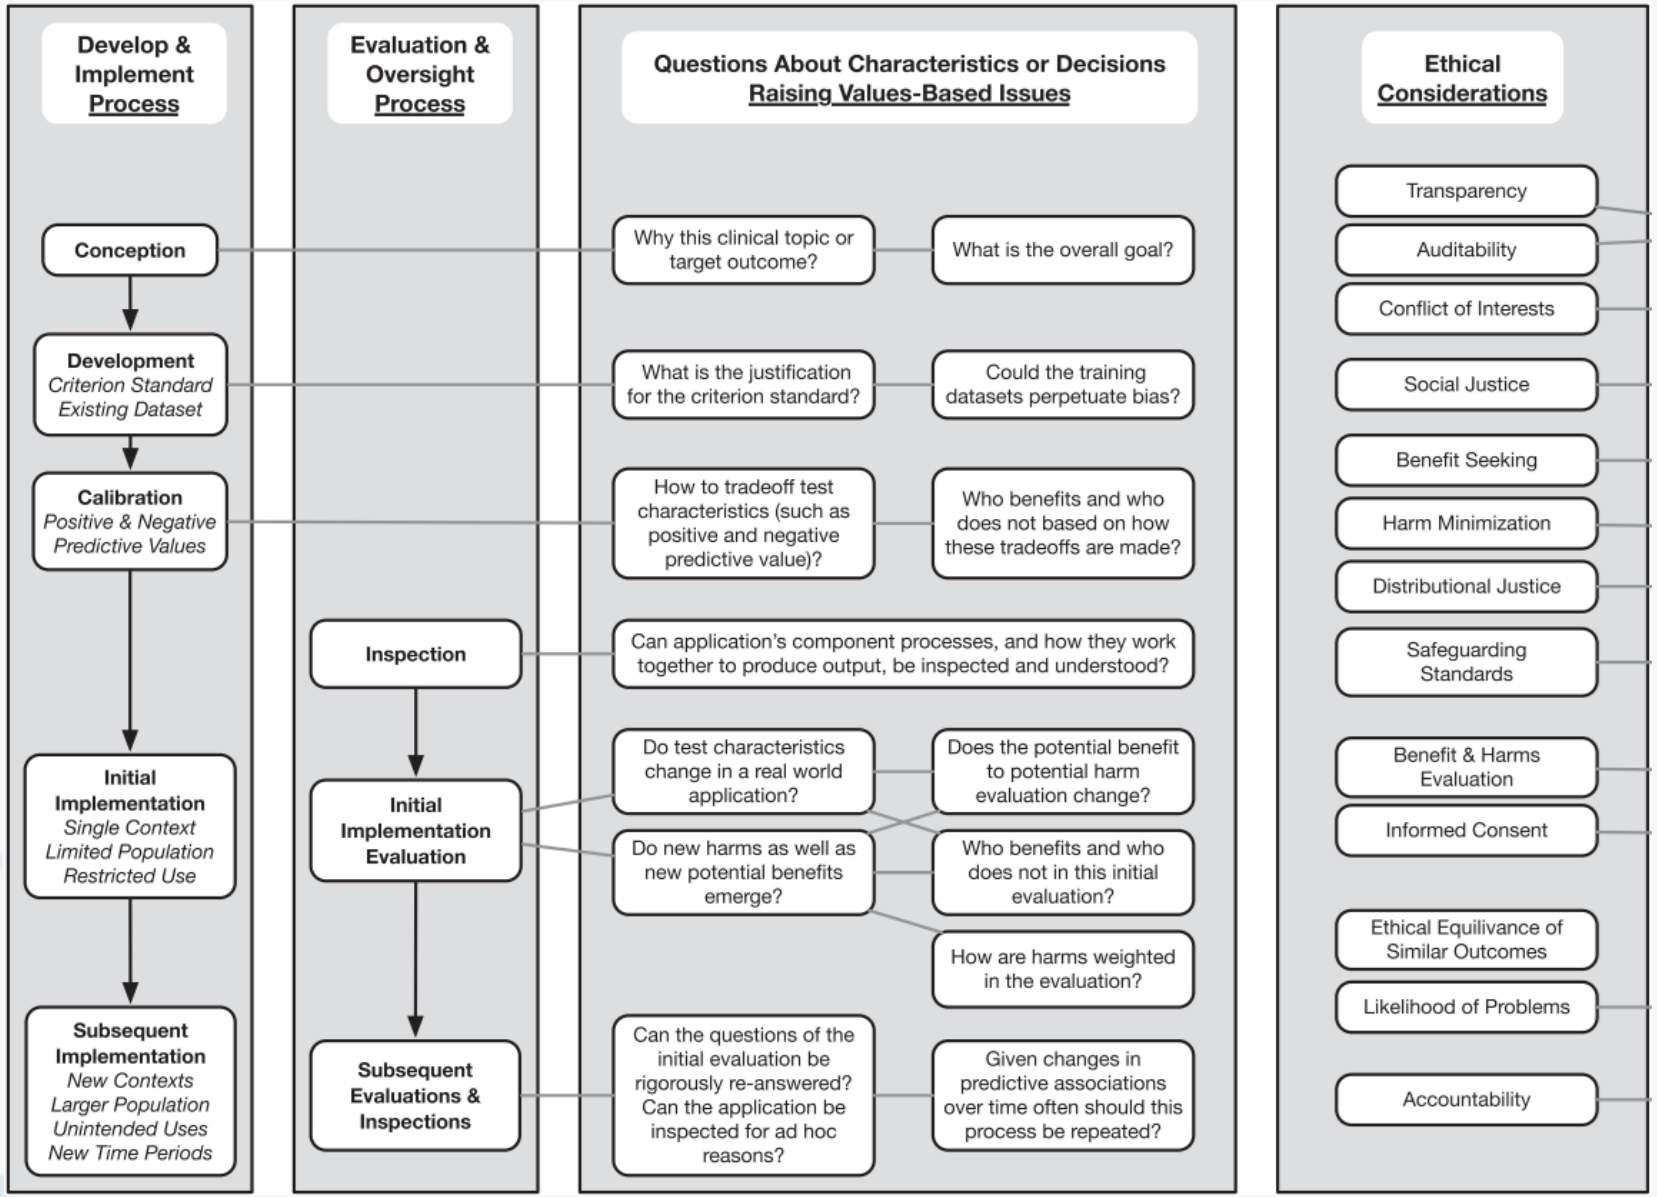
- A aplicação deve funcionar com segurança, eficiência e equidade
- Determinar a precisão não é algo simples
- Necessidade de estudos que validem os resultados dos modelos de ML_HC
- Imprecisões e danos não devem superar benefícios e devem ser distribuídas entre os pacientes de forma equitativa

Implementação, avaliação e supervisão

- No mundo real pode haver erro humano do operador
- Avaliar a relação benefício-dano (continuidade do benefício com o tempo)
- Necessidade de inspeção do ML-HCA de tempos em tempos

Implementação, avaliação e supervisão

- Cuidado: existe uma tendência a julgar erros do modelo mais severamente do que erros humanos
- Avaliações de impacto dos resultados do modelo sobre o fluxo de rotina do trabalho clínico
- Monitoramento se não começou a ser usado para outros fins (predição de mortalidade para restringir internações)


Develop & Implement Process
Evaluation & Oversight Process
Questions About Characteristics or Decisions Raising Values-Based Issues
Ethical Considerations
Conception
Development
Criterion Standard
Existing Dataset
Calibration
Positive & Negative Predictive Values
Initial Implementation
Single Context
Limited Population
Restricted Use
Subsequent Implementation
New Contexts
Larger Population
Unintended Uses
New Time Periods
Inspection
Initial Implementation Evaluation
Subsequent Evaluations & Inspections
Why this clinical topic or target outcome?
What is the overall goal?
What is the justification for the criterion standard?
Could the training datasets perpetuate bias?
How to tradeoff test characteristics (such as positive and negative predictive value)?
Who benefits and who does not based on how these tradeoffs are made?
Can application's component processes, and how they work together to produce output, be inspected and understood?
Do test characteristics change in a real world application?
Does the potential benefit to potential harm evaluation change?
Do new harms as well as new potential benefits emerge?
Who benefits and who does not in this initial evaluation?
How are harms weighted in the evaluation?
Can the questions of the initial evaluation be rigorously re-answered? Can the application be inspected for ad hoc reasons?
Given changes in predictive associations over time often should this process be repeated?
Transparency
Auditability
Conflict of Interests
Social Justice
Benefit Seeking
Harm Minimization
Distributional Justice
Safeguarding Standards
Benefit & Harms Evaluation
Informed Consent
Ethical Equilivance of Similar Outcomes
Likelihood of Problems
Accountability

Utilizando o pipeline

- Traz um panorama das questões éticas que podem ser levantadas em cada ponto
- Mesmo se o foco for em um ponto particular, devem ser avaliadas considerações éticas anteriores a esse ponto
- Existe herança de decisões operacionais éticas anteriores
- Serve também para antecipar problemas éticos de um projeto

Conclusão

- ML-HCAs tem muitos potenciais benefícios
- Complexidade das considerações éticas
- Necessidade de estruturação e mapeamento
- Criação do pipeline como apoio
- Auxílio com um panorama de questões éticas relevantes
- Facilitar o diálogo interdisciplinar

Referência

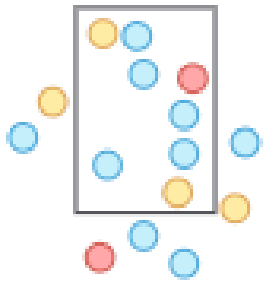
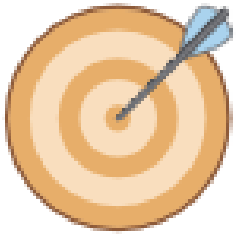
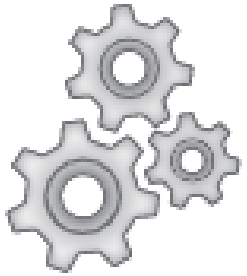
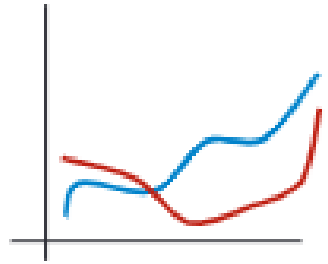


Char, D. S., Abràmoff, M. D., & Feudtner, C. (2020). Identifying ethical considerations for machine learning healthcare applications. The American Journal of Bioethics, 20(11), 7-17.

Artigo:

Ethical Machine Learningin Healthcare

Authors: Irene Y. Chen, Emma Pierson, Sherri Rose, Shalmali Joshi, Kadija Ferryman, and Marzyeh Ghassemi

1 Problem selection	2 Data collection	3 Outcome definition	4 Algorithm development	5 Postdeployment considerations
				
Disparities in funding and problem selection priorities are an ethical violation of principles of justice.	A focus on convenient samples can exacerbate existing disparities in marginalized and underserved populations, violating do-no-harm principles.	Biased clinical knowledge, implicit power differentials, and social disparities of the healthcare system encode bias in outcomes that violate justice principles.	Default practices, like evaluating performance on large populations, violate beneficence and justice principles when algorithms do not work for subpopulations.	Targeted, spot-check audits and a lack of model documentation ignore systematic shifts in populations risks and patient safety, furthering risk to underserved groups.

Seleção do problema

- Questão problemática se as pesquisa propostas e financiadas se concentram nas necessidades de saúde de grupos favorecidos.
- Lacuna 10/90: a grande maioria dos dólares em pesquisa em saúde é gasta em problemas que afetam uma pequena fração da população global.

Coleta dos dados

- Falta de identificação de grupos vulneráveis (Canadá e França não coletam raça em seus sistemas de informação de saúde).
- Desbalanceamento para os grupos vulneráveis (menos dados).

Definição do desfecho

Exemplos: incentivos econômicos podem alterar o registro do código de diagnóstico, o protocolo clínico afeta a frequência e a observação de testes anormais, a desconfiança racial histórica pode atrasar o atendimento e afetar os resultados do paciente e a coleta de dados errada pode gerar rótulos inconsistentes em raios-X.

Desenvolvimento do algoritmo

- Assim como os dados não são neutros, os algoritmos também não são neutros.
- Uma quantidade desproporcional de poder fica nas equipes de pesquisa que tomam decisões sobre os componentes críticos de um algoritmo, como a função de perda.
  - Escolhas comuns como a perda de erro absoluto L1 e a perda de erro quadrado L2 não geram as mesmas funções condicionais do resultado.

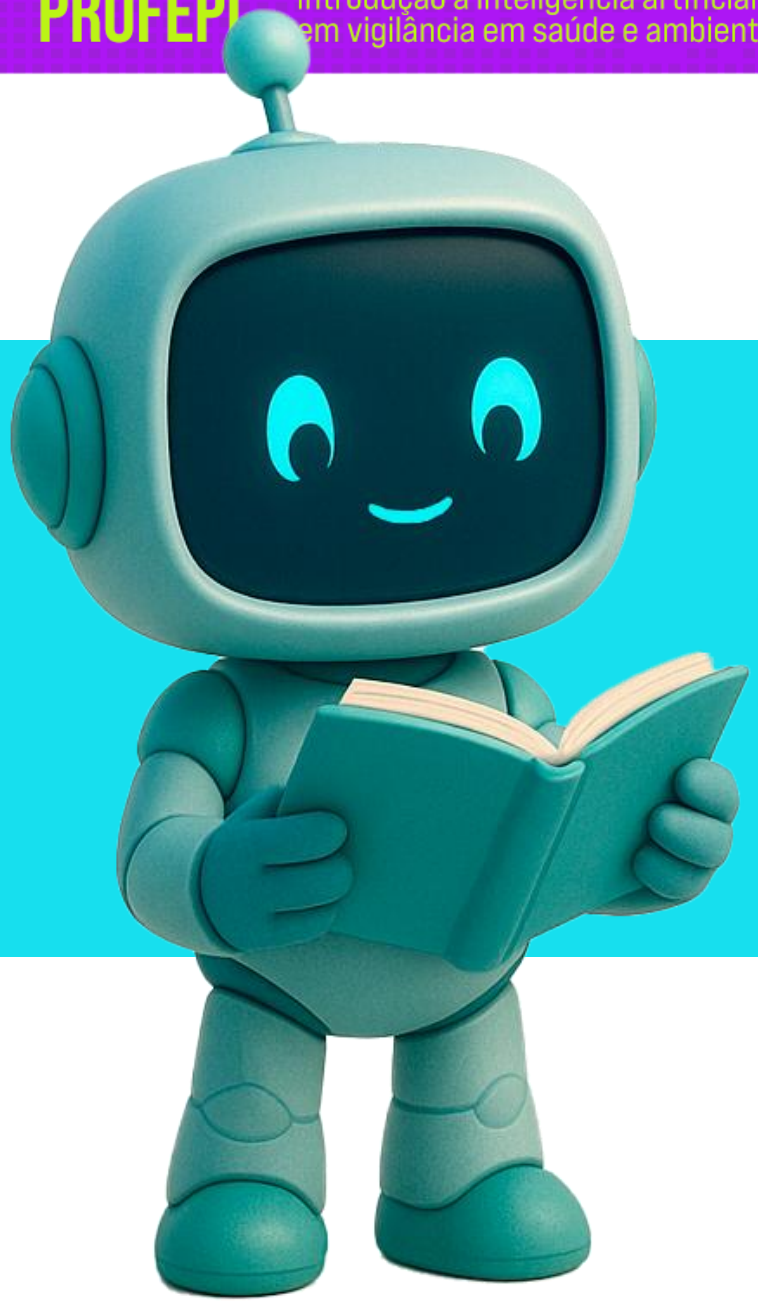
Desenvolvimento do algoritmo

- Quando os dados carecem de diversidade e não são representativos da população-alvo onde o modelo seria implantado, o sobreajuste de algoritmos tem o potencial de prejudicar desproporcionalmente os grupos marginalizados.
- É possível adicionar restrições ou penalidades para remover desigualdades preditivas com impactos baixos no ajuste global.

Pós desenvolvimento do algoritmo

- É importante medir e abordar o impacto dos modelos por meio de auditorias para analisar viés e impacto clínico em diferentes grupos.
- Uma melhor documentação dos dados que suportam o treinamento inicial do modelo pode ajudar a expor fontes de discriminação nos dados coletados.

A incorporação do machine learning na saúde não pode ser vista apenas como um avanço tecnológico, mas como um processo que exige reflexão crítica em todas as suas etapas.



A ética não é um detalhe a ser pensado no final, mas um elemento central que deve orientar todo o ciclo de desenvolvimento e uso dessas tecnologias.

Obrigada!

Keisyanne de Araujo Moura



@labdaps

keisyannemoura@usp.br