

PROFEPI Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde

Introdução à

Inteligência Artificial para Predições

em Vigilância em Saúde e Ambiente

Módulo 4

Refinamento dos modelos e temas emergentes em IA preditiva

OPAS Organização Pan-Americana da Saúde / Organização Mundial da Saúde Américas

SUS

MINISTÉRIO DA SAÚDE

GOVERNO DO BRASIL
DO LADO DO POVO BRASILEIRO

MINISTÉRIO DA SAÚDE
SECRETARIA DE VIGILÂNCIA EM SAÚDE E AMBIENTE (SVSA)

Coordenação-Geral

Mariângela Simão

Secretária de Vigilância em Saúde e Ambiente–SVSA/MS

Guilherme Loureiro Werneck

Diretor do Departamento de Ações Estratégicas de Epidemiologia e Vigilância em Saúde e Ambiente–Daevs/SVSA/MS

Vivian Siqueira Santos Gonçalves

Coordenadora-Geral de Desenvolvimento da Epidemiologia em Serviços–CGDEP/Daevs/SVSA/MS

Equipe Técnica

Amanda Maciel de Quadros–CGDEP/Daevs/SVSA/MS

Antonio Ygor Modesto de Oliveira–CGDEP/Daevs/SVSA/MS

Cíntia Pereira Donateli–CGDEP/Daevs/SVSA/MS

Criação Digital

Matheus Nunes Oliveira Alves–CGDEP/Daevs/SVSA/MS

Otávio Francisco Batista Martins–CGDEP/Daevs/SVSA/MS

Professores

Alexandre Dias Porto Chiavegatto Filho–Universidade de São Paulo (USP)

Keisyanne de Araujo Moura–Universidade de São Paulo (USP)

André Henrique Alves Carneiro–Universidade de São Paulo (USP)

Marcela Quaresma Soares–Universidade de São Paulo (USP)

Vinícius de Camargo–Universidade de São Paulo (USP)

ORGANIZAÇÃO PAN-AMERICANA DE SAÚDE ORGANIZAÇÃO MUNDIAL DA SAÚDE (OPAS/OMS)

Coordenação-Geral

Cristian Morales Fuhrimann–Representante da OPAS/OMS no Brasil

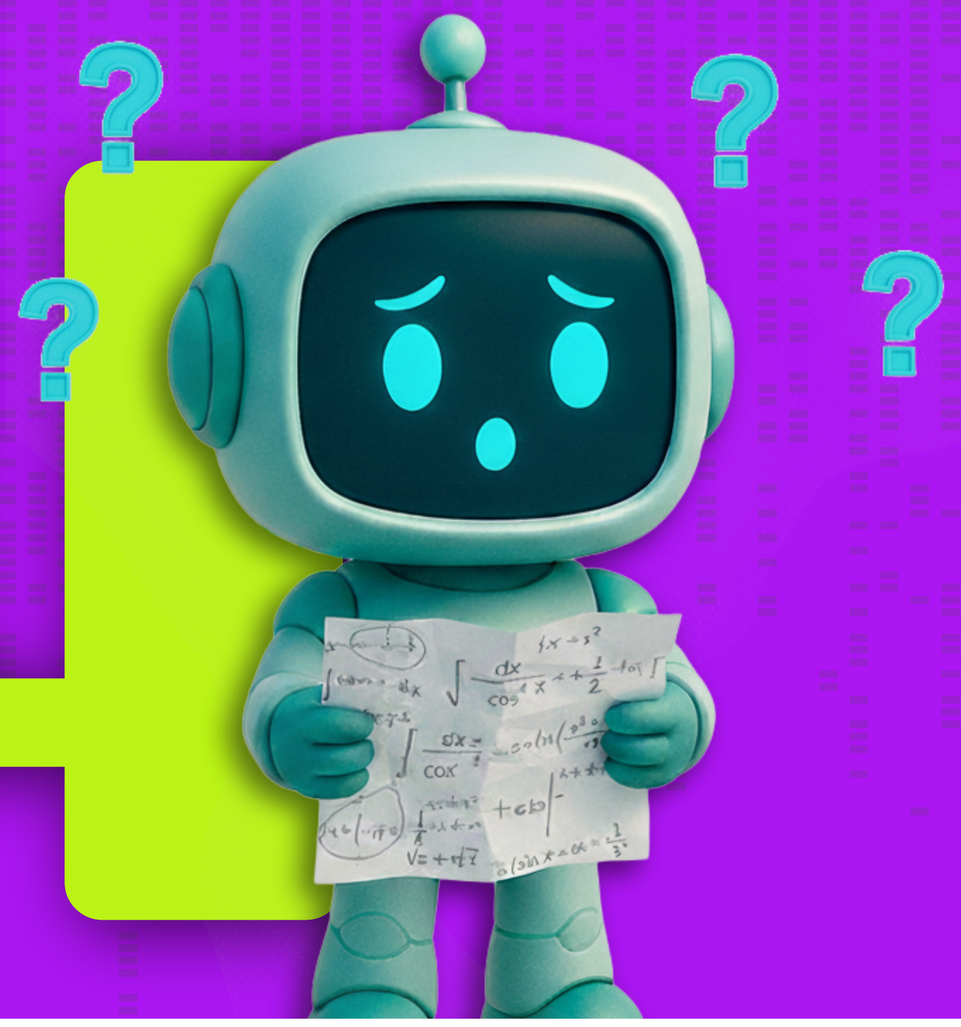
Alexander Rosewell–Coordenador de Emergências, Evidência e Inteligência em Saúde no Brasil

Equipe Técnica

Josy Maria de Pinho da Silva–OPAS/OMS

capítulo 8

MÓDULO 4



Estratégias para Seleção de Variáveis Preditoras

Introdução

O desenvolvimento de algoritmos que realizam boas predições em saúde é um dos objetivos centrais da ciência de dados contemporânea. No entanto, o caminho para alcançar uma alta performance preditiva possui imensos desafios técnicos. Entre as principais razões para o baixo desempenho de um algoritmo, estão a extrapolação inadequada dos resultados, o pré-processamento insuficiente dos dados, a validação inadequada da qualidade do modelo e, de forma ainda mais importante, o sobreajuste (*overfitting*).

Contudo, mesmo com a execução técnica correta, a performance de um modelo pode ser limitada pela ausência de variáveis preditoras verdadeiramente fortes. Este capítulo explora as estratégias principais para a seleção de variáveis preditoras, uma etapa decisiva para o sucesso de qualquer projeto de *machine learning* na área da saúde.

Pré-processamento dos Dados: a base da modelagem preditiva

O pré-processamento de dados é uma fase muito importante da análise preditiva que estabelece as bases para a construção de um modelo robusto. Muito além de uma tarefa mecânica, trata-se de um processo que exige tanto rigor técnico quanto discernimento conceitual.

Envolve desde a seleção criteriosa de variáveis que realmente possuem poder preditivo até a detecção e correção de armadilhas, como o vazamento de informação, que pode comprometer seriamente a validade do modelo.

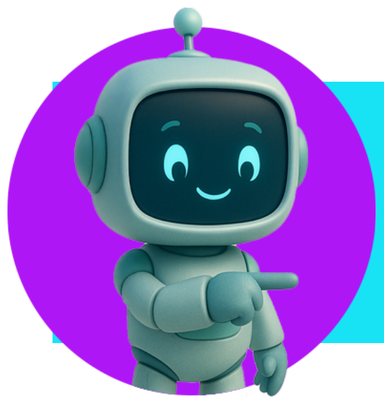
Cada uma dessas etapas, se negligenciada, pode introduzir vieses ou ruídos que inviabilizam a generalização do algoritmo para novos contextos.

> Em última análise, o pré-processamento não apenas prepara os dados para os algoritmos, mas também determina se as conclusões extraídas terão relevância clínica e aplicabilidade prática.

Preditores Plausíveis e a Natureza da Predição

O ponto de partida para a seleção de variáveis é o uso do bom senso do pesquisador para pré-selecionar preditores que sejam plausíveis. Em análises de *big data*, é comum que coincidências ocorram, levando o algoritmo a atribuir grande importância a associações espúrias.

É importante compreender que os preditores não precisam ter uma relação causal com o desfecho. Eles precisam apenas predizê-lo de forma consistente.



Um bom exemplo é a internação recente em uma UTI como preditora para o risco de óbito. A internação não é a causa da morte, mas sim um forte indicador da gravidade do estado do paciente.

Cuidado com o Vazamento de Informações (*Data Leakage*)

Um dos erros mais graves no pré-processamento é o vazamento de informações, ou -*data leakage*-. Isso acontece quando os dados de treinamento contêm informações ocultas sobre o desfecho, fazendo com que o modelo aprenda padrões que não são de seu interesse. Situações comuns incluem uma variável preditora que, na verdade, é consequência do desfecho ou a presença do mesmo indivíduo nos conjuntos de treino e teste.

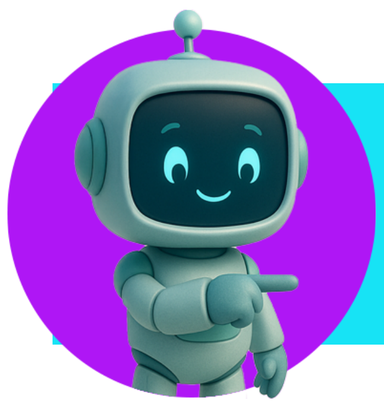
A Necessidade de Reduzir o Número de Variáveis

Após a seleção inicial de preditores plausíveis e a mitigação de vazamentos de informação, surge com frequência a necessidade de reduzir o número de variáveis utilizadas na modelagem.

Essa etapa, conhecida como redução de dimensionalidade, não é apenas uma conveniência técnica, mas um elemento estratégico para aumentar a eficiência e a robustez dos modelos.

Em contextos de saúde, a simplificação do conjunto de variáveis tem impacto direto na viabilidade do algoritmo preditivo, pois facilita a coleta de dados em regiões com menos infraestrutura e diminui os custos associados à obtenção e manutenção de informações clínicas ou laboratoriais. Além disso, ao reduzir o número de preditores, o tempo de treinamento dos algoritmos é significativamente encurtado, tornando possível explorar diferentes abordagens de modelagem em menos tempo.

A filtragem de variáveis também atua como uma segunda triagem, ajudando a eliminar preditores redundantes ou ruidosos, que poderiam confundir o algoritmo e reduzir sua capacidade de generalização.



Mais importante, concentra a atenção nos preditores que de fato carregam informação útil para antecipar o desfecho, aumentando tanto a interpretabilidade quanto a aplicabilidade dos modelos em cenários reais.

Métodos de Seleção de Variáveis

Existem diversas abordagens para selecionar o subconjunto ideal de variáveis preditoras. Elas variam desde técnicas estatísticas clássicas até métodos acoplados a algoritmos de *machine learning*.

Regressões Penalizadas: As regressões penalizadas são uma classe de algoritmos que introduzem uma penalidade aos coeficientes do modelo para evitar o sobreajuste. A penalização Ridge encolhe os parâmetros, mas não os zera, não realizando, portanto, a seleção de variáveis. Por outro lado, a penalização Lasso (L1) é capaz de zerar os coeficientes de variáveis menos importantes, realizando simultaneamente a regularização e a seleção de preditores ao penalizar os valores absolutos dos parâmetros.

Métodos Baseados em Árvores de Decisão: Algoritmos de *machine learning* baseados em árvores, como as Árvores de Decisão e o *Random Forest*, são particularmente úteis para a seleção de variáveis. Uma árvore de decisão funciona dividindo os dados em ramos baseados em testes em diferentes variáveis, com o objetivo de criar nós finais (folhas) que sejam o mais homogêneos possível em relação ao desfecho.

A importância de uma variável (*feature importance*) nesses modelos é calculada com base na redução de impureza que ela proporciona. A importância de uma variável é a soma total da redução de impureza que ela gerou em todas as divisões da árvore, sendo maior se a redução for alta e se o nó contiver muitas amostras.

Abordagens Avançadas para Seleção de Variáveis

Eliminação Recursiva de Variáveis (RFE)

Esse método busca encontrar um conjunto mínimo de variáveis, removendo recursivamente os preditores menos importantes e recalculando o ranking a cada passo, até que o conjunto com o menor erro de predição seja encontrado. A performance é sempre avaliada em observações não utilizadas no treinamento (*out-of-bag*).

Permutação

Nesse caso, os valores do desfecho são permutados aleatoriamente, mantendo a estrutura de correlação entre os preditores intacta. Uma variável é considerada importante se sua relevância no modelo com os dados reais for consistentemente maior do que nos modelos com o desfecho permutado.

Importância Variável Relativa Recorrente

Vários modelos de *Random Forest* são gerados com diferentes sementes aleatórias. A importância de cada variável é calculada e normalizada pela importância mínima em cada execução. São consideradas importantes as variáveis que atingem um limiar de importância pré-especificado.

Boruta

O Boruta é um dos métodos mais robustos para seleção de variáveis, amplamente reconhecido em estudos de simulação como a técnica de melhor desempenho para identificar preditores realmente relevantes.

Sua lógica parte de uma ideia engenhosa: criar “variáveis sombra”, que são cópias artificiais das variáveis originais, com valores aleatoriamente permutados. Essas variáveis não carregam informação preditiva real e servem como parâmetro de comparação.

Uma variável do conjunto original só é considerada importante se sua relevância, medida pela importância atribuída pelo modelo (geralmente *Random Forest*), for consistentemente superior à da melhor variável sombra.

Essa abordagem protege contra a inclusão de preditores espúrios, que poderiam gerar interpretações enganosas ou sobreajuste. Além disso, o Boruta apresenta a vantagem de ser eficaz não apenas em cenários de alta dimensionalidade, mas também em contextos com poucos preditores, garantindo flexibilidade e confiabilidade.

Por sua capacidade de equilibrar rigor estatístico com aplicabilidade prática, o Boruta se consolidou como uma ferramenta importante para aumentar a solidez e o uso prático dos modelos preditivos em saúde.

Conclusão

Estudos de simulação demonstraram que o algoritmo Boruta se destaca como o mais eficaz e intuitivo para a seleção estatística de variáveis após a definição do algoritmo com todas as preditoras.

Seus resultados são consistentes tanto para problemas de regressão quanto de classificação, e sua aplicabilidade se estende a cenários de baixa dimensionalidade, tornando-o uma ferramenta versátil e poderosa.

A seleção criteriosa de variáveis preditoras, utilizando métodos robustos como o Boruta, é, portanto, um passo importante para o desenvolvimento de modelos de *machine learning* que sejam não apenas tecnicamente corretos, mas também clinicamente úteis e viáveis de serem colocados em prática.

capítulo 9

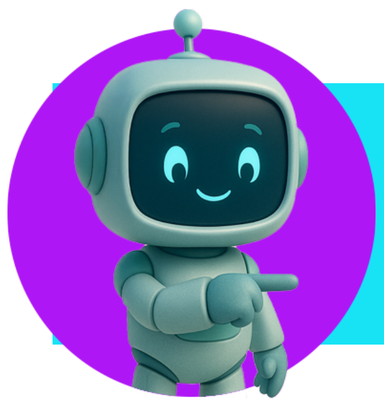
MÓDULO 4



Estratégias de Identificação de Variáveis Preditoras: SHAP values, modelos substitutos e causalidade

Introdução

Nos últimos anos, a aplicação de técnicas de inteligência artificial/*machine learning* na saúde pública vem crescendo de forma significativa. Essas ferramentas permitem utilizar grandes volumes de dados provenientes de sistemas como o SIM (Sistema de Informações sobre Mortalidade), o SINAN (Sistema de Informação de Agravos de Notificação) e o SIH/SUS (Sistema de Internações Hospitalares) para antecipar riscos, otimizar recursos e apoiar decisões estratégicas no Sistema Único de Saúde (SUS).



No entanto, a utilização desses modelos preditivos traz um desafio central: como interpretar os algoritmos? Em muitas situações, não basta apenas saber que o modelo “funciona” ou que apresenta bons indicadores de acurácia

Para que os resultados possam orientar políticas públicas e ganhar adesão dos profissionais de saúde, é essencial compreender quais variáveis estão influenciando as previsões e de que forma isso ocorre (Doshi-Velez & Kim, 2017; Ribeiro, Singh & Guestrin, 2016).

É importante destacar que o objetivo da predição não é explicar a causalidade de um fenômeno, mas antecipar sua ocorrência. Se o interesse do pesquisador for estabelecer relações de causa e efeito, devem-se utilizar métodos de inferência causal, como ensaios clínicos randomizados ou técnicas de modelagem causal. O papel dos algoritmos de ML, nesse contexto, é predizer com acurácia, e não necessariamente revelar mecanismos causais (Pearl, 2009).

A Busca por Algoritmos Interpretáveis

O tema da interpretabilidade dos algoritmos surge, portanto, como uma questão central. A busca por modelos “explicáveis” não significa reduzir a complexidade das técnicas, mas garantir que os resultados sejam compreensíveis e úteis para os profissionais que tomarão decisões baseadas neles.

Podemos destacar três grandes razões para investir em interpretabilidade:

1. **Identificação de preditores indesejáveis (*data leakage*):** um algoritmo pode estar utilizando informações que não deveriam estar disponíveis no momento da predição. Por exemplo, se um modelo de risco de mortalidade hospitalar usa "tempo de internação" como variável preditiva, temos um problema, pois essa informação só está disponível após o desfecho. A interpretação permite identificar e corrigir esse tipo de erro.

2. **Aceitação pelos profissionais de saúde:** médicos, gestores e técnicos tendem a confiar mais em modelos quando compreendem como as decisões são tomadas. A explicabilidade contribui para que os algoritmos sejam vistos como ferramentas de apoio, e não como "caixas-pretas" inacessíveis (Lipton, 2018).

3. **Garantia de maior robustez e ética:** a interpretabilidade também auxilia na detecção de vieses e injustiças. Estudos já demonstraram que algoritmos podem, inadvertidamente, reproduzir desigualdades sociais, como no caso de um modelo de alocação de recursos em saúde nos Estados Unidos que discriminava pacientes negros (Obermeyer *et al.*, 2019). Detectar e corrigir tais distorções é fundamental para garantir equidade no SUS.

   Apesar de sua relevância, a interpretabilidade não está isenta de desafios. Em alguns casos, a divulgação excessiva dos critérios pode até gerar manipulação. Por exemplo, se fosse público que morar em determinado bairro fosse critério para priorização de cirurgias, indivíduos poderiam falsificar informações para obter vantagem. Isso reforça a necessidade de equilibrar transparência e segurança

Estratégias para interpretação

Existem duas grandes abordagens para tornar modelos de *machine learning* mais interpretáveis: a interpretação intrínseca e a interpretação extrínseca (também chamada de explicabilidade pós-hoc).

1. Interpretação intrínseca

Alguns algoritmos já são naturalmente interpretáveis, pois sua estrutura permite compreender de forma clara a relação entre variáveis e desfecho.

- Regressão linear e logística: permitem observar diretamente os coeficientes, que indicam a direção (positiva ou negativa) e a intensidade da associação entre preditores e resultados.
- Árvores de decisão simples: sua lógica "se... então..." (*if-then rules*) facilita o entendimento dos caminhos usados pelo modelo para classificar ou prever.

Essas técnicas, embora transparentes, muitas vezes não alcançam a mesma performance preditiva que modelos mais complexos, como *random forests* ou redes neurais profundas.

2. Interpretação extrínseca (pós-hoc)

Quando utilizamos algoritmos mais sofisticados – por exemplo, *gradient boosting*, *XGBoost*, ou redes neurais artificiais –, a estrutura do modelo se torna uma "caixa-preta". Nesse caso, aplicam-se ferramentas externas que permitem extrair interpretações após o treinamento.

- LIME (*Local Interpretable Model-agnostic Explanations*): gera um banco de dados com pequenas variações nos valores das variáveis e constrói um modelo simples (como regressão linear) para explicar o comportamento local da predição (Ribeiro, Singh e Guestrin, 2016).
- SHAP (*SHapley Additive exPlanations*): baseado na teoria dos jogos, calcula a contribuição marginal de cada variável para uma predição específica ou para o conjunto de dados como um todo (Lundberg e Lee, 2017).

A escolha entre interpretação intrínseca e extrínseca depende do contexto. Em cenários de saúde pública, onde decisões podem afetar diretamente políticas e pessoas, muitas vezes é preferível combinar modelos robustos com técnicas de explicabilidade. Assim, conseguimos o melhor dos dois mundos: alto desempenho preditivo e clareza para orientar gestores e profissionais.

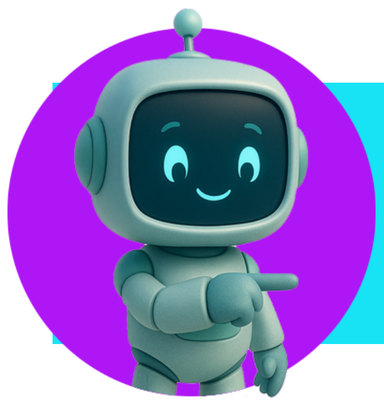
SHAP: fundamentos e propriedades

O método SHAP tem se destacado como uma das ferramentas mais sólidas e amplamente utilizadas para explicabilidade de modelos. Ele parte da teoria dos valores de Shapley, desenvolvida no campo da teoria dos jogos cooperativos, cujo objetivo é calcular como cada "jogador" contribui para o resultado final de um jogo (Shapley, 1953).

Aplicado ao *machine learning*, cada variável é vista como um jogador, e sua contribuição é medida em relação à predição do modelo. Dessa forma, o SHAP consegue responder perguntas como: "quanto a variável idade aumentou (ou diminuiu) a probabilidade de mortalidade hospitalar neste paciente específico?"

As principais propriedades do SHAP são:

- **Precisão local:** mostra exatamente por que um caso específico recebeu determinada predição.
- **Robustez a variáveis ausentes:** se uma variável não é relevante, sua contribuição é zero.
- **Consistência:** se uma variável se torna mais importante em um novo modelo, o valor SHAP aumenta proporcionalmente.



Essas características tornam o SHAP particularmente adequado para aplicações em saúde, pois permitem análises tanto individuais (locais) quanto globais (em toda a base de dados).

Aplicações do SHAP em Saúde Pública

O grande diferencial do SHAP em relação a outras métricas é sua capacidade de explicar de forma clara como cada variável contribui para uma predição. Isso é especialmente relevante na saúde pública, em que gestores e profissionais precisam compreender os fatores que influenciam riscos para priorizar intervenções, planejar recursos e garantir a equidade das ações.

1

Importância dos preditores: o SHAP ajuda a identificar quais variáveis têm maior impacto em um modelo preditivo.

- Exemplo prático: em um modelo para prever hipertensão em crianças, o SHAP pode revelar que o índice de massa corporal (IMC) é muito mais relevante do que o número de consultas médicas no último mês.
- Aplicação na gestão: esse tipo de resultado orienta secretarias de saúde a priorizarem políticas voltadas à prevenção da obesidade infantil, em vez de concentrarem esforços apenas no aumento de consultas.

2

Explicação individual (interpretação local): o SHAP também permite compreender por que um caso específico foi classificado de determinada forma.

- Exemplo prático: uma vítima registrada no SINAN como "alto risco de repetição de violência" pode ter sido classificada assim porque o histórico de notificações anteriores foi o fator mais determinante.
- Aplicação na gestão: esse nível de explicação permite direcionar intervenções mais assertivas, como acompanhamento prioritário pela rede de proteção social.

3

Resumo global do modelo: além das explicações individuais, os gráficos do SHAP oferecem uma visão geral dos fatores mais importantes em toda a base de dados.

- Exemplo prático: em análises de mortalidade do SIM, os gráficos SHAP podem mostrar que idade e escolaridade são os maiores preditores de mortalidade por doenças crônicas não transmissíveis (DCNT).
- Aplicação na gestão: gestores municipais podem usar essa informação para definir ações específicas em populações de maior vulnerabilidade, como idosos com baixa escolaridade.

4

Detecção de vieses: o SHAP ajuda a verificar se variáveis sensíveis, como raça/cor ou local de residência, estão influenciando as predições de forma injusta.

- Exemplo prático: um modelo de risco de hospitalização pode estar atribuindo maior probabilidade a pessoas negras ou moradores de regiões periféricas, sem que esses fatores tenham relação direta com a condição clínica.
- Aplicação na gestão: ao detectar esse viés, é possível ajustar o modelo para evitar discriminações e garantir maior justiça no acesso aos serviços do SUS.

5

Auditoria, ética e regulação: em contextos de vigilância e políticas públicas, muitas vezes é necessário justificar as decisões tomadas por algoritmos. O SHAP oferece uma explicação clara e auditável.

- Exemplo prático: ao utilizar um algoritmo para priorizar pacientes em cirurgias eletivas, a secretaria de saúde pode demonstrar, por meio dos valores SHAP, que a decisão se baseou em variáveis clinicamente relevantes, como idade e comorbidades, e não em fatores socioeconômicos injustos.

Vantagens para a prática em saúde

- Interpretação local e global: permite entender tanto os casos individuais quanto o conjunto populacional.
- Compatibilidade com qualquer algoritmo: pode ser aplicado em regressões, árvores de decisão, redes neurais e modelos mais complexos, como XGBoost.
- Visualizações intuitivas: gráficos como *beeswarm*, *waterfall* e *force plots* tornam os resultados acessíveis também a gestores não especialistas em ciência de dados.

Essas aplicações fazem do SHAP uma ferramenta estratégica para as secretarias de saúde, pois une rigor estatístico com clareza prática, fortalecendo a tomada de decisão baseada em evidências.

Modelos substitutos

Outra estratégia relevante para interpretação de modelos complexos são os chamados modelos substitutos. Eles consistem em construir um segundo modelo, de natureza mais simples e interpretável, que aproxima o comportamento do modelo original.

A lógica é a seguinte: o modelo de *machine learning* "caixa-preta" (como uma rede neural ou um *XGBoost*) é treinado para atingir a melhor performance preditiva possível. Em seguida, cria-se um modelo substituto – como uma regressão linear ou uma árvore de decisão simples – utilizando as mesmas variáveis de entrada, mas agora ajustado para reproduzir as decisões do modelo original.

Esse procedimento permite extrair regras e pesos interpretáveis que ajudam a compreender o raciocínio do algoritmo, mesmo sem abrir diretamente sua estrutura complexa.

LIME (*Local Interpretable Model-agnostic Explanations*)

Entre os métodos substitutos, o LIME é um dos mais conhecidos. Sua proposta é gerar pequenas perturbações nos dados originais – isto é, criar versões ligeiramente alteradas dos valores das variáveis – e observar como o modelo complexo reage.

A partir disso, o LIME constrói um modelo simples local (geralmente uma regressão linear) para explicar a predição daquele ponto específico. Em outras palavras, ele funciona como uma "lupa", mostrando, em nível individual, quais variáveis tiveram maior peso em determinada predição (Ribeiro, Singh e Guestrin, 2016).

Aplicações em saúde

- **Predição de óbito hospitalar:** o LIME pode ajudar a explicar por que um paciente foi classificado como de alto risco, mostrando que, naquele caso, o tempo de internação e a presença de comorbidades foram os fatores decisivos.
- **Modelos de violência:** em análises do SINAN, o LIME pode indicar que, para uma vítima específica, o histórico de múltiplas notificações foi determinante na classificação de alto risco de repetição de violência.
- **Doenças crônicas:** em modelos de predição de hipertensão infantil, o LIME pode evidenciar, em casos específicos, que fatores como IMC elevado e baixa prática de atividade física foram os principais responsáveis pela predição positiva.

Limitações dos modelos substitutos

Apesar de sua utilidade, é importante reconhecer algumas limitações:

- Incerteza estatística: muitos métodos de explicabilidade não quantificam o grau de incerteza associado às explicações.
- Dependência entre variáveis: quando existe alta correlação entre preditores (como peso e IMC), a atribuição de importância pode ser distorcida.
- Alto custo computacional: em grandes bases, como o SIM nacional, o uso repetido de modelos substitutos pode demandar tempo e infraestrutura robusta.

Desafios e Limitações da Interpretabilidade

Embora a interpretabilidade dos modelos de *machine learning* seja fundamental, ela enfrenta uma série de desafios metodológicos e conceituais. Entender essas limitações é essencial para que gestores e profissionais de saúde utilizem os resultados de forma crítica e responsável.

1

Inferência e incerteza estatística: muitos métodos de explicabilidade, como SHAP ou LIME, fornecem explicações sem quantificar a incerteza associada. Isso significa que não sabemos, de forma clara, o quanto aquela interpretação é estável ou poderia variar em outro conjunto de dados.

- Exemplo em saúde: ao interpretar um modelo que prevê óbito hospitalar, podemos concluir que a idade é a principal variável em um hospital específico, mas não ter segurança sobre se esse padrão se repete em outros contextos ou regiões.

2

Predição ≠ Causalidade: um dos pontos mais críticos é que a importância preditiva não equivale à causalidade (Pearl, 2009).

- Exemplo em saúde: o fato de um paciente ter sido internado em UTI pode ser um forte preditor de mortalidade futura, mas não significa que a UTI cause o óbito. Confundir esses conceitos pode levar a interpretações equivocadas e até a políticas inadequadas.

3 **Dependência entre variáveis:** quando variáveis estão altamente correlacionadas, torna-se difícil separar suas contribuições individuais.

- Exemplo em saúde: peso e IMC frequentemente caminham juntos. Em modelos de predição de hipertensão infantil, pode ser complicado determinar qual dos dois realmente tem maior impacto. Nesses casos, a importância atribuída pode se diluir entre variáveis correlacionadas.

4 **Manipulação e segurança:** a divulgação excessiva sobre como um algoritmo toma decisões pode gerar risco de manipulação do sistema.

- Exemplo em saúde: se fosse público que morar em determinado bairro aumenta a chance de priorização em filas cirúrgicas, indivíduos poderiam declarar falsamente residência naquela região para obter vantagem.

5 **Definição de interpretabilidade:** não há um consenso universal sobre como medir a interpretabilidade de um modelo. Ao contrário de métricas de performance (como acurácia ou AUC), que têm valores numéricos bem definidos, a interpretabilidade é subjetiva e pode depender do perfil do usuário final (Lipton, 2018).

- Exemplo em saúde: para um analista de dados, um gráfico de dependência pode ser considerado altamente interpretável; já para um gestor municipal, uma árvore de decisão simples pode ser mais clara.

6 **Alto custo computacional:** Métodos como SHAP exigem grande poder de processamento, especialmente em bases volumosas, como o SIM ou o SINAN nacionais. Isso pode limitar seu uso em secretarias de saúde com infraestrutura tecnológica mais restrita.

Considerações práticas

Esses desafios mostram que a interpretabilidade deve ser usada como ferramenta auxiliar, e não como resposta definitiva. O ideal é sempre combinar explicações geradas por IA com o conhecimento dos especialistas de saúde e com a análise epidemiológica tradicional. Assim, evitamos tanto o risco de confiar cegamente em modelos, quanto o de rejeitar tecnologias úteis por receio de sua complexidade.

Conclusões e Perspectivas Futuras

A interpretabilidade em modelos de inteligência artificial e *machine learning* não é apenas um detalhe técnico: ela é um componente central para que essas tecnologias possam ser incorporadas de forma ética, eficaz e sustentável na saúde pública.

Ao longo deste capítulo, vimos que:

- **Predição não é causalidade:** modelos preditivos identificam padrões úteis para antecipar riscos, mas não explicam mecanismos causais. Para análises causais, devem-se utilizar métodos específicos de inferência.
- **Interpretabilidade é estratégica:** seja por meio de modelos intrínsecos (como regressões e árvores simples) ou extrínsecos (como SHAP e LIME), compreender as variáveis que influenciam uma predição é essencial para a aceitação e o uso prático dos modelos.
- **SHAP se destaca:** por oferecer explicações locais (individuais) e globais (populacionais), com propriedades matemáticas consistentes, o SHAP é hoje uma das ferramentas mais sólidas para apoiar decisões em saúde.
- **Desafios persistem:** problemas como correlação entre variáveis, incerteza estatística, alto custo computacional e risco de manipulação precisam ser continuamente enfrentados para que os algoritmos sejam usados com segurança.

Implicações para a saúde pública

No contexto do SUS e das secretarias de saúde, a interpretabilidade pode apoiar:

- **Vigilância epidemiológica:** identificar fatores preditores de agravos como violência de repetição, suicídio ou complicações por doenças crônicas.
- **Gestão de recursos:** priorizar grupos populacionais de maior risco de forma transparente e auditável.
- **Políticas equitativas:** detectar e corrigir vieses que poderiam reforçar desigualdades sociais e raciais.

Perspectivas futuras

O campo da interpretabilidade em *machine learning* ainda está em evolução. Alguns caminhos promissores incluem:

- **Integração com ética e regulação:** organismos nacionais e internacionais começam a exigir que algoritmos de saúde sejam explicáveis e auditáveis, como forma de proteger os cidadãos.
- **Interdisciplinaridade:** a interpretabilidade precisa dialogar com outras áreas do conhecimento, como psicologia e sociologia, para desenvolver formas de comunicação mais adequadas a diferentes públicos.
- **Tecnologias mais acessíveis:** com o avanço das ferramentas abertas e das infraestruturas em nuvem, é esperado que métodos como SHAP e LIME se tornem mais viáveis mesmo para municípios com menor capacidade computacional.

Referências

Bishop, C. M. (1995). **Neural Networks for Pattern Recognition**. Oxford University Press.

Doshi-Velez, F., & Kim, B. (2017). **Towards A Rigorous Science of Interpretable Machine Learning**. arXiv preprint arXiv:1702.08608.

Lipton, Z. C. (2018). **The mythos of model interpretability**. Communications of the ACM, 61(10), 36–43.

Lundberg, S. M., & Lee, S.-I. (2017). **A unified approach to interpreting model predictions**. Advances in Neural Information Processing Systems (NeurIPS), 30.

Molnar, C. (2022). **Interpretable Machine Learning**. 2nd edition.

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). **Dissecting racial bias in an algorithm used to manage the health of populations**. Science, 366(6464), 447–453.

Pearl, J. (2009). Causality: **Models, Reasoning and Inference**. Cambridge University Press.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": **Explaining the predictions of any classifier**. Proceedings of the 22nd ACM SIGKDD, 1135–1144.



capítulo 10

MÓDULO 4



Perspectivas do uso de Machine Learning na Saúde: aprendizado de transferência, federado e contínuo

Além do Machine Learning Tradicional

O paradigma clássico da área de *machine learning* (ML) opera sob a premissa de que os dados de treinamento e teste são extraídos da mesma distribuição e que cada tarefa é resolvida de forma isolada.

No entanto, o cenário da saúde é frequentemente caracterizado pela escassez de dados em contextos específicos e pela necessidade de proteger a privacidade do paciente. Para superar esses desafios, abordagens avançadas, como o aprendizado de transferência, o aprendizado federado e o aprendizado contínuo, estão ganhando destaque, prometendo revolucionar a forma como os modelos preditivos são desenvolvidos e implementados.

Aprendizado de Transferência (*Transfer Learning*)

Transfer Learning (TL) é uma solução poderosa para o problema da insuficiência de dados. A essência do TL é aproveitar o conhecimento adquirido em um domínio de origem, onde há abundância de dados, e transferi-lo para um domínio de destino, no qual os dados são escassos.

O que se transfere são os pesos de um modelo pré-treinado, e, historicamente, as redes neurais profundas (*Deep Learning*) têm sido o veículo mais comum para essa transferência, especialmente em tarefas envolvendo imagens e processamento de linguagem natural (NLP).

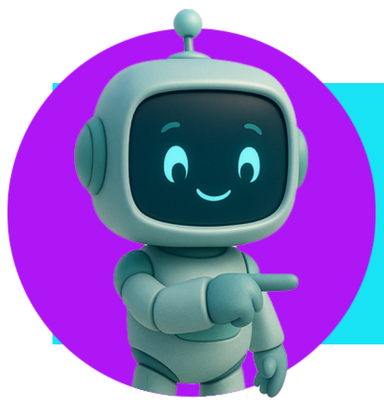
A decisão de quando aplicar o TL depende da disponibilidade de dados, da similaridade entre os domínios e da constatação de que a transferência efetivamente melhora a performance do modelo no novo contexto.

Estudo de Caso: o Projeto IACOV-BR e a Predição na COVID-19

Um exemplo prático da aplicação desses conceitos no Brasil é o estudo multicêntrico IACOV-BR, que visou a predição de desfechos relacionados à COVID-19, como óbito, necessidade de UTI e ventilação mecânica. O estudo envolveu 18 hospitais de diversas regiões do país, refletindo uma grande heterogeneidade demográfica, de recursos e de práticas clínicas, com amostras que variavam de 47 a 1.776 pacientes.

O objetivo central era investigar se agregar dados de múltiplos hospitais para o treinamento de algoritmos poderia melhorar a capacidade preditiva em cada hospital individualmente. Foram testadas oito estratégias de treinamento distintas, desde o treino puramente local (usando apenas 70% dos dados do próprio hospital) até diferentes formas de agregar dados de outros hospitais, seja por região ou de todo o país.

Os resultados, no entanto, foram claros. Para a maioria dos hospitais e desfechos, o treinamento local demonstrou ser a melhor estratégia. Isso sugere que a heterogeneidade entre as regiões brasileiras é tão grande que a agregação de dados, ao invés de ajudar, introduz ruído e prejudica a performance.



Essa constatação reforça que não existe uma solução única e que é necessário testar múltiplas estratégias para encontrar a abordagem ideal em cada contexto específico do mundo real.

Aprendizado de Transferência em Ação: Ajuste Fino de Modelos

Explorando uma abordagem mais sofisticada, o estudo IACOV-BR utilizou aprendizado de transferência em modelos baseados em árvores, como o XGBoost. A técnica consiste em utilizar um modelo pré-treinado no hospital de origem (aquele com o melhor desempenho local) como base e, em seguida, realizar um "ajuste fino", adicionando novas árvores treinadas especificamente com os dados do hospital de destino para capturar seus padrões particulares.

As análises buscaram avaliar se essa transferência superaria a simples validação externa do melhor modelo. Os resultados mostraram que o aprendizado de transferência conseguiu melhorar o desempenho em vários hospitais, mas o grau de melhoria variou consideravelmente.

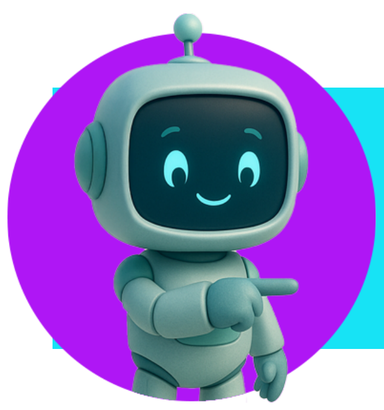
Uma análise de sensibilidade revelou que a maior parte da melhoria na performance ocorria com a adição das primeiras árvores, com o desempenho se estabilizando em seguida, indicando que um ajuste fino direcionado pode ser mais eficiente.

Esses resultados apontam para o potencial do aprendizado de transferência como uma estratégia para disseminar a inteligência artificial na saúde. Em vez de exigir que cada hospital desenvolva um modelo complexo do zero, o que seria inviável para centros com poucos dados, essa abordagem permite a adaptação de um modelo robusto e já validado às realidades locais.

Isso não apenas acelera o desenvolvimento e a implementação de ferramentas preditivas, mas também abre caminho para um ecossistema de saúde mais colaborativo, no qual o conhecimento gerado em grandes centros pode ser transferido e refinado para beneficiar uma rede mais ampla de hospitais e pacientes.

Aprendizado Federado (Federated Learning)

Paralelamente aos desafios de volume e diversidade de dados, a privacidade é uma preocupação primordial. O Aprendizado Federado (*Federated Learning*) surge como resposta a essa necessidade.



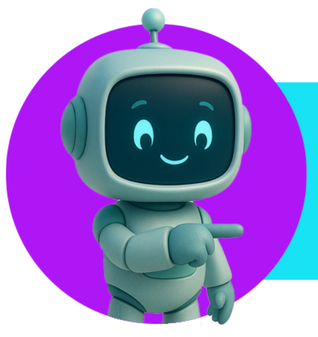
Sua principal proposta é treinar um modelo global de *machine learning* de forma colaborativa sem que os dados brutos precisem sair de seus locais de origem, como hospitais ou dispositivos móveis.

Nesse sistema, cada dispositivo ou instituição treina um modelo localmente. Em seguida, apenas as atualizações desse modelo são enviadas a um servidor central, que as agrega para criar um modelo global aprimorado.

Essa abordagem respeita as rigorosas práticas de privacidade e as regulamentações como a LGPD, permitindo a colaboração entre instituições que, de outra forma, não poderiam compartilhar dados de pacientes. O aprendizado federado, no entanto, enfrenta seus próprios desafios, como a heterogeneidade dos dados entre os diferentes locais e a necessidade de otimizar a comunicação para ser eficiente.

Aprendizado Contínuo (Online Learning)

Por fim, o campo do aprendizado de máquina está evoluindo do modelo tradicional *offline*, em que o treinamento ocorre em lotes (*batch*), para o Aprendizado Contínuo ou *Online Learning*. Nessa modalidade, os dados chegam de forma sequencial, em um fluxo contínuo, e o modelo é atualizado a cada nova observação.



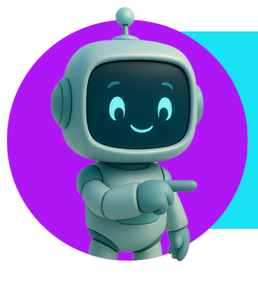
Isso permite que o algoritmo se adapte em tempo real a novas tendências e padrões, com um custo computacional menor para cada atualização.

Essa capacidade de adaptação instantânea é importante para aplicações de grande escala e dinâmicas, como as encontradas no setor de saúde, em que novas informações sobre pacientes e tratamentos surgem constantemente.

Considerações finais

A integração desses três aprendizados – transferência, federado e contínuo – representa a próxima fronteira para a inteligência artificial na saúde. Juntas, elas abordam os principais gargalos do setor: a escassez de dados, as barreiras de privacidade e a natureza estática dos modelos tradicionais.

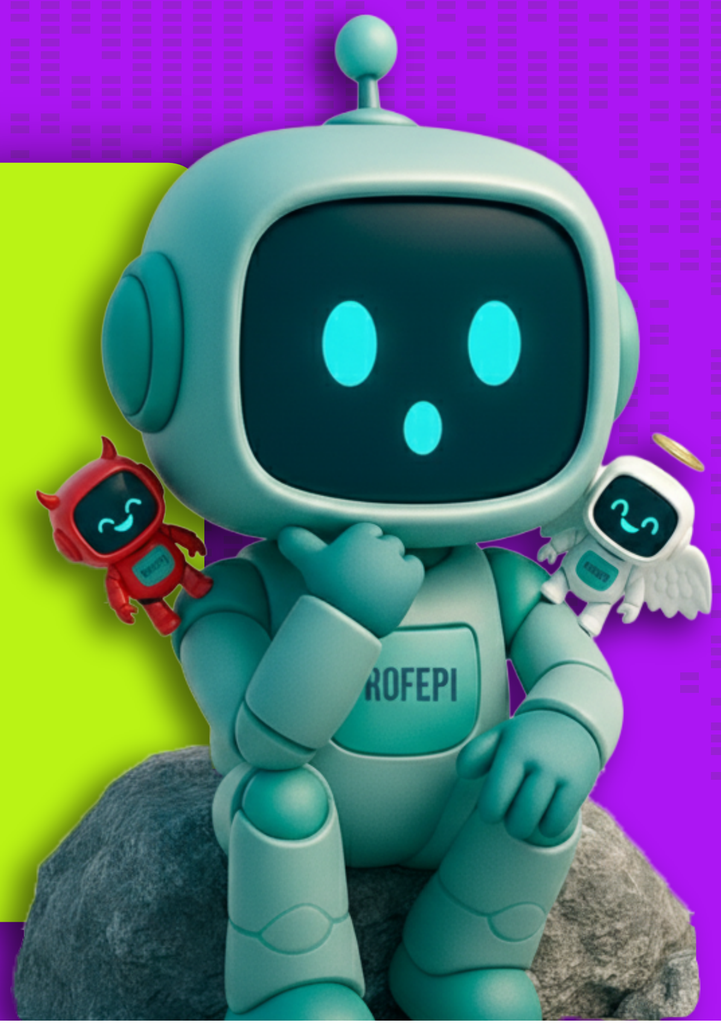
Pode-se imaginar um futuro em que um modelo de base, desenvolvido em um grande centro de pesquisa, é compartilhado via aprendizado de transferência. Em seguida, ele é aprimorado de forma colaborativa e segura por uma rede de hospitais por meio do aprendizado federado, sem que nenhum dado sensível seja exposto. Finalmente, esse modelo global é continuamente atualizado em cada local com novos dados de pacientes em tempo real, por meio do aprendizado contínuo.



Essa colaboração de diferentes técnicas emergentes em IA tem o potencial de criar um ecossistema de saúde verdadeiramente inteligente, dinâmico e ético, acelerando a inovação e melhorando os desfechos clínicos em uma escala sem precedentes.

capítulo 11

MÓDULO 4



Desafios Éticos em Inteligência Artificial na Saúde

Introdução

A incorporação da inteligência artificial (IA) na saúde já não é uma promessa distante: ela está presente em sistemas de vigilância epidemiológica, diagnósticos por imagem, gestão hospitalar e até na alocação de recursos em saúde. Entretanto, o uso dessas ferramentas traz desafios éticos complexos, que precisam ser considerados desde a concepção até a supervisão contínua dos modelos (Char, Abràmoff e Feudtner, 2020).

Entre esses desafios, destacam-se a representatividade dos dados e o risco de preconceito algorítmico, que podem impactar diretamente a equidade em saúde.

1. Vieses e Desigualdades nos Dados

Os dados de saúde não são neutros. Eles refletem desigualdades históricas e estruturais. Quando modelos de ML são treinados com essas bases, podem ampliar disparidades, em vez de reduzi-las.

- Exemplo internacional: nos EUA, um algoritmo amplamente utilizado para priorizar pacientes com maior risco de complicações subestimava pacientes negros, porque usava custos hospitalares como proxy de gravidade – e historicamente esses custos eram menores em populações negras devido a menor acesso a serviços (Obermeyer *et al.*, 2019).

- Exemplo em vigilância: bases como SINAN ou SIH podem subnotificar populações indígenas, tornando os algoritmos menos sensíveis para esse grupo.

2. Categorias de Vieses em IA Aplicada à Saúde

O desenvolvimento e a aplicação de algoritmos de *machine learning* em saúde estão sujeitos a diferentes formas de viés. Esses vieses podem se originar tanto da forma como os dados são coletados e representados quanto da maneira como os algoritmos são interpretados e utilizados pelos profissionais.

1

Viés de minoria: Ocorre quando há baixa representatividade de determinados grupos populacionais nos dados de treinamento.

- Exemplo: se um algoritmo de predição de risco cardiovascular for treinado majoritariamente com dados de adultos brancos urbanos, ele poderá ter desempenho muito pior para populações indígenas ou quilombolas, que são sub-representadas nos registros.
- Consequência: modelos tornam-se menos confiáveis para grupos vulneráveis, aumentando o risco de decisões clínicas ou de gestão inadequadas.
- Implicação para o SUS: se políticas de prevenção forem orientadas por esses modelos, populações já invisibilizadas podem continuar sem receber atenção proporcional às suas necessidades.

2

Viés de automação: refere-se à tendência dos profissionais em aceitar de forma acrítica as decisões de um sistema automatizado, mesmo quando ele está errado (*automation bias*).

- Exemplo: se um algoritmo indicar que um paciente tem baixo risco de complicação, médicos podem relaxar a vigilância, mesmo diante de sinais clínicos que indicariam o contrário.
- Consequência: erros do algoritmo passam despercebidos e podem comprometer o cuidado.
- Implicação para a saúde pública: gestores podem aceitar previsões algorítmicas sobre surtos ou riscos sem considerar limitações metodológicas, levando a decisões equivocadas na alocação de recursos.

3

Viés de rejeição: é o oposto do anterior: ocorre quando profissionais desconfiam excessivamente do algoritmo, mesmo quando a previsão é correta (*rejection bias*).

- Exemplo: um modelo pode identificar corretamente que determinado bairro apresenta risco elevado de dengue. Porém, se os gestores desacreditarem do resultado por considerarem a ferramenta “inacessível” ou “caixa-preta”, podem deixar de agir preventivamente.
- Consequência: perde-se a oportunidade de agir de forma antecipada, desperdiçando o potencial da IA.
- Implicação para o SUS: dificulta a adoção de tecnologias inovadoras, perpetuando desigualdades no acesso a ferramentas modernas de vigilância.

4

Viés de privilégio: refere-se à priorização de condições de saúde que afetam principalmente grupos mais privilegiados, em detrimento das doenças que impactam populações vulneráveis.

- Exemplo: grandes investimentos em IA para câncer de pele em países de alta renda, enquanto doenças negligenciadas, como leishmaniose, doença de Chagas ou hanseníase, recebem pouca atenção tecnológica.
- Consequência: reforça a "lacuna 10/90" já descrita na literatura em saúde global, em que 90% dos recursos de pesquisa são destinados a apenas 10% dos problemas que afetam a população mundial.
- Implicação para a saúde pública: algoritmos desenvolvidos sem foco nas Doenças Crônicas Não Transmissíveis (DCNTs) mais prevalentes em países de baixa e média renda podem não responder às reais demandas do SUS.

Esses quatro tipos de vieses mostram que a IA em saúde não é neutra. Ela pode tanto corrigir desigualdades quanto agravá-las, dependendo de como for concebida, validada e aplicada.

3. Equidade e Justiça Distributiva em IA Aplicada à saúde

O conceito de justiça distributiva refere-se à forma como bens, serviços e oportunidades são distribuídos entre diferentes grupos da sociedade. No contexto da saúde, isso significa garantir que todos os indivíduos, independentemente de raça, gênero, classe social ou local de moradia, tenham acesso justo aos benefícios proporcionados pela inteligência artificial (IA).

A preocupação é que, sem medidas proativas, algoritmos de *machine learning* podem reproduzir ou ampliar desigualdades históricas, dado que:

1. Os dados de saúde são coletados de forma desigual;
2. As doenças que afetam populações privilegiadas tendem a receber mais atenção científica e tecnológica;
3. Os modelos podem apresentar performance inferior em populações vulneráveis, prejudicando justamente aqueles que mais necessitam de cuidados.

Três dimensões de equidade em IA em saúde:

1. Resultados iguais

O objetivo é que os benefícios clínicos e de saúde pública sejam igualmente distribuídos entre grupos protegidos (negros, indígenas, mulheres, populações de baixa renda) e grupos majoritários.

- **Exemplo:** um algoritmo para triagem de risco cardiovascular deve ser capaz de prever infartos com a mesma eficácia em homens e mulheres. Se ele acerta mais em homens, isso gera desigualdade de resultados.
- **Desafio:** garantir que o modelo não apenas seja preciso globalmente, mas que não agrave disparidades entre grupos.

2. Performance igual

A equidade também depende de que o modelo apresente sensibilidade, especificidade e valor preditivo positivo semelhantes em diferentes grupos.

- **Exemplo:** se um modelo de predição de câncer de mama for menos sensível em mulheres negras por falta de dados representativos, isso pode atrasar diagnósticos e aumentar mortalidade nesse grupo.
- **Métricas utilizadas:**
  - igualdade de oportunidade: mesma sensibilidade entre grupos;
  - probabilidades equalizadas: sensibilidade e especificidade iguais;
  - paridade preditiva: mesmo valor preditivo positivo.
- **Desafio:** muitas vezes, não é possível atingir todas as métricas de justiça simultaneamente. É necessário priorizar de acordo com o contexto epidemiológico e social.

3. Alocação justa de recursos

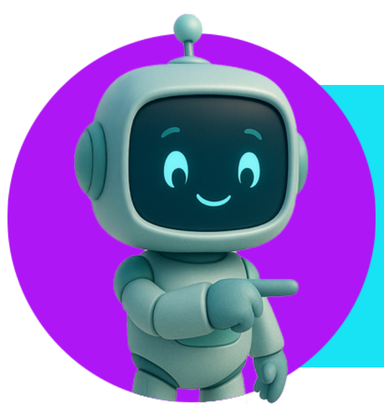
Decisões algorítmicas muitas vezes orientam a distribuição de recursos em saúde, como leitos de UTI, exames de imagem ou equipes de atenção básica.

- **Exemplo:** se um algoritmo de alocação de leitos priorizar pacientes de regiões mais ricas (onde há mais dados disponíveis e melhor registro de saúde), isso pode concentrar recursos em populações já privilegiadas.
- **Implicação no SUS:** é essencial que algoritmos sejam auditados para garantir que populações vulneráveis recebam recursos de forma proporcional às suas necessidades de saúde.

O dilema dos trade-offs

Um ponto crítico é que diferentes métricas de justiça podem ser incompatíveis. Por exemplo:

- um modelo pode atingir paridade no valor preditivo positivo (PPV), mas ainda assim não apresentar sensibilidades iguais entre grupos;
- ajustar o limiar de decisão para aumentar a sensibilidade em um grupo pode elevar a taxa de falsos positivos nesse mesmo grupo.



Isso significa que não existe um modelo “perfeitamente justo”. A decisão sobre qual métrica priorizar deve ser tomada de forma transparente, envolvendo profissionais de saúde, gestores, cientistas de dados e, idealmente, representantes da sociedade civil.

Por que a justiça distributiva importa no SUS?

No Brasil, a equidade é um dos princípios organizativos do SUS. Isso significa que as tecnologias em saúde, incluindo IA, precisam ser desenhadas para reduzir desigualdades, e não reforçá-las.

- Exemplo prático: se um modelo identifica áreas com maior risco de surtos de dengue, mas não inclui favelas por subnotificação, o resultado será a priorização de bairros formais, ampliando a vulnerabilidade das populações mais pobres.
- Ação necessária: garantir representatividade adequada nos bancos de dados, avaliar desempenho estratificado e adotar políticas públicas que incluam critérios de justiça social no uso da IA.

4. Pipeline ético: do Desenho à Supervisão

A ética em inteligência artificial aplicada à saúde não pode ser pensada apenas no final do processo. Ela deve ser considerada em todas as fases do ciclo de vida de um modelo de *machine learning* (Char, Abràmoff e Feudtner, 2020).

Esse percurso é chamado de *pipeline* ético, que envolve desde a concepção inicial até a supervisão contínua da tecnologia em uso.

Concepção do modelo

- Definição clara de objetivos: o modelo deve ser construído para responder a um problema real de saúde pública ou clínica, e não apenas por interesse tecnológico.
- Participação de partes interessadas: médicos, gestores, cientistas de dados e representantes de populações vulneráveis devem participar da definição da meta.
- Transparência e auditabilidade: o sistema precisa ser explicável o suficiente para permitir auditorias independentes.
- Exemplo aplicado: ao propor um modelo para prever risco de repetição de violência, é essencial discutir desde o início como os dados serão usados, quais variáveis serão incluídas e quais impactos sociais podem surgir.

Coleta e preparação de dados

- Representatividade: é crucial garantir que grupos protegidos (ex.: negros, indígenas, populações rurais) estejam devidamente representados.
- Documentação rigorosa: registrar como os dados foram coletados, quais variáveis estão disponíveis e quais lacunas existem.
- Privacidade: balancear a necessidade de identificar desigualdades com a proteção de informações sensíveis.
- Exemplo aplicado: em um modelo para predição de hipertensão infantil, certificar-se de que crianças de diferentes níveis socioeconômicos e regiões do país estejam incluídas nos dados.

Desenvolvimento do modelo

- Escolhas técnicas conscientes: algoritmos e funções de perda não são neutros; eles podem favorecer determinados grupos.
- Controle de vieses: aplicar técnicas de balanceamento de dados, inclusão de restrições éticas ou penalizações que minimizem desigualdades preditivas.
- Exemplo aplicado: ao treinar um modelo para alocação de leitos de UTI, é possível ajustar parâmetros para evitar que bairros mais ricos sejam favorecidos apenas por terem mais registros.

Calibração e validação

- Validação estratificada: avaliar métricas de sensibilidade, especificidade e valor preditivo por subgrupos (raça, gênero, território).
- Equidade como critério: não basta atingir alta acurácia global; é preciso verificar se o modelo funciona igualmente bem em diferentes grupos populacionais.
- Exemplo aplicado: validar se um algoritmo para triagem de risco de suicídio tem o mesmo desempenho em homens jovens e em mulheres idosas.

Implementação prática

- Integração ao fluxo de trabalho: o algoritmo deve ser incorporado aos processos clínicos ou de vigilância de forma que faça sentido para os profissionais.
- Treinamento dos usuários: médicos, enfermeiros e gestores precisam compreender como interpretar os resultados e suas limitações.
- Exemplo aplicado: em secretarias municipais, um sistema de predição de surtos só será útil se os técnicos entenderem as variáveis usadas e como agir diante dos alertas.

Supervisão contínua

- Monitoramento ativo: acompanhar periodicamente o desempenho do modelo em diferentes populações e contextos.
- Auditoria ética: avaliar se o algoritmo está produzindo resultados justos ou se está reforçando desigualdades.
- Feedback constante: incorporar opiniões de profissionais de saúde e dos próprios pacientes.
- Exemplo aplicado: um algoritmo de priorização de cirurgias deve ser monitorado para garantir que não esteja discriminando, por exemplo, moradores de regiões periféricas.

5. Estudos de caso

Predição de alta hospitalar: modelos podem prever permanência mais longa para pacientes de bairros pobres, o que leva gestores a alocar menos recursos nesses locais – reforçando desigualdades.

Monitoramento intensivo: sistemas de predição para deterioração clínica podem falhar em grupos minoritários, por falta de exemplos no treinamento.

Diagnóstico automatizado por imagem: algoritmos treinados com radiografias de um único país podem ter performance inferior em outros contextos, prejudicando populações sub-representadas.

Recomendações para Prática em Saúde Pública

- Envolver múltiplos atores (gestores, profissionais de saúde, representantes de populações vulneráveis) no desenho e implantação.
- Transparência e comunicação: explicar de forma clara como o modelo foi desenvolvido e quais são suas limitações.
- Auditoria independente: permitir que modelos utilizados em políticas públicas sejam revisados por instituições externas.
- Regulação e governança: acompanhar iniciativas internacionais de regulação de IA em saúde, como as diretrizes da Organização Mundial da Saúde (WHO, 2021).

Conclusão

A inteligência artificial aplicada à saúde tem enorme potencial para melhorar diagnósticos, otimizar recursos, apoiar a vigilância epidemiológica e promover um cuidado mais eficiente e personalizado. No entanto, esse potencial só se realiza de maneira justa quando os desafios éticos são reconhecidos e tratados de forma sistemática.

Ao longo deste capítulo, vimos que:

- os dados não são neutros: eles carregam marcas de desigualdades históricas e estruturais. Se utilizados de forma acrítica, os algoritmos de *machine learning* podem perpetuar preconceitos já existentes.
- existem diferentes formas de viés: desde a falta de representatividade de grupos minoritários até a priorização de doenças que afetam populações mais privilegiadas. Esses vieses podem distorcer diagnósticos, atrasar tratamentos ou restringir o acesso de populações vulneráveis a recursos escassos.
- a justiça distributiva é essencial: a equidade precisa ser medida em termos de resultados iguais, performance igual e alocação justa de recursos. Isso reforça os princípios constitutivos do SUS, que preveem universalidade e equidade como pilares da política de saúde brasileira.
- a ética deve estar presente em todo o ciclo de vida da IA: da concepção e coleta de dados à validação, implementação e supervisão contínua. O *pipeline* ético funciona como um guia prático para garantir que algoritmos sejam não apenas eficazes, mas também socialmente responsáveis.

Em outras palavras, a IA não é apenas uma ferramenta técnica, mas também uma tecnologia social, cujo impacto depende das escolhas humanas que guiam sua criação e uso.

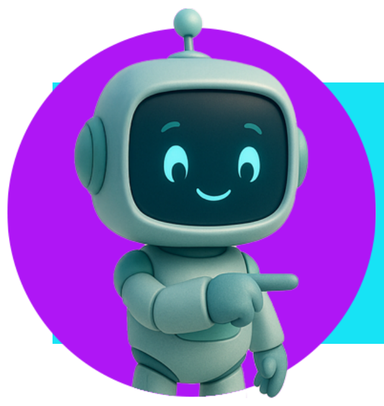
Perspectivas para o SUS

No contexto brasileiro, incorporar a ética à IA em saúde significa:

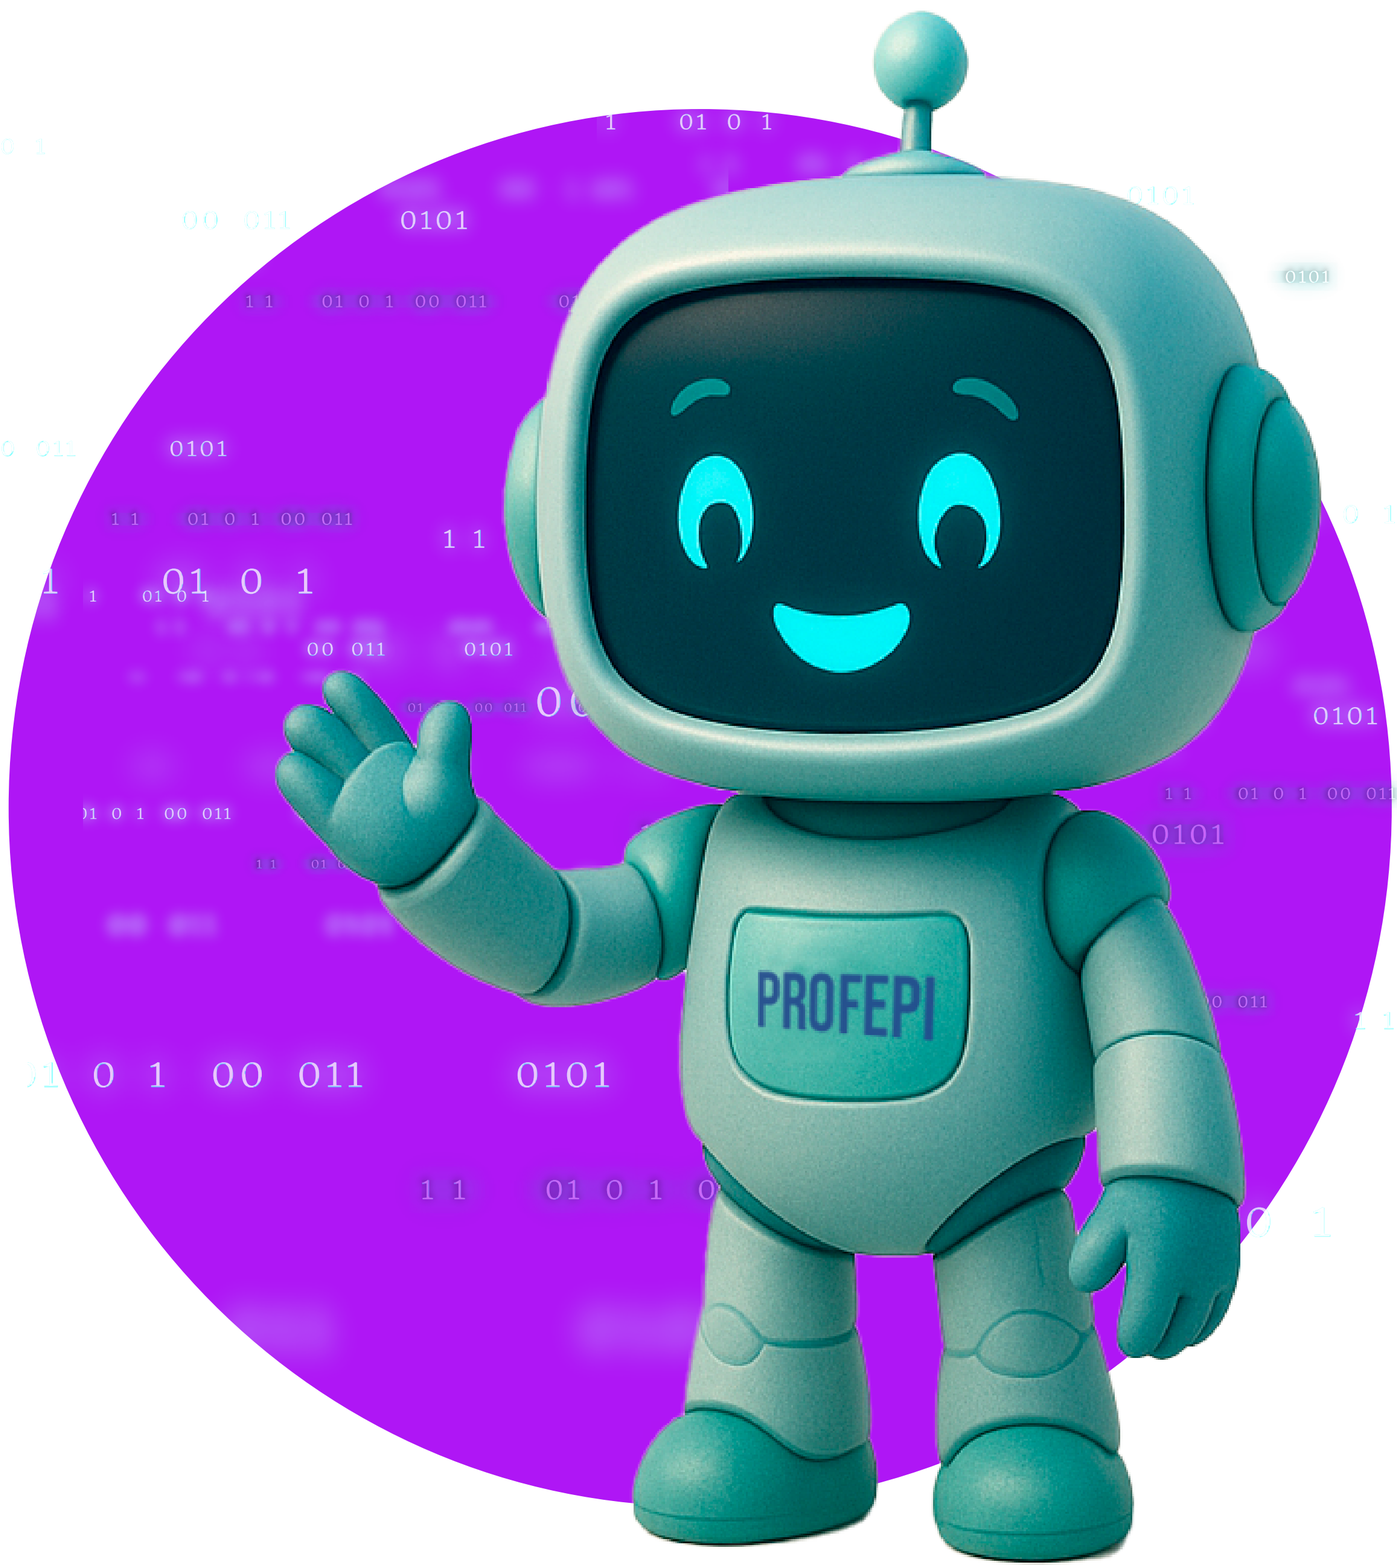
- fortalecer a representatividade dos grupos mais vulneráveis nas bases de dados (indígenas, quilombolas, populações periféricas);
- adotar práticas de auditoria e transparência, permitindo que modelos usados em políticas públicas possam ser revisados e compreendidos pela sociedade;
- formar equipes interdisciplinares que integrem epidemiologistas, cientistas de dados, profissionais de saúde e representantes sociais no desenvolvimento de algoritmos;
- garantir regulação e governança, alinhando-se a diretrizes internacionais, como as recomendações da Organização Mundial da Saúde (WHO, 2021), mas adaptadas ao contexto do SUS.

Reflexão final

Se mal conduzida, a inteligência artificial pode se tornar uma “máquina de desigualdades”, reproduzindo preconceitos já enraizados. Por outro lado, se projetada com justiça e equidade desde o início, ela pode ser uma aliada estratégica na redução das iniquidades em saúde.



Assim, a questão central não é apenas se devemos usar IA na saúde, mas como iremos usá-la: com responsabilidade ética, rigor técnico e compromisso com os princípios do SUS.



OPAS
Organização Pan-Americana da Saúde
Organização Mundial da Saúde
ESCRITÓRIO REGIONAL PARA AS Américas

SUS

MINISTÉRIO DA SAÚDE

GOVERNO DO BRASIL
DO LADO DO POVO BRASILEIRO



PROFEPI

Programa de Fortalecimento da Epidemiologia nos Serviços de Saúde